

Politechnika Warszawska
Wydział Elektryczny

ROZPRAWA DOKTORSKA

**Zastosowanie sieci neuronowych do odtwarzania
prędkości kątowej wirnika
oraz strumienia stojana
w układzie napędowym z silnikiem klatkowym**

mgr inż. Bartłomiej Ufnalski

Promotor: dr hab. inż. Lech M. Grzesiak, prof. nzw. PW.

Warszawa 2004

Powstaniu niniejszej rozprawy towarzyszyły inspirujące rozmowy z pracownikami Instytutu Sterowania i Elektroniki Przemysłowej, twórcza atmosfera panująca w pracowniach Zakładu Napędu Elektrycznego oraz wyrozumiałość szeregu bliskich mi osób. Za wszystko to bardzo dziękuję.

W szczególności pragnę podziękować profesorowi Lechowi M. Grzesiakowi za cenne rady i poświęcony czas.

Prace tę dedykuję mojej ukochanej żonie Kasi.

Bartek

Spis treści

Wykaz oznaczeń i skrótów	4
1 Wprowadzenie	8
2 Przegląd metod odtwarzania prędkości kątowej wirnika silnika indukcyjnego	14
2.1 Bezpośrednie wyznaczanie z równań stanu	14
2.2 Filtracja Kalmana	17
2.3 Obserwator Luenbergera	23
2.4 Obserwatory w trybie ruchu ślizgowego	28
2.5 Śledzenie asymetrii magnetycznych maszyny	31
2.6 Nakładanie sygnału o niskiej częstotliwości	34
2.7 Adaptacyjne układy z modelem odniesienia	34
2.8 Estymatory neuronowe	39
2.9 Inne estymatory prędkości kątowej wirnika	46
3 Odtwarzanie strumienia stojana silnika indukcyjnego	48
3.1 Problem całkowania siły elektromotorycznej	48
3.2 Filtr dolnoprzepustowy	50
3.3 Przestrajany filtr dolnoprzepustowy	51
3.4 Przestrajany kaskadowy filtr dolnoprzepustowy	54
3.5 Ulepszone schematy całkowania	57
3.6 Adaptacyjna filtracja neuronowa	59
3.7 Neuronowe sieci rekurencyjne	61
3.8 Podsumowanie	63
4 Sieć jednokierunkowa jako estymator prędkości kątowej wirnika silnika indukcyjnego	64
4.1 Sieci dynamiczne	64
4.2 Określenie i podstawowe właściwości sieci statycznych	68
4.3 Rozszerzanie bazy aproksymatora neuronowego	70
4.4 Wstępne nieliniowe przetwarzanie sygnałów dla silnika indukcyjnego	78

4.5	Metody tworzenia bazy sygnałów dla neuronowego estymatora prędkości kątowej wirnika silnika klatkowego	82
4.5.1	Wybrane podstawowe pojęcia z matematyki statystycznej	83
4.5.2	Algorytm największego spadku liczby warunkowej	86
4.5.3	Analiza składowych głównych	88
4.5.4	Analiza składowych niezależnych	92
4.5.5	Klasteryzacja	96
4.6	Podsumowanie	98
5	Neuronowy estymator strumienia stojana z dynamicznym wstępnym przetwarzaniem sygnałów elektrycznych	99
5.1	Ograniczenia modelu napięciowego	99
5.2	Rekonstrukcja strumienia stojana wspomagana sieciami neuronowymi . . .	101
5.3	Neuronowy aproksymator składowych strumienia stojana ze wstępny dy- namicznym przetwarzaniem sygnałów	102
5.4	Podsumowanie	105
6	Badania symulacyjne opracowanych estymatorów prędkości kątowej wir- nika i wektora strumienia stojana silnika indukcyjnego	106
6.1	Opis układu sterowania	106
6.2	Badania neuronowych estymatorów prędkości kątowej wirnika	112
6.2.1	Estymator prędkości kątowej wirnika - struktura A	113
6.2.2	Estymator prędkości kątowej wirnika - struktura B	115
6.2.3	Estymator prędkości kątowej wirnika - struktura C i C'	116
6.2.4	Estymator prędkości kątowej wirnika - struktura D	118
6.2.5	Estymator prędkości kątowej wirnika - struktura E	120
6.2.6	Szczegółowe badania estymatora D	121
6.3	Badania neuronowego estymatora strumienia magnetycznego stojana . . .	124
6.4	Podsumowanie	125
7	Badania eksperimentalne	136
7.1	Opis stanowiska laboratoryjnego	136
7.2	Wyniki badań estymatora prędkości kątowej wirnika	138
7.3	Wyniki badań estymatora strumienia stojana	145
7.4	Podsumowanie	147
8	Wnioski końcowe	149
Bibliografia		153

Wykaz oznaczeń i skrótów

- \mathbb{C} - zbiór liczb zespolonych
 $\text{diag}(\bullet)$ - macierz diagonalna
 e, ε - błąd odtwarzania, uchyb regulacji, uchyb strojący
 \underline{e}_m - wektor przestrzenny siły elektromotorycznej (wyznaczanej jako napięcie na zaciskach stojana pomniejszone o spadek napięcia na rezystancji stojana i indukcyjności rozproszenia stojana) - nie mylić z \underline{v}_{emf}
 $\exp(\bullet)$ - funkcja eksponencjalna
 h, T_p - okres dyskretyzacji, okres próbkowania
 \mathbf{I} - macierz jednostkowa
 \underline{i}_s - wektor przestrzenny prądu stojana
 \underline{i}_r - wektor przestrzenny prądu wirnika
 j - jednostka urojona
 J - moment bezwładności
 \mathbf{J} - macierz obrotu o $-\frac{\pi}{2}$
 k_b - współczynnik proporcjonalności biegunów obserwatora i biegunów (zespolonych) silnika
 K_P, K_I - nastawy regulatora proporcjonalno-calkującego (PI)
 \mathbf{K}_k - wzmocnienie Kalmana w chwili k -tej
 $\text{kurt}(\bullet)$ - kurtoza
 \mathbf{L}, \mathbf{G} - macierz wzmocnień obserwatora Luenbergera
 L_m - indukcyjność wzajemna (główna, magnesowania)
 L_r - indukcyjność wirnika
 L_s - indukcyjność stojana
 M_e - moment elektromagnetyczny
 $\text{mean}(\bullet)$ - wartość średnia (notacja zgodna z Matlab^(R))
 M_z - moment obciążający (zakłócający)
 \mathbb{N} - zbiór liczb naturalnych
 $N(\bullet, \bullet)$ - rozkład normalny
 n, k, p, l - liczby naturalne (np. liczba sygnałów, numer chwili czasowej, wymiar macierzy i/lub wektora)
newff(\bullet), repmat(\bullet) - funkcje dostępne w środowisku Matlab^(R) [1]
 p_b - liczba par biegunów

$p(\bullet)$ - prawdopodobieństwo wystąpienia wartości \bullet

\mathbf{Q} - macierz kowariancji szumu procesowego

Q - moc bierna

\mathbb{R} - zbiór liczb rzeczywistych

\mathbf{R} - macierz kowariancji szumu pomiarowego

R_s - rezystancja stojana

R_r - rezystancja wirnika

r_{ij} - współczynnik korelacji sygnału i -tego i j -tego

$r_{i\omega}$ - współczynnik korelacji sygnału i -tego i sygnału prędkości kątowej wirnika

s - zmienna zespolona w dziedzinie transformat Laplace'a

$\text{sign}(\bullet)$ - funkcja *signum*

T - temperatura w skali Kelvina

$\tanh(\bullet)$ - funkcja tangens hiperboliczny (funkcja sigmoidalna bipolarna)

$\text{tril}(\bullet)$ - macierz, w której elementy powyżej diagonali zastąpiono zerami (macierz trój-kątna dolna)

\underline{u}_s - wektor przestrzenny napięcia stojana

\underline{v}_{emf} - wektor przestrzenny siły elektromotorycznej (wyznaczanej jako napięcie na zaciskach stojana pomniejszone o spadek napięcia na rezystancji stojana)

\mathbf{W} - macierz wag sztucznej sieci neuronowej

\mathbf{w} - wektor wag neuronu

w - waga neuronu

$w_{ij}^{(n)}$ - waga j -tego neuronu warstwy n -tej na sygnale pochodząącym z i -tego neuronu warstwy poprzedniej lub i -tego wejścia perceptronu

z^{-1} - dyskretny operator opóźnienia o jedną próbkę

α - współczynnik momentum

α_T - termiczny współczynnik rezystywności (TWR)

γ_{kurt} - eksces (kurtozy)

γ_s - położenie kątowe wektora strumienia stojana względem spoczywającego układu współrzędnych związanego ze stojanem

ω_c - pulsacja odcięcia filtra

ω_m - prędkość kątowa wirnika

ω_r - elektryczna prędkość kątowa wirnika

ω_{sl} - pulsacja poślizgu względem strumienia stojana

$\omega_{\psi s}, \omega_e$ - prędkość kątowa wektora strumienia stojana

$\underline{\psi}_s$ - wektor przestrzenny strumienia stojana

$\underline{\psi}_r$ - wektor przestrzenny strumienia wirnika

σ - współczynnik rozproszenia ($\sigma = 1 - \frac{L_m^2}{L_s L_r}$)

σ_{ij} - kowariancja sygnału i -tego i j -tego

τ - stała czasowa członu inercyjnego pierwszego rzędu

τ_r - stała czasowa obwodu wirnika

η - współczynnik uczenia

η_r - odwrotność stałej czasowej obwodu wirnika

$\Re(\bullet)$ - część rzeczywista liczby zespolonej

$\Im(\bullet)$ - część urojona liczby zespolonej

$\mu, E[\bullet], \bar{\bullet}$ - wartość oczekiwana (wartość średnia)

$\underline{\bullet}$ - liczba zespolona (wektor dwuwymiarowy)

$a, b, \gamma, g, f, x, y, u, \dots$ - skalar (liczba, współczynnik liczbowy, element macierzy), nazwa funkcji, nazwa sygnału

$\mathbf{x}, \mathbf{y}, \mathbf{u}, \dots$ - wektor (zmiennych stanu, próbek sygnału, itp.)

A, B, Q, \dots - wielomian zmiennej z^{-1} , skalar, zbiór sygnałów, transmitancja operatorowa

$\mathbf{A}, \mathbf{B}, \mathbf{X}, \mathbf{Y}, \dots$ - macierz

$\bullet_{s\alpha}, \bullet_{s\beta}$ - wielkości związane ze stojanem wyrażone w spoczywającym układzie współrzędnych prostokątnych $\alpha\beta$

$\bullet_{r\alpha}, \bullet_{r\beta}$ - wielkości związane z wirnikiem wyrażone w spoczywającym układzie współrzędnych prostokątnych $\alpha\beta$

$\bullet_{sx}, \bullet_{sy}$ - wielkości związane ze stojanem wyrażone w układzie współrzędnych prostokątnych xy , wirującym współbieżnie z polem stojana

$\bullet_{rx}, \bullet_{ry}$ - wielkości związane z wirnikiem wyrażone w układzie współrzędnych prostokątnych xy , wirującym współbieżnie z polem stojana

\bullet^{ref} - wartość zadana

$\hat{\bullet}$ - wielkość (wartość) estymowana

\bullet^{est} - wielkość (wartość) estymowana - oznaczenie stosowane na wykresach

\bullet_N - wartość znamionowa

\bullet^- - wartość *a priori*

\bullet_{DC} - składowa stała sygnału (pojęciowo niczym nie różni się od wartości średniej $\bar{\bullet}$, niemniej jednak omawiając zagadnienia z dziedziny statystyki przyjęło się używać terminu „wartość średnia”, z kolei w dziedzinie elektrotechniki posługujemy się zazwyczaj terminem „składowa stała”)

$\bullet_k, \bullet(k)$ - wartość w chwili k -tej

\bullet^* - wielkość (liczba zespolona) sprzężona

$\dot{\bullet}, \frac{d}{dt}\bullet$ - pochodna po czasie

\propto - proporcjonalny do

$\Delta\bullet$ - przyrost, zmiana (również różnica wartości dwóch wielkości fizycznych, tj. niekiedy zmiana wartości jednej wielkości)

$\tilde{\bullet}$ - punkt pracy, wokół którego dokonano linearyzacji układu

\bullet^T - macierz transponowana

\bullet' - macierz transponowana (notacja zgodna z Matlab^(R))

\forall - dla każdego

$\angle(\bullet, \bullet)$ - miara kąta pomiędzy wektorami

- $\angle, \arg(\bullet)$ - argument liczby zespolonej, kąt do dodatniej półosi osi rzeczywistej
- $|\bullet|, \|\bullet\|$ - ogólnie norma wektora (macierzy) - w niniejszej pracy jest to zawsze norma L^2 wektora, długość wektora, moduł liczby zespolonej
- $[\bullet]$ - entier (cecha liczby, największa liczba całkowita nie większa niż \bullet)
- $\bullet-\bullet-\dots-\bullet$, gdzie \bullet liczby naturalne - zapis wykorzystywany do opisu struktury jednokierunkowego perceptronu wielowarstwowego - kolejne liczby naturalne oznaczają: liczbę wejść, liczby neuronów w warstwach ukrytych, liczbę neuronów w warstwie wyjściowej (liczbę wyjść sztucznej sieci neuronowej)
- BIBO - Bounded Input Bounded Output (dotyczy stabilności systemu)
- DSFOC - sterowanie zorientowane względem wektora pola (strumienia) magnetycznego stojana, przy czym położenie tego wektora wyznaczane jest bezpośrednio na podstawie jego estymaty (*ang.* Direct Stator Field Oriented Control)
- HPF - filtr górnoprzepustowy (*ang.* High-Pass Filter)
- ICA - analiza składowych niezależnych (*ang.* Independent Component Analysis)
- LPF - filtr dolnoprzepustowy (*ang.* Low-Pass Filter)
- MIMO - obiekt o wielu wejściach i wielu wyjściach (*ang.* Multiple Input Multiple Output)
- PCA - analiza składowych głównych (*ang.* Principal Component Analysis)
- PCLPF - przestrajany kaskadowy filtr dolnoprzepustowy (*ang.* Programmable Cascaded Low-Pass Filter)
- PI - człon (regulator) proporcjonalno-całkujący
- PLPF - przestrajany filtr dolnoprzepustowy (*ang.* Programmable Low-Pass Filter)
- PWM, MSI - modulacja szerokości impulsów (*ang.* Pulse Width Modulation)
- SG - składowa główna (dotyczy PCA)
- SI - silnik indukcyjny (klatkowy)
- SISO - obiekt o jednym wejściu i jednym wyjściu (*ang.* Single Input Single Output)
- SN - składowa niezależna (dotyczy ICA)
- SSN - sztuczna sieć neuronowa
- UPU - układ pomiaru napięcia

Rozdział 1

Wprowadzenie

Nowoczesne przekształtnikowe układy napędowe coraz częściej bazują na algorytmach sterowania wspomaganych matematycznymi modelami zachowań ludzkiego umysłu, czyli tzw. sztuczną inteligencją. Próby naśladowania tej dziedziny natury zaowocowały m.in. sztucznymi sieciami neuronowymi (SSN), logiką rozmytą, zbiorami przybliżonymi i algorytmami genetycznymi. Szczególnie popularnym i zarazem wygodnym narzędziem do przetwarzania danych są SSN. Stawia się tezę, że bardzo trudno byłoby obecnie wskazać przynajmniej jedną dziedzinę wiedzy, w której sieci jeszcze nie zastosowano. Cytując za profesorem Ryszardem Tadeusiewiczem z AGH w Krakowie ([2] z 2000 roku) - „*Technika sieci neuronowych nie jest już dziś szczególną nowością. A jednak od 1986 roku, kiedy to ogłoszenie przez Dawida Rumelharta koncepcji uczenia sieci metodą backpropagation spowodowało gwałtowny przypływ zainteresowania tą techniką, rokrocznie notuje się kilkudziesięcioprocentowy wzrost liczby doniesień dotyczących naukowych i praktycznych aspektów wykorzystania sieci neuronowych. Szacuje się (na podstawie danych IEEE z października 1998 roku), że obecnie na świecie średnio co pięć sekund pojawia się nowa publikacja lub nowe doniesienie konferencyjne dotyczące sieci neuronowych, zaś z analizy rynku księgarskiego wynika (dane wydawnictwa Springer z lipca 1999), że na temat sieci neuronowych wydano na świecie ponad 7 tysięcy tytułów różnych podręczników i książek, przy czym niektóre z nich rozeszły się w nakładach kilkunastu lub kilkudziesięciu tysięcy egzemplarzy.*” Część tych publikacji dotyczy napędu elektrycznego. Na samych tylko stronach internetowych IEEE¹ znajduje się ponad 100 artykułów opisujących różne zastosowania SSN w napędach elektrycznych, z czego ponad połowa poświęcona jest układom z silnikiem indukcyjnym. We współczesnych napędach prądu przemiennego, sztuczne sieci neuronowe wykorzystano do realizacji niemal każdej funkcji układu sterowania, w tym: obserwatorów (zadanie identyfikacji), regulatorów (zadanie sterowania), modulatorów PWM, diagnozowania. Szczególnie chętnie sięgamy po SSN, gdy zawiodą techniki opracowane dla modeli

¹<http://ieeexplore.ieee.org/>

liniowych. Techniki neuronowe pozwalają w stosunkowo prosty sposób rozwiązać wiele zagadnień nieparametrycznej identyfikacji nieliniowych obiektów, takich jak silnik indukcyjny. Pozwalają na pracę z obiektem, który stanowi „czarną skrzynkę”, tj. znamy jego wejścia i wyjścia, a nie potrafimy opisać wiążących ich reguł. Nierzadko też zdarza się, że model parametryczny jest bardzo skomplikowany i wrażliwy na zmiany parametrów, a odpowiadający mu model neuronowy jest dużo prostszy i bardziej odporny na zmiany parametrów obiektu.

Napędy z silnikami indukcyjnymi pozostają w wielu aplikacjach rozwiązaniami najbardziej niezawodnymi i jednocześnie najtańszymi [3]. Zasada działania i budowa asynchronicznego silnika klatkowego pozostaje niezmienna od ponad 110 lat. Z drugiej jednak strony, rozwój energoelektroniki i techniki mikroprocesorowej pozwolił na budowę układów sterowania zapewniających dobre właściwości ruchowe napędów z silnikiem indukcyjnym. Kolejnym krokiem było wyeliminowanie przetwornika mechaniczno-elektrycznego prędkości kątowej wirnika, w celu zwiększenia niezawodności napędu i obniżenia kosztów. Wielu badaczy skupiło się na opracowywaniu metod odtwarzania tej prędkości na podstawie mierzących prądów i napięć stojana maszyny. Równocześnie wiele algorytmów sterowania zakłada znajomość strumienia magnetycznego stojana lub wirnika, który to jest niemierzalny w maszynie o wykonaniu klasycznym. Opracowywane są zatem coraz to nowsze modele odtwarzania strumieni magnetycznych. Różnorodność proponowanych rozwiązań znajduje swoje odzwierciedlenie w szeregu monografii poświęconych sterowaniu silnikiem indukcyjnym. Znaczące miejsce zajmują wśród nich książki autorstwa Polaków, w tym prof. Teresy Orłowskiej-Kowalskiej [4], prof. Zbigniewa Krzemińskiego [5], prof. Mariana P. Kaźmierkowskiego [6], i wielu innych projektujących współczesne napędy przekształtnikowe. Kilka rozwiązań z tego obszaru wykorzystuje technikę sztucznych sieci neuronowych. Proponowane sieci uczone w trybie on-line¹ realizują algorytm adaptacji prędkości w układach z modelem odniesienia [7, 8, 9]. Mimo wykorzystania SSN, otrzymane układy realizują typową identyfikację parametryczną. Drugą grupę stanowią układy odtwarzania prędkości z sieciami trenowanymi w trybie off-line². Bazują one na zdolności odpowiednio skonstruowanych sieci do aproksymowania dowolnych, w tym silnie nieliniowych, zależności funkcyjnych. Proponowane sieci uczone w trybie off-line mają zazwyczaj architekturę wielowarstwowej sieci jednokierunkowej, a aproksymacja dynamiki uzyskiwana jest poprzez wprowadzenie linii opóźnień na sygnałach wejściowych [10] oraz niekiedy, dodatkowo rekurencji [11]. Podobnie, opracowane sieci do odtwarzania strumienia stojana [12, 13], mają architekturę sekwencyjnej sieci Jordana, będącej jednym z przykładów sieci rekurencyjnych. Wspólną cechą rozwiązań z drugiej grupy, jest odtwarzanie wybranych zmiennych

¹podczas pracy układu, w czasie rzeczywistym

²przed uruchomieniem układu, nie w czasie rzeczywistym

stanu na podstawie chwilowych nieprzetworzonych wartości prądów i napięć stojana, podawanych bezpośrednio na wejścia sieci neuronowej. Pod pojęciem „nieprzetworzonych” należy rozumieć - nie poddanych przekształceniom nieliniowym lub nie przetworzonych dynamicznie. W rozwiązaniach tych, sygnały trójfazowych prądów i napięć przekształcane są zazwyczaj, przy wykorzystaniu definicji wektora przestrzennego, do składowych prostokątnych w spoczywającym układzie współrzędnych związanym ze stojanem. Przekształcenia te są prostymi, najwyżej trójargumentowymi, funkcjami liniowymi i nie zmieniają charakteru sygnału (np. z sinusoidalnego na niesinusoidalny). Rozwiązania z sieciami rekurencyjnymi dziedziczą niestety wszystkie wady tych struktur, w tym brak gwarancji stabilności¹ sieci uczonej w schemacie szeregowo-równoległym (szczególny w rozdziale 4.), po przejściu do trybu odtwarzania, oraz wymóg równości częstotliwości próbkowania zbioru uczącego i częstotliwości pracy podczas odtwarzania. Tę ostatnią wadę posiadają również sieci z liniami opóźnień na sygnałach wejściowych. Zbiory uczące dla tych struktur są często nie-współmiernie duże do rozwiązywanego zadania aproksymacji. Uzyskiwana dokładność jest zazwyczaj niewystarczająca, a napęd po przełączeniu sprzężenia na wyjście SSN zachowuje się niestabilnie, a w najlepszym przypadku obserwuje się wyraźne pogorszenie odpowiedzi układu na zmianę sygnału prędkości zadanej (patrz przykładowo rysunek 10.43(c), strona 445 w [10]). Zdaniem autora, źródłem większości problemów jest silne niedopasowanie, chociażby częstotliwościowe, sygnałów prądów i napięć do odtwarzanej prędkości kątowej wirnika. Już kilka lat temu zauważono (zespół prof. Teresy Orłowskiej-Kowalskiej z Politechniki Wrocławskiej, czy też zespół prof. Lecha M. Grzesiaka z Politechniki Warszawskiej), że rozbudowywanie zbioru uczącego o sygnały przetworzone nieliniowo (np. moduł prądu stojana) znaczaco poprawia dokładność odtwarzania. W [13] zaproponowano nawet całkowite zrezygnowanie z nieprzetworzonych sygnałów elektrycznych, co okazało się bardzo inspirujące i dało zalążek do powstania niniejszej rozprawy. Równolegle zadano sobie pytanie, w jaki nieparametryczny sposób można by rozwiązać zadanie odtwarzania strumienia stojana, bez wykorzystywania sieci rekurencyjnej. Uznano, że niezbędne jest odpowiednie nieliniowe i/lub dynamiczne przetworzenie sygnałów dostępnych w układzie sterowania, w celu ich skutecznego wykorzystania do realizacji zadania nieparametrycznej estymacji wybranych zmiennych stanu obiektu. Przeprowadzone badania pokazały, że możliwe staje się wtedy wykorzystanie sieci jednokierunkowych bez linii opóźnień na sygnałach wejściowych. Pozwała to uniknąć szeregu problemów związanych z sieciami rekurencyjnymi i użyciem linii opóźnień na wejściach sieci.

Teza. Możliwe jest skuteczne odtworzenie prędkości kątowej wirnika i wek-

¹Rozumienie słowa „stabilny” i „niestabilny” w odniesieniu do sieci rekurencyjnej uczonej w trybie off-line zostanie omówione w rozdziale 4. Jest ono odmienne od definicji stabilności w sensie BIBO (*ang. Bounded Input Bounded Output*).

tora strumienia stojana przy wykorzystaniu jednokierunkowych sieci neuronowych trenowanych w trybie off-line, pod warunkiem rozszerzenia baz aproksymatorów poprzez wstępne nieliniowe lub dynamiczne przetworzenie sygnałów chwilowych napięć i prądów stojana silnika klatkowego.

Za cel pracy przyjęto opracowanie nieparametrycznych estymatorów prędkości kątowej wirnika i strumienia magnetycznego stojana silnika klatkowego, bazujących na jednokierunkowej sieci neuronowej trenowanej w trybie off-line. Za najważniejsze zadania do zrealizowania, w ramach projektu neuronowego aproksymatora prędkości kątowej wirnika, uznano:

- zaproponowanie reguł wstępnego nieliniowego przetwarzania sygnałów elektrycznych;
- określenie kryteriów przydatności sygnałów w proponowanej architekturze estymatora;
- algorytmizowanie procesu tworzenia bazy aproksymatora, w tym:
 - zaproponowanie metod eliminacji sygnałów ze zbioru kandydackiego;
 - przebadanie metod redukcji wymiaru podprzestrzeni aproksymatora poprzez kompresję informacji;
- przetestowanie otrzymanych estymatorów w pętli sprzężenia zwrotnego napędu ze sterowaniem polowo-zorientowanym (układ Direct Stator Field Oriented Control);
- sformułowanie kryteriów jakości i porównanie zaproponowanych metod tworzenia bazy aproksymatora;
- budowę eksperymentalnego bezczujnikowego napędu DSFOC z neuronowym estymatorem prędkości kątowej wirnika;

Z kolei, za kluczowe zadania związane z projektem neuronowego aproksymatora strumienia stojana, należy uznać:

- zaprojektowanie wstępnego dynamicznego przetwarzania sygnałów elektrycznych umożliwiającego odtwarzanie składowych strumienia stojana przy użyciu sieci jednokierunkowej;
- zbadanie odporności otrzymanego estymatora strumienia na zmiany rezystancji stojana.

Praca składa się z ośmiu rozdziałów uzupełnionych o wykaz najważniejszych oznaczeń i spis literatury. W rozdziale pierwszym autor zamieścił wprowadzenie, sformułował tezę i określił cele rozprawy.

W rozdziale drugim znalazły się informacje o dostępnych metodach odtwarzania prędkości kątowej wirnika silnika indukcyjnego. W szczególności przedstawiono bezpośrednią syntezę z równań stanu (wyznaczanie poślizgu, pseudoinwersja), filtrację Kalmana, obserwatora Luenbergera, obserwatory w trybie ruchu ślizgowego, śledzenie asymetrii magnetycznych maszyny, nakładanie sygnału o niskiej częstotliwości, adaptacyjne układy z modelem odniesienia. Omówiono także wady proponowanych rozwiązań neuronowych z sieciami uczonymi w trybie off-line.

Rozdział trzeci poświęcono zagadnieniu odtwarzania strumienia stojana. Skupiono się na sposobach rozwiązywania problemów związanych z całkowaniem siły elektromotorycznej. Przedstawiono między innymi układy z przestrajanym filtrem dolnoprzepustowym i ulepszone schematy całkowania. Udowodniono, że opublikowane w 2004 roku rozwiązanie z adaptacyjną filtracją neuronową [14], nie różni się niczym od filtracji przy pomocy członu inercyjnego pierwszego rzędu. Zwróciło tym samym uwagę na częste nadużywanie chwytnego określenia - sieci neuronowe. Przedstawiono inspirujące rozwiązanie z rekurencyjną siecią neuronową, dające możliwość uodpornienia estymatora na zmiany rezystancji stojana. Rozdział ten, wraz z poprzednim stanowią tło dla rozwiązań zaproponowanych w dwóch kolejnych rozdziałach.

I tak, w rozdziale czwartym opisano opracowane metody tworzenia bazy sygnałów dla neuronowego estymatora prędkości kątowej wirnika. Wykorzystano algorytm największego spadku liczby warunkowej (bazujący na dekompozycji SVD, *ang.* Singular Value Decomposition [15]), analizę składowych głównych (*ang.* Principal Component Analysis, PCA [16]) i niezależnych (*ang.* Independent Component Analysis, ICA [16]). Zaproponowano autorskie rozwiązanie wykorzystujące analizę korelacyjną i algorytm największego spadku liczby warunkowej.

Oryginalny neuronowy aproksymator składowych strumienia stojana z dynamicznym wstępnym przetwarzaniem sygnałów, przedstawiono w rozdziale piątym.

Na początku rozdziału szóstego zamieszczono opis układu sterowania wykorzystanego zarówno w badaniach symulacyjnych, jak i eksperymentalnych. Rozdział ten prezentuje przede wszystkim wyniki badań symulacyjnych opracowanych estymatorów.

Charakterystykę stanowiska laboratoryjnego i wyniki wybranych badań nad bezczujnikowym napędem prądu przemiennego z neuronowymi estymatorami prędkości kątowej wirnika oraz wektora strumienia stojana zebrano w rozdziale siódmym.

Rozprawę zamyka rozdział ósmy, w którym sformułowano wnioski końcowe, podsumowano osiągnięcia własne i nakreślono problemy otwarte.

W trakcie redagowania niniejszej rozprawy, autor kilkakrotnie otarł się o zagadnienie czystości językowej. Język techniczny pełen jest słów zaczerpniętych z języka angielskiego - słów, które nie znalazły się jeszcze w uznanych słownikach języka polskiego. Polskie odpowiedniki nierzadko nie istnieją, albo mają charakter opisowy, co znaczająco utrudnia posługiwanie się nimi. Autor świadomie kilka z nich potraktował jako zapożyczenia. Zwyczajowo, końcówki deklinacyjne nieugruntowanych zapożyczeń pisane są po apostrofie. Stąd pojawiające się w tekście: anti-windup'u, off-line'owego i inne, które mogą razić purytan językowych, co nie było zamysłem autora. Nie zrezygnowano również całkowicie z wyrażeń potocznych wykorzystując przede wszystkim ich obrazowość, umieszczało je jednak w cudzysłowach. Tak więc w tekście napotkamy np. "podpis prądowy", "widziane" w czasie uczenia itd. Dodatkowo, z uwagi na brak zgodności wśród autorów co do definicji sieci statycznej i dynamicznej, w paragrafach 4.1 i 4.2 określono własne, wygodne pod kątem omawianych zagadnień, znaczenia tych wyrażeń.

Rozdział 2

Przegląd metod odtwarzania prędkości kątowej wirnika silnika indukcyjnego

2.1. Bezpośrednie wyznaczanie z równań stanu

Najstarsze historycznie metody odtwarzania prędkości kątowej wirnika silnika indukcyjnego polegają na jej bezpośrednim wyznaczaniu z równań stanu. Zakładając szereg uproszczeń i wprowadzając pojęcie wektora przestrzennego, trójfazowy silnik klatkowy możemy opisać w spoczywającym układzie współrzędnych prostokątnych $\alpha\beta$ związanym ze stojanem, zestawem pięciu równań [17, 18]:

$$\begin{aligned}\underline{u}_s &= R_s \underline{i}_s + \frac{d}{dt} \underline{\psi}_s \\ 0 &= R_r \underline{i}_r + \frac{d}{dt} \underline{\psi}_r - j p_b \omega_m \underline{\psi}_r \\ \underline{\psi}_s &= L_s \underline{i}_s + L_m \underline{i}_r \\ \underline{\psi}_r &= L_r \underline{i}_r + L_m \underline{i}_s \\ \frac{d}{dt} \omega_m &= \frac{1}{J} \left[-\frac{3}{2} p_b L_m \Im(\underline{i}_s^* \underline{i}_r) - M_z \right],\end{aligned}\tag{2.1}$$

gdzie: \underline{u}_s - wektor przestrzenny napięcia stojana, \underline{i}_s , \underline{i}_r - wektory przestrzenne prądów stojana i wirnika, $\underline{\psi}_s$, $\underline{\psi}_r$ - wektory przestrzenne strumieni stojana i wirnika, R_s , R_r , L_s , L_r , L_m - odpowiednio rezystancje i indukcyjności stojana i wirnika oraz indukcyjność główna (magnesowania), p_b - liczba par biegunów, ω_m - prędkość kątowa wirnika, M_z - moment obciążający. Iloczyn $p_b \omega_m$ nazywany jest elektryczną prędkością kątową wirnika [19]. Prędkość wirnika związana jest z pulsacją poślizgu zależnością

$$\omega_m = \frac{\omega_{\psi s} - \omega_{sl}}{p_b},\tag{2.2}$$

przy czym $\omega_{\psi s}$ jest prędkością kątową strumienia stojana, ω_{sl} - pulsacją poślizgu. Wprowadzając wirujący układ współrzędnych prostokątnych xy związanego ze strumieniem stojana, otrzymujemy po odpowiednich przekształceniach zależność [17, 18]:

$$\omega_{sl} = \frac{L_s \left(i_{sy} + \sigma \tau_r \frac{di_{sy}}{dt} \right)}{\tau_r (\psi_{sx} - \sigma L_s i_{sx})}, \quad (2.3)$$

w której $\sigma = 1 - \frac{L_m^2}{L_s L_r}$, $\tau_r = \frac{L_r}{R_r}$ oraz i_{sx} , i_{sy} , ψ_{sx} - składowe prądu i strumienia stojana w wirującym układzie współrzędnych ($\psi_{sy} = 0$). Z kolei prędkość wirowania układu współrzędnych otrzymujemy ze wzoru

$$\begin{aligned} \omega_{\psi s} &= \frac{d}{dt} \arctan \left(\frac{\psi_{s\beta}}{\psi_{s\alpha}} \right) = \\ &= \frac{(u_{s\beta} - R_s i_{s\beta}) \psi_{s\alpha} - (u_{s\alpha} - R_s i_{s\alpha}) \psi_{s\beta}}{\psi_{s\alpha}^2 + \psi_{s\beta}^2}. \end{aligned} \quad (2.4)$$

Istnieje wiele analogicznych rozwiązań bezpośredniego wyznaczania prędkości. Opis większości z nich zawarto w [18]. Przykładowo w [20, 21] lub [17] znajdziemy schemat estymacji oparty o poślizg względem strumienia wirnika. W rozwiązaniu tym mamy

$$\omega_m = \frac{1}{p_b} \cdot \frac{1}{\psi_{r\alpha}^2 + \psi_{r\beta}^2} \left[\left(\psi_{r\alpha} \dot{\psi}_{r\beta} - \dot{\psi}_{r\alpha} \psi_{r\beta} \right) - \frac{L_m}{\tau_r} (\psi_{r\alpha} i_{s\beta} - \psi_{r\beta} i_{s\alpha}) \right]. \quad (2.5)$$

Do tej rodziny rozwiązań należy również zaliczyć tzw. pseudoinwersję [22]. Na podstawie równań (2.1) otrzymujemy zależność

$$\underline{a}(t) \omega_m(t) = \underline{b}(t), \quad (2.6)$$

w której

$$\underline{a}(t) = j p_b \sigma \underline{i}_s(t) - j p \frac{1}{L_s} \underline{\psi}_s(t) \quad (2.7)$$

oraz

$$\underline{b}(t) = -\frac{1}{L_s} \underline{u}_s(t) + \left(\frac{R_s}{L_s} + \frac{1}{\tau_r} \right) \underline{i}_s(t) + \sigma \frac{d}{dt} \underline{i}_s(t) - \frac{1}{\tau_r L_s} \underline{\psi}_s(t). \quad (2.8)$$

Równanie liniowe (2.6) posiada zespolone współczynniki $\underline{a}(t), \underline{b}(t) \in \mathbb{C}$. Jakakolwiek nie-dokładność w wyznaczeniu tych współczynników może spowodować, że obliczona prędkość nie będzie liczbą rzeczywistą. Dlatego też równanie to należy rozbić na układ dwóch równań uzyskanych z porównania odpowiednio części rzeczywistych i urojonych przy założeniu $\omega_m(t) \in \mathbb{R}$. Otrzymujemy

$$\begin{cases} \Re(\underline{a}(t)) \omega_m(t) = \Re(\underline{b}(t)) \\ \Im(\underline{a}(t)) \omega_m(t) = \Im(\underline{b}(t)) \end{cases} \quad (2.9)$$

Niestety dla przebiegów sinusoidalnych współczynniki $\Re(\underline{a}(t)), \Im(\underline{a}(t)), \Re(\underline{b}(t))$ i $\Im(\underline{b}(t))$ przyjmują okresowo wartości zerowe (lub bliskie zeru), co uniemożliwia wiarygodne wyznaczenie prędkości $\omega_m(t)$ w oparciu o pojedyncze równanie. Układ (2.9) jest układem nadokreślonym i należy go rozwiązać w sensie najmniejszych kwadratów [15], tj. dla

$$\mathbf{A} \boldsymbol{\omega}_m = \mathbf{B} \quad (2.10)$$

wykonujemy lewostronne mnożenie przez transponowaną macierz układu

$$\mathbf{A}^T \mathbf{A} \omega_m = \mathbf{A}^T \mathbf{B} \quad (2.11)$$

i otrzymujemy

$$\omega_m = (\mathbf{A}^T \mathbf{A})^{-1} (\mathbf{A}^T \mathbf{B}). \quad (2.12)$$

Dodatkowe wygładzenie estymaty uzyskujemy poprzez rozszerzenie układu do postaci

$$\left\{ \begin{array}{l} \Re(\underline{a}(t)) \omega_m(t') = \Re(\underline{b}(t)) \\ \Re(\underline{a}(t-h)) \omega_m(t') = \Re(\underline{b}(t-h)) \\ \dots \\ \Re(\underline{a}(t-nh)) \omega_m(t') = \Re(\underline{b}(t-nh)) \\ \Im(\underline{a}(t)) \omega_m(t') = \Im(\underline{b}(t)) \\ \Im(\underline{a}(t-h)) \omega_m(t') = \Im(\underline{b}(t-h)) \\ \dots \\ \Im(\underline{a}(t-nh)) \omega_m(t') = \Im(\underline{b}(t-nh)) \end{array} \right., \quad (2.13)$$

gdzie h jest okresem próbkowania, natomiast $t' \in [t-nh, t] \wedge n \in \mathbb{N}$. Do wyznaczenia prędkości zgodnie z (2.12) można wykorzystać dowolny podzbiór równań układu (2.13). Niemniej jednak każdy podzbiór inny niż (2.9) wprowadza dodatkowe opóźnienie.

Omówione w tym podrozdziale rozwiązania określane są często mianem symulatorów lub estymatorów z otwartą pętlą sprzężenia zwrotnego (*ang. open-loop estimators*). Oznacza to, że w swej strukturze nie wykorzystują żadnych algorytmów korekcji estymaty. Są przez to bardzo wrażliwe na niedokładności w określeniu parametrów silnika oraz zmiany tych parametrów w trakcie pracy napędu. Można je stosować w zasadzie wyłącznie w obecności algorytmów adaptacji parametrów silnika. Dodatkowo wymagają one wyznaczenia odpowiednich strumieni, co wiąże się z wykonaniem obliczeń zgodnie z zależnościami

$$\left\{ \begin{array}{l} \psi_{s\alpha} = \psi_{s\alpha}(t_0) + \int_{t_0}^t (u_{s\alpha} - R_s i_{s\alpha}) dt \\ \psi_{s\beta} = \psi_{s\beta}(t_0) + \int_{t_0}^t (u_{s\beta} - R_s i_{s\beta}) dt \\ \psi_{r\alpha} = \frac{L_r}{L_m} (\psi_{s\alpha} - \sigma L_s i_{s\alpha}) \\ \psi_{r\beta} = \frac{L_r}{L_m} (\psi_{s\beta} - \sigma L_s i_{s\beta}) \end{array} \right.. \quad (2.14)$$

Należy zatem rozwiązać problem warunków początkowych i składowej stałej związanego z całkowaniem. Zagadnienia te zostaną opisane w kolejnym rozdziale dotyczącym odtwarzania strumienia stojana.

Oryginalną analizę zagadnienia odtwarzania prędkości można znaleźć w [23]. Model silnika (2.1) zastąpiono zestawem modeli mechanicznych i przy ich użyciu zilustrowano wybrane metody wyznaczania prędkości kątowej wirnika.

2.2. Filtracja Kalmana

W 1960 roku został opublikowany artykuł [24], w którym Węgier Rudolf E. Kalman opisał rekurencyjne rozwiązywanie problemu dyskretnej liniowej filtracji. Problem ten dotyczył oszacowania chwilowego stanu układu dynamicznego, przy założeniu, że zarówno pomiar jak i sam proces przetwarzania wewnątrz układu są obarczone błędem. W rozwiązaniu przyjmuje się, że zakłócenia są białym szumem typu gaussowskiego. Ze względu na szerokie zastosowania, filtr Kalmana stał się przedmiotem intensywnych badań i od czasu pierwszej publikacji wprowadzono wiele modyfikacji i ulepszeń. W 1969 został wykorzystany jako estymator 21 zmiennych stanu w module księżycowym Apolla 11. Obecnie jest szeroko stosowany w układach regulacji automatycznej. Obszarem zastosowań obejmuje również rekonstrukcję obrazów, telekomunikację, modelowanie statystyczne zjawisk demograficznych, uczenie sztucznych sieci neuronowych. Algorytmy filtra Kalmana z powodzeniem wykorzystano do estymacji prędkości mechanicznej silnika indukcyjnego [25].

Problem filtracji Kalmana dotyczy oszacowania stanu $\mathbf{x} \in \mathbb{R}^n$ dyskretnego procesu opisanego stochastycznym, liniowym równaniem różnicowym

$$\mathbf{x}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{B}\mathbf{u}_{k-1} + \mathbf{w}_{k-1}, \quad (2.15)$$

przy znajomości pomiaru $\mathbf{z} \in \mathbb{R}^m$ danego zależnością

$$\mathbf{z}_k = \mathbf{H}\mathbf{x}_k + \mathbf{v}_k, \quad (2.16)$$

gdzie: \mathbf{A} - macierz $n \times n$ wiążąca stan układu w chwili poprzedniej ze stanem w chwili następnej, \mathbf{B} - macierz $n \times l$ wiążąca wymuszenie $\mathbf{u} \in \mathbb{R}^l$ ze stanem układu, \mathbf{H} - macierz $m \times n$ wiążąca stan układu z pomiarem, \mathbf{w} i \mathbf{v} - zmienne losowe reprezentujące szum procesu oraz szum pomiaru. Zakładamy, że szумy te są od siebie niezależne, białe, o normalnym rozkładzie prawdopodobieństwa. Symbolicznie możemy to zapisać następująco

$$p(w) \sim N(0, \mathbf{Q}) \quad (2.17)$$

$$p(v) \sim N(0, \mathbf{R}), \quad (2.18)$$

gdzie \mathbf{Q} i \mathbf{R} są macierzami kowariancji.

Algorytm filtra Kalmana jest optymalny pod względem minimalizacji wariancji błędu estymacji. Zdefiniujmy $\hat{\mathbf{x}}_k^- \in \mathbb{R}^n$ jako określenie *a priori* stanu w chwili k na podstawie wiedzy o procesie w chwili $k-1$ oraz $\hat{\mathbf{x}}_k \in \mathbb{R}^n$ jako określenie *a posteriori* stanu w chwili k na podstawie pomiaru \mathbf{z}_k . Stąd otrzymujemy błędy estymacji *a priori* i *a posteriori* dane odpowiednio zależnościami

$$\mathbf{e}_k^- = \mathbf{x}_k - \hat{\mathbf{x}}_k^-, \quad (2.19)$$

$$\mathbf{e}_k = \mathbf{x}_k - \hat{\mathbf{x}}_k \quad (2.20)$$

oraz ich kowariancje

$$\mathbf{P}_k^- = E[\mathbf{e}_k^- \mathbf{e}_k^{-T}], \quad (2.21)$$

$$\mathbf{P}_k = E[\mathbf{e}_k \mathbf{e}_k^T]. \quad (2.22)$$

Estymata *a posteriori* jest liniową kombinacją estymaty *a priori* $\hat{\mathbf{x}}_k^-$ i ważonej różnicy pomiędzy aktualnym pomiarem \mathbf{z}_k i przewidywanym pomiarem $\mathbf{H}\hat{\mathbf{x}}_k^-$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + \mathbf{K}_k(\mathbf{z}_k - \mathbf{H}\hat{\mathbf{x}}_k^-). \quad (2.23)$$

Różnicę $\mathbf{z}_k - \mathbf{H}\hat{\mathbf{x}}_k^-$ nazywamy innowacją pomiaru. Macierz \mathbf{K}_k , zwana wzmocnieniem Kalmana, minimalizuje kowariancję błędu *a posteriori* (2.22) i dana jest wzorem

$$\mathbf{K}_k = \mathbf{P}_k^- \mathbf{H}^T (\mathbf{H}\mathbf{P}_k^- \mathbf{H}^T + \mathbf{R})^{-1}. \quad (2.24)$$

Z powyższego wynika, że filtr Kalmana przybliża przebieg procesu wykorzystując formę sprzężenia zwrotnego w postaci zaszumionego pomiaru. Równania filtru możemy podzielić na równania aktualizacji czasu, z których obliczamy wielkości *a priori*:

$$\hat{\mathbf{x}}_k^- = \mathbf{A}\hat{\mathbf{x}}_{k-1} + \mathbf{B}\mathbf{u}_{k-1}, \quad (2.25)$$

$$\mathbf{P}_k^- = \mathbf{A}\mathbf{P}_{k-1}\mathbf{A}^T + \mathbf{Q} \quad (2.26)$$

oraz równania aktualizacji pomiaru, na podstawie których otrzymujemy wielkości *a posteriori*:

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + \mathbf{K}_k(\mathbf{z}_k - \mathbf{H}\hat{\mathbf{x}}_k^-), \quad (2.27)$$

$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}) \mathbf{P}_k^-, \quad (2.28)$$

gdzie \mathbf{K}_k dane jest zależnością (2.24).

Jeżeli obiekt jest nieliniowy, to należy go zlinearyzować wokół aktualnej średniej i kowariancji. Otrzymujemy w ten sposób rozszerzony filtr Kalmana (Extended Kalman Filter, EKF). Algorytm rozszerzonego filtra Kalmana ma również zastosowanie do jednoczesnej estymacji zmiennych stanu i parametrów obiektu [26]. W takim bowiem przypadku nawet obiekt liniowy pod względem związków między zmiennymi stanu, zazwyczaj generuje zagadnienie nieliniowe z uwagi na związki występujące między zmiennymi stanu i odtwarzanymi parametrami. Dla obiektu opisanego układem stochastycznych równań nieliniowych

$$\begin{cases} \mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}, \mathbf{w}_{k-1}), \\ \mathbf{z}_k = h(\mathbf{x}_k, \mathbf{v}_k) \end{cases}, \quad (2.29)$$

dokonujemy linearyzacji wokół

$$\begin{cases} \tilde{\mathbf{x}}_k = f(\hat{\mathbf{x}}_{k-1}, \mathbf{u}_{k-1}, 0) \\ \tilde{\mathbf{z}}_k = h(\tilde{\mathbf{x}}_k, 0) \end{cases}. \quad (2.30)$$

Otrzymujemy

$$\begin{cases} \mathbf{x}_k \approx \tilde{\mathbf{x}}_k + \mathbf{A}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + \mathbf{W}\mathbf{w}_{k-1}, \\ \mathbf{z}_k \approx \tilde{\mathbf{z}}_k + \mathbf{H}(\mathbf{x}_k - \hat{\mathbf{x}}_k) + \mathbf{V}\mathbf{v}_k, \end{cases} \quad (2.31)$$

gdzie \mathbf{A} , \mathbf{W} , \mathbf{H} , \mathbf{V} są macierzami Jakobiego, pochodnych cząstkowych, danymi zależnościami:

$$\mathbf{A}_{[i,j]} = \frac{\partial f_{[i]}}{\partial x_{[j]}}(\hat{\mathbf{x}}_{k-1}, \mathbf{u}_{k-1}, 0), \quad (2.32)$$

$$\mathbf{W}_{[i,j]} = \frac{\partial f_{[i]}}{\partial w_{[j]}}(\hat{\mathbf{x}}_{k-1}, \mathbf{u}_{k-1}, 0), \quad (2.33)$$

$$\mathbf{H}_{[i,j]} = \frac{\partial h_{[i]}}{\partial x_{[j]}}(\tilde{\mathbf{x}}_k, 0), \quad (2.34)$$

$$\mathbf{V}_{[i,j]} = \frac{\partial h_{[i]}}{\partial v_{[j]}}(\tilde{\mathbf{x}}_k, 0). \quad (2.35)$$

Dla przejrzystości zapisu, po lewej stronie zależności (2.32)-(2.35) pominięto k w dolnym indeksie. Stąd odpowiednie równania przewidywania stanu, przewidywania kowariancji błędu, korekcji estymaty pomiarem i aktualizacji kowariancji błędu przyjmują postać

$$\hat{\mathbf{x}}_k^- = f(\hat{\mathbf{x}}_{k-1}, \mathbf{u}_{k-1}, 0), \quad (2.36)$$

$$\mathbf{P}_k^- = \mathbf{A}_k \mathbf{P}_{k-1} \mathbf{A}_k^T + \mathbf{W}_k \mathbf{Q}_{k-1} \mathbf{W}_k^T, \quad (2.37)$$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + \mathbf{K}_k (\mathbf{z}_k - h(\hat{\mathbf{x}}_k^-, 0)), \quad (2.38)$$

$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_k^-, \quad (2.39)$$

przy czym występujące w równaniach (2.38) i (2.39) wzmacnienie Kalmana dane jest zależnością

$$\mathbf{K}_k = \mathbf{P}_k^- \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_k^- \mathbf{H}_k^T + \mathbf{V}_k \mathbf{R} \mathbf{V}_k^T)^{-1}. \quad (2.40)$$

Bardziej szczegółową genezę równań filtra można znaleźć w [27] oraz [28].

Projektując EKF dla silnika indukcyjnego stajemy w pierwszej kolejności przed koniecznością wyboru modelu matematycznego obiektu. Mamy do dyspozycji model prądowy, napięciowy (strumieniowy) oraz modele mieszane. W publikacji [25] porównano model prądowy proponowany przez Brunsbacha z modelem mieszanym wykorzystywanym przez Vasa. Z uwagi na większą stabilność modelu mieszanego, wykorzystamy go w dalszej

części do wyznaczenia wzmacnienia Kalmana. W modelu tym zmiennymi stanu są składowe prądu stojana i składowe strumienia wirnika. Obiekt opisujemy w przestrzeni stanów równaniami

$$\begin{aligned} \frac{d}{dt} \begin{bmatrix} i_{s\alpha} \\ i_{s\beta} \\ \psi_{r\alpha} \\ \psi_{r\beta} \end{bmatrix} &= \begin{bmatrix} -\left(\frac{R_s}{\sigma L_s} + \frac{1-\sigma}{\sigma \tau_r}\right) & 0 & \frac{L_m}{\sigma L_s L_r \tau_r} & \frac{L_m \omega_r}{\sigma L_s L_r} \\ 0 & -\left(\frac{R_s}{\sigma L_s} + \frac{1-\sigma}{\sigma \tau_r}\right) & -\frac{L_m \omega_r}{\sigma L_s L_r} & \frac{L_m}{\sigma L_s L_r \tau_r} \\ \frac{L_m}{\tau_r} & 0 & -\frac{1}{\tau_r} & -\omega_r \\ 0 & \frac{L_m}{\tau_r} & \omega_r & -\frac{1}{\tau_r} \end{bmatrix} \begin{bmatrix} i_{s\alpha} \\ i_{s\beta} \\ \psi_{r\alpha} \\ \psi_{r\beta} \end{bmatrix} + \\ &+ \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} u_{s\alpha} \\ u_{s\beta} \end{bmatrix}, \end{aligned} \quad (2.41)$$

$$\mathbf{z} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} i_{s\alpha} \\ i_{s\beta} \\ \psi_{r\alpha} \\ \psi_{r\beta} \end{bmatrix}, \quad (2.42)$$

gdzie: $\sigma = 1 - \frac{L_m^2}{L_s L_r}$, $\tau_r = \frac{L_r}{R_r}$, natomiast ω_r jest szukaną kątową prędkością elektryczną wirnika. Znając ω_r wyznaczamy prędkość kątową wirnika z zależności

$$\omega_m = \frac{\omega_r}{p_b}, \quad (2.43)$$

gdzie p_b - liczba par biegunów. Zauważmy, że w układzie (2.41) pominięto równanie dynamiki prędkości kątowej. W rozwiązyaniu tym szukaną prędkość wirnika traktujemy jako parametr występujący w macierzy stanu. Macierze filtru zostaną tak zbudowane, aby estymacja zmiennych stanu była połączona z jednoczesną estymacją zmieniającego się parametru ω_r . Równanie (2.41) należy zapisać w postaci dyskretnej. Przyjmując $\frac{dx}{dt} \approx \frac{x_k - x_{k-1}}{h}$, $a_0 = \frac{1}{L_s L_r - L_m^2}$, $a_1 = 1 - a_0 R_s L_r h$, $a_2 = a_0 L_m^2 h$, $a_3 = a_0 L_m h$, $a_4 = L_m h$, $a_5 = a_0 L_r h$, gdzie h jest okresem próbkowania, otrzymujemy

$$\begin{aligned} \begin{bmatrix} i_{s\alpha}(k) \\ i_{s\beta}(k) \\ \psi_{r\alpha}(k) \\ \psi_{r\beta}(k) \end{bmatrix} &= \begin{bmatrix} a_1 - \frac{a_2}{\tau_r} & 0 & \frac{a_3}{\tau_r} & a_3 \omega_r(k-1) \\ 0 & a_1 - \frac{a_2}{\tau_r} & -a_3 \omega_r(k-1) & \frac{a_3}{\tau_r} \\ \frac{a_4}{\tau_r} & 0 & 1 - \frac{h}{\tau_r} & -h \omega_r(k-1) \\ 0 & \frac{a_4}{\tau_r} & h \omega_r(k-1) & 1 - \frac{h}{\tau_r} \end{bmatrix} \begin{bmatrix} i_{s\alpha}(k-1) \\ i_{s\beta}(k-1) \\ \psi_{r\alpha}(k-1) \\ \psi_{r\beta}(k-1) \end{bmatrix} + \\ &+ \begin{bmatrix} a_5 & 0 \\ 0 & a_5 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} u_{s\alpha}(k-1) \\ u_{s\beta}(k-1) \end{bmatrix}. \end{aligned} \quad (2.44)$$

Z uwagi na czytelność zapisu, chwilę czasową umieszczone w nawiasach zamiast w dolnym indeksie, jak to miało miejsce we wzorach (2.15)-(2.40). Następnie wyznaczamy odpowiednio Jakobiany. Stosując oznaczenia jak w (2.32)-(2.35), otrzymujemy

$$\mathbf{A} = \begin{bmatrix} a_1 - \frac{a_2}{\tau_r} & 0 & \frac{a_3}{\tau_r} & a_3 \hat{\omega}_r(k-1) & a_3 \hat{\psi}_{r\beta}(k-1) \\ 0 & a_1 - \frac{a_2}{\tau_r} & -a_3 \hat{\omega}_r(k-1) & \frac{a_3}{\tau_r} & -a_3 \hat{\psi}_{r\alpha}(k-1) \\ \frac{a_4}{\tau_r} & 0 & 1 - \frac{h}{\tau_r} & -h \hat{\omega}_r(k-1) & -h \hat{\psi}_{r\beta}(k-1) \\ 0 & \frac{a_4}{\tau_r} & h \hat{\omega}_r(k-1) & 1 - \frac{h}{\tau_r} & h \hat{\psi}_{r\alpha}(k-1) \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}, \quad (2.45)$$

$$\mathbf{W} = \text{diag}([1, 1, 1, 1, 1]), \quad (2.46)$$

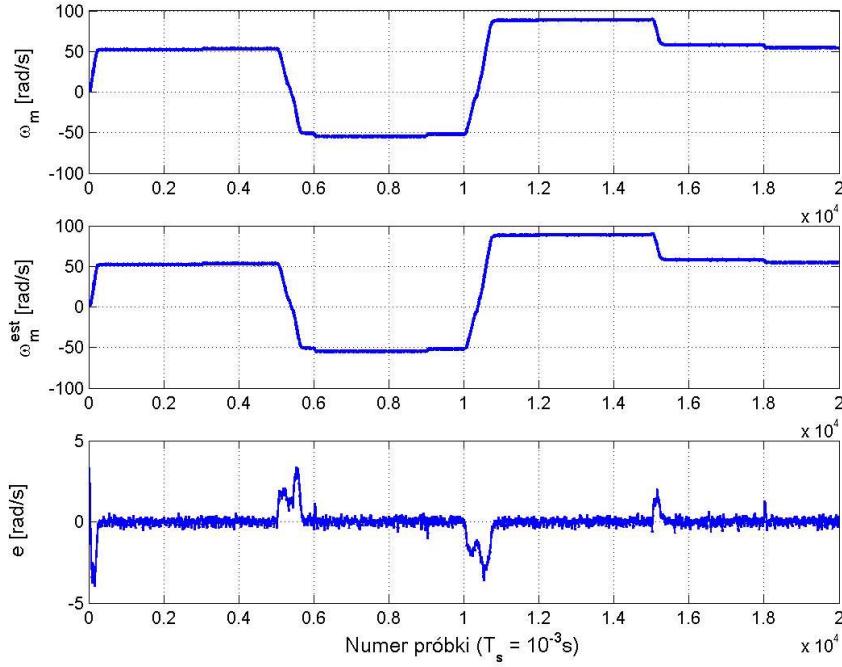
$$\mathbf{H} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}, \quad (2.47)$$

$$\mathbf{V} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}. \quad (2.48)$$

Pochodne cząstkowe w Jakobianach obliczamy po zmiennych stanu $[i_{s\alpha}, i_{s\beta}, \psi_{r\alpha}, \psi_{r\beta}]$ oraz po parametrze ω_r . Zakładamy, że prędkość kątowa wirnika nie zmienia się w stopniu za- uważalnym w czasie jednego okresu h obliczeń algorytmu. Macierz kowariancji \mathbf{R} szumu pomiarowego wyznaczamy na podstawie danych z eksperymentu. Dużo trudniej jest oszacować macierz kowariancji \mathbf{Q} szumu procesu. W układzie rzeczywistym nie dysponujemy pomiarami umożliwiającymi jednoznaczne określenie tej macierzy. Jest to problem, na który wskazują liczni autorzy [4]. Macierz \mathbf{Q} dobieramy metodą prób i błędów, stosując się do ogólnych wytycznych będących wynikiem doświadczeń innych konstruktorów. Proponowane są również algorytmy strojenia macierzy \mathbf{R} i \mathbf{Q} bazujące na metodach sztucznej inteligencji. Przykładowo w [29] zaprojektowano genetyczny algorytm optymalizacji macierzy autokowariancji szumów.

W celu weryfikacji przedstawionych zależności zbudowano model symulacyjny estymatora prędkości. W modelu tym przyjęto, dla silnika o mocy 1.5 kW i prędkości znamionowej 930obr/min, dyskretyzację pierwszego rzędu z krokiem $h = 1$ ms. Przykładowe wyniki odtwarzania prędkości kątowej wirnika przedstawiono na rysunku 2.1.

Większość opisanych w literaturze estymatorów prędkości bazujących na algorytmach Kalmana, wykorzystuje model (2.44) z odtwarzaną prędkością jako parametrem w macierzy stanu. W pracy [30] przedyskutowano wrażliwość algorytmu na zmiany rezystancji stojana i wirnika. Pokazano również wpływ konfiguracji macierzy kowariancji szumów na pracę estymatora. Wykorzystując symetrie widoczne w macierzach (2.45)-(2.48),



Rysunek 2.1. Wyniki odtwarzania prędkości kątowej wirnika przy użyciu rozszerzonego filtru Kalmana

w [31] zredukowano liczbę mnożeń i dodawań, jakie należy wykonać w celu wyznaczenia wzmacnienia (2.40). Kolejnym sposobem optymalizacji liczby działań jest stosowanie modeli zredukowanych drugiego rzędu, w których wymuszeniem są składowe prądu stojana, zmiennymi stanu składowe strumienia wirnika, a wyjściami składowe napięcia stojana [32]. W rozwiązaniu tym wykorzystano wektor stanu rozszerzony o wektor parametrów $[R_s, \sigma L_s, R_r, \frac{1}{L_r}]$. Rozwiązanie to nie jest interesujące z punktu widzenia niżej rozprawy, ponieważ zakłada obecność czujnika prędkości kątowej - prędkość nie jest współrzędną odtwarzanego wektora. Natomiast w [33] zaprezentowano dwa modele o zredukowanym rzędzie: $[\psi_{sd}, \psi_{sq}, \omega_r]$ w układzie wirującym zgodnie z wektorem strumienia wirnika oraz $[\psi_{r\alpha}, \psi_{r\beta}, \omega_r]$ w układzie spoczywającym związanym ze stojanem. W pracy tej omówiono również model pełnego rzędu $[\psi_{s\alpha}, \psi_{s\beta}, \psi_{r\alpha}, \psi_{r\beta}, \omega_r]$. W [34] zaprojektowano filtr do jednoczesnej estymacji prędkości, strumienia i rezystancji wirnika. Z kolei w [35] przedstawiono wyniki badań trzech różnych estymatorów o rozszerzonych wektorach stanu równych odpowiednio: $[i_{s\alpha}, i_{s\beta}, \psi_{r\alpha}, \psi_{r\beta}, \omega_r]$; $[\psi_{s\alpha}, \psi_{s\beta}, \psi_{r\alpha}, \psi_{r\beta}, \frac{1}{\tau_r}]$ oraz $[\psi_{s\alpha}, \psi_{s\beta}, \psi_{r\alpha}, \psi_{r\beta}, \omega_r, \frac{1}{\tau_r}]$. Istnieją również rozwiązania zawierające połączone szeregowo: liniowy filtr Kalmana (LKF) i rozszerzony filtr EKF [36]. Algorytm LKF wykorzystano tutaj do wyznaczenia zastępczego momentu zakłócającego. Omawiana filtracja pojawia się również w rozwiązaniach mieszanych, w których wykorzystano LKF w połączeniu z członem PI do adaptacji prędkości kątowej wirnika [37].

Pomimo niewątpliwej zalety filtru Kalmana polegającej na minimalizowaniu wrażliwości na zakłócenia pomiarowe, posiada on szereg wad utrudniających jego zastosowanie do odtwarzania zmiennych stanu silnika indukcyjnego [4]:

- konieczność wykonania złożonych operacji matematycznych w każdym kroku obliczeniowym,
- brak możliwości jednoznacznego określenia macierzy kowariancji szumu pomiarowego i procesowego (o ile macierz kowariancji szumu pomiarowego można oszacować na podstawie pomiarów, o tyle macierz kowariancji szumu procesowego dobiera się metodą prób i błędów),
- bardzo ograniczona elastyczność algorytmu pod względem możliwości kształtuowania dynamiki obserwatora.

2.3. Obserwator Luenbergera

Założymy, że znany jest opis systemu w dziedzinie czasu

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u} \quad (2.49)$$

$$\mathbf{y} = \mathbf{C}\mathbf{x}, \quad (2.50)$$

a stan początkowy $\mathbf{x}(0) = \mathbf{x}_0$ jest nieznany. Symulator systemu można przedstawić w postaci

$$\dot{\hat{\mathbf{x}}} = \mathbf{A}\hat{\mathbf{x}} + \mathbf{B}\mathbf{u}, \quad (2.51)$$

$$\dot{\hat{\mathbf{y}}} = \mathbf{C}\hat{\mathbf{x}}, \quad (2.52)$$

gdzie $\hat{\mathbf{x}}(0) = \hat{\mathbf{x}}_0$ oznacza znany stan początkowy symulatora systemu. Odejmując stronami (2.49) od (2.51) otrzymujemy równanie dynamiki błędu odtwarzania

$$\dot{\mathbf{e}} = \mathbf{A}\mathbf{e}, \quad (2.53)$$

gdzie $\mathbf{e} = \mathbf{x} - \hat{\mathbf{x}}$. W przypadku takiego symulatora błąd odtwarzania dąży do zera wyłącznie dla układów stabilnych. Dodatkowo, dla układów stabilnych, dynamika dążenia błędu do zera jest identyczna z dynamiką samego obiektu. Cechy te są nieakceptowalne w zdecydowanej większości aplikacji. Do równania stanu symulatora (2.51) wprowadzamy człon korekcyjny $\mathbf{L}(\mathbf{y} - \hat{\mathbf{y}})$, który porównuje sygnał wyjściowy systemu i zmodyfikowanego w ten sposób symulatora. Otrzymujemy równanie stanu obserwatora Luenbergera¹

$$\dot{\hat{\mathbf{x}}} = \mathbf{A}\hat{\mathbf{x}} + \mathbf{B}\mathbf{u} + \mathbf{L}(\mathbf{y} - \mathbf{C}\hat{\mathbf{x}}) \quad (2.54)$$

¹W 1963 roku Dawid G. Luenberger opublikował rozprawę doktorską poświęconą obserwatorom stanu. Uważa się go za ojca słowa „obserwator” w znaczeniu algorytmu wnioskowania o stanie układu dynamicznego na podstawie sygnałów wejściowych i wyjściowych obiektu regulacji, w celu użycia tej informacji do tworzenia sprzężeń zwrotnych w zamkniętych układach sterowania.

oraz równanie dynamiki błędu odtwarzania

$$\dot{\mathbf{e}} = (\mathbf{A} - \mathbf{LC})\mathbf{e}. \quad (2.55)$$

Jeżeli obiekt jest obserwowałny, to dobierając odpowiednio macierz \mathbf{L} można ulokować wartości własne macierzy $\mathbf{A} - \mathbf{LC}$ w dowolnym miejscu na płaszczyźnie zespolonej. Lokując te bieguny w lewej półpłaszczyźnie zapewniamy asymptotyczne dążenie błędu odtwarzania do zera. Dodatkowo możemy kształtować szybkość zbieżności błędu estymacji. Bieguny obserwatora powinny być położone na lewo od biegunów układu regulacji. W przypadku liniowego układu stacjonarnego zadanie arbitralnego ulokowania biegunów posiada rozwiązanie analityczne. W przypadku układów niestacjonarnych lub nieliniowych mówimy o rozszerzonym obserwatorze Luenbergera (Extended Luenberger Observer, ELO). Jedna grupa rozwiązań zakłada, że macierz wzmacnień \mathbf{L} w ELO ustalana jest w trybie off-line, tak aby wartości własne zlinearyzowanej macierzy dynamiki błędu, dla założonego ograniczonego zbioru stanów układu, położone były na lewo od osi urojonej. Drugą grupę tworzą rozwiązania, w których wzmacnienia obserwatora są adaptowane w miarę postępowania procesu estymacji. Przykładowo, w [38, 39] przedstawiono algorytm wstecznej propagacji w czasie pochodnych cząstkowych względem współczynników wzmacnienia obserwatora. Jest on analogiczny do algorytmu wstecznej propagacji błędu wykorzystywanego w uczeniu sztucznych sieci neuronowych. Podobne algorytmy często spotykamy w rozwiązaniach zagadnień adaptacji układów czasu rzeczywistego [40].

W literaturze można znaleźć opis szeregu aplikacji wykorzystujących obserwator Luenbergera do odtwarzania zmiennych stanu i parametrów silnika indukcyjnego. W artykule [41] pokazano jak odtworzyć strumień wirnika i stałą czasową wirnika, przy założeniu dostępności prędkości kątowej. Zaproponowany obserwator jest rzędu zredukowanego. Przykładowy estymator prędkości mechanicznej, momentu obciążającego i strumienia wirnika przedstawiono w [42]. Autor stwierdza przewagę obserwatora rzędu pełnego nad obserwatorem rzędu zredukowanego oraz rozszerzonego filtra Luenbergera nad rozszerzonym filtrem Kalmana w odniesieniu do zagadnień estymacji zmiennych stanu silnika indukcyjnego. Uważam że, dyskusję tę należy bezwzględnie uważać za otwartą. Z uwagi na charakter obiektu, w tym cechy układów pomiarowych, nie można go jednoznacznie zaliczyć do grupy obiektów deterministycznych lub obiektów stochastycznych. Sam silnik jest w zasadzie deterministyczny. Niemniej jednak obecność przekształtnika generującego wyższe harmoniczne napięcia, które mogą być traktowane jako źródła szumu systemowego [34], oraz układy czujników prądu i napięcia wprowadzające szum pomiarowy, czynią system również stochastycznym. Wnioskując z liczby pojawiających się na ten temat artykułów, ELO i EKF mają porównywalną liczbę zwolenników co przeciwników.

Podstawowym problemem przy realizacji omawianego obserwatora jest algorytm doboru macierzy wzmacnień \mathbf{L} . W [42] wykorzystano procedurę arbitralnego umieszczania

biegunów uruchamianą w każdym okresie obliczeń estymatora. Rozwiążanie to jest bardzo obliczeniochłonne. Kolejna propozycja polega na śledzeniu położenia biegunów silnika, które są biegunami stabilnymi, i dobieranie biegunów macierzy $\mathbf{A} - \mathbf{LC}$ tak, aby były do nich proporcjonalne. Zadanie to posiada rozwiązanie analityczne [43, 44]. Elementy macierzy wzmacnień są tutaj odpowiednimi funkcjami parametrów silnika, prędkości wirnika i założonej stałej proporcjonalności. Na przykładzie tego rozwiązania zilustrowany zostanie proces projektowania obserwatora Luenbergera dla silnika indukcyjnego.

Projektowanie rozpoczynamy od opisania obiektu w układzie spoczywającym związanym ze stojanem. Za zmienne stanu przyjmujemy prąd stojana i strumień wirnika. Prędkość wirnika traktowana jest jako parametr macierzy stanu. Oznaczając:

$$\begin{aligned}
\mathbf{I} &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\
\mathbf{J} &= \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \\
\mathbf{A}_{11} &= -\left(\frac{R_s}{\sigma L_s} + \frac{1-\sigma}{\sigma \tau_r}\right) \mathbf{I} = a_{r11} \mathbf{I} \\
\mathbf{A}_{12} &= \frac{L_m}{\sigma L_s L_r} \left(\frac{1}{\tau_r} \mathbf{I} - \omega_r \mathbf{J}\right) = a_{r12} \mathbf{I} + a_{i12} \mathbf{J} \\
\mathbf{A}_{21} &= \frac{L_m}{\tau_r} \mathbf{I} = a_{r21} \mathbf{I} \\
\mathbf{A}_{22} &= -\frac{1}{\tau_r} \mathbf{I} + \omega_r \mathbf{J} = a_{r22} \mathbf{I} + a_{i22} \mathbf{J} \\
\mathbf{B}_1 &= \frac{1}{\sigma L_s} \mathbf{I} = b_1 \mathbf{I} \\
\mathbf{C} &= [\mathbf{I}, \mathbf{0}],
\end{aligned} \tag{2.56}$$

otrzymujemy

$$\frac{d}{dt} \begin{bmatrix} i_{s\alpha} \\ i_{s\beta} \\ \psi_{r\alpha} \\ \psi_{r\beta} \end{bmatrix} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix} \begin{bmatrix} i_{s\alpha} \\ i_{s\beta} \\ \psi_{r\alpha} \\ \psi_{r\beta} \end{bmatrix} + \begin{bmatrix} \mathbf{B}_1 \\ \mathbf{0} \end{bmatrix} \begin{bmatrix} u_{s\alpha} \\ u_{s\beta} \end{bmatrix} = \mathbf{Ax} + \mathbf{Bu}, \tag{2.57}$$

$$\mathbf{y} = \begin{bmatrix} i_{s\alpha} \\ i_{s\beta} \end{bmatrix} = \mathbf{Cx} \begin{bmatrix} i_{s\alpha} \\ i_{s\beta} \\ \psi_{r\alpha} \\ \psi_{r\beta} \end{bmatrix} = \mathbf{Cx}. \tag{2.58}$$

Model ten jest analogiczny do (2.41). Wprowadzone oznaczenia mają na celu wyłącznie ułatwienie wyznaczenia macierzy wzmacnień \mathbf{G} występującej w równaniu obserwatora

$$\frac{d}{dt} \hat{\mathbf{x}} = \hat{\mathbf{A}} \hat{\mathbf{x}} + \mathbf{Bu} + \mathbf{G}(\hat{\mathbf{y}} - \mathbf{y}), \tag{2.59}$$

gdzie macierz $\mathbf{G} = -\mathbf{L}$ z równania (2.54). Macierz \mathbf{G} wzmacnień obserwatora dana jest wzorem

$$\mathbf{G} = \begin{bmatrix} g_1 & -g_2 \\ g_2 & g_1 \\ g_3 & -g_4 \\ g_4 & g_3 \end{bmatrix}, \quad (2.60)$$

w którym

$$\begin{aligned} g_1 &= (k_b - 1)(a_{r11} + a_{r22}) \\ g_2 &= (k_b - 1)a_{i22} \\ g_3 &= (k_b^2 - 1)(ca_{r11} + a_{r21}) - c(k_b - 1)(a_{r11} + a_{r22}) \\ g_4 &= -c(k_b - 1)a_{i22} \\ c &= \frac{\sigma L_s L_r}{L_m}. \end{aligned} \quad (2.61)$$

Dodatni współczynnik proporcjonalności k_b określa położenie biegunów obserwatora w stosunku do biegunów silnika. Symbol estymaty nad macierzą \mathbf{A} w (2.59) sygnalizuje jej zależność od estymowanej prędkości kątowej wirnika. Wykorzystując teorię stabilności Lapunowa wyprowadzono schemat adaptacji prędkości wirnika

$$\hat{\omega}_r = K_P(e_{is\alpha}\hat{\psi}_{r\beta} - e_{is\beta}\hat{\psi}_{r\alpha}) + K_I \int (e_{is\alpha}\hat{\psi}_{r\beta} - e_{is\beta}\hat{\psi}_{r\alpha}) dt, \quad (2.62)$$

w którym $e_{is\alpha} = i_{s\alpha} - \hat{i}_{s\alpha}$, $e_{is\beta} = i_{s\beta} - \hat{i}_{s\beta}$, natomiast K_P i K_I są odpowiednio dobranymi parametrami członu proporcjonalno-całkującego. Dodatkowo w [43] i/lub [44] znajdziemy algorytm adaptacji rezystancji stojana i odwrotności stałej czasowej wirnika. Przechodząc do budowy modelu należy zdyskretyzować z krokiem h równanie (2.59) otrzymując

$$\hat{\mathbf{x}}_k = \hat{\mathbf{A}}_d \hat{\mathbf{x}} + \mathbf{B}_d \mathbf{u} + \mathbf{G}_d(\mathbf{C} \hat{\mathbf{x}} - \mathbf{y}), \quad (2.63)$$

gdzie

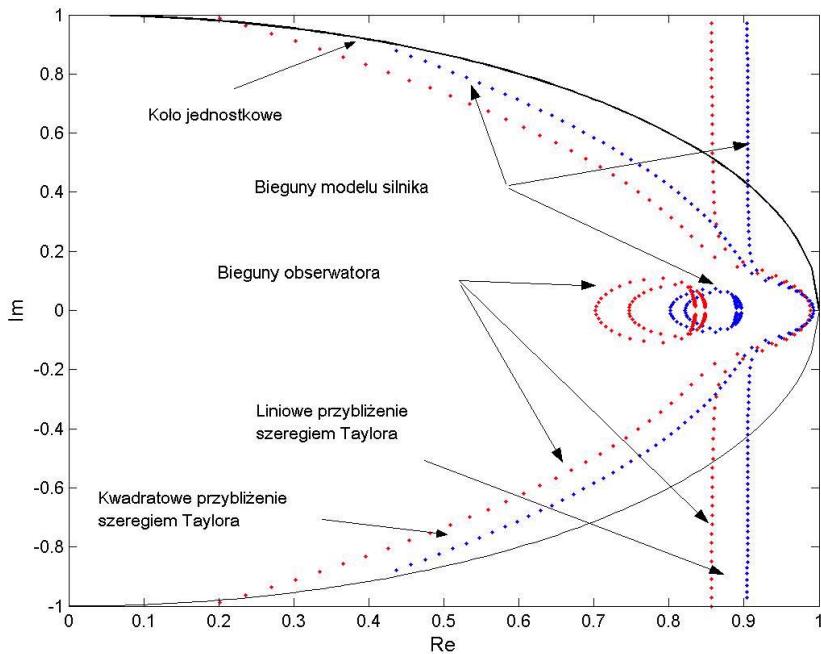
$$\hat{\mathbf{A}}_d = e^{\hat{\mathbf{A}}h} \cong \mathbf{I} + \hat{\mathbf{A}}h + \frac{\hat{\mathbf{A}}^2 h^2}{2!} + \dots \quad (2.64)$$

$$\mathbf{B}_d = \int_0^h e^{\hat{\mathbf{A}}t} \mathbf{B} dt \cong \mathbf{B}h + \frac{\hat{\mathbf{A}}\mathbf{B}h^2}{2!} + \dots, \quad (2.65)$$

przy czym \mathbf{G}_d jest ekwiwalentną dyskretną macierzą wzmacnień członu korekcyjnego obserwatora. Przeważnie ograniczamy się do przybliżenia liniowego (wstecznego schematu Eulera). Otrzymujemy wtedy

$$\begin{aligned} \hat{\mathbf{A}}_d &= \mathbf{I} + \hat{\mathbf{A}}h \\ \mathbf{B}_d &= \mathbf{B}h \\ \mathbf{G}_d &= \mathbf{G}h. \end{aligned} \quad (2.66)$$

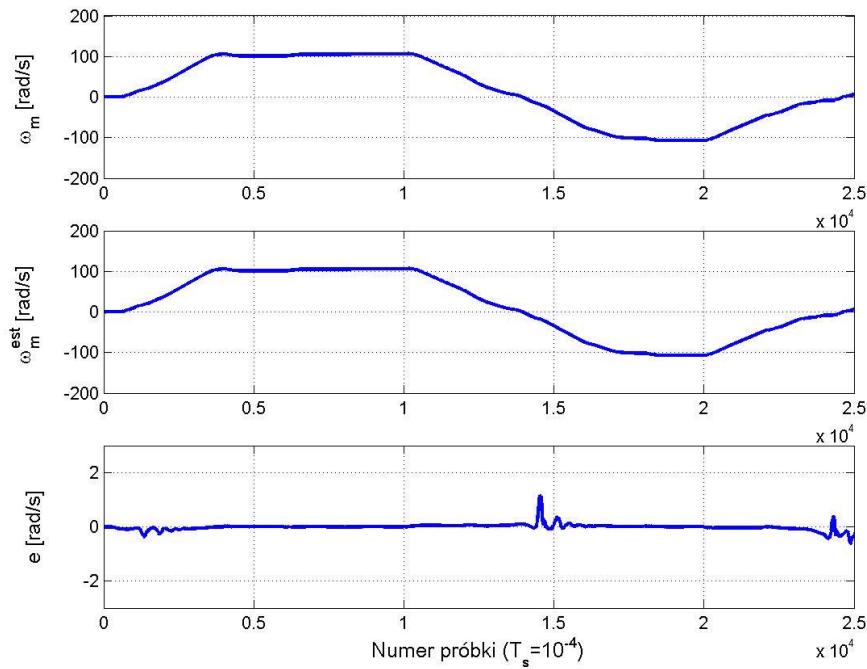
Jest to równoznaczne z przyjęciem przybliżenia $\frac{dx}{dt} \approx \frac{x_k - x_{k-1}}{h}$. Rozwinięcie kwadratowe można stosować w celu poprawienia dokładności dla dużych h . Okupione to jednak zostaje dużo większym nakładem obliczeniowym. Nawet dla małych h i dostatecznie dużej prędkości bieguny modelu dyskretnego silnika, a zatem również bieguny dyskretnego obserwatora, wychodzą poza koło jednostkowe (rysunek 2.2) i układ staje się niestabilny. Dzieje się tak również przy uwzględnianiu kolejnych wyrazów w rozwinięciu Taylora. Projektując estymator należy zatem szczególną uwagę zwrócić na zapewnienie odpowiedniego zapasu stabilności w przewidzianym zakresie prędkości napędu.



Rysunek 2.2. Położenie biegunków dyskretnego modelu silnika i związanego z nim obserwatora ($k_b = 1.5$), przy zmieniającej się prędkości, dla dwóch różnych schematów dyskretyzacji: $\hat{\mathbf{A}}_d = \mathbf{I} + \hat{\mathbf{A}}h$ oraz $\hat{\mathbf{A}}_d = \mathbf{I} + \hat{\mathbf{A}}h + \frac{\hat{\mathbf{A}}^2 h^2}{2!}$

W celach poznanawczych zbudowano model symulacyjny estymatora prędkości bazujący na obserwatorze Luenbergera (2.63) z przybliżeniami (2.66), w których przyjęto $h = 100\mu s$ dla silnika o mocy 1.5kW i prędkości znamionowej 930obr/min. Do adaptacji prędkości wykorzystano regułę (2.62). Przykładowe wyniki odtwarzania przedstawiono na rysunku 2.3.

Omówiony algorytm jest wciąż udoskonalany. Modyfikowane są reguły wiążące biegunki obserwatora z biegunami silnika [45, 46]. Poprawiane są reguły adaptacji prędkości [47], proponowane są metody optymalizacji trajektorii biegunków w oparciu o algorytmy genetyczne [48], realizacje rozmyte obserwatora [48], nowe metody redukcji rzędu obserwatora i dobór wzmacnień dla struktury zredukowanej [49].



Rysunek 2.3. Przykładowe wyniki odtwarzania prędkości kątowej wirnika przy użyciu obserwatora Luenbergera

2.4. Obserwatory w trybie ruchu ślizgowego

Rozwój przekształtników energoelektronicznych wykorzystujących łączniki półprzewodnikowe spowodował powstanie nowej klasy układów zwanych systemami o zmiennej strukturze (Variable Structure Systems, VSS). Na potrzeby tych układów opracowano teorię nieliniowego sterowania w tzw. trybie ruchu ślizgowego lub inaczej poślizgowego (*ang. sliding-mode*). W sterowaniu poślizgowym stan łączników jest funkcją chwilowych wartości zmiennych stanu układu. Funkcje te projektujemy tak, aby trajektoria systemu pozostała na założonej powierzchni w przestrzeni fazowej. Podstawy teorii ruchu poślizgowego można znaleźć w [50]. Jednym z twórców tej teorii jest Vadim I. Utkin. W latach 1975–1978 pracował w ramach międzynarodowego projektu nad sterowaniem poślizgowym silnika indukcyjnego. W artykule [51] zawarł on podstawowe wiadomości z zakresu sterowania poślizgowego w napędzie elektrycznym. Teoria systemów VSS zainspirowała do stworzenia szczególnej klasy obserwatorów o zmiennej strukturze. Obserwatory te pracują w trybie ruchu ślizgowego, a ich wspólną cechą jest obecność funkcji przełączających. Projektowanie obserwatorów sliding-mode dla nieliniowych układów dynamicznych opisano między innymi w [52]. W zdecydowanej większości proponowanych obserwatorów sliding-mode dla silnika indukcyjnego, nieciągłe funkcje przełączające są zbudowane w oparciu o znaki błędów odtwarzania prądów stojana [53, 54, 55, 56, 57, 58, 59, 60, 61]. Projektowanie obserwatora pracującego w trybie ruchu ślizgowego omówione zostanie na przykładzie jednego

z najnowszych rozwiązań zaproponowanego w [60]. Równania opisujące silnik indukcyjny przekształcamy do postaci

$$\begin{cases} \frac{di_{s\alpha}}{dt} = \gamma F_\alpha - k_1 i_{s\alpha} + k_2 u_{s\alpha} \\ \frac{di_{s\beta}}{dt} = \gamma F_\beta - k_1 i_{s\beta} + k_2 u_{s\beta} \\ \frac{d\psi_{r\alpha}}{dt} = -F_\alpha + \eta_r L_m i_{s\alpha} \\ \frac{d\psi_{r\beta}}{dt} = -F_\beta + \eta_r L_m i_{s\beta} \end{cases}, \quad (2.67)$$

gdzie $F_\alpha = \eta_r \psi_{r\alpha} + \omega_r \psi_{r\beta}$, $F_\beta = \eta_r \psi_{r\beta} - \omega_r \psi_{r\alpha}$, $\eta_r = \frac{1}{\tau_r} = \frac{R_r}{L_r}$, $k_2 = \frac{1}{\sigma L_s}$, $k_1 = k_2 \left(R_s + \frac{L_m^2}{L_r \tau_r} \right)$, $\sigma = 1 - \frac{L_m^2}{L_s L_r}$, $\gamma = \frac{k_2 L_m}{L_r}$. W rozwiązaniu tym zakładamy, że prędkość elektryczna wirnika ω_r jest nieznanym, wolnozmiennym parametrem. Budujemy obserwator prądów stojana pracujący w trybie ruchu ślizgowego i opisany zależnościami

$$\begin{cases} \frac{\hat{di}_{s\alpha}}{dt} = \gamma V_\alpha - k_1 \hat{i}_{s\alpha} + k_2 u_{s\alpha} \\ \frac{\hat{di}_{s\beta}}{dt} = \gamma V_\beta - k_1 \hat{i}_{s\beta} + k_2 u_{s\beta} \end{cases}, \quad (2.68)$$

w których V_α i V_β są nieciągłymi funkcjami przełączającymi określonymi następująco:

$$\begin{cases} V_\alpha = -V_0 \operatorname{sign}(\hat{i}_{s\alpha} - i_{s\alpha}) = -V_0 \operatorname{sign}(s_\alpha) \\ V_\beta = -V_0 \operatorname{sign}(\hat{i}_{s\beta} - i_{s\beta}) = -V_0 \operatorname{sign}(s_\beta) \end{cases}. \quad (2.69)$$

Posługując się teorią Lapunowa, można pokazać, że istnieje stała wartość V_0 taka, że trajektoria obserwatora prądu stojana pojawia się na powierzchni $s_\alpha = s_\beta = 0$. W efekcie prawidłowo dobranego wzmacnienia V_0 , błąd odtwarzania dąży do zera. Odejmując stronami (2.68) od (2.67) otrzymujemy opis dynamiki zmian tego błędu:

$$\begin{cases} \dot{s}_\alpha = \gamma V_\alpha - \gamma(\eta_r \psi_{r\alpha} + \omega_r \psi_{r\beta}) - k_1 s_\alpha \\ \dot{s}_\beta = \gamma V_\beta - \gamma(\eta_r \psi_{r\beta} - \omega_r \psi_{r\alpha}) - k_1 s_\beta \end{cases}. \quad (2.70)$$

Wstawiając do (2.70) $s_\alpha = s_\beta = \dot{s}_\alpha = \dot{s}_\beta = 0$ otrzymujemy wyrażenia na tzw. składowe sterowania równoważnego

$$\begin{cases} V_{\alpha eq} = \eta_r \psi_{r\alpha} + \omega_r \psi_{r\beta} \\ V_{\beta eq} = \eta_r \psi_{r\beta} - \omega_r \psi_{r\alpha} \end{cases}. \quad (2.71)$$

Składowe te możemy otrzymać poprzez dolnoprzepustową filtrację funkcji przełączających (2.69). Pamiętając, że $\dot{\omega}_r \cong 0$ i różniczkując obustronnie (2.71) możemy wyznaczyć prędkość elektryczną wirnika

$$\omega_r = \frac{\dot{V}_{\alpha eq} \dot{\psi}_{r\beta} - \dot{V}_{\beta eq} \dot{\psi}_{r\alpha}}{\dot{\psi}_{r\alpha}^2 + \dot{\psi}_{r\beta}^2}. \quad (2.72)$$

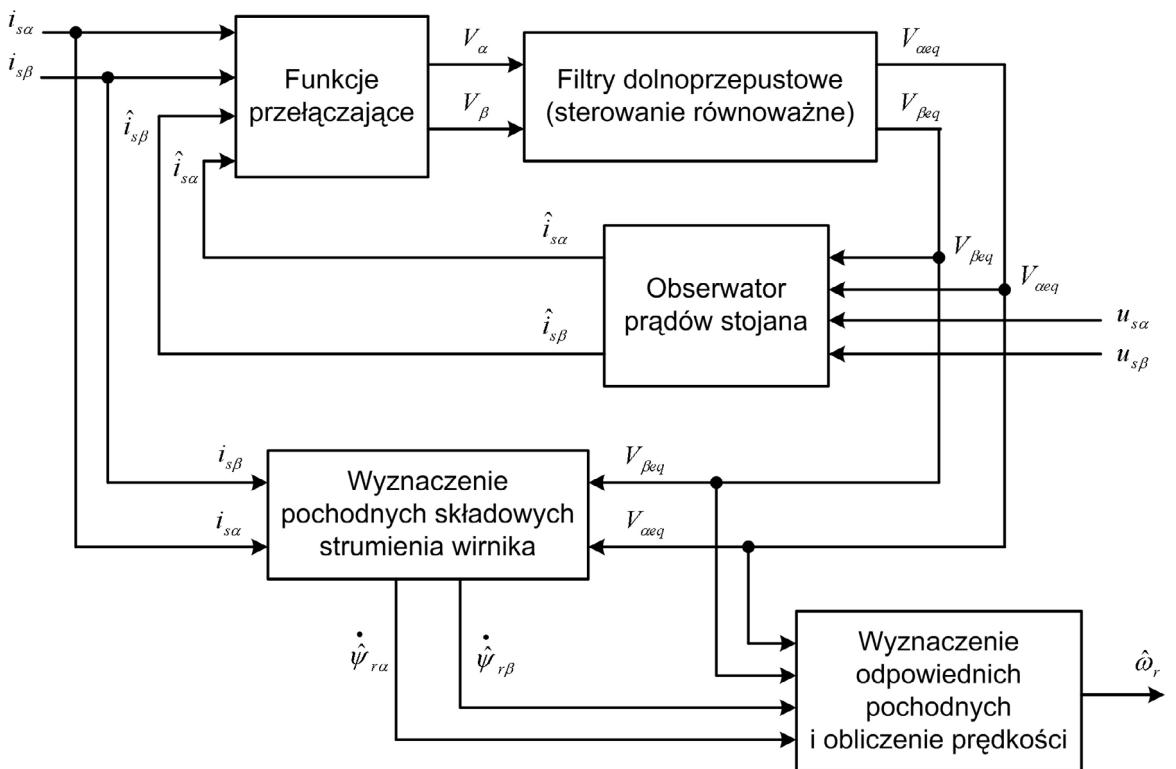
Występujące we wzorze (2.72) pochodne składowych strumienia wirnika zastępujemy pochodnymi estymat, które zgodnie z (2.67) oraz (2.71) dane są zależnościami

$$\begin{cases} \dot{\hat{\psi}}_{r\alpha} = -V_{\alpha eq} + \eta_r L_m \hat{i}_{s\alpha} \\ \dot{\hat{\psi}}_{r\beta} = -V_{\beta eq} + \eta_r L_m \hat{i}_{s\beta} \end{cases}. \quad (2.73)$$

Stąd prędkość wirnika możemy wyznaczyć w oparciu o prostą zależność

$$\omega_r = \frac{\dot{V}_{\alpha eq} \dot{\psi}_{r\beta} - \dot{V}_{\beta eq} \dot{\psi}_{r\alpha}}{\left(\dot{\psi}_{r\alpha} \right)^2 + \left(\dot{\psi}_{r\beta} \right)^2}. \quad (2.74)$$

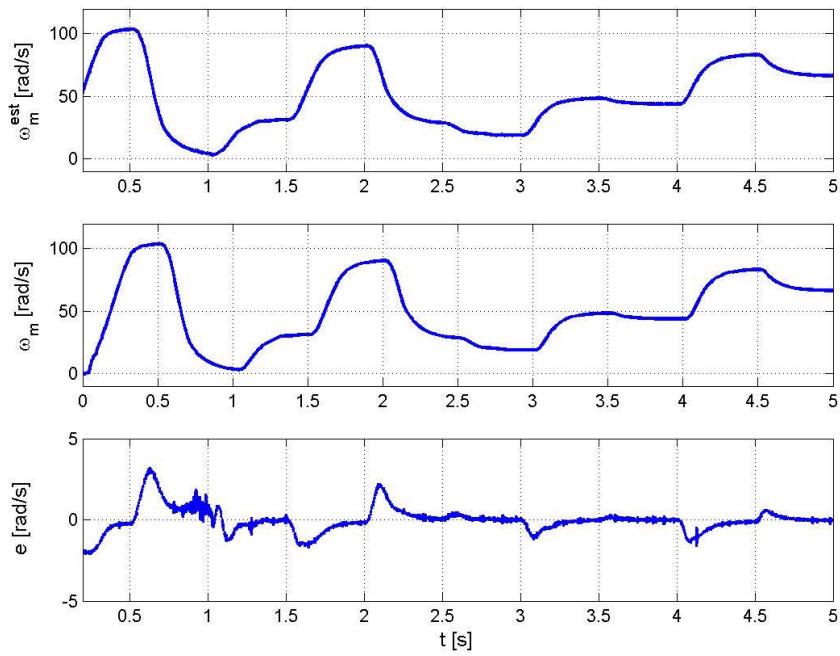
Autor opisanego rozwiązania nie komentuje pojawiającego się problemu numerycznego wyznaczenia pochodnych składowych sterowania równoważnego $\dot{V}_{\alpha eq}$, $\dot{V}_{\beta eq}$. W celu prześledzenia tego zagadnienia zbudowano dyskretny model symulacyjny omawianego obserwatora. Schemat blokowy obserwatora sliding-mode przedstawiono na rysunku 2.4. Blok różnicz-



Rysunek 2.4. Schemat blokowy obserwatora pracującego w trybie ruchu ślizgowego

kowania w dziedzinie dyskretnej zrealizowano zastępując pochodną średnią arytmetyczną kilku ilorazów różnicowych funkcji. W podejściu tym pochodna sygnału y w chwili k przybliżana jest, na przykład, zależnością

$$\begin{aligned} \dot{y}(k) &\cong \frac{\frac{y(k)-y(k-2n)}{2nh} + \frac{y(k-n)-y(k-2n)}{nh} + \frac{y(k-n)-y(k-3n)}{2nh}}{3} = \\ &= \frac{y(k) + 3y(k-n) - 3y(k-2n) - y(k-3n)}{6nh} = \\ &= y \frac{1 + 3z^{-n} - 3z^{-2n} - z^{-3n}}{6nh}, \end{aligned} \quad (2.75)$$



Rysunek 2.5. Przykładowe wyniki odtwarzania prędkości kątowej wirnika z wykorzystaniem metody ruchu ślizgowego

gdzie: h - okres próbkowania, n - liczba naturalna, z^{-1} - operator opóźnienia. Różniczkowanie takie wprowadza niestety znaczne opóźnienie do układu. Przykładowe wyniki odtwarzania prędkości wirnika przy użyciu obserwatora sliding-mode zilustrowano na rysunku 2.5. W omawianym artykule [60] zwrócono uwagę na możliwość poprawy jakości odtwarzania małych prędkości poprzez dodanie adaptacji wzmacnienia V_0 i częstotliwości odcięcia filtrów LPF.

2.5. Śledzenie asymetrii magnetycznych maszyny

Dla zerowej częstotliwości stojana, nawet teoretycznie, żadna informacja o dynamice wirnika nie jest dostępna na zaciskach silnika. BezczuJNIKOWE metody bazujące na modelu matematycznym uwzględniającym jedynie podstawową harmoniczną napięcia stojana zatwierdzają przy zerowej i niskich częstotliwościach, niezależnie od jakości zastosowanego algorytmu. Chęć wyeliminowania czujnika prędkości i położenia w aplikacjach wymagających pełnej kontroli momentu przy zerowej i małych prędkościach, skierowało uwagę inżynierów na asymetrie magnetyczne silnika indukcyjnego. W ostatnim dziesięcioleciu opracowano szereg metod wykorzystujących asymetrie magnetyczne do wyznaczania obrazu przestrzennego strumieni magnetycznych w silniku indukcyjnym. Wyniki tych badań zaowocowały budową bezczuJNIKOWYCH napędów z silnikiem indukcyjnym, pozwalających na sterowanie

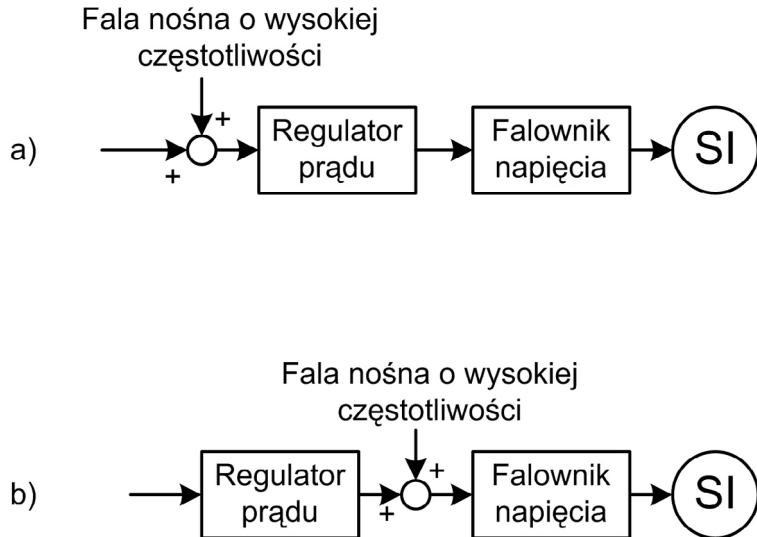
momentem i położeniem przy niskich i zerowych prędkościach. Projektując typowy silnik indukcyjny dążymy do stworzenia maszyny możliwie najbardziej symetrycznej z elektrycznego i magnetycznego punktu widzenia. Utrudnia to projektowanie układów śledzenia niewielkich niezamierzonych asymetrii. Początkowo metody te były skuteczne dla silników indukcyjnych, w których w sposób zamierzony wprowadzono pewne asymetrie. Był to silniki specjalnie przerabiane do celów badawczych. Obecnie dysponujemy metodami pozwalającymi na sterowanie seryjnymi silnikami bez zamierzonych asymetrii, nawet tych z zamkniętymi żlobkami wirnika [62]. Każdy silnik indukcyjny jest urządzeniem anizotropowym pod względem elektrycznym i magnetycznym. Podstawowe i nieuniknione źródła tych asymetrii to:

- dyskretyzacja uzwojeń stojana, tj. ich koncentracja w żlobkach stojana,
- obecność żlobków wirnika i stojana wokół szczeliny powietrznej,
- zmiany szczeliny powietrznej wywołane statyczną i dynamiczną ekscentrycznością wirnika względem stojana,
- nasycanie się zębów wirnika i stojana.

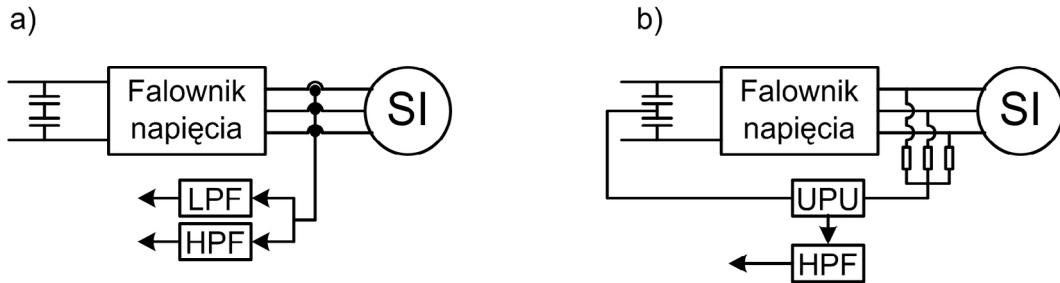
Ekscentryczność statyczna polega na ruchu obrotowym wirnika wokół jego geometrycznej osi, która nie pokrywa się jednak z osią stojana, natomiast ekscentryczność dynamiczna, dotyczy sytuacji ruchu obrotowego geometrycznej osi wirnika wokół osi stojana. Na etapie projektowym zakładamy oczywiście brak ekscentryczności. Jej występowanie jest skutkiem niedokładności wykonania urządzenia. Pozostałe z wymienionych źródeł asymetrii wynikają z założeń projektowych maszyny.

Idealna maszyna miałaby sinusoidalny rozkład uzwojeń stojana i wirnika oraz gładką magnetycznie szczelinę powietrzną. Zasilana symetrycznym, sinusoidalnym trójfazowym napięciem odpowiadałaby w stanie ustalonej prędkości mechanicznej symetrycznymi, trójfazowymi, sinusoidalnymi prądami. Z uwagi na występujące anizotropie, w widmie prądu stojana pojawiają się prążki, których częstotliwości związane są z prędkością kątową wirnika [63, 64]. Z powodu niskiej amplitudy tych harmonicznych w stosunku do pozostałych obecnych w widmie prądu stojana, a wynikających m.in. z obecności falownika napięcia, ich śledzenie jest bardzo utrudnione. Metody bazujące na wzbudzeniu podstawową harmoniczną napięcia i obserwowania tzw. "podpisu prądowego" nie rozwiązują zadania odtwarzania prędkości dla częstotliwości prądu stojana bliskich zeru.

Problemy odtwarzania prędkości bliskich zeru i zerowych oraz odtwarzanie położenia wirnika i/lub strumienia wirnika rozwiązyano poprzez wstrzykiwanie dodatkowego prądu lub napięcia o wysokiej częstotliwości (rys. 2.6). Metody te możemy podzielić, z uwagi



Rysunek 2.6. Różnice topologiczne układów ze wstrzykiwaniem sygnału: a) prądu, b) napięcia o wysokiej częstotliwości



Rysunek 2.7. Realizacja pomiarów sygnałów w metodach: a) HFMT, b) ZST

na sygnał mierzony, na dwie grupy. Do pierwszej grupy zaliczamy rozwiązania bazujące na pomiarze prądów fazowych (HFMT, High Frequency Modulation Techniques) [65, 66, 67, 68, 69, 70, 71, 72]. Drugą grupę tworzą rozwiązania, w których dokonuje się pomiaru napięcia na zacisku zerowym uzwojeń stojana lub, gdy ten jest niedostępny, punktu zerowego symetrycznej gwiazdy rezystorów dołączonej do zacisków stojana (ZST, Zero Sequence Technique) [73, 74, 62]. Za poziom odniesienia dla tych pomiarów przyjmuje się połowę napięcia obwodu pośredniczącego. Topologiczne różnice tych dwóch układów pokazano na rysunku 2.7. Dodatkowo istnieją dwa różne sposoby kształtowania sygnału wysokoczęstotliwościowego. W jednych aplikacjach jest to sygnał wytwarzający wirujące sinusoidalne pole magnetyczne [68, 69], w innych wymuszany jest sygnał pulsacyjny [75, 67]. Najczęściej wykorzystywanymi asymetriami są te wynikające z nasycania i żlobkowania. Istnieją również funkcjonujące rozwiązania bazujące na wspomnianej wcześniej koncentracji uzwojeń stojana w żlobkach [76]. Wśród metod opartych na zmianach reaktancji należy wymienić INFORM (Indirect Flux detection by On-line Reactance Measurement) opracowaną przez M. Schrödla [77]. Przykładowo w [78] wykorzystano ją do badań porównawczych.

nawczych maszyn o zamkniętych i otwartych żlobkach wirnika. W metodzie tej na czas podania napięcia testującego wstrzymywane jest wzbudzenie podstawowe.

Wiele publikowanych metod zakłada występowanie pojedynczej asymetrii o sinusoidalnym rozkładzie przestrzennym. W rzeczywistej maszynie występuje jednocześnie wiele asymetrii. Nie uniemożliwia to stosowania tych metod. Ogranicza jednak ich dokładność. W celu poprawy dokładności stosuje się modele odsprzęgające efekty poszczególnych anizotropii [69].

Trudności związane ze śledzeniem asymetrii magnetycznych maszyny, mobilizują do dalszych poszukiwań coraz to lepszych obserwatorów bazujących na parametrycznych modelach silnika indukcyjnego. Ciekawym przykładem może być tutaj obserwator opisany w [5], w którym prędkość kątowa wirnika nie występuje jako parametr w modelu maszyny asynchronicznej, lecz pojawia się jako współczynnik w zakłóceniach.

2.6. Nakładanie sygnału o niskiej częstotliwości

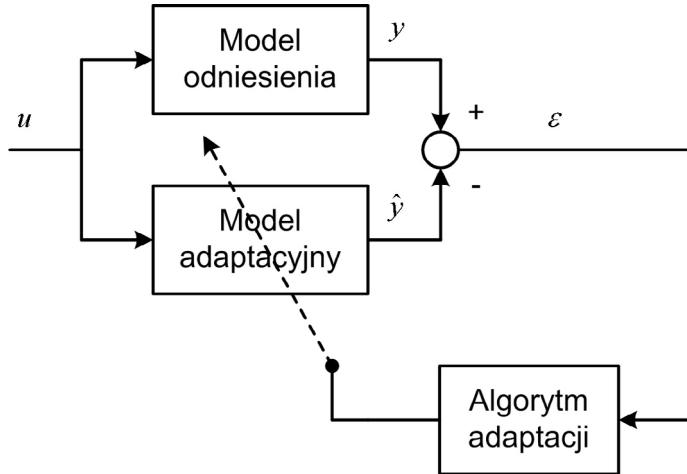
W artykułach [79, 80, 81, 82, 83] V.-L. Leppänen i J. Luomiego opisano napęd wektorowy z nakładanym sygnałem o niskiej częstotliwości umożliwiający orientację sterowania zgodnie ze strumieniem wirnika również przy zerowej częstotliwości. Zastosowany obserwator nie zakłada obecności pasożytniczych asymetrii maszyny indukcyjnej. Wykorzystuje natomiast mechaniczną reakcję wirnika na dodany wolnozmienny sygnał prądowy. Wymuszając dodatkowy wolnozmienny sinusoidalny przebieg prądu, w kierunku estymowanej osi d strumienia wirnika, wywołujemy reakcję mechaniczną wirnika będącą funkcją błędu wyznaczenia tej osi. Oscylacje prędkości indukują oscylacyjną składową siły elektromotorycznej, która może zostać wyznaczona na podstawie napięć stojana. Składowa ta wykorzystywana jest do obliczenia sygnału błędu, który następnie służy do regulowania sygnału testowego tak, aby zgadzał się z kierunkiem strumienia wirnika. Stosowalność tej metody ograniczona jest do napędów o niezbyt wysokim całkowitym momencie bezwładności. Autorzy podają w [80] górną granicę na poziomie

$$J_{\max} = L_m \frac{3}{2} \left(\frac{p_b \psi_{r0}}{R_r} \right), \quad (2.76)$$

gdzie ψ_{r0} jest strumieniem wirnika w stanie ustalonym.

2.7. Adaptacyjne układy z modelem odniesienia

Obserwatory prędkości o architekturze adaptacyjnych układów z modelem odniesienia (MRAS, Model Reference Adaptive System) należą do najczęściej stosowanych rozwiązań



Rysunek 2.8. Podstawowa struktura adaptacyjnego układu z modelem odniesienia (MRAS)

w napędach bezczujnikowych [84]. Podstawową strukturę takiego obserwatora przedstawiono na rysunku 2.8. Układ MRAS składa się z modelu odniesienia (modelu referencyjnego) i modelu adaptacyjnego. W obu modelach wyznaczane są te same wielkości, a różnica między nimi służy do dostrajania wybranych parametrów w modelu adaptacyjnym. Struktura podstawowa może zostać rozbudowana o mechanizmy adaptacji również parametrów modelu odniesienia. Omówiony wcześniej obserwator Luenbergera z algorytmem adaptacji prędkości traktowanej jako parametr w macierzy stanu może zostać zaliczony do rodziny rozwiązań typu MRAS. Adaptacja prędkości zgodnie z zależnością (2.62) oznacza wykorzystywanie sygnału proporcjonalnego do błędu odtworzenia momentu elektromagnetycznego [85, 86, 47, 87]. Stąd w [87] strukturę tę nazwano MRAS-moment. Rolę modelu odniesienia pełni tutaj obiekt fizyczny (silnik). W tej części omówione zostaną rozwiązania, w których model odniesienia jest modelem matematycznym opisującym wybrane aspekty działania obiektu fizycznego.

Autorem prekursorskiego rozwiązania typu MRAS w dziedzinie estymacji prędkości kątowej wirnika silnika indukcyjnego jest Colin Schauder [84]. W proponowanym przez niego rozwiązaniu [20] modelem odniesienia jest tzw. model napięciowy, dany układem równań

$$\left\{ \begin{array}{l} \frac{d\psi_{s\alpha}}{dt} = u_{s\alpha} - R_s i_{s\alpha} \\ \frac{d\psi_{s\beta}}{dt} = u_{s\beta} - R_s i_{s\beta} \\ \psi_{r\alpha} = \frac{L_r}{L_m} (\psi_{s\alpha} - \sigma L_s i_{s\alpha}) \\ \psi_{r\beta} = \frac{L_r}{L_m} (\psi_{s\beta} - \sigma L_s i_{s\beta}) \end{array} \right. , \quad (2.77)$$

pozwalający wyznaczyć strumień wirnika na podstawie mierzonych wartości prądów i napięć na zaciskach maszyny. Modelem adaptacyjnym jest tzw. model prądowy, opisany równaniami

$$\left\{ \begin{array}{l} \frac{d\hat{\psi}_{r\alpha}}{dt} = \frac{L_m}{\tau_r} i_{s\alpha} - \hat{\omega}_r \hat{\psi}_{r\beta} - \frac{1}{\tau_r} \hat{\psi}_{r\alpha} \\ \frac{d\hat{\psi}_{r\beta}}{dt} = \frac{L_m}{\tau_r} i_{s\beta} + \hat{\omega}_r \hat{\psi}_{r\alpha} - \frac{1}{\tau_r} \hat{\psi}_{r\beta} \end{array} \right. , \quad (2.78)$$

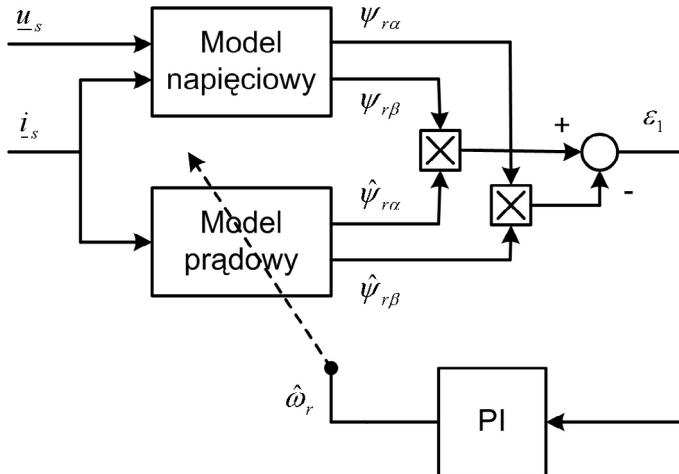
w którym występuje szukana prędkość wirnika. Na podstawie kryterium hiperstabilności Popowa wyprowadzany jest mechanizm adaptacji prędkości wirnika

$$\hat{\omega}_r = K_P \varepsilon_1 + K_I \int \varepsilon_1 dt, \quad (2.79)$$

w którym

$$\varepsilon_1 = \hat{\psi}_{r\alpha} \psi_{r\beta} - \psi_{r\alpha} \hat{\psi}_{r\beta} = \Im(\underline{\psi}_r \underline{\hat{\psi}}_r^*) \propto |\underline{\psi}_r| |\underline{\hat{\psi}}_r| \sin \angle(\underline{\psi}_r, \underline{\hat{\psi}}_r) \quad (2.80)$$

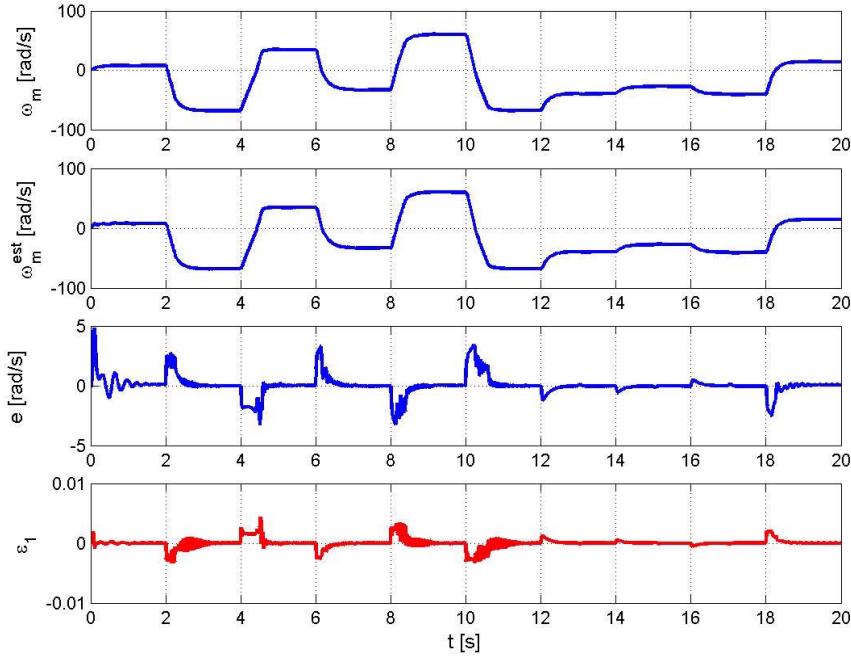
jest miarą błędu pomiędzy wyjściami modelu odniesienia i modelu adaptacyjnego, natomiast K_P i K_I to odpowiednie stałe dodatnie. Zauważmy, że adaptacja odbywa się przy pomocy członu PI, którego wejście jest proporcjonalne do sinusa kąta między porównywanymi wektorami $\underline{\psi}_r$ i $\underline{\hat{\psi}}_r$. Układ ten może być interpretowany jako PLL (Phase Locked Loop), w którym rolę członu przesuwającego fazę pełni model adaptacyjny. W literaturze rozwiazanie to bywa nazywane „MRAS1”. Rysunek 2.9 ilustruje konfigurację estymatora



Rysunek 2.9. Estymator prędkości zaproponowany przez C. Schaudera

MRAS1. Skuteczność tego rozwiązania zależy przede wszystkim od odpowiedniej realizacji całkowania w modelu odniesienia, od obecności równoległej adaptacji rezystancji stojana, od odpowiedniej filtracji sygnałów strumieni przed wyznaczeniem wartości ε_1 i innych zbiegów praktycznych opisanych szczegółowo w [20, 88, 89].

W celach poznawczych zbudowano model symulacyjny bezczujnikowego napędu SFOC z estymatorem MRAS1 zawierającym zalecane modyfikacje. Przykładowe wyniki symulacji przedstawione na rysunku 2.10, dowodzą skuteczności opisanego rozwiązania po uwzględnieniu zalecanych modyfikacji. Trudno jest jednak stwierdzić wyższość lub niższość jakiegokolwiek z prezentowanych rozwiązań w stosunku do pozostałych. Wynik porównania zależy w dużej mierze od przyjętych kryteriów. W [90] podjęto próbę porównania m.in. MRAS1 z MRAS-moment. Sformułowano odpowiednie kryteria porównawcze i przy ich



Rysunek 2.10. Przykładowe przebiegi symulacyjne odtwarzania prędkości kątowej wirnika przy wykorzystaniu układu MRAS1

użyciu stwierdzono nieznaczną przewagę rozwiązania MRAS-moment. Zauważono również, że w celu wiarygodnego oceniania rosnącej liczby dostępnych rozwiązań, należało stworzyć jednolite wymagające kryteria porównawcze. Z kolei w [91] wykorzystano łącznie oba wspomniane rozwiązania do budowy estymatora, w którym modelem odniesienia jest obserwator pełnego rzędu ze sprzężeniem od błędu prądu przetwarzanym przez człon PI. Modelem adaptacyjnym jest model prądowy (2.78). Strojenie prędkości, występującej zarówno w macierzach stanu obserwatora i modelu adaptacyjnego, odbywa się zgodnie z regułą (2.79). Poglądowy schemat tego układu przedstawiono na rysunku 2.11.

Dalsze badania nad układami o tej topologii zaowocowały kolejnymi rozwiązaniami różniącymi się zmiennymi wyjściowymi podlegającymi porównywaniu. W artykule [92] zaproponowano dwa nowe estymatory (oznaczmy je MRAS2 i MRAS3), wykorzystujące indukowaną siłę elektromotoryczną. Sygnały błędu służące do dostrajania prędkości to odpowiednio

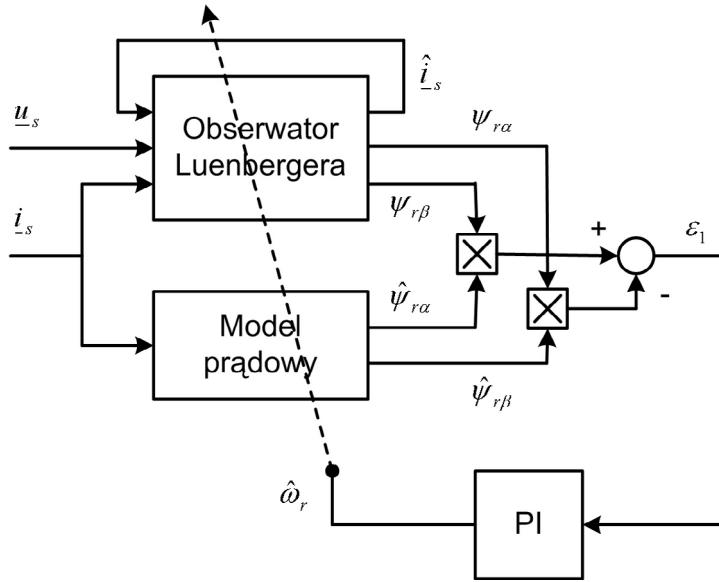
$$\varepsilon_2 = \Im(\underline{e}_m \dot{\underline{e}}_m^*) \quad (2.81)$$

oraz

$$\varepsilon_3 = \Im(\Delta \underline{e}_m \dot{i}_s^*) = \Im((\underline{e}_m - \hat{\underline{e}}_m) \dot{i}_s^*), \quad (2.82)$$

gdzie \underline{e}_m jest indukowaną siłą elektromotoryczną określoną w modelu odniesienia zależnością

$$\underline{e}_m = \underline{u}_s - \left(R_s \dot{i}_s + \sigma L_s \frac{di_s}{dt} \right). \quad (2.83)$$



Rysunek 2.11. MRAS z obserwatorem pełnego rzędu jako modelem odniesienia

Zaletą MRAS2 i MRAS3 jest brak problemu całkowania. Dodatkowo MRAS3 jest odporny na zmiany rezystancji stojana i wirnika [92]. Przechodząc do implementacji należy szczególnie uwagę zwrócić na realizację różniczkowania po czasie prądu stojana. Należy bowiem pamiętać, że różniczkowanie sygnałów mierzonych w napędzie z falownikiem napięcia nie jest rzeczą prostą. Szczególnie, w (2.83) pochodna prądu występuje ze stosunkowo małym wzmacnieniem i nie jest bezpośrednio wykorzystywana do określenia sygnału dostrajającego (w przeciwnieństwie do omówionego w dalszej części algorytmu MRAS4). W 2000 roku MRAS2 z powodzeniem wykorzystano w napędzie śródmiejskiego elektrycznego autobusu (100kW) [93]. Kolejny z opracowanych algorytmów (MRAS4) jest odporny na zmiany indukcyjności rozproszenia σL_s [94]. Użyto w nim sygnału błędu

$$\varepsilon_4 = \Im \left(\Delta e_m \frac{di_s^*}{dt} \right). \quad (2.84)$$

Obecność pochodnej prądu stojana w sygnale dostrajającym jest poważnym ograniczeniem, jeżeli weźmiemy pod uwagę implementację w układzie napędowym z falownikiem napięcia. Przystępny opis algorytmów MRAS1-MRAS4, bez dowodów stabilności, można znaleźć w [18]. Jedno z najnowszych rozwiązań (2001) bazuje na pomiarze mocy biernej [95]. Uchyb strojący określony jest wzorem

$$\varepsilon_5 = Q - \hat{Q}, \quad (2.85)$$

w którym $Q = \Im(\underline{u}_s \underline{i}_s^*)$ jest wyjściem modelu odniesienia określonym jednoznacznie na podstawie chwilowych wartości prądów i napięć. Tak więc budowa modelu odniesienia nie wymaga znajomości żadnych parametrów silnika ani też modelowania jakiejkolwiek dynamiki. Oczywiście wyznaczenie \hat{Q} wiąże się ze znajomością wybranych parametrów obiektu

i modelowaniem dynamiki układu. Rozwiążanie to, jak zauważają sami jego autorzy, jest pokrewne algorytmowi MRAS3. Podstawiając (2.82) do (2.83) otrzymujemy

$$\begin{aligned}
 \varepsilon_3 &= \Im(\underline{e}_m i_s^*) - \Im(\hat{\underline{e}}_m \underline{i}_s^*) = \\
 &= \Im\left(\left(\underline{u}_s - \left(R_s \dot{i}_s + \sigma L_s \frac{d\underline{i}_s}{dt}\right)\right) i_s^*\right) - \Im(\hat{\underline{e}}_m \underline{i}_s^*) = \\
 &= \Im\left(\left(\underline{u}_s - \sigma L_s \frac{d\underline{i}_s}{dt}\right) i_s^*\right) - \Im(\hat{\underline{e}}_m \underline{i}_s^*) = \\
 &= \Im(\underline{u}_s i_s^*) - \sigma L_s \Im\left(\frac{d\underline{i}_s}{dt} i_s^*\right) - \Im(\hat{\underline{e}}_m \underline{i}_s^*) = \\
 &= Q - \sigma L_s \Im\left(\frac{d\underline{i}_s}{dt} i_s^*\right) - \Im(\hat{\underline{e}}_m \underline{i}_s^*), \tag{2.86}
 \end{aligned}$$

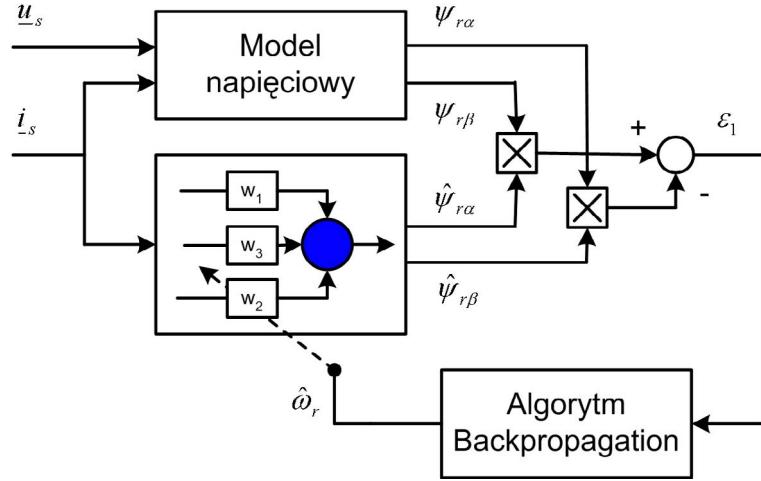
co wyraźnie wskazuje na podobieństwa między tymi układami.

Omówione pięć rozwiązań nie obejmuje oczywiście wszystkich dostępnych w literaturze propozycji (patrz np. [96, 84]), niemniej jednak stanowią one reprezentatywną grupę rozwiązań typu MRAS. W obrębie każdego z omówionych schematów istnieje szereg rozwiązań alternatywnych. Szczególnie często modyfikowanym algorytmem jest MRAS1. Przykładowo, w [97] modelem odniesienia jest obserwator zredukowanego rzędu. Z kolei w [98] przytaczana jest reguła odtwarzania błędu między prędkością estymowaną i rzeczywistą, zamiast samej prędkości. Algorytm adaptacji w MRAS1 doczekał się również realizacji neuronowych z siecią uczoną on-line. Rozwiązania te zostaną bardziej szczegółowo omówione w następnym paragrafie.

Duża przejrzystość i istnienie analitycznych warunków stabilności układów MRAS czyni z tych algorytmów wygodne narzędzie do analizy wybranych schematów regulacji. Niektórzy autorzy dążą do przedstawienia układów, które pierwotnie nie były projektowane jako układy z modelem odniesienia, w tej właśnie postaci, w celu analitycznego wyprowadzenia wartości wybranych parametrów układu estymacji i sterowania [99].

2.8. Estymatory neuronowe

Estymatory zawierające struktury neuronowe można podzielić na dwie podstawowe grupy. Pierwszą z nich tworzą struktury ze sztuczną siecią neuronową uczoną on-line, tj. wagi tej sieci aktualizowane są w czasie rzeczywistym, w każdym kroku obliczeniowym algorytmu obserwatora. Do drugiej grupy należy zaliczyć rozwiązania z siecią neuronową trenowaną off-line, której wagi nie są modyfikowane w czasie rzeczywistym, tzn. nauczoną raz przed rozpoczęciem właściwego procesu odtwarzania. Grupę pierwszą otwiera propozycja L. Ben-Brahima i R. Kurosawy [7, 100] z roku 1993. Jest to estymator o strukturze MRAS1, przy czym regułę adaptacji wyprowadzono w oparciu o algorytm wstępnej propagacji błędu [101], wykorzystywany w uczeniu SSN. Zauważmy, że model prądowy (2.78) po



Rysunek 2.12. Schemat układu zaprojektowanego przez L. Ben-Brahima i R. Kurosawę

zdyskretyzowaniu z krokiem h przybiera postać

$$\begin{cases} \hat{\psi}_{r\alpha}(k) = h \frac{L_m}{\tau_r} i_{s\alpha}(k-1) - h \hat{\omega}_r(k-1) \hat{\psi}_{r\beta}(k-1) + \left(1 - \frac{h}{\tau_r}\right) \hat{\psi}_{r\alpha}(k-1) \\ \hat{\psi}_{r\beta}(k) = h \frac{L_m}{\tau_r} i_{s\beta}(k-1) + h \hat{\omega}_r(k-1) \hat{\psi}_{r\alpha}(k-1) + \left(1 - \frac{1}{\tau_r}\right) \hat{\psi}_{r\beta}(k-1) \end{cases}. \quad (2.87)$$

Wykorzystując zapis w dziedzinie zespolonej, otrzymujemy

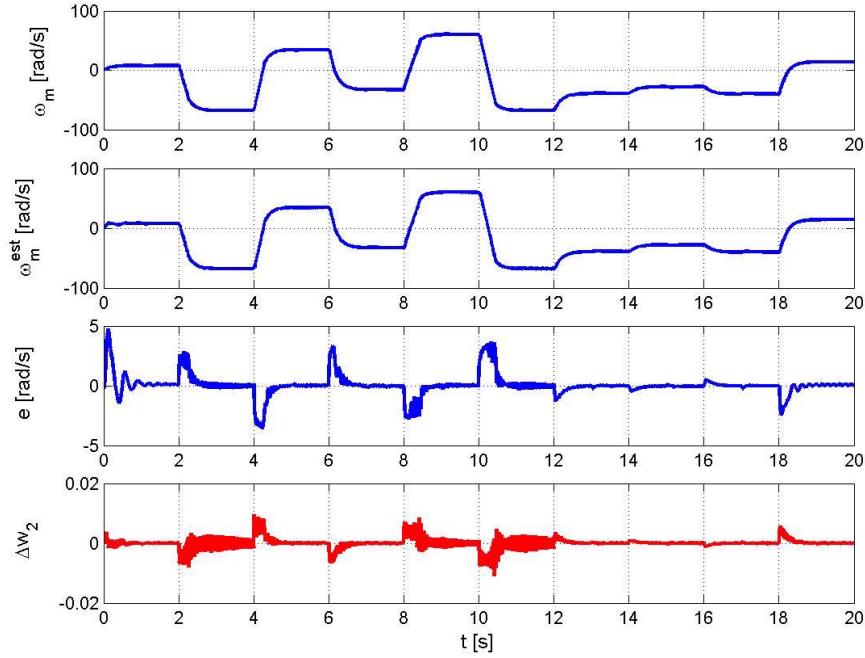
$$\hat{\psi}_r(k) = w_1 \hat{\psi}_r(k-1) + j w_2 \hat{\psi}_r(k-1) + w_3 i_s(k-1), \quad (2.88)$$

przy czym $w_1 = 1 - \frac{h}{\tau_r}$, $w_2 = h \hat{\omega}_r$ oraz $w_3 = h \frac{L_m}{\tau_r}$. Model odniesienia można teraz zinterpretować jako neuron z liniową funkcją aktywacji (ADALINE, ADAptive LINEar, ADAptive LInear NEuron, ADAptive LINear Element) zdefiniowany w dziedzinie liczb zespolonych. Jest on oczywiście równoważny sieci dwuneuronowej, która realizuje przetwarzanie części rzeczywistej i urojonej sygnałów zgodnie z (2.87). Waga w_2 jest proporcjonalna do szukanej prędkości wirnika. Wykorzystując model odniesienia (2.77) jako nauczyciela i stosując algorytm wstępnej propagacji błędu otrzymujemy regułę adaptacji wagi w_2 , czyli jednocześnie prędkości wirnika, w następującej postaci [7, 100]:

$$\begin{cases} \Delta w_2(k) = (\psi_{r\beta}(k) - \hat{\psi}_{r\beta}(k)) \hat{\psi}_{r\alpha}(k-1) - (\psi_{r\alpha}(k) - \hat{\psi}_{r\alpha}(k)) \hat{\psi}_{r\beta}(k-1) \\ w_2(k) = w_2(k-1) + \eta \Delta w_2(k) + \alpha \Delta w_2(k-1) \end{cases}, \quad (2.89)$$

gdzie η - współczynnik uczenia, α - współczynnik momentum. Schemat tak zaprojektowanego estymatora zamieszczono na rysunku 2.12, a przykładowe wyniki symulacji na rysunku 2.13. Należy przy tym podkreślić, że sieć neuronową z liniową funkcją aktywacji dla każdego neuronu, trudno uważać za typową SSN wraz z jej wszystkimi zaletami, w szczególności odpornością na zakłócenia i zmiany parametrów [102]. Dodatkowo zauważmy, że reguła (2.89), którą po podstawieniu $w_2 = h \hat{\omega}_r$, można zapisać w postaci

$$\begin{cases} \Delta w_2(k) = (\psi_{r\beta}(k) - \hat{\psi}_{r\beta}(k)) \hat{\psi}_{r\alpha}(k-1) - (\psi_{r\alpha}(k) - \hat{\psi}_{r\alpha}(k)) \hat{\psi}_{r\beta}(k-1) \\ \hat{\omega}_r(k) = \hat{\omega}_r(k-1) + \frac{\alpha+\eta}{h} \Delta w_2(k-1) + \frac{\eta}{h} (\Delta w_2(k) - \Delta w_2(k-1)) \end{cases}, \quad (2.90)$$



Rysunek 2.13. Odtwarzanie prędkości kątowej wirnika z wykorzystaniem neuronu ADALINE uczzonego algorytmem wstecznej propagacji błędu

wykazuje wiele analogii do reguły (2.79), która po zdyskretyzowaniu z krokiem h przyjmuje postać

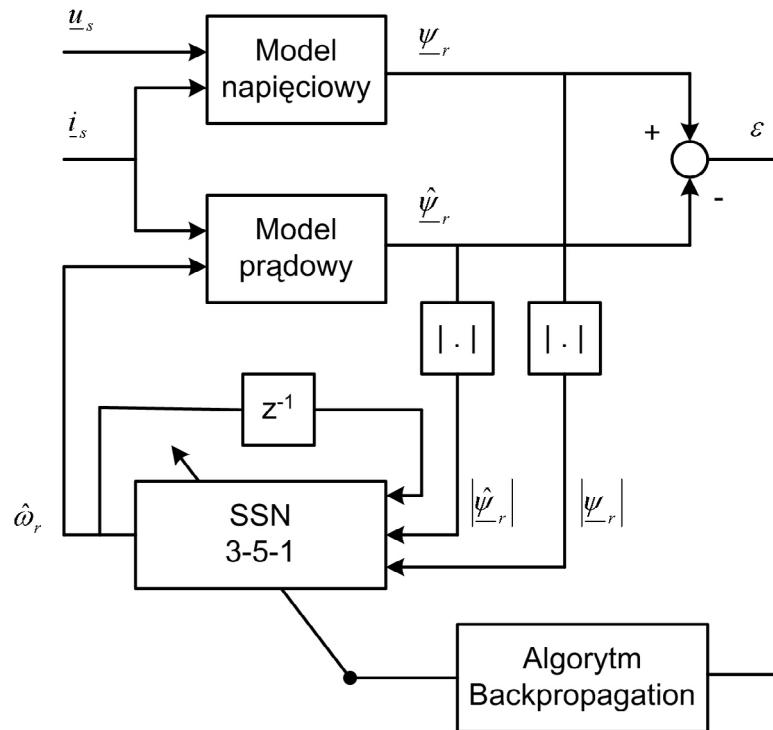
$$\hat{\omega}_r(k) = \hat{\omega}_r(k-1) + K_I h \varepsilon_1(k) + K_P (\varepsilon_1(k) - \varepsilon_1(k-1)). \quad (2.91)$$

Porównanie MRAS1, MRAS2, MRAS3 i MRAS ze wsteczną propagacją błędu znajdziemy np. w [21]. Znaczną poprawę jakości odtwarzania możemy uzyskać zastępując $\hat{\psi}_r(k-1)$ w (2.87) zmienną $\underline{\psi}_r(k-1)$ otrzymywana z modelu odniesienia [8]. Rozwiązaniem wzorowanym na estymatorze L. Ben-Brahima i R. Kurosawy jest propozycja D.L. Sobczuka [103, 8]. Modelem adaptacyjnym jest neuron liniowy z czterema wejściami $\underline{\psi}_r(k-1)$, $j\underline{\psi}_r(k-1)$, $\underline{i}_s(k-1)$, $\underline{u}_s(k-1)$. Wyjściem neuronu jest estymowany prąd stojana $\hat{i}_s(k)$. Funkcję modelu odniesienia pełni automatycznie silnik. Wydaje się, że wybranie odniesienia nie obarczonego błędami modelowania, bo będącego sygnałem mierzonym, implikuje wyraźną przewagę nad poprzednim rozwiązaniem. Autorzy [103] twierdzą jednak, że oba układy dają podobne rezultaty symulacyjne i eksperymentalne. Zmniejszenie wrażliwości estymatora Ben-Brahima na niedokładności określenia parametrów silnika można uzyskać poprzez zastąpienie modelu prądowego strumienia wirnika neuronowym modelem obserwatora zredukowanego rzędu [4].

Wykorzystanie gradientowej metody uczenia związane jest z heurystycznym doborem współczynnika uczenia i współczynnika momentum. Można tego uniknąć posługując się innym algorytmem adaptacji wag neuronu ADALINE. W [104] zaproponowano użycie re-

kurencyjnego algorytmu najmniejszych kwadratów (RLS, Recursive Least-Squares).

Jak już wspomniano, struktura zbudowana z elementów ADALINE w zasadzie nie przeprowadza cech sztucznej inteligencji. Rozbudowując ten element o silnie nieliniową funkcję aktywacji, np. funkcję sigmoidalną unipolarną (zwaną inaczej funkcją logistyczną) lub tangens hiperboliczny (zwany też funkcją sigmoidalną bipolarną), uzyskujemy możliwość tworzenia struktur będących uniwersalnymi aproksymatorami funkcji nieliniowych. Przykładowe rozwiązanie z nieliniowym perceptronem wielowarstwowym uczonym on-line omówiono w [9]. Zaproponowany układ posiada strukturę MRAS1, przy czym do adaptacji prędkości wykorzystano perceptron wielowarstwowy z sigmoidalną warstwą ukrytą uczyony metodą wstępnej propagacji błędu. Wejściami sieci są moduły wektora strumienia wirnika odtwarzanego w napięciowym modelu referencyjnym oraz prądowym modelu adaptacyjnym. Wyjście sieci jest proporcjonalne do estymowanej prędkości. Sieć ma strukturę sekwencyjną sieci Jordana [105], tj. dodatkowo na wejście sieci podawana jest poprzednia wartość wyjścia sieci (odtwarzanej prędkości). Wagi sieci aktualizowane są w czasie rzeczywistym na podstawie błędu odtworzenia wektora strumienia wirnika. Schemat blokowy układu przedstawiono na rysunku 2.14.



Rysunek 2.14. Struktura układu MRAS z nieliniowym neuronowym estymatorem prędkości

Drugą grupę tworzą estymatory, w których prędkość kątowa wirnika odtwarzana jest przy pomocy nieliniowej sieci neuronowej uczonej w trybie off-line. Rozwiązania te ba-

zują na ogólnym przekonaniu, że w łatwo mierzalnych sygnałach jakimi są prądy i napięcia stojana, zawarta jest informacja o prędkości kątowej wirnika. Pozostaje odpowiedź na pytanie, czy ta informacja jest wystarczająca, a jeżeli tak, to w jaki sposób ją wydobyć. Przy założeniu znajomości modelu matematycznego maszyny stosunkowo łatwo jest pokazać podstawnosć tego przekonania. Wystarczająco przekonujące są chociażby omówione wcześniej algorytmy z istniejącymi dowodami ich zbieżności. Pozostaje wciąż otwarta dyskusja, jak skutecznie odtwarzać prędkość bez korzystania z modelu matematycznego i/lub asymetrii magnetycznych silnika. Strony tej dyskusji są zgodne co do tego, że jest to możliwe w zasadzie jedynie z wykorzystaniem elementów sztucznej inteligencji. Proponowane rozwiązania korzystają m.in. z nieliniowych struktur neuronowych. Zaletą obserwatorów neuronowych jest ich zdolność do pracowania z obiektem, którego dokładny opis matematyczny jest skomplikowany lub stosunkowo trudny do zbudowania. W takiej sytuacji znamy wejścia i wyjścia, nie znamy natomiast wiążących ich reguł. Szczególnie często zdarza się to w przypadku obiektów silnie nieliniowych. Wysoce motywująca do badań w tym kierunku jest teoria Kołmogorowa [101], która dowodzi istnienia rozwiązania problemu aproksymacji funkcji wielu zmiennych przez superpozycję wielu funkcji jednej zmiennej. W odniesieniu do sieci neuronowych uzyskujemy dowód uniwersalności struktur neuronowych jako aproksymatorów funkcji nieliniowych, zarówno ciągłych jak i nieciągłych [106].

Prędkość kątową wirnika można aproksymować zależnością

$$\omega_m(k) = f_1(\underline{u}_s(k), M_z(k), \underline{u}_s(k-1), M_z(k-1), \dots), \quad (2.92)$$

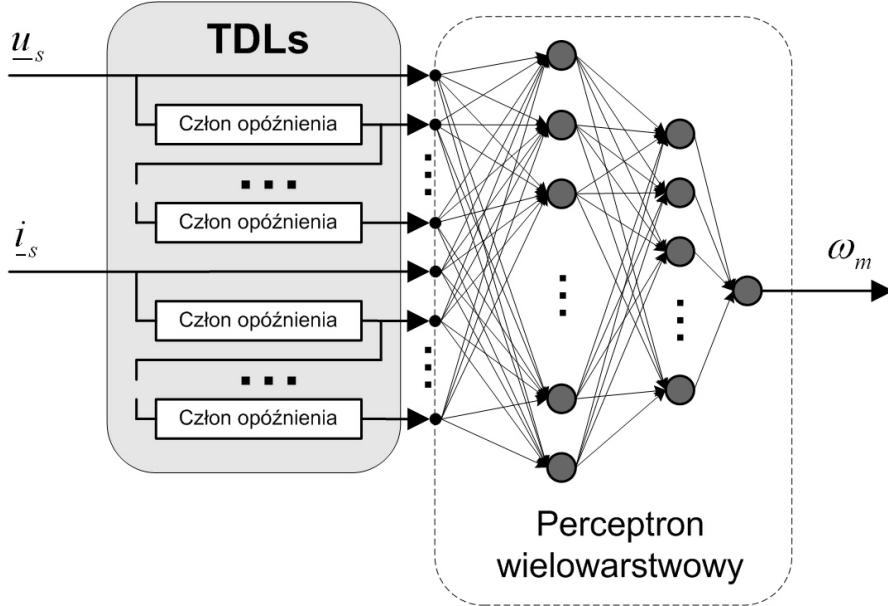
gdzie $f_1(\bullet)$ jest funkcją nieliniową. Opis (2.92) zakłada znajomość warunków początkowych. Funkcję $f_1(\bullet)$ możemy aproksymować przy użyciu sieci neuronowej. Z praktycznego punktu widzenia podejście bazujące na zależności (2.92) wymagałoby wcześniejszego odtwarzania momentu obciążenia. Zakładając, że informacja o momencie obciążenia zawarta jest w prądzie stojana możemy jednak napisać

$$\omega_m(k) = f_2(\underline{u}_s(k), \underline{i}_s(k), \underline{u}_s(k-1), \underline{i}_s(k-1), \dots), \quad (2.93)$$

gdzie $f_2(\bullet)$ jest pewną funkcją nieliniową. Daje to podstawy do odtwarzania prędkości na podstawie chwilowych wartości prądów i napięć stojana. Uwzględniając ograniczenia sprzętowe należy odpowiednio skrócić historię w czasie o sygnałach mierzonych (w rozwiązaniu czysto abstrakcyjnym historia ta sięga chwili włączenia napędu). Otrzymujemy strukturę jak na rysunku 2.15. Aproksymacja dynamiki uzyskiwana jest tutaj poprzez wprowadzenie linii opóźnień (TDLs, Tapped Delay Lines) na sygnałach wejściowych. Przykładowo, w [10] założono

$$\omega_m(k) = f_3(\underline{u}_s(k), \underline{i}_s(k), \underline{u}_s(k-1), \underline{i}_s(k-1)), \quad (2.94)$$

przy czym \underline{u}_s oraz \underline{i}_s wyrażone są w spoczywającym układzie odniesienia. Funkcję $f_3(\bullet)$ aproksymowano przy użyciu sieci jednokierunkowej 8–16–1 uczonej algorytmem wstęp-



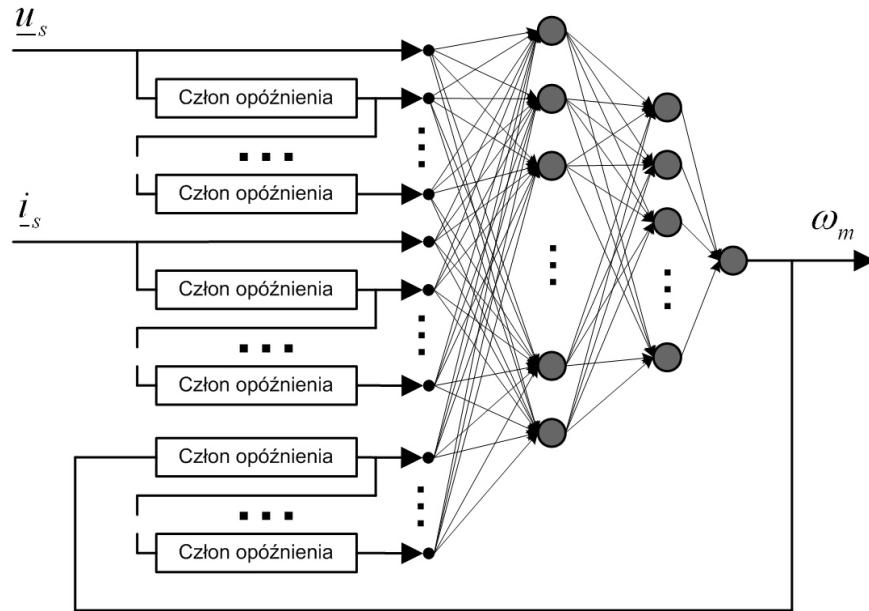
Rysunek 2.15. Przykładowa architektura sieci z liniami opóźnienia na sygnałach wejściowych

nej propagacji błędu. W warstwie ukrytej wykorzystano sigmoidalną funkcję aktywacji. Wyniki przedstawione na stronach 363-365 omawianej publikacji wydają się być bardzo obiecujące. Brakuje wykresów przedstawiających błąd odtwarzania. Niemniej jednak kolejne przebiegi dotyczące analogicznego rozwiązania przedstawione na stronach 444-446 [10] wskazują na duże niedokładności w śledzeniu prędkości zadanej w sytuacji wykorzystania estymaty prędkości jako sygnału sprzężenia zwrotnego w napędzie z polowo zorientowanym układem sterowania. W tym przypadku również nie przedstawiono wykresów błędu odtwarzania. Natomiast przedstawione przebiegi prędkości mierzonej (rysunek 10.43(c), strona 445 w [10]) wskazują na bardzo "niespokojną" pracę napędu. Rozwiązania wykorzystujące opis (2.93) były szeroko testowane przez autora. Podjęto próby rozszerzania historii w czasie i zwiększania liczby neuronów. Uczenie tych sieci przysparzało wielu problemów i przeważnie uzyskiwano niewystarczającą dokładność i odporność na zmiany parametrów silnika. Podejście typu (2.93) dawało stabilne rozwiązania wyłącznie w sferze symulacji nie uwzględniających szumów pomiarowych. W obecności szumów i sprzężeń zwrotnych od estymaty zarówno badania symulacyjne jak i eksperymentalne wskazywały na bardzo ograniczone możliwości zastosowań tego estymatora, a wręcz na jego bezużyteczność.

Rozbudowując strukturę z rysunku 2.15 do struktury przedstawionej na rysunku 2.16 otrzymujemy podstawową sieć z rodziny rekurencyjnych [105]. Sieci takie dedykowane są odtwarzaniu dynamiki układu. Oznacza to zmodyfikowanie równania (2.93) na przykład do postaci

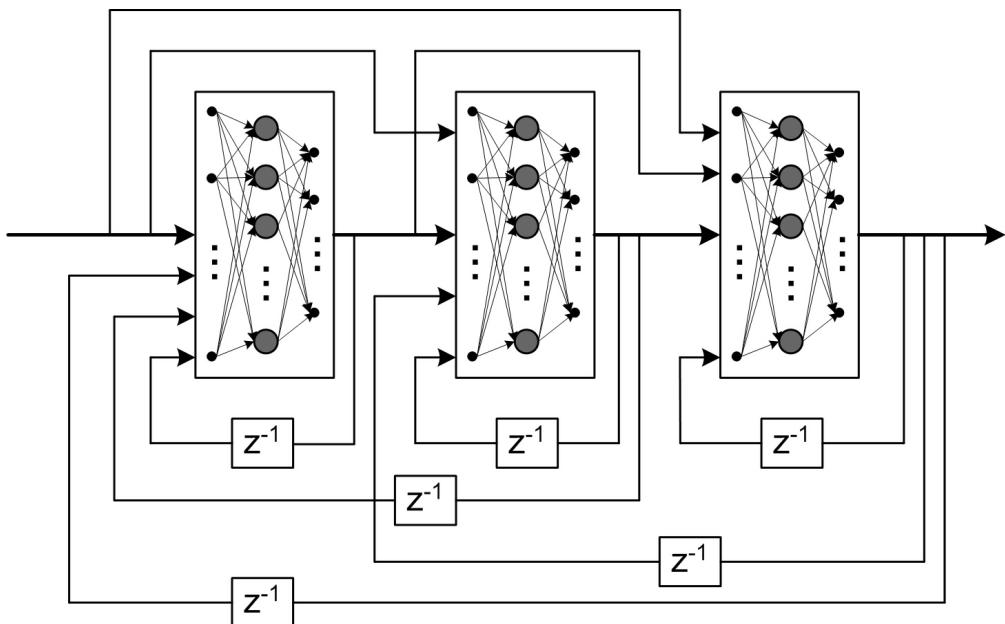
$$\omega_r(k) = f_4(\omega_r(k-1), \omega_r(k-2), \dots, \underline{u}_s(k), \underline{i}_s(k), \underline{u}_s(k-1), \underline{i}_s(k-1), \dots). \quad (2.95)$$

Zauważmy, że równanie (2.95) wykazuje wiele analogii do modelu NARMAX (Nonlinear



Rysunek 2.16. Sieć rekurencyjna odtwarzająca prędkość kątową wirnika

AutoRegressive Moving Average with eXogenous inputs) [107, 108, 109]. W przypadku sieci wielowarstwowych sprzężenia zwrotne mogą się pojawiać również w obrębie pojedynczej warstwy lub kilku kolejnych warstw. Dodatkowo można rozszerzyć połączenia o ka-skady, czyli dodać bezpośrednie podawanie sygnałów wejściowych na kolejne warstwy sieci. Ogólną architekturę takiej sieci przedstawiono na rysunku 2.17. Wyniki badań nad takimi



Rysunek 2.17. Sieć wielowarstwowa ze wszystkimi możliwymi połączeniami rekurencyjnymi i ka-skadowymi

estymatorami prędkości przedstawiono w [11] oraz powtórzono częściowo w [6]. W [11] stwierdzono, że w zasadzie nie jest możliwa dostatecznie dokładna rekonstrukcja prędkości napędu o zmiennej częstotliwości na podstawie chwilowych wartości prądów i napięcia stojana podawanych bezpośrednio na wejścia sztucznej sieci neuronowej o architekturze jak na rysunku 2.17. Zdaniem autora rozprawy, **podstawowych źródeł problemu należy doszukiwać się w dużej rozbieżności pomiędzy spektrum częstotliwości sygnałów wejściowych i spektrum sygnału wyjściowego oraz obecności sprzężeń zwrotnych w strukturze estymatora.** Sieci takie mają tendencję do wzmacniania się i przenoszenia częstotliwości wejściowych na wyjście. W [11] podkreślono, że uzyskanie estymaty obarczonej błędem nie przekraczającym 4% wymagało podania dodatkowych informacji na wejścia sieci. Rozważano sygnał częstotliwości prądu stojana, modułów prądu i napięcia stojana. Przedstawione wyniki dotyczyły odtwarzania prędkości w napędzie ze sterowaniem częstotliwościowym typu $U/f = \text{const}$. Nie przedstawiono niestety wyników dla napędu ze sterowaniem wektorowym wykorzystującym sygnał estymaty neuronowej w pętli regulacji prędkości. Wspólną cechą wszystkich proponowanych rozwiązań były chwilowe wartości prądów jako jedne z wejść sieci. Bardzo inspirujące dla dalszych kierunków badań okazało się, wyżej wspomniane, wprowadzanie dodatkowych przetworzonych sygnałów na wejścia estymatora. Równie pobudzające były wyniki opublikowane w [110] dotyczące odtwarzania prędkości poprzez neuronowy aproksymator funkcji f_5 :

$$\omega_r(k) = f_5(\underline{u}_s(k), \underline{i}_s(k)). \quad (2.96)$$

W rozwiązaniu tym zrezygnowano z wykorzystania linii opóźnień. Mimo braku historii w czasie o obiekcie na wejściach estymatora, uzyskano stabilny napęd bezczujnikowy. Niestety zamieszczone przebiegi prędkości dla układu z czujnikiem i bez wskazują na wyraźne pogorszenie pracy napędu po przełączeniu sprzężenia zwrotnego na estymator (oscylacyjne dochodzenie do wartości zadanej). Ograniczenia występujące przy próbie odtwarzania prędkości na podstawie chwilowych wartości prądu i napięcia stojana, podawanych bezpośrednio na wejścia sztucznej sieci neuronowej, przeanalizowano w [111] oraz [112]. Niedoskonałości proponowanych rozwiązań z zakresu estymatorów neuronowych z tej grupy uzasadniają celowość podjętych badań. W dalszej części rozprawy opisane zostaną autorskie rozwiązania dotyczące estymatorów prędkości kątowej wirnika uczonych w trybie off-line.

2.9. Inne estymatory prędkości kątowej wirnika

Z uwagi na wielką różnorodność proponowanych metod odtwarzania prędkości kątowej wirnika silnika indukcyjnego, omówienie wszystkich opublikowanych rozwiązań jest w zasadzie

niemożliwe. Istnieje szereg rozwiązań nie dających się jednoznacznie zaklasyfikować do jednej z wyżej wymienionych grup. Przykładowo, w [113] wykorzystano schematy MRAS1-MRAS4 do określenia czterech różnych struktur sieci rekurencyjnych uczonych w trybie off-line. W [114] opisano estymator neuronowy zbudowany z trzech sieci rekurencyjnych wzorowany na filtrze Kalmana. W strukturze tego estymatora obecna jest SSN dokonująca predykcji prądów stojana, SSN realizująca predykcję prędkości oraz sieć odpowiedzialna za aktualizację estymaty prędkości. Wzorując się na obserwatorze Luenbergera i układach MRAS opracowano szereg obserwatorów prędkości z zamkniętą pętlą sprzężenia zwrotnego (np. [115]). Proponowane są również obserwatory projektowane w oparciu o tzw. model multiskalarne maszyny asynchronicznej [5, 116, 117, 118].

Odtwarzanie zmiennych stanu silnika indukcyjnego jest wciąż otwartym tematem i można pokusić się o stwierdzenie, że średnio co miesiąc opracowywane jest nowe rozwiązanie z tej dziedziny.

Rozdział 3

Odtwarzanie strumienia stojana silnika indukcyjnego

3.1. Problem całkowania siły elektromotorycznej

Precyzyjne odtwarzanie strumienia stojana (lub wirnika) jest niezbędnym elementem układów ze sterowaniem polowo-zorientowanym (Field Oriented Control, FOC) i układów z bezpośrednią kontrolą momentu (Direct Torque Control, DTC). W wielu rozwiązaniach nie rozgranicza się zagadnienia estymacji strumienia stojana od zagadnienia odtwarzania strumienia wirnika. Są one bowiem związane prostą zależnością

$$\begin{cases} \psi_{r\alpha} = \frac{L_r}{L_m} (\psi_{s\alpha} - \sigma L_s i_{s\alpha}) \\ \psi_{r\beta} = \frac{L_r}{L_m} (\psi_{s\beta} - \sigma L_s i_{s\beta}) \end{cases}. \quad (3.1)$$

Odtwarzanie strumienia odbywa się w szeregu rozwiązań równolegle z estymacją prędkości kątowej wirnika (np. omówiony wcześniej filtr Kalmana i obserwator Luenbergera). Ponadto istnieje szereg modeli, na wyjściu których otrzymujemy strumień. Opis niektórych z nich można znaleźć w [18, 119]. Są to estymatory z otwartą pętlą sprzężenia zwrotnego. Opracowano również wiele obserwatorów z zamkniętą pętlą sprzężenia zwrotnego. Ich krótką charakterystykę zamieszczono np. w [120, 119]. Klasyfikację większości rozwiązań wraz z odpowiednią literaturą podano w [121, 122].

W dalszej części pracy, do testowania estymatorów strumienia stojana, wykorzystano napęd wektorowy ze sterowaniem zorientowanym zgodnie z wektorem strumienia stojana. Założono, że wykorzystany estymator strumienia będzie niezależny od dostępności sygnału prędkości i/lub położenia wirnika. Dodatkowo przyjęto znajomość tylko jednego parametru silnika - rezystancji uzwojeń stojana. Przy takich założeniach strumień stojana można

odtworzyć w oparciu o zależności

$$\begin{cases} \psi_{s\alpha} = \psi_{s\alpha}(t_0) + \int_{t_0}^t (u_{s\alpha} - R_s i_{s\alpha}) dt \\ \psi_{s\beta} = \psi_{s\beta}(t_0) + \int_{t_0}^t (u_{s\beta} - R_s i_{s\beta}) dt \end{cases}. \quad (3.2)$$

Wprowadzając oznaczenia składowych indukowanej w uzwojeniach stojana siły elektromotorycznej $v_{emf\alpha} = u_{s\alpha} - R_s i_{s\alpha}$ oraz $v_{emf\beta} = u_{s\beta} - R_s i_{s\beta}$, otrzymujemy

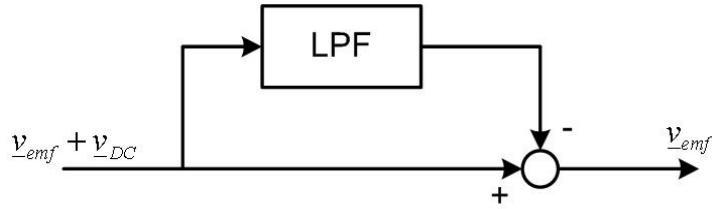
$$\begin{cases} \psi_{s\alpha}(t) = \psi_{s\alpha}(t_0) + \int_{t_0}^t v_{emf\alpha}(t) dt \\ \psi_{s\beta}(t) = \psi_{s\beta}(t_0) + \int_{t_0}^t v_{emf\beta}(t) dt \end{cases}. \quad (3.3)$$

Całkowanie siły elektromotorycznej jest najprostszym sposobem odtworzenia strumienia stojana. Jednocześnie algorytm ten wymaga znajomości tylko jednego parametru maszyny, tj. rezystancji uzwojeń stojana. Niemniej jednak praktyczna realizacja tego schematu wymaga rozwiązania kilku problemów związanych z zastosowaniem operacji całkowania, a należą do nich:

- nieznajomość warunków początkowych,
- możliwość występowania składowej stałej w sygnałach $v_{emf\alpha}$ i $v_{emf\beta}$ na skutek niedoskonałości układów pomiarowych,
- pojawianie się składowej stałej w sygnale estymaty przy skokowych zmianach częstotliwości i/lub amplitudy siły elektromotorycznej,
- obecność szumów pomiarowych związanych m.in. z pracą falownika.

Nierozwiązanie tych problemów prowadzi do występowania, w stanie ustalonej prędkości napędu, składowej stałej w sygnałach estymat składowych strumienia, co jest nieprawdą dla prawidłowo sterowanej symetrycznej maszyny indukcyjnej. Dodatkowo składowa stała wprowadzana przez układy pomiarowe powoduje liniowe narastanie estymaty do nieskończoności. Są to elementarne cechy związane z pamiętająco-sumującym charakterem członu całkującego. Ilustrację tych efektów zamieszczono między innymi w [123] i [124].

Usuwanie składowej stałej z sygnałów pomiarowych można zrealizować z wykorzystaniem filtra dolnoprzepustowego. Przy założeniu stosunkowo małego offsetu i jego stałości lub wolnozmienności w porównaniu z siłą elektromotoryczną stosujemy strukturę jak na rysunku 3.1, w której stałą czasową członu inercyjnego pierwszego rzędu dobieramy na



Rysunek 3.1. Schemat usuwania składowej stałej z sygnałów pomiarowych

odpowiednio wysokim poziomie, tak aby nie pogorszyć pracy układu dla małych prędkości (częstotliwości) [123]. Najprostszy algorytm eliminowania składowej stałej na wyjściu członu całkującego bazuje na wyznaczaniu średniej łańcuchowej [ruchomej] (*ang. moving average*) za okres napięcia, prądu lub strumienia oraz na jej cyklicznym odejmowaniu od wyjścia integratora [123, 125]. Rozwiążanie to posiada dwie bardzo poważne wady. Po pierwsze zerowa wartość średnia za okres jest prawdą tylko i wyłącznie w stanach ustalonych. W stanach przejściowych (dynamicznych) nie można stosować pojęcia okresu, a wartość średnia strumienia, w przedziale między kolejnymi narastającymi [malejącymi] przejściami przez zero lub kolejnymi maksimami [minimami] jednego z trzech wymienionych sygnałów, **nie** jest zerowa. W takiej sytuacji odejmowanie tej średniej jest błędem. Po drugie, cykliczne odejmowanie wyznaczonej wartości średniej objawia się skokowymi zmianami estymaty, co jest sprzeczne z fizycznymi podstawami powstawania strumienia. Badania symulacyjne wykonane przez autora rozprawy wskazują, że zastosowanie takiego algorytmu korekcji może prowadzić nawet do niestabilności układu w sensie utraty kontroli prędkości w stanie dynamicznym. W dalszej części rozdziału omówiono szereg rozwiązań pozwalających na skuteczne odtwarzanie wektora przestrzennego strumienia stojana.

3.2. Filtr dolnoprzepustowy

Zauważmy, że zależność

$$y = \frac{1}{s}x, \quad (3.4)$$

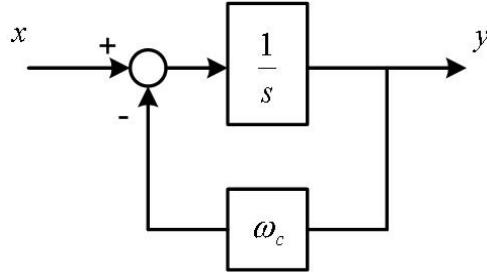
opisującą całkowanie sygnału x , można rozpisać do równoważnej postaci [120]:

$$y = \frac{1}{s + \omega_c}x + \frac{\omega_c}{s + \omega_c}y, \quad (3.5)$$

gdzie ω_c jest pulsacją odcięcia filtra dolnoprzepustowego. Pomijając drugi składnik sumy w (3.5), otrzymujemy przybliżenie członu całkującego członem inercyjnym pierwszego rzędu

$$y = \frac{1}{s + \omega_c}x, \quad (3.6)$$

co jest równoważne wprowadzeniu ujemnego sprzężenia korygującego jak na rysunku 3.2. Zastąpienie członu całkującego (3.4) członem inercyjnym (3.6) rozwiązuje problemy na-



Rysunek 3.2. Cz³on całkujący ze sprzężeniem zapobiegającym nieograniczonemu narastaniu sygnału wyjściowego

rastania sygnału wyjściowego do nieskończoności i utrzymywania się składowej stałej na wyjściu. Zakładamy oczywiście, że offset układów pomiarowych został usunięty (rys. 3.1). Okupione to jednak zosta³o przesunięciem fazowym i zmniejszeniem amplitudy w stosunku do wyjścia integratora, zależnym od częstotliwości sygnału całkowanego. Konsekwencją tego jest nieprawidłowa orientacja układu sterowania, a co za tym idzie pogorszenie pracy napędu.

3.3. Przestrajany filtr dolnoprzepustowy

Opóźnienie i zmiana amplitudy wprowadzana przez (3.6) w stosunku do (3.4) mogą zostać skompensowane zgodnie z zależnością [126]:

$$\frac{\underline{\psi}_s}{v_{emf}} = \frac{1}{s + \omega_c} \frac{\sqrt{\omega_e^2 + \omega_c^2}}{|\omega_e|} \exp(-j\varphi), \quad (3.7)$$

gdzie: ω_e - pulsacja (częstość kątowa) strumienia stojana $\underline{\psi}_s$, $\exp(-j\varphi) = \cos(\varphi) - j \sin(\varphi)$, przy czym

$$\begin{cases} \cos(\varphi) = \frac{|\omega_e|}{\sqrt{\omega_e^2 + \omega_c^2}} \\ \sin(\varphi) = \frac{\omega_c}{\sqrt{\omega_e^2 + \omega_c^2}} \end{cases}. \quad (3.8)$$

Przekształcając (3.7) do postaci dyskretnej wprowadzamy automatycznie błąd modelowania, który z kolei powoduje błąd w odtworzeniu strumienia. Błąd ten jest szczególnie poważny, gdy $\omega_e < \omega_c$. Dlatego też biegum $-\omega_c$ filtra dolnoprzepustowego nie może być stały. W [126] przyjęto, że jest on proporcjonalny do $|\omega_e|$. Stąd

$$\omega_c = \frac{|\omega_e|}{k}, \quad (3.9)$$

gdzie $k = \text{const}$. Podstawiając (3.9) do (3.7) i (3.8) otrzymujemy

$$\frac{\hat{\underline{\psi}}_s}{v_{emf}} = \frac{1}{s + |\omega_e|/k} \sqrt{1 + \frac{1}{k^2}} \exp(-j\varphi) \quad (3.10)$$

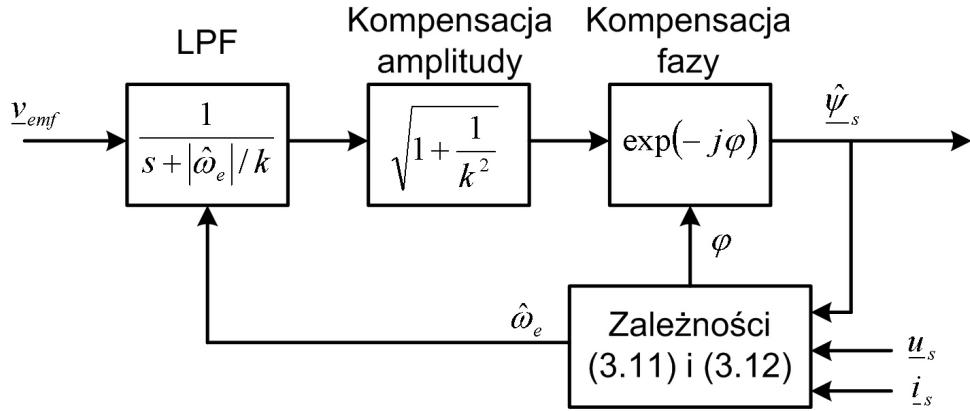
oraz

$$\begin{cases} \cos(\varphi) = \frac{1}{\sqrt{1+1/k^2}} \\ \sin(\varphi) = \frac{\text{sign}(\omega_e)/k}{\sqrt{1+1/k^2}} \end{cases}, \quad (3.11)$$

gdzie $\text{sign}(\bullet)$ oznacza funkcję *signum*. W omawianej pracy dobrano $k = 3$. Dodatkowo wprowadzono dolne ograniczenie na ω_c równe 1 w celu zapobieżenia dążeniu stałej czasowej filtra do nieskończoności dla ω_e dążącej do zera. Pulsację ω_e zastępujemy oczywiście jej estymatą $\hat{\omega}_e$ określona zależnością:

$$\hat{\omega}_e = \frac{v_{emf\beta}\hat{\psi}_{s\alpha} - v_{emf\alpha}\hat{\psi}_{s\beta}}{\left|\hat{\psi}_s\right|^2}. \quad (3.12)$$

Poglądowy schemat opisanego estymatora strumienia stojana przedstawiono na rysunku 3.3 wzorowanym na rysunku 2 z [126] oraz rysunku 3 z [127]. W podobny sposób można

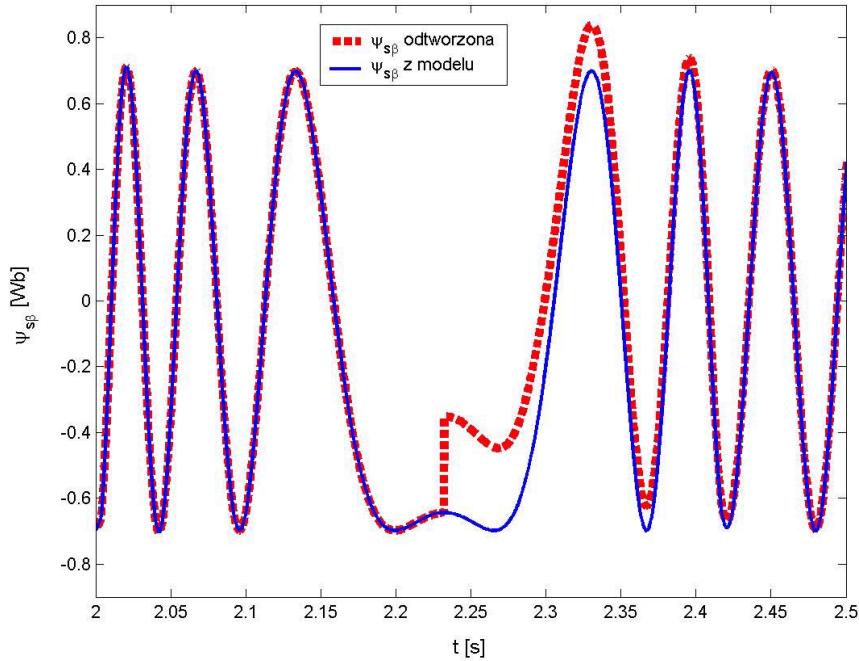


Rysunek 3.3. Przestrajany filtr dolnoprzepustowy z kompensacją fazy i amplitudy

skorygować zmianę fazy i amplitudy związaną z obecnością filtrów analogowych (sprzętowych) [128, 129, 130]. Przeprowadzone badania symulacyjne wykazały nieprawidłowe funkcjonowanie estymatora z rysunku 3.3 w chwili zmiany kierunku wirowania strumienia stojana. Przykładowy przebieg składowej strumienia i jej estymaty podano na rysunku 3.4.

Obserwujemy skokową zmianę odtworzonych składowych strumienia w chwili zmiany kierunku wirowania wektora pola. Prześledziwszy schemat z rysunku 3.3, natychmiast otrzymujemy wyjaśnienie tej nieprawidłowości. Zauważmy, że:

- wyjście członu inercyjnego nie może zmienić się skokowo,
- przy założeniu (3.9), korekcja amplitudy jest stała w czasie,
- korekcja fazy zmienia się skokowo (!!!) wraz ze zmianą znaku pulsacji ω_e .



Rysunek 3.4. Nieprawidłowe działanie PLPF przy zmianie kierunku wirowania wektora strumienia

Odpowiednia modyfikacja omawianego estymatora pozwala na wyeliminowanie stwierdzonej nieprawidłowości. Wystarczy w (3.10) zamienić kolejność operacji filtrowania dolnoprzepustowego i korekcji fazy, tj. zamiast

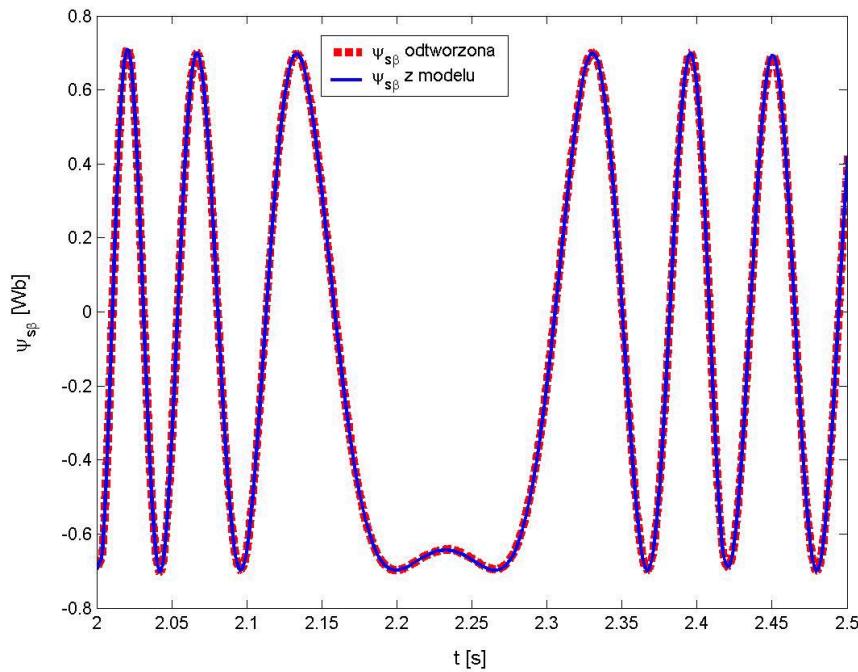
$$\hat{\psi}_s = \left(\frac{1}{s + |\omega_e| / k} v_{emf} \right) \sqrt{1 + \frac{1}{k^2}} \exp(-j\varphi) \quad (3.13)$$

należy zastosować

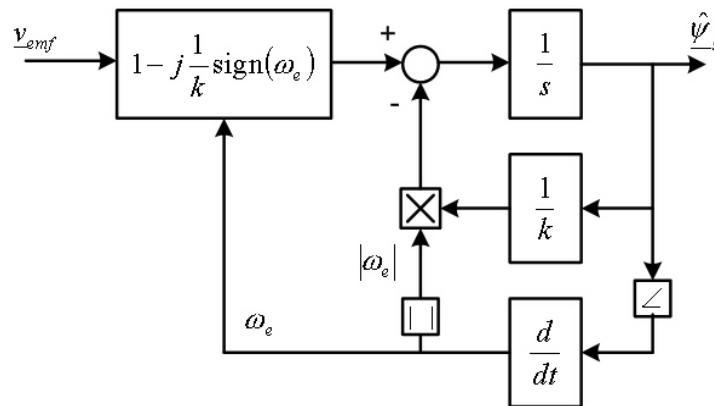
$$\hat{\psi}_s = (v_{emf} \exp(-j\varphi)) \sqrt{1 + \frac{1}{k^2}} \frac{1}{s + |\omega_e| / k}. \quad (3.14)$$

Otrzymujemy w ten sposób algorytm odtwarzania strumienia stojącego nie dopuszczający skokowych zmian na wyjściu estymatora. Należy przy tym zaznaczyć, że prawe strony wzorów (3.13) i (3.14) nie opisują szeregowego połączenia stacjonarnych układów liniowych, dlatego też kolejność przekształceń jest ważna. Wyniki odtwarzania składowej strumienia z wykorzystaniem zmodyfikowanego algorytmu przedstawiono na rysunku 3.5. Identyczne rozwiązanie zaproponowano w [131] (2001). Schemat blokowy tego estymatora podano na rysunku 3.6. Problem dryftu zostaje więc rozwiązany bez pogorszenia odpowiedzi w stanach ustalonych i z prawidłowym funkcjonowaniem w stanach dynamicznych [131].

Niektórzy autorzy, wychodząc z założenia, że przedstawiona powyżej analiza jest w zasadzie słuszna jedynie w stanach ustalonych dla sygnałów sinusoidalnych, proponują uaktywnianie kompensacji fazy i amplitudy wyłącznie w stanach ustalonych napędu [132, 133].



Rysunek 3.5. Przykładowy wynik odtwarzania strumienia przy użyciu zmodyfikowanego PLPF



Rysunek 3.6. Zmodyfikowany przestrajany filtr dolnoprzepustowy z kompensacją fazy i amplitudy

3.4. Przestrajany kaskadowy filtr dolnoprzepustowy

Dla małych pulsacji strumienia stała czasowa pojedynczego członu inercyjnego realizującego całkowanie powinna być duża. To z kolei powoduje powolne zanikanie składowej stałej. Problem ten można rozwiązać poprzez zastosowanie szeregowego połączenia kilku filtrów dolnoprzepustowych [134]. Otrzymujemy w ten sposób kaskadowy filtr dolnoprzepustowy (CLPF, Cascaded Low-Pass Filter). Przyjmijmy, że łączymy szeregowo trzy człony o trans-

mitancji

$$G_1 = \frac{1}{s\tau + 1}, \quad (3.15)$$

otrzymując filtr

$$G = \frac{1}{(s\tau + 1)^3}. \quad (3.16)$$

W stanie ustalonym dla sygnału sinusoidalnego o pulsacji ω_e filtr (3.16) wprowadza opóźnienie

$$\varphi = 3 \arctan(\tau\omega_e) \quad (3.17)$$

oraz zmniejszenie amplitudy

$$|G| = \frac{1}{\sqrt{[1 + (\tau\omega_e)^2]^3}}. \quad (3.18)$$

Dla uproszczenia przyjmijmy brak filtrów analogowych w torach pomiarowych prądów i napięć stojana. Aby filtr (3.16) realizował całkowanie siły elektromotorycznej, należy przyjąć $\varphi = \frac{\pi}{2}$ oraz wprowadzić kompensację amplitudy

$$K = \frac{1}{\omega_e |G|}. \quad (3.19)$$

Otrzymujemy w ten sposób przestrajany filtr dolnoprzepustowy (PCLPF, Programmable Cascaded Low-Pass Filter), w którym

$$\tau = \frac{1}{\omega_e} \tan \frac{\pi}{6} = \frac{\sqrt{3}}{3} \frac{1}{\omega_e} \quad (3.20)$$

oraz

$$K = \frac{1}{\omega_e} \sqrt{[1 + (\tau\omega_e)^2]^3} = \frac{8\sqrt{3}}{9} \frac{1}{\omega_e}. \quad (3.21)$$

Schemat takiego filtra przedstawiono na rysunku 3.7. Odpowiednio modyfikując (3.20) i (3.21) można dodatkowo skompensować zmianę amplitudy i fazy wprowadzaną przez filtry analogowe [134]. Poważne wątpliwości budzi obecne w (3.20) i (3.21) dzielenie przez pulsację, która przy zmianie kierunku wirowania pola przechodzi przez zero. Niemniej jednak zastępując (3.16) filtrem kaskadowym

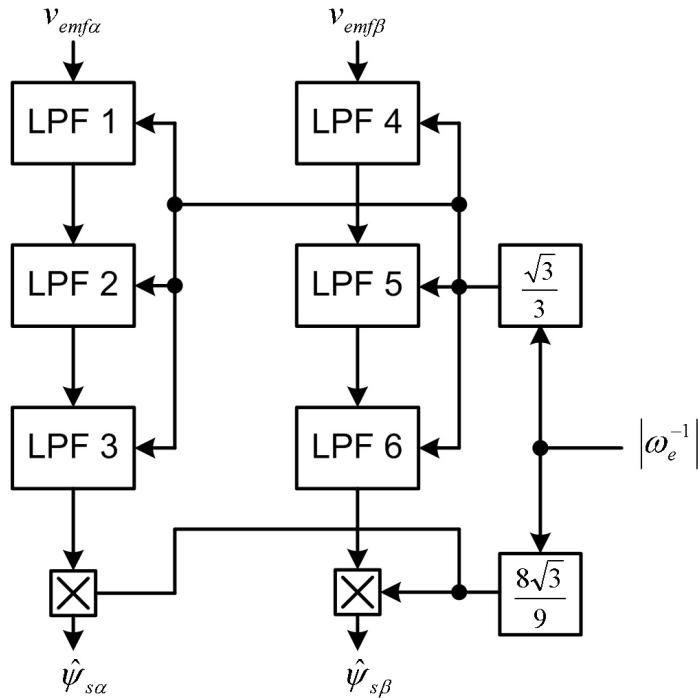
$$G = \frac{1}{(s + \omega_c)^3}, \quad (3.22)$$

wielkości przestrajane przybierają postać

$$\omega_c = \frac{\omega_e}{\tan \frac{\pi}{6}} = \omega_e \sqrt{3} \quad (3.23)$$

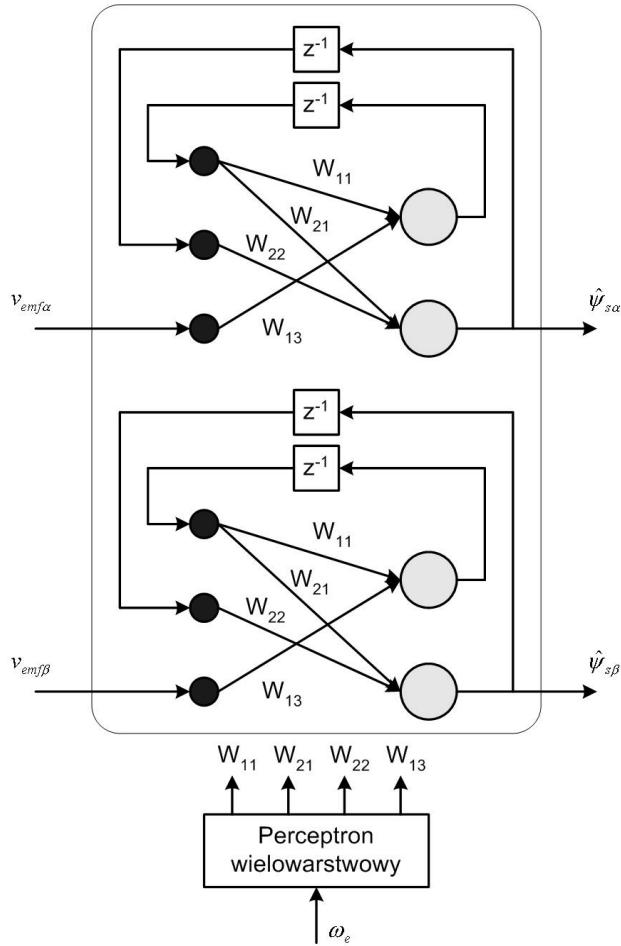
oraz

$$K = \frac{1}{\omega_e} \sqrt{(\omega_c^2 + \omega_e^2)^3} = 8\omega_e^2, \quad (3.24)$$



Rysunek 3.7. Struktura przestrajanego kaskadowego filtru dolnoprzepustowego realizującego operację całkowania

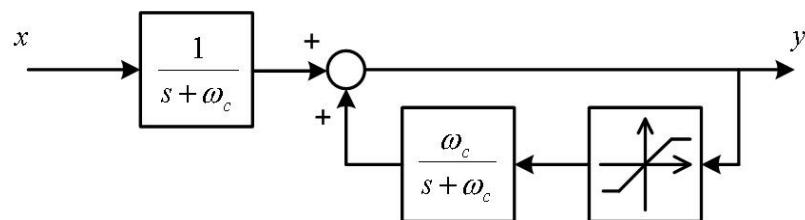
co wyklucza żądania wykonania działań zabronionych. Tak zaprojektowany PCLPF posiada jednak poważne wady. Po pierwsze jest bardzo czuły na niedokładności w określaniu ω_e , która oczywiście jest estymowana w oparciu o zależność (3.12). Po drugie zachowuje się nieprawidłowo przy zmianie kierunku wirowania strumienia - obie składowe estymaty strumienia przyjmują wtedy wartości zerowe (3.24). Dodatkowo odtwarzanie składowych strumienia w stanach dynamicznych jest dużo gorsze niż przy wykorzystaniu PLPF (3.14). Problem nieprawidłowego zerowania się estymat można rozwiązać przenosząc korekcję amplitudy przed kaskadę filtrów. Nie rozwiązuje to jednak dużych uchybów odtwarzania w stanach dynamicznych. Znamienne jest, że w żadnej ze znanych autorowi prac opisujących zastosowanie PCLPF do odtwarzania strumienia stojana i/lub wirnika nie zamieszczono wyników dla nawrotu [134, 135, 136, 12]. Omawiany filtr posiada również realizację neuronową. Dwustopniowy filtr dolnoprzepustowy zaimplementowano przy pomocy sieci rekurencyjnej, przy czym zestaw odpowiednich wag dla tej sieci generuje wielowarstwowa sieć jednokierunkowa, której wejściem jest pulsacja strumienia (rys. 3.8) [136, 12]. Rozwiązanie takie, przy założeniu odpowiednio przeprowadzonego procesu off-line'owego uczenia obu sieci, nie posiada większości wad implementacji klasycznej (nieneuronowej).



Rysunek 3.8. Neuronowa realizacja PCLPF

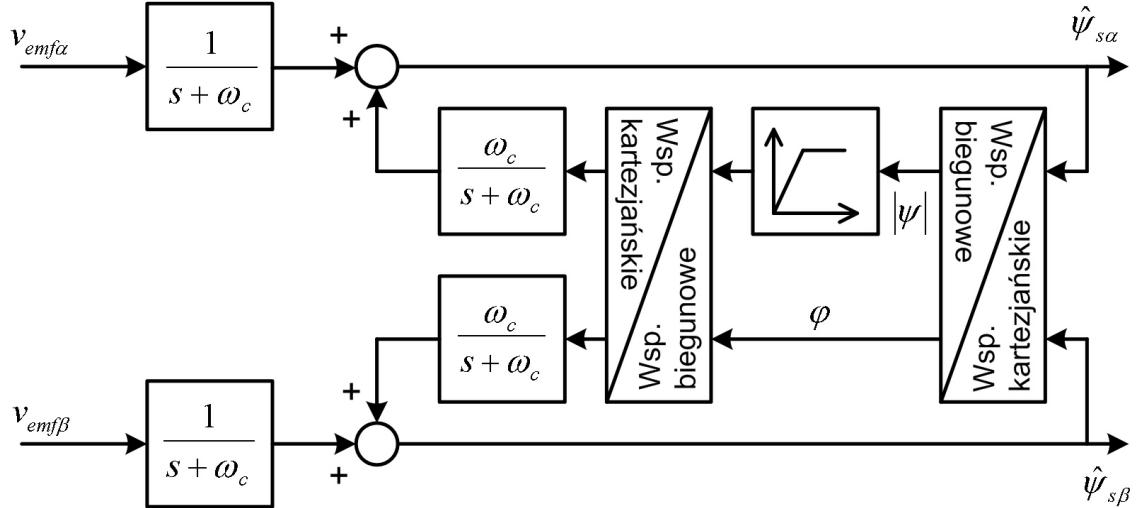
3.5. Ulepszzone schematy całkowania

Opracowano szereg ulepszonych schematów całkowania siły elektromotorycznej, nie wymagających, w odróżnieniu od np. PLPF, estymacji pulsacji strumienia. Bazują one na zależności (3.5). Najprostszy z nich polega na wprowadzeniu nasycenia w torze dodatniego sprzężenia zwrotnego (rys. 3.9) [124]. Algorytm ten jest jednak bardzo czuły na nieprawidłowo określony poziom nasycenia. Dodatkowo odtwarzanie składowych wektora strumienia odbywa się w dwóch niezależnych torach, każdy jak na rysunku 3.9. Algorytm ten nie wykorzystuje więc potencjalnych możliwości korekcji pojawiających się w przypadku jed-

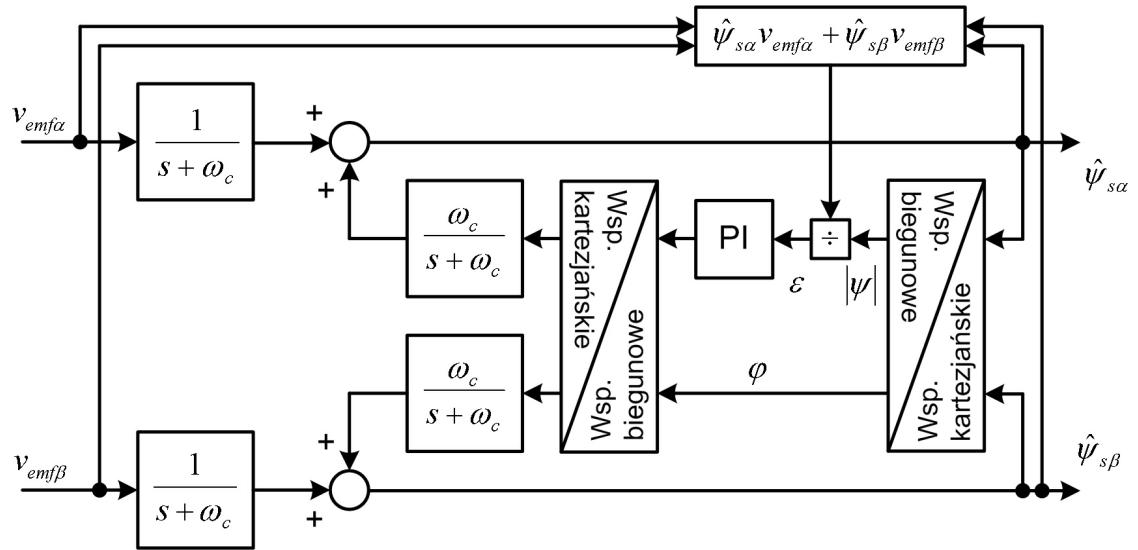


Rysunek 3.9. Integrator z nasyceniem w torze dodatniego sprzężenia zwrotnego

noczesnej analizy obu składowych wektorów przestrzennych siły elektromotorycznej i strumienia. Możliwości te zostały wykorzystane w dwóch kolejnych rozwiązaniach (rys. 3.10 i 3.11) [124].



Rysunek 3.10. Ulepszony schemat całkowania z nasyceniem w torze amplitudy



Rysunek 3.11. Ulepszony schemat całkowania z regulacją PI uchybu ortogonalności siły elektromotorycznej i strumienia

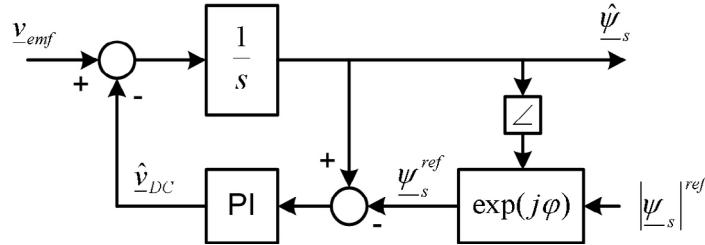
Algorytm z rysunku 3.10 nie zniekształca sygnału sinusoidalnego nawet dla nieprawidłowo określonego poziomu nasycenia. Dodatkowo w [137] opisano układ, w którym nasycenie to jest aktualizowane przy zmieniających się warunkach pracy napędu. Najbardziej

interesujący okazuje się jednak algorytm z rysunku 3.11. Nie zakłada on bowiem znajomości amplitudy odtwarzanego strumienia. Wykorzystuje natomiast ortogonalność wektorów przestrzennych siły elektromotorycznej i odtwarzanego strumienia stojana w stanie ustalonym. W oparciu o iloczyn skalarny zbudowano sygnał błędu będący miarą nieortogonalności tych wektorów

$$\varepsilon = \frac{\underline{v}_{emf} \circ \hat{\underline{\psi}}_s}{|\hat{\underline{\psi}}_s|} = \frac{v_{emf\alpha} \hat{\psi}_{s\alpha} + v_{emf\beta} \hat{\psi}_{s\beta}}{|\hat{\underline{\psi}}_s|} = |\underline{v}_{emf}| \cos \angle (\underline{v}_{emf}, \hat{\underline{\psi}}_s) \quad (3.25)$$

i posłużyono się adaptacją typu PI. Przeciwnicy tego rozwiązania zwracają uwagę na stany dynamiczne, dla których nieprawdą jest, że $\hat{\underline{\psi}}_s \perp \underline{v}_{emf}$. Przeprowadzone przez autora rozprawy badania symulacyjne wskazują na dużą skuteczność tego rozwiązania, a odpowiednio dobrane nastawy regulatora PI amplitudy pozwalają uzyskać pomijalne zniekształcenia w stanach dynamicznych przy jednoczesnym wyeliminowaniu problemów całkowania w stanie ustalonym.

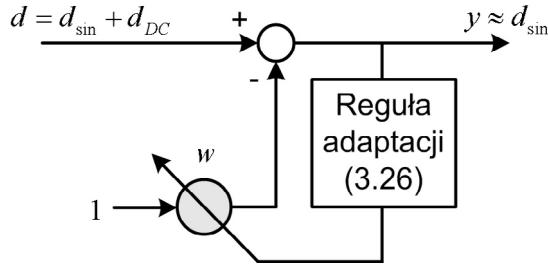
Algorytmem adaptacji PI posłużyono się również w [138]. Wejściem regulatora PI jest różnica między strumieniem zadanym i odtworzonym, przy założeniu tej samej fazy. Sygnał wyjściowy regulatora, będący estymatą wektora offsetu DC, odejmowany jest od wejścia integratora (rys. 3.12).



Rysunek 3.12. Schemat układu całkującego z regulacją PI od uchybu amplitudy

3.6. Adaptacyjna filtracja neuronowa

Na początku 2004 roku opublikowano artykuł [14], w którym do eliminacji składowej stałej wykorzystano neuron ADALINE. Autorzy artykułu przekonują czytelnika o przewadze tego algorytmu nad stosowanymi do tej pory. Niestety bardziej wnikliwa analiza dowodzi, że zaproponowane rozwiązanie jest równoważne zastosowaniu filtru dolnoprzepustowego (3.6). Do wyeliminowania składowej stałej z sygnału siły elektromotorycznej i sygnału estymaty strumienia wykorzystano dwa identyczne filtry o strukturze jak na rysunku 3.13. Do



Rysunek 3.13. Neuronowy adaptacyjny filtr składowej stałej

uczenia neuronu (w trybie on-line) wykorzystano regułę

$$w(k+1) = w(k) + 2\eta [d(k) - w(k)], \quad (3.26)$$

gdzie: η - współczynnik uczenia, d - wejście filtru (sygnał ze składową stałą d_{DC}), w - wyjście neuronu (estymowana składowa stała równa liczbowo wadze neuronu). Wyjście filtru

$$y(k) = d(k) - w(k) \quad (3.27)$$

jest estymatą sygnału $d - d_{DC}$ w sensie najmniejszych kwadratów. Przekształcając (3.26) i uwzględniając (3.27), otrzymujemy

$$\frac{2\eta}{T_s} y(k) = \frac{w(k+1) - w(k)}{T_s}, \quad (3.28)$$

co przy odpowiednich założeniach, jest równoważne w dziedzinie ciągłej operacji całkowania

$$w = \frac{2\eta}{T_s} \frac{1}{s} y, \quad (3.29)$$

gdzie T_s - okres próbkowania. Oznaczając $\omega_c = \frac{2\eta}{T_s}$ i korzystając z (3.27) możemy zapisać

$$y = d - \frac{\omega_c}{s} y, \quad (3.30)$$

co z kolei jest równoważne zależności

$$y = \frac{s}{s + \omega_c} d. \quad (3.31)$$

Dowodzimy w ten sposób, że opracowany w [14] adaptacyjny filtr neuronowy jest **równoważny** dyskretniej realizacji filtru górnoprzepustowego (3.31). Przyjmując, analogicznie jak w omawianym artykule, że wejściem filtru jest wyjście członu całkującego, tj. $d = \frac{1}{s}x$, otrzymujemy

$$y = \frac{s}{s + \omega_c} \frac{1}{s} x = \frac{1}{s + \omega_c} x, \quad (3.32)$$

co oznacza filtrację dolnoprzepustową (3.6). Przeprowadzone badania symulacyjne potwierdziły udowodnioną równoważność wraz z jej wszystkimi konsekwencjami, tj. przesunięciem fazowym i zmianą amplitudy w stanie ustalonym. Podsumowując, opisanego w [14] algorytmu wyznaczania strumienia bazującego na adaptacyjnej filtracji neuronowej nie można uznać za oryginalny. Jest on bowiem równoważny najprostszej filtracji dolnoprzepustowej przy użyciu członu inercyjnego pierwszego rzędu.

3.7. Neuronowe sieci rekurencyjne

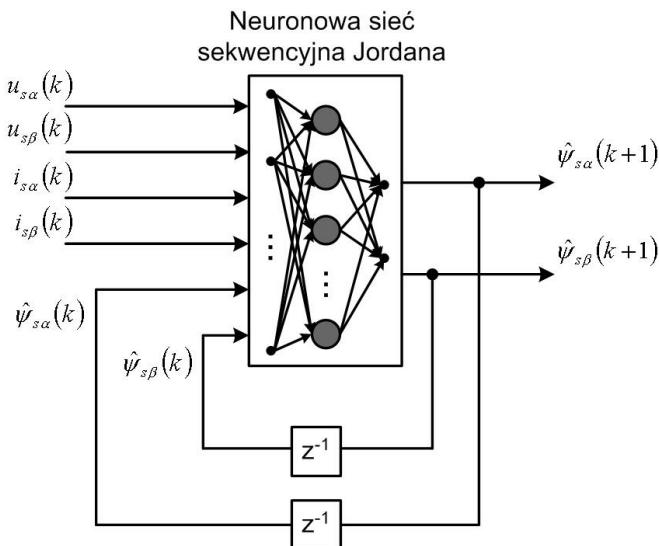
Wadą wszystkich rozwiązań bazujących na całkowaniu siły elektromotorycznej jest ich wrażliwość na zmiany rezystancji uzwojeń stojana. Skuteczność opisanych wyżej metod zależy od jakości zastosowanego algorytmu adaptacji tej rezystancji. Interesującą alternatywą dla tych rozwiązań stanowią estymatory neuronowe, które nie wymagają znajomości rezystancji stojana. Proponowane estymatory neuronowe wektora strumienia stojana i/lub wirnika mają strukturę sieci rekurencyjnej [13, 6, 139]. Zapisując (3.2) w formie dyskretnej, otrzymujemy

$$\begin{cases} \psi_{s\alpha}(k+1) = \psi_{s\alpha}(k) + h(u_{s\alpha}(k) - R_s i_{s\alpha}(k)) \\ \psi_{s\beta}(k+1) = \psi_{s\beta}(k) + h(u_{s\beta}(k) - R_s i_{s\beta}(k)) \end{cases}, \quad (3.33)$$

gdzie h jest okresem próbkowania. Przy założeniu, że rezystancja stojana R_s występująca w (3.2) jest zmienna w czasie, a informacja o niej jest zawarta w prądach i napięciach stojana, zadanie to sprowadza się do neuronowego modelowania funkcji nieliniowych f_1 i f_2 , takich że

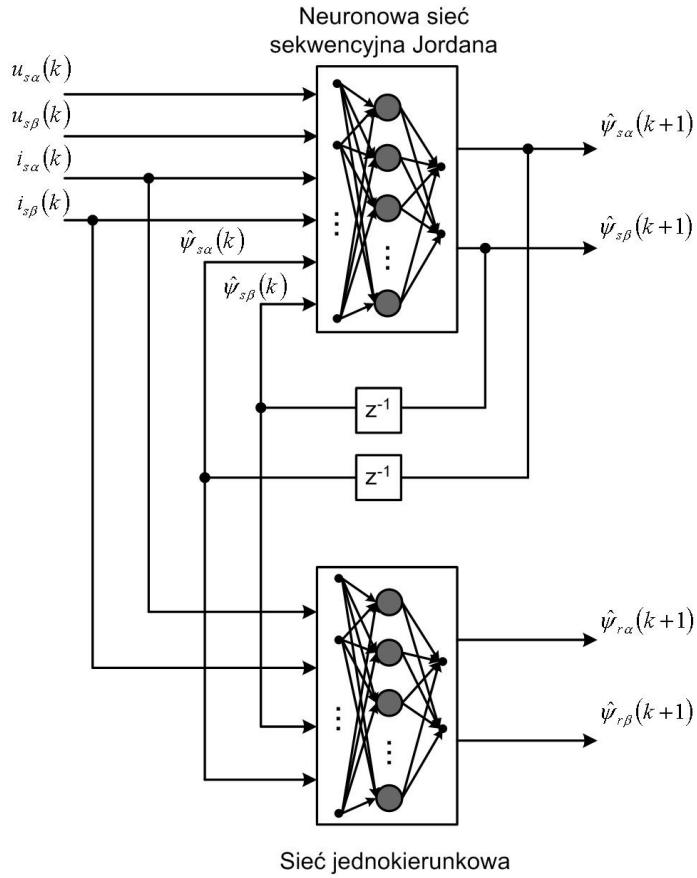
$$\begin{cases} \psi_{s\alpha}(k+1) = f_1(\psi_{s\alpha}(k), u_{s\alpha}(k), i_{s\alpha}(k)) \\ \psi_{s\beta}(k+1) = f_2(\psi_{s\beta}(k), u_{s\beta}(k), i_{s\beta}(k)) \end{cases}. \quad (3.34)$$

Przeprowadzone badania symulacyjne wskazują, że najlepszą generalizację i największą



Rysunek 3.14. Schemat rekurencyjnej sieci odtwarzającej wektor strumienia stojana

odporność na zmiany rezystancji stojana uzyskujemy, gdy obie funkcje f_1 i f_2 modelowane są przez tą samą sieć neuronową. Otrzymana sieć jest rekurencyjną siecią sekwencyjną Jordana. Schemat takiego estymatora przedstawiono na rysunku 3.14. Dołączając kaskadowo sieć neuronową aproksymującą zależność (3.1) otrzymujemy neuronowy estymator strumieni silnika indukcyjnego. Oznacza to rozbudowanie struktury z rysunku 3.14 do



Rysunek 3.15. Schemat kaskadowej sieci neuronowej odtwarzającej wektory strumienia stojana i wirnika

struktury przedstawionej na rysunku 3.15 wzorowanym na rysunku z [13]. Wprowadzając do zbioru uczącego zmiany parametru R_s można uzyskać lepsze wyniki niż w metodach z całkowaniem estymaty siły elektromotorycznej obliczanej przy założeniu braku adaptacji R_s . Wadą rozwiązań wykorzystujących rekurencyjne sieci neuronowe jest brak gwarancji stabilności uzyskanego modelu identyfikacji równoległej (patrz rozdział 4.). Projektując zbiór uczący dla sieci neuronowych z rysunku 3.15, musimy dysponować próbami sygnału strumienia. Przyjmując, że maszyna jest w wykonaniu standardowym i brak w niej czujników strumienia magnetycznego, pozostaje wykorzystanie zbiorów uczących z modeli symulacyjnych lub z estymatorów algorytmicznych uruchomionych w układzie rzeczywistym. W pierwszym przypadku jakość uzyskanego estymatora zależy silnie od dokładności zaproponowanego modelu matematycznego układu napędowego, w drugim zaś - sieć neuronowa modeluje estymator algorytmiczny, a nie rzeczywisty proces kształtuowania strumienia - dyskusyjna staje się wtedy przewaga otrzymanego rozwiązania neuronowego nad algorytmicznym. Może się jednak okazać, że odpowiednia struktura neuronowa jest łatwiejsza w realizacji od estymatora algorytmicznego.

3.8. Podsumowanie

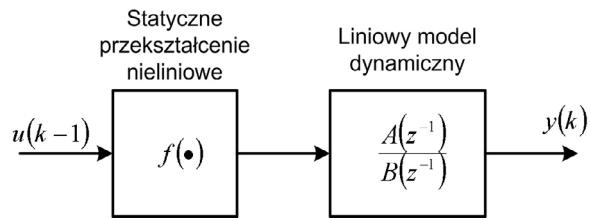
Różnorodność proponowanych rozwiązań z dziedziny odtwarzania strumienia stojana, przy jednoczesnym braku algorytmu “idealnego”, zachęca do dalszych poszukiwań. Szczególnie interesujące okazują się estymatory posiadające w swej strukturze sztuczne sieci neuronowe. W rozwiązaniach tych pojawiają się potencjalne możliwości uodpornienia estymatora na zmiany rezystancji stojana. Możliwe staje się wtedy zrezygnowanie z algorytmów adaptacji tego parametru. Proponowane w literaturze rozwiązania neuronowe zawierają w swej strukturze sieć rekurencyjną. Jednym z celów pracy jest zbadanie możliwości wykorzystania sieci nierekurencyjnych (statycznych) do modelowania pewnych zachowań układów dynamicznych. W rozdziale 6. przedstawione zostaną badania symulacyjne nowego estymatora strumienia bazującego na statycznej sieci neuronowej. Rozwiązanie to pozwoli na wykorzystanie “inteligentnych” zachowań sztucznych sieci neuronowych przy jednoczesnym ominięciu problemów związanych ze stosowaniem sieci rekurencyjnych.

Rozdział 4

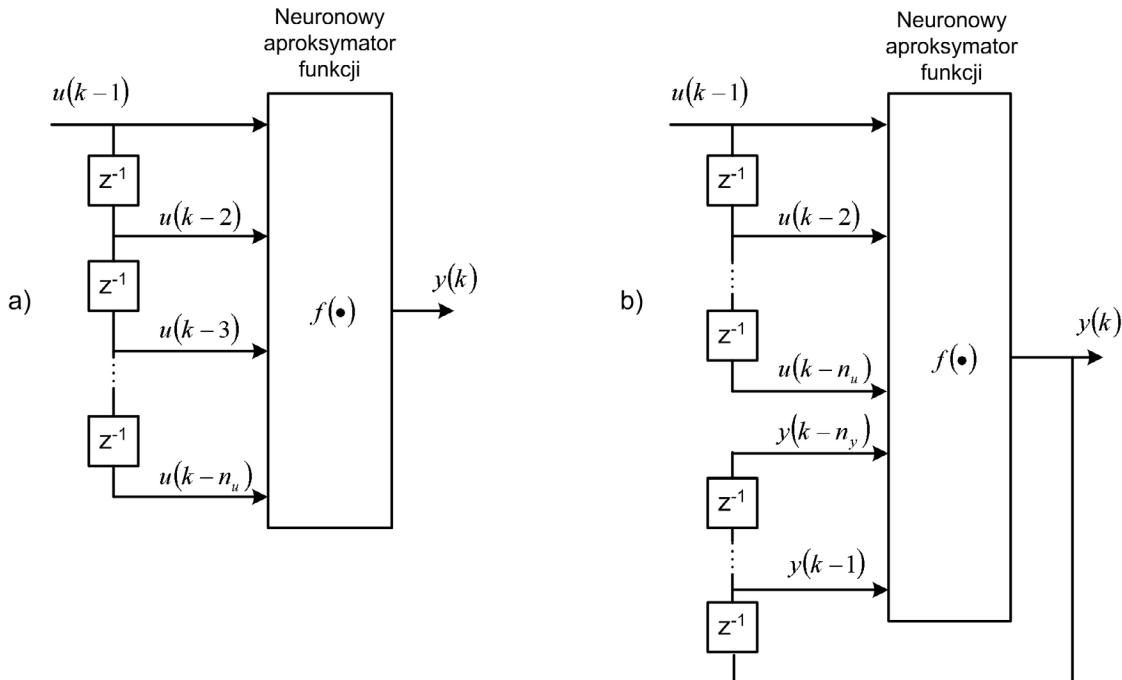
Sieć jednokierunkowa jako estymator prędkości kątowej wirnika silnika indukcyjnego

4.1. Sieci dynamiczne

Nieparametryczna identyfikacja nieliniowych obiektów dynamicznych jest przedmiotem nieustających badań. Podstawowym narzędziem wykorzystywanym do budowy modeli identyfikacji są sztuczne sieci neuronowe pełniące rolę uniwersalnych aproksymatorów funkcji. Wzorując się na modelach dla układów liniowych zaproponowano szereg schematów identyfikacji dla układów nieliniowych. Wśród typowych rozwiązań dla układów liniowych o jednym wejściu i jednym wyjściu (SISO, Single Input Single Output) należy wymienić model obiektu o skończonej odpowiedzi impulsowej (FIR, Finite Impulse Response), model szeregowo-równoległy ARX (AutoRegressive, eXternal input), jego rozszerzenie uwzględniające sygnał szumów ARMAX (AutoRegressive, Moving Average, eXternal input) oraz model równoległy OE (Output Error model), w którym sygnał zakłóceń może być dowolnego typu, tj. może być skorelowany z wejściem obiektu. Opisy tych modeli zamieszczono między innymi w [40]. Z kolei dla obiektów nielinowych opracowano liczną grupę modeli bazujących na szeregowym i/lub równoległym połączeniu bloków statycznych przekształceń nieliniowych i liniowych modeli dynamicznych. Najbardziej popularną strukturę z tej rodziny - model Hammersteina - przedstawiono na rysunku 4.1. Inne rozwiązania z tej rodziny to, na przykład, model Wienera, Ursona, Lura. Zaliczamy je do tzw. modeli Volterra [140]. Typowe rozwiązania neuronowe nie wprowadzają struktury blokowej, tj. modelowanie nieliniowych przekształceń i dynamiki odbywa się w tej samej sieci. Przykładowe neuronowe realizacje dwóch wybranych modeli dla układów nieliniowych przedstawiono na rysunku 4.2. W szczególności rysunek 4.2a przedstawia



Rysunek 4.1. Model Hammersteina nieliniowego obiektu dynamicznego



Rysunek 4.2. Neuronowe realizacje nieliniowych modeli układów dynamicznych: a) model o skończonej odpowiedzi impulsowej FIR oraz b) model typu OE (Output Error)

neuronową realizację modelu FIR, natomiast rysunek 4.2b - nieliniowy model odpowiadający identyfikacji typu OE. Przegląd większości proponowanych rozwiązań można znaleźć w [40, 141, 17]. Wspólną cechą wszystkich rozwiązań z tej rodziny jest modelowanie dynamiki obiektu poprzez rozbudowanie perceptronu wielowarstwowego o linie opóźnień na sygnałach wejściowych (TDNN, Tapped Delay Neural Network, Time-Delayed Neural Network) i/lub sprzężenia zwrotne (RNN, Recurrent Neural Network). W dalszej części pracy sieci te nazywane będą dla uproszczenia sieciami dynamicznymi. Określenie "dynamiczny" może wydać się nieadekwatne, szczególnie w odniesieniu do nierekurencyjnej sieci TDNN. Brak jednoznacznej definicji dynamicznej sieci neuronowej skłonił autora do przyjęcia na potrzeby niniejszej rozprawy prostej klasyfikacji omawianych sieci na dynamiczne i statyczne. Pod pojęciem sieci dynamicznej rozumieć będziemy perceptron wielowarstwowy rozbudowany o opóźnienia na sygnałach wejściowych i/lub sprzężenia rekurencyjne [142]. Jednocześnie należy mieć na uwadze, że wielu autorów zawiera zbiór sieci dynamicznych do struktur będących połączeniem dynamicznych modeli neuronów [2]. Inni rezerwują określe-

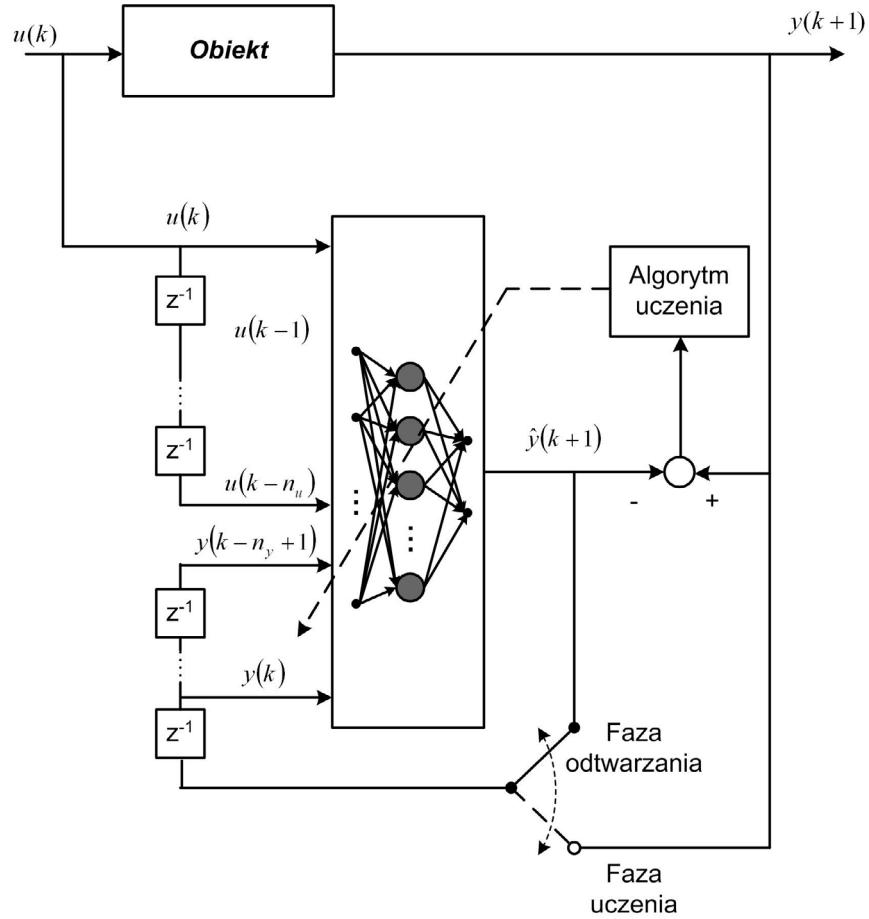
nie “dynamiczny” wyłącznie dla sieci zmieniających, na skutek douczania, swoją strukturę podczas pracy w trybie odtwarzania [143].

Sieci dynamiczne dedykowane są modelowaniu układów dynamicznych i mimo szeregu wad w wielu sytuacjach stanowią jedyne rozwiązanie zagadnienia nieparametrycznej identyfikacji nieliniowych obiektów dynamicznych. Wśród szeregu trudności związanych z użyciem sieci dynamicznych należy wymienić przede wszystkim:

- bardziej złożone podejście do problemu uczenia (np. dynamiczny algorytm wstępnej propagacji, algorytm filtra Kalmana);
- brak gwarancji stabilności uzyskanego modelu identyfikacji równoleglej;
- wymóg równości częstotliwości próbkowania zbioru uczącego i częstotliwości pracy sieci w trybie odtwarzania (dotyczy sieci uczonych off-line).

Problem zbieżności estymat jest szczególnie wyraźny, gdy nauczona w modelu szeregowo-równoległym sieć wykorzystujemy jako estymator sygnału w układzie bezczujnikowym. W trybie odtwarzania przechodzimy wtedy na model równoległy, zastępując mierzone wyjście obiektu wyjściem sieci neuronowej (rys. 4.3). Otrzymana w ten sposób sekwencyjna sieć Jordana często okazuje się być niestabilną. Pod pojęciem niestabilności nie należy rozumieć tutaj rozbiegania się estymaty do nieskończoności. Jest to oczywiście niemożliwe w przypadku sekwencyjnej sieci Jordana o chociaż jednej warstwie z nieliniowymi funkcjami aktywacji o ograniczonym zbiorze wartości, nauczonej w trybie off-line. Zgodnie z definicją stabilności w sensie BIBO (Bounded Input Bounded Output), układem stabilnym jest układ, który dla każdego sygnału wejściowego o ograniczonej amplitudzie, odpowiada ograniczonym sygnałem wyjściowym (w sensie amplitudy). W myśl tej definicji, omawiana sieć z przynajmniej jedną warstwą neuronów o funkcji przenoszenia typu tangens hiperboliczny, czy funkcja sigmoidalna unipolarna, jest zawsze obiektem stabilnym. Na potrzeby niniejszej rozprawy przyjęto nieco inne rozumienie słowa “stabilny” w odniesieniu do sieci rekurencyjnej uczonej w schemacie szeregowo-równoległym. Zaobserwowano, że najczęstszym problemem sieci uczonych zgodnie ze schematem 4.3, w sytuacji gdy $u = [\underline{u}_s, \underline{i}_s]$ i $y = \underline{\psi}_s$ lub $y = \omega_m$, jest oscylacyjne wzburdzanie się sieci w trybie odtwarzania, mimo ustalonego stanu obiektu. Również często obserwowano nasycanie się warstwy nieliniowej i izolowanie się sieci od sygnałów wejściowych, tj. niereagowanie na ich zmiany w sposób wynikający ze zbioru uczącego. Taką sieć nazywać będziemy niestabilną. Źródłem tych problemów można doszukiwać się w charakterze odtwarzanych sygnałów. Zauważmy bowiem, że przybliżając całkowanie metodą prostokątów z niedomiarem, otrzymujemy

$$\underline{\psi}_s(k+1) = T_s(\underline{u}_s(k) - R_s \underline{i}_s(k)) + \underline{\psi}_s(k) \quad (4.1)$$



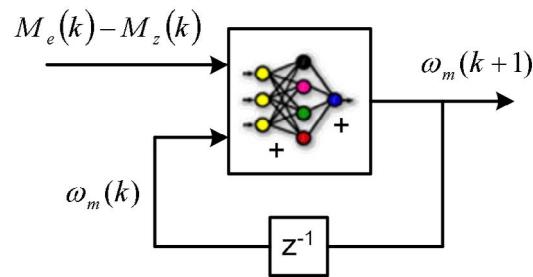
Rysunek 4.3. Ogólna struktura układu identyfikacji obiektu dynamicznego z wykorzystaniem sieci neuronowej

oraz

$$\omega_m(k+1) = \frac{T_s}{J} (M_e - M_z) + \omega_m(k). \quad (4.2)$$

Ze wzorów (4.1) i (4.2) wynika, że istnieje duże prawdopodobieństwo powstania, w procesie uczenia, silnego dodatniego sprzężenia zwrotnego w strukturze rekurencyjnej (rys. 4.4), które może powodować niestabilność neuronowego emulטורza obiektu.

Pytanie, czy możliwe jest modelowanie pewnych zachowań obiektu dynamicznego przy pomocy sieci statycznych, okazało się bardzo twórcze. W efekcie zaprojektowano efektywny



Rysunek 4.4. Neuronowa struktura rekurencyjna wynikająca bezpośrednio z równania (4.2)

estymator prędkości kątowej wirnika silnika indukcyjnego bazujący na sieci statycznej.

4.2. Określenie i podstawowe właściwości sieci statycznych

Pod pojęciem sieci statycznej będziemy rozumieć perceptron wielowarstwowy bez linii opóźnień na sygnałach wejściowych i jakichkolwiek sprzężeń zwrotnych. Dodatkowo zakładamy brak połączeń kaskadowych. Oznacza to, że przepływ sygnałów w sieci jest jednokierunkowy, z warstwy do warstwy, a bezpośrednio na wejścia sieci nie są podawane opóźnione wartości innych wejść. Jest to najprostsza struktura wielowarstwowa, której niewątpliwą zaletą jest prostota algorytmu uczenia (np. algorytm propagacji wstecznej wraz z jego licznymi modyfikacjami, opisany w prawie każdej publikacji poświęconej modelowaniu neuronowemu [40, 101, 4]). Dodatkowo istnieje dowód stosowności tej struktury jako aproksymatora dowolnej funkcji nieliniowej [2, 144]. Oznacza to, że odpowiednio dobierając liczbę warstw i liczbę neuronów w warstwach, możemy uzyskać zbieżność błędu uczenia do dowolnie małej wartości. Oczywistą cechą tej struktury jest jej stosowność wyłącznie do modelowania relacji typu funkcja, tzn.

$$(\forall k \neq l) (u(k) = u(l) \Rightarrow y(k) = y(l)), \quad (4.3)$$

gdzie: u - wejście sieci, y - pożądane wyjście sieci, k, l - numery par uczących. Relację typu funkcja nazywać będziemy często zależnością statyczną. Zauważmy, że warunek (4.3) nie jest spełniony nawet dla najprostszego obiektu dynamicznego SISO, jakim jest człon inercyjny pierwszego rzędu, pobudzonego skokiem jednostkowym. Dlatego też nie jest możliwe odtwarzanie wyjścia tego obiektu na podstawie jego wejścia przy użyciu sieci statycznej. Niemniej jednak dla obiektów bardziej złożonych, o wielu wejściach i wielu wyjściach (MIMO, Multiple Inputs Multiple Outputs), zadanie estymacji może polegać na odtwarzaniu określonego wyjścia układu przy założeniu dostępności wybranych sygnałów wejściowych i **wyjściowych**. Informacja o dynamice obiektu jest wtedy podawana na wejścia sieci w postaci mierzonych wybranych sygnałów wyjściowych obiektu. Niespełnienie warunku (4.3) nie jest wtedy z góry przesadzone. Z sytuacją taką mamy do czynienia między innymi w zagadnieniu odtwarzania prędkości kątowej wirnika silnika indukcyjnego. Na podstawie napięcia stojana (jedno z wejść obiektu) i prądu stojana (jedno z wyjść obiektu) staramy się odtworzyć wybraną wielkość wyjściową (prędkość kątową wirnika). Widzimy zatem, że w formułowanym zadaniu, pojęcia wejście obiektu i wejście jego modelu neuronowego nie są równoważne.

Z praktycznego punktu widzenia, warunek istnienia modelu statycznego (4.3) nie musi

być aż tak ostry. Wystarczy, aby

$$(\forall k \neq l) (u(k) \approx u(l) \Rightarrow y(k) \approx y(l)). \quad (4.4)$$

Warunek (4.4) należy sprecyzować wprowadzając względną dokładność określenia równości dwóch wektorów wejściowych i dwóch odpowiadających im wektorów wyjściowych [145]. Mówimy, że k -ta próbka wejściowa jest nieroróżnialna od l -tej z dokładnością ε , wtedy i tylko wtedy, gdy

$$\begin{cases} \|u(k) - u(l)\| \leq \varepsilon \|u(k)\| \\ \|u(l) - u(k)\| \leq \varepsilon \|u(l)\| \end{cases}. \quad (4.5)$$

Jednocześnie odpowiadające im wektory wyjściowe uznamy za nieroróżnialne z dokładnością δ , wtedy i tylko wtedy, gdy

$$\begin{cases} \|y(k) - y(l)\| \leq \delta \|y(k)\| \\ \|y(l) - y(k)\| \leq \delta \|y(l)\| \end{cases}. \quad (4.6)$$

Relację spełniającą warunki (4.5) i (4.6) nazywamy zależnością (ε, δ) -statyczną [145] i piszymy

$$u \xrightarrow{\varepsilon, \delta} y. \quad (4.7)$$

Każdy problem sprowadzalny do (4.7) można rozwiązać przy użyciu sieci statycznej, która wykona zadanie aproksymowania funkcji $f(\bullet)$ takiej, że

$$y \stackrel{\varepsilon, \delta}{=} f(u). \quad (4.8)$$

Wśród zalet rozwiązań bazujących na sieciach statycznych należy wymienić między innymi:

- brak problemu stabilności modelu;
- możliwość użycia różnych okresów próbkowania przy tworzeniu zbioru uczącego i w trybie odtwarzania;
- brak problemu nieroróżnialności sygnałów wejściowych.

Z kolei rozwiązania wykorzystujące sieci dynamiczne (TDNN, RNN) uczone w trybie off-line wymagają ustalonego okresu próbkowania, a jego zmiana wymaga ponownego przeprowadzenia procesu uczenia. Stosowanie architektury TDNN wymusza odpowiednie ograniczenie z góry częstotliwości próbkowania w celu zachowania rozróżnialności między sygnałem pierwotnym i sygnałem przesuniętym w czasie [111]. Dodatkowo przygotowując zbiór uczący dla sieci statycznej możemy zmieniać częstotliwość próbkowania, co pozwala zmniejszyć rozmiar tego zbioru bez utraty prawidłowej generalizacji. W zasadzie pojęcie częstotliwości próbkowania zbioru uczącego dla opisanych w dalszej części pracy sieci

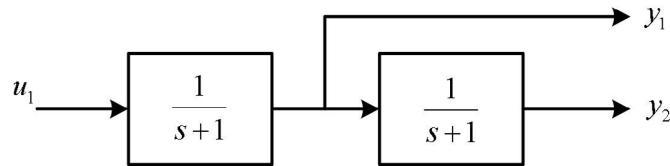
neuronowych jest nieprecyzyjne i powinno zostać zastąpione pojęciem średniej częstotliwości próbkowania. Założmy, że chcemy odtworzyć prędkość kątową wirnika w układzie napędowym, dla którego z zadowalającym przybliżeniem prawdą jest, że $\omega_m = f(\underline{u}_s, \underline{i}_s)$. Dodatkowo przyjmijmy, że odpowiedź układu na skokową zmianę prędkości zadanej z 0 na ω_N przybliżono członem inercyjnym pierwszego rzędu, otrzymując stałą czasową τ . W celu wygenerowania stanów układu w miarę równomiernie pokrywających przestrzeń możliwych stanów napędu, przyjęto losowe skokowe zmiany prędkości zadanej, przy czym generator losowy uruchamiano z okresem ok. 5τ . Tak określona częstotliwość pracy generatora, zapewnia zrównoważony pod względem czasu trwania, udział stanów ustalonych i przejściowych w rejestrówanych przebiegach ω_m , \underline{u}_s oraz \underline{i}_s . Przyjmijmy, że przebiegi te zarejestrowano z okresem próbkowania równym np. $10^{-3}\tau$ na odcinku czasu 1000τ , otrzymując w ten sposób ciąg 10^6 potencjalnych par uczących postaci $((\underline{u}_s, \underline{i}_s), \omega_m)$. Jednocześnie stwierdzono eksperymentalnie, że bazując na zdolnościach do generalizacji, wystarczające jest przyjęcie okresu próbkowania na poziomie $10^{-1}\tau$. Zatem, konstruując zbiór uczący należy w nim zawrzeć co setny wyraz otrzymanego ciągu. O takim zbiorze uczącym można powiedzieć, że został spróbkowany z określona częstotliwością. Możliwe jest jednak postępowanie mniej konwencjonalne - z otrzymanego ciągu wybieramy **losowo** 10^4 par i tworzymy z nich zbiór uczący. W tym przypadku nie można już mówić o konkretnym okresie próbkowania sygnałów uczących - należy rozumować kategoriami średniego okresu próbkowania. Przeprowadzone porównawcze badania symulacyjne wskazują na równoważność obu metod postępowania pod względem dokładności estymat $\hat{\omega}_m$ uzyskanych na zbiorze testującym.

Duża elastyczność rozwiązań opartych o sieć statyczną, przy jednocześnie problemach związanych ze stosowaniem sieci dynamicznych, skłania do poszukiwania zależności statycznych w układach dynamicznych i zastępowania estymatorów TDNN/RNN sieciami statycznymi.

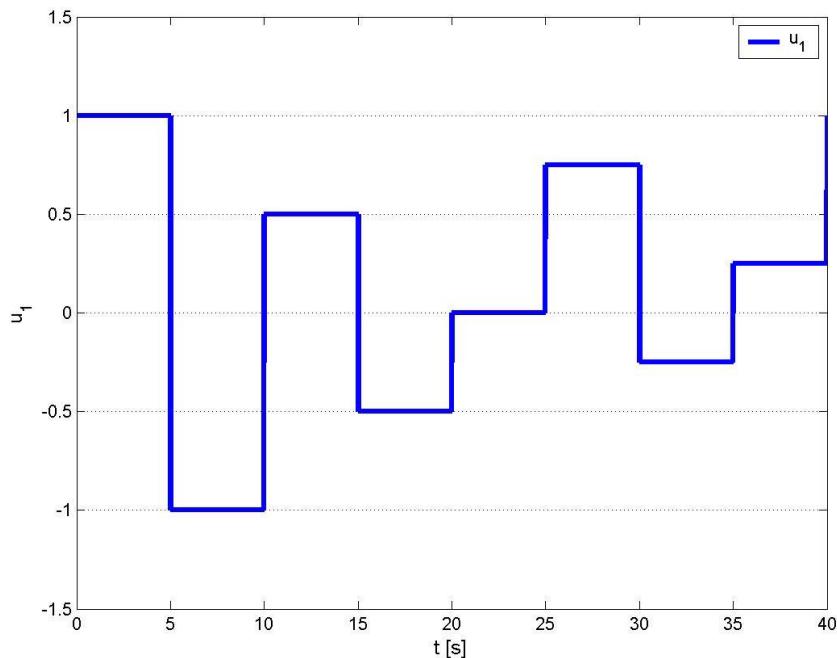
4.3. Rozszerzanie bazy aproksymatora neuronowego

Podstawowe ograniczenie w stosowalności sieci statycznych do odtwarzania sygnałów w układach dynamicznych, wynika z braku odwzorowania zbioru sygnałów wejściowych na wyjściowe w tych układach. Cechą układu dynamicznego jest zależność jego wyjść od historii w czasie sygnałów wymuszających.

Problem 1. Na przykładzie szeregowego połączenia dwóch członów inercyjnych pokażemy, jak wspomnianą “historię w czasie” można w wybranych zagadnieniach przekształcić w “historię w wymiarze”. Założmy, że odtwarzanym wyjściem układu jest y_1 , natomiast sygnały mierzone to wejście u_1 i wyjście y_2 (rys. 4.5). Zadanie polega na odtworzeniu



Rysunek 4.5. Obiekt dynamiczny, na podstawie którego zilustrowano rozszerzanie bazy aproksymatora neuronowego o sygnały wyjściowe układu



Rysunek 4.6. Przebieg wymuszenia wykorzystany w doświadczeniu z obiektem z rysunku (4.5)

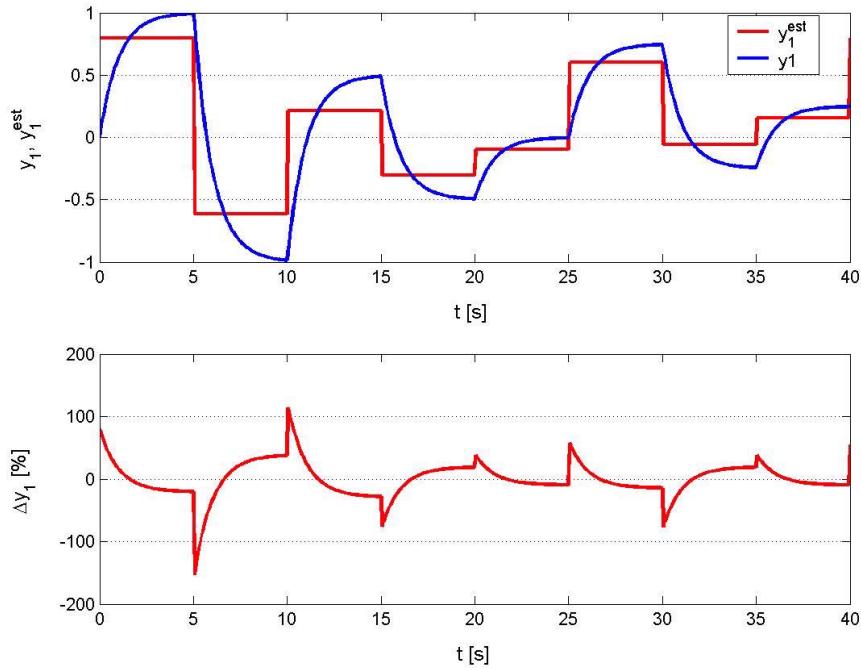
sygnału y_1 z przykładową dokładnością 5%, dla określonego charakteru sygnału pobudzającego u_1 , przy użyciu sieci statycznej.

Rozwiązańe 1. Przyjmując, że sygnał wymuszenia ma przebieg schodkowy jak na rysunku 4.6, niemożliwe jest odtworzenie y_1 na podstawie u_1 . Przykładowe wyniki dla sieci 1-15-5-1 z sigmoidalnymi warstwami ukrytymi przedstawiono na rysunku 4.7. Wystarczy jednak rozszerzyć sygnały wejściowe sieci o y_2 , aby przekształcić zadanie do problemu modelowania funkcji (rys. 4.8).

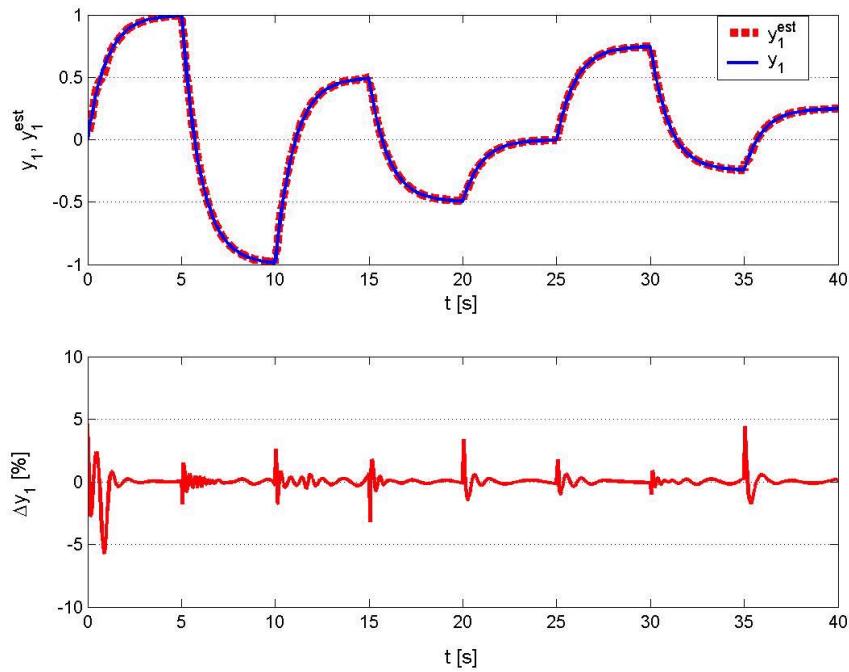
Wniosek 1a. Wykorzystanie wybranych wyjść obiektu jako wejście modelu neuronowego, może przekształcić problem modelowania dynamicznego do zadania modelowania statycznego.

Niestety zmiana charakteru sygnału pobudzającego na sumę schodkowego i sinusoidalnego o zmiennej częstotliwości, czyni zaproponowany zestaw sygnałów wejściowych (u_1, y_2) niewystarczającym (rys. 4.9).

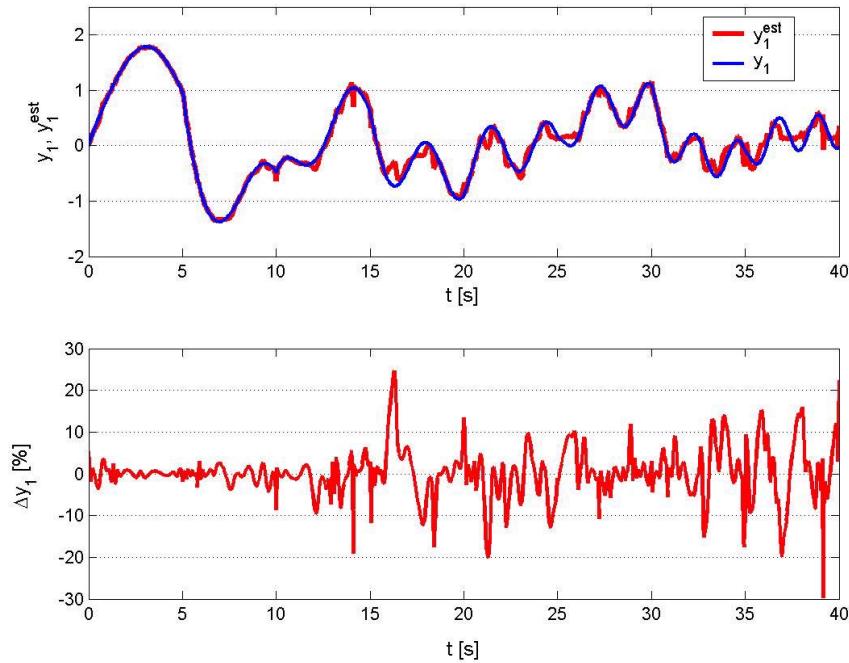
Wniosek 1b. Istnienie zależności statycznych między wejściami i wyjściami



Rysunek 4.7. Nieudana próba odtworzenia wyjścia y_1 obiektu z rysunku 4.5, na podstawie wejścia u_1 , przy użyciu statycznej SSN



Rysunek 4.8. Odtwarzanie wyjścia y_1 obiektu z rysunku 4.5, przy wykorzystaniu statycznej SSN, której wejście stanowi para sygnałów (u_1, y_2)

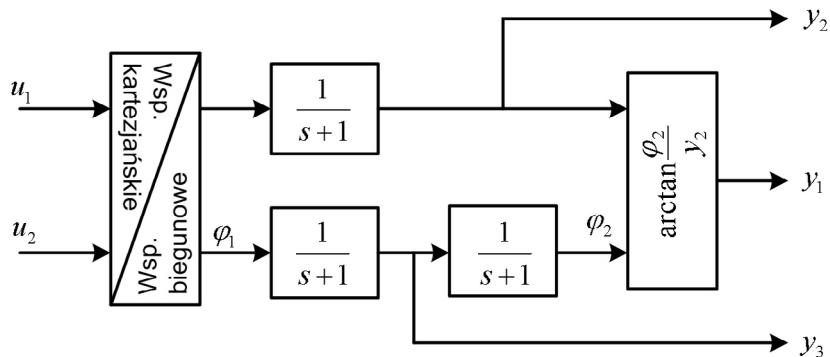


Rysunek 4.9. Nieuudana próba odtworzenia wyjścia y_1 obiektu z rysunku 4.5, przy zmienionym charakterze wymuszenia w stosunku do przedstawionego na rysunku 4.6

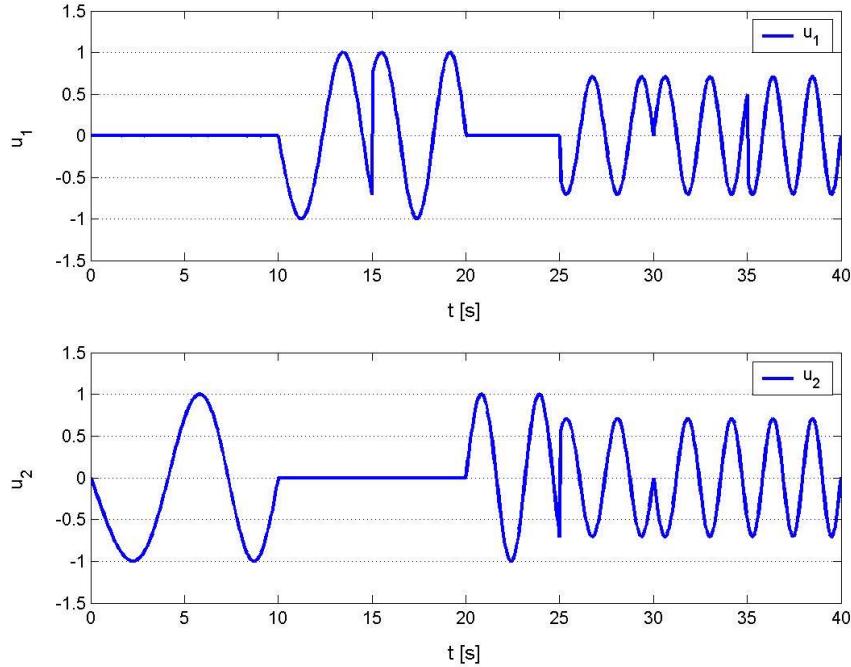
obiektu dynamicznego, może zależeć od przebiegu występujących w układzie pobudzeń.

Problem 2. W układzie przedstawionym na rysunku 4.10 należy odtworzyć sygnał y_1 . Zakładamy łatwą mieralność sygnałów u_1, u_2, y_2, y_3 . Przebiegi wymuszeń podano na rysunku 4.11.

Rozwiążanie 2. Do modelowania układu wykorzystano sieć 4–15–5–1, której wejściem był zestaw sygnałów (u_1, u_2, y_2, y_3) . Błąd uczenia takiej sieci nie spadł jednak poniżej 10^{-2} . Wyniki odtwarzania dla tej sieci przedstawiono na rysunku 4.12. Zwiększenie liczby neuronów w warstwach ukrytych nie spowodowało spadku błędu uczenia. Zastępując sygnały



Rysunek 4.10. Obiekt dynamiczny, na podstawie którego zilustrowano rolę wstępnego przetwarzania nieliniowego



Rysunek 4.11. Przebieg wymuszenia wykorzystany w doświadczeniu z obiektem z rysunku 4.10

u_1 i u_2 sygnałami

$$u_3 = \arg(u_1 + ju_2) \quad (4.9)$$

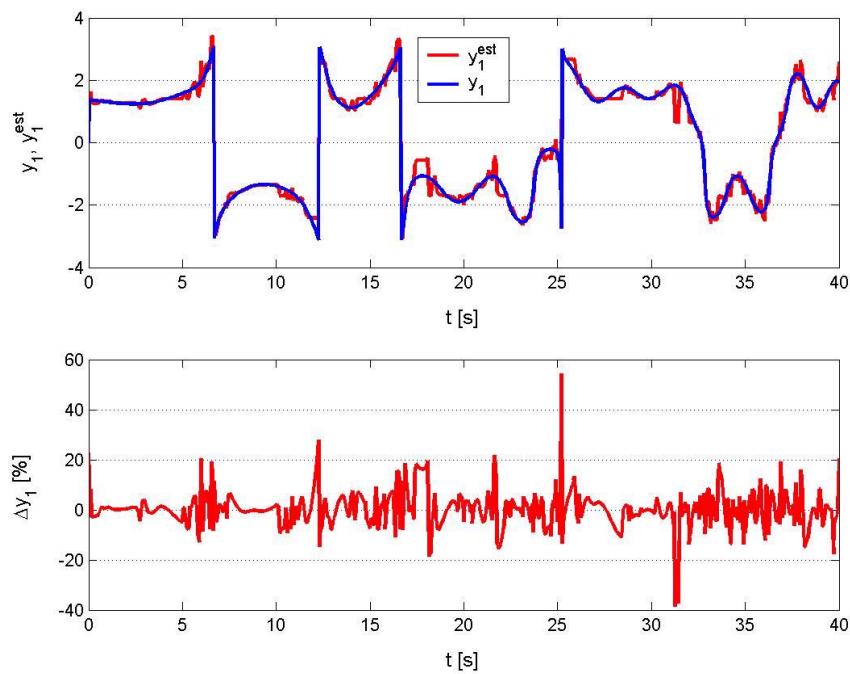
oraz

$$u_4 = |u_1 + ju_2| \quad (4.10)$$

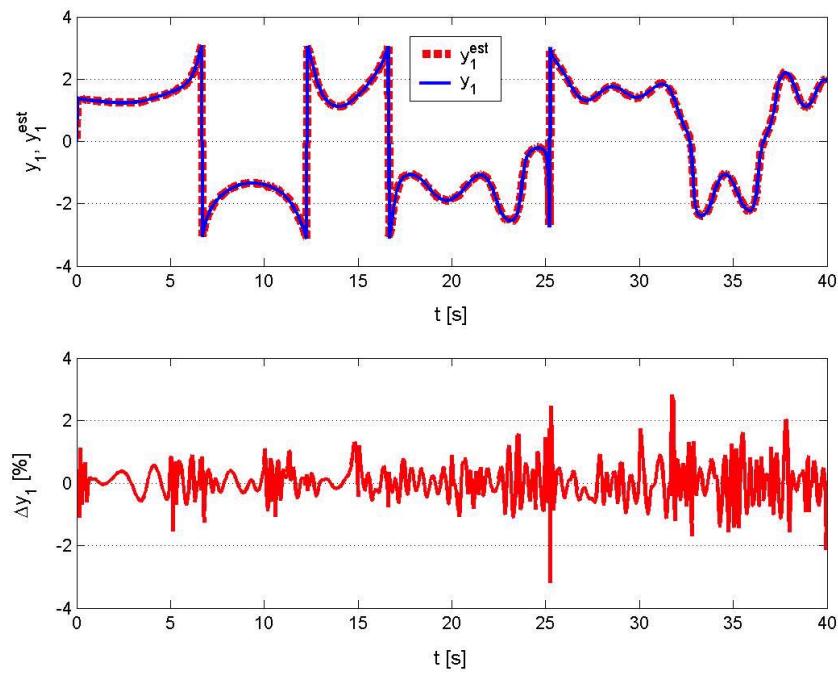
otrzymujemy, przy tej samej złożoności sieci, spadek błędu uczenia poniżej 10^{-3} . Przykładowe wyniki odtwarzania dla sieci o wejściach (u_3, u_4, y_2, y_3) przedstawia rysunek 4.13. Obserwujemy wyraźną poprawę w stosunku do odtwarzania na podstawie sygnałów (u_1, u_2, y_2, y_3) .

Wniosek 2. Budowanie bazy aproksymatora neuronowego w oparciu o sygnały będące nieliniowymi funkcjami sygnałów mierzonych, może zdecydowanie poprawić dokładność uzyskanych estymat. Intuicyjne wytłumaczenie tego efektu jest stosunkowo proste. Odpowiednio dobrane przekształcenia nieliniowe zawierają część wiedzy o obiekcie. W konsekwencji, sieć nie musi modelować opisanych nimi aspektów działania obiektu. Może się również okazać, że obecność konkretnych odwzorowań nieliniowych przekształca zadanie do lepiej uwarunkowanego, wygładzając funkcję przybliżającą relację pomiędzy zbiorem wejściowym i wyjściowym sieci.

Problem 3. Należy odtworzyć sygnał y_1 w układzie z rysunku 4.5 dla wymuszenia będącego sumą sygnału schodkowego i sinusoidalnego o zmiennej częstotliwości. Relacja $((u_1, y_2), y_1)$ w tak postawionym zadaniu nie jest funkcją. Na podstawie wniosku 2. rozszerzamy bazę aproksymatora funkcji o wejścia będące nieliniowymi funkcjami już istniejących wejść. Szereg przeprowadzonych prób nie pozwolił poprawić wyników z rysunku 4.9. Ozna-



Rysunek 4.12. Wyniki odtwarzania wyjścia y_1 obiektu z rysunku 4.10, na podstawie nie przetworzonych sygnałów (u_1, u_2, y_2, y_3) podawanych bezpośrednio na wejścia statycznej SSN



Rysunek 4.13. Wyniki odtwarzania wyjścia y_1 obiektu z rysunku 4.10 na podstawie zbioru sygnałów (u_3, u_4, y_2, y_3), zawierającego sygnały przetworzone zgodnie z zależnościami (4.9) i (4.10)

czy to, że relacja $((u_1, y_2), y_1)$ jest silnie niefunkcyjna i bez wprowadzenia historii w czasie zadanie jest nie do rozwiązania z założoną dokładnością.

Wniosek 3a. **Podawanie dodatkowych sygnałów na wejścia sieci, będących nieliniowymi funkcjami już istniejących wejść, nie transformuje relacji typu niefunkcja w relację typu funkcja.** Z praktycznego punktu widzenia możemy uzyskać jedynie lepsze uwarunkowanie problemu, tj. wygładzenie aproksymowanej hiperpowierzchni. Jednak dla relacji silnie niefunkcyjnej nie uzyskamy akceptowalnych estymat z modelu statycznego.

Rozwiązańe 3. Zadanie to można jednak rozwiązać przy pomocy sieci statycznej modelując część dynamiki obiektu poza siecią neuronową. Zauważmy, że architektura TDNN pozwala przy odpowiednio długich liniach opóźnień rozbudować bazę aproksymatora do takiej, dla której spełniona jest zależność (4.7). Analogicznie, podawanie na wejścia sieci dodatkowych sygnałów, będących odfiltrowanymi sygnałami już istniejących wejść, może szereg zagadnień przekształcić do zadań modelowania statycznego. Przewagą takiego rozwiązania nad modelem TDNN jest brak konieczności ponownego uczenia sieci w sytuacji zmiany okresu próbkowania. Jednocześnie przy tworzeniu zbioru uczącego okres próbkowania sygnałów uczących może być zmienny. W dalszej części pracy, ten sposób przygotowywania sygnałów wejściowych będzie nazywany wstępnym przetwarzaniem dynamicznym. Wybór rodzaju filtrów może być podektywany charakterem obiektu, nie jest jednak jednoznaczny. Problem 3. można rozwiązać podając na wejście sieci dodatkowe sygnały

$$\begin{cases} y_3 = \frac{1}{0.05s+1}u_1 \\ y_4 = \frac{1}{0.05s+1}y_3 \end{cases} . \quad (4.11)$$

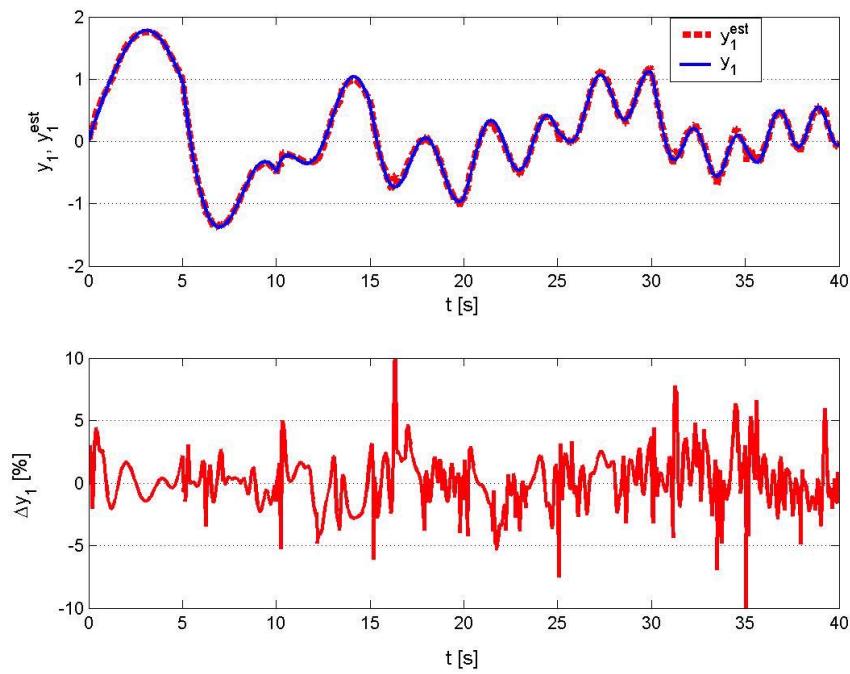
Zauważmy, że zaproponowany szeregowy filtr odpowiada charakterem modelowanemu obiekowi dynamicznemu. Niemniej jednak stała czasowa filtra jest o rząd wielkości mniejsza od stałych czasowych obiektu. Filtr ten nie modeluje bezpośrednio obiektu, ale obecność par (u_1, y_3) i (u_1, y_4) wprowadza na wejścia sieci pewną wiedzę o historii w czasie sygnału wymuszającego. Okazuje się to wystarczające - relacja $((u_1, y_2, y_3, y_4), y_1)$ może być odzworzona z założoną dokładnością przy użyciu sieci statycznej 4-15-5-1 (rys. 4.14).

Omawiany problem można również rozwiązać stosując zamiast (4.11) filtry wszechprzepustowe

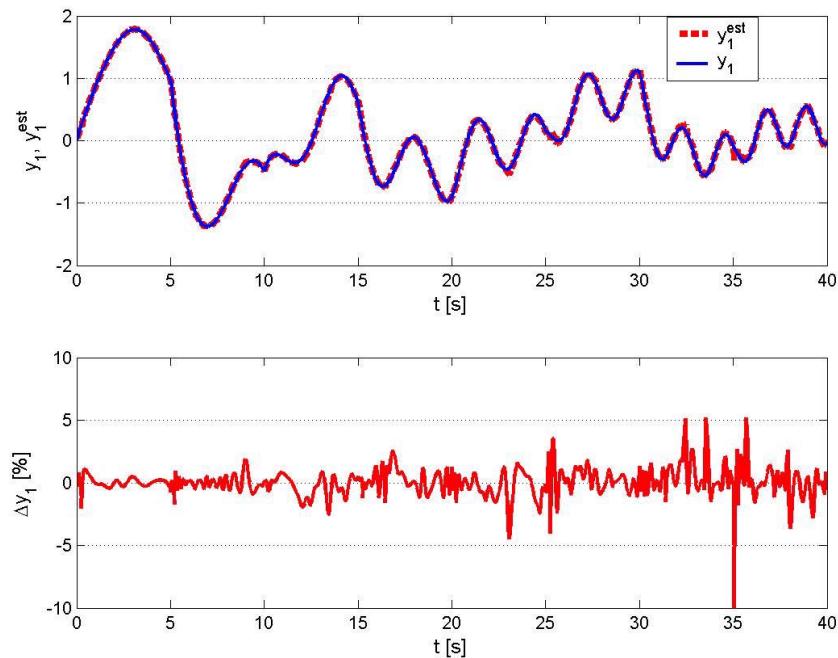
$$\begin{cases} y_3 = \frac{-0.05s+1}{0.05s+1}u_1 \\ y_4 = \frac{-0.05s+1}{0.05s+1}y_3 \end{cases} . \quad (4.12)$$

Wyniki odtwarzania dla tak określonej bazy czterowymiarowej przedstawia rysunek 4.15.

Wniosek 3b. **Skutecznym sposobem rozszerzania bazy aproksymatora neuronowego jest dynamiczne przetwarzanie (filtracja) już istniejących wejść sieci. Odpowiednio dobrane filtry pozwalają zagadnienia niefunkcyjne przekształcić do problemów modelowania statycznego.**



Rysunek 4.14. Odtwarzanie w oparciu o bazę zawierającą kaskadę (4.11) odfiltrowanego dolno-przepustowo sygnału wymuszenia

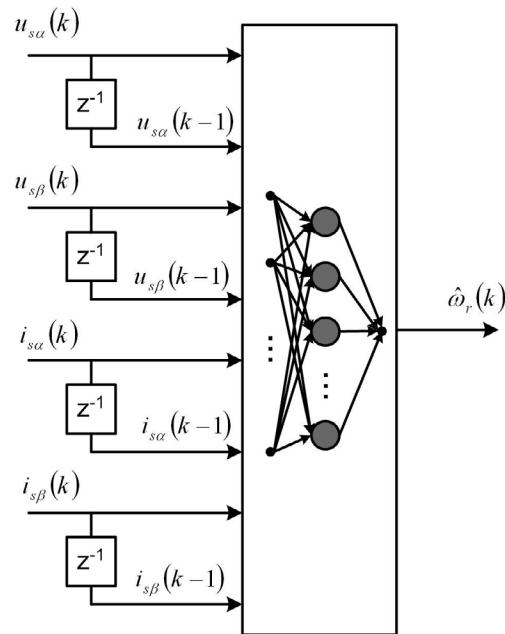


Rysunek 4.15. Odtwarzanie w oparciu o bazę zawierającą kaskadę (4.12) odfiltrowanego wszech-przepustowo sygnału wymuszenia

Z uwagi na brak jednoznacznych zasad projektowania wstępniego przetwarzania nieliniowego i dynamicznego, wybór odpowiednich filtrów i funkcji nieliniowych wymaga dużej intuicji i nierzadko odbywa się metodą prób i błędów. Najprawdopodobniej nie da się stworzyć uniwersalnych reguł pozwalających na modelowanie statyczne dowolnego obiektu dynamicznego lub na stwierdzenie nieistnienia modelu statycznego. Niemniej jednak, biorąc pod uwagę konkretny obiekt dynamiczny może okazać się, że zaproponowanie w miarę spójnego zbioru reguł tworzenia bazy aproksymatora, nie jest szczególnie trudne. W dalszej części rozdziału omówione zostaną opracowane i przebadane przez autora metody tworzenia bazy dla sieci statycznej odtwarzającej prędkość kątową wirnika silnika indukcyjnego.

4.4. Wstępne nieliniowe przetwarzanie sygnałów dla silnika indukcyjnego

Odtwarzanie prędkości kątowej silnika indukcyjnego na podstawie chwilowych wartości prądów i napięć stojana, podawanych bezpośrednio na wejścia sieci neuronowej, związane jest z modelowaniem silnie nieliniowych zależności. Dlatego też proponowany między innymi w [10] estymator, którego schemat przedstawiono na rysunku 4.16, cechuje stosunkowo duża wrażliwość na zakłócenia pomiarowe i zmiany parametrów obiektu. Tak



Rysunek 4.16. Neuronowy estymator prędkości kątowej wirnika silnika klatkowego proponowany w [10]

Sformułowane zadanie można określić mianem źle uwarunkowanego - spektrum częstotliwości

ści sygnałów wejściowych sieci neuronowej jest znaczowo różne od spektrum częstotliwości sygnału wyjściowego, a zastosowana sieć jest obiektem statycznym i ma tendencję do przenoszenia częstotliwości obecnych w sygnałach wejściowych na swoje wyjście. Problem ten jest szczególnie wyraźny w stanie ustalonej prędkości napędu, gdy sygnały wejściowe sieci zmieniają się sinusoidalnie (z częstotliwością np. 50 Hz), natomiast wyjście sieci powinno być stałe (częstotliwość 0 Hz). Należy zatem zaprojektować odpowiednie wstępne przetwarzanie nielinowe, zapewniające dopasowanie częstotliwościowe sygnałów wejściowych sieci do sygnału prędkości kątowej. Funkcja przetwarzająca $f(u_{s\alpha}, u_{s\beta}, i_{s\alpha}, i_{s\beta})$ powinna posiadać następujące własności:

- a) w stanach ustalonej prędkości kątowej wirnika jej wartość też jest stała,
- b) w stanach przejściowych napędu widmo sygnału przetworzonego powinno być zbliżone do widma odtwarzanej prędkości kątowej.

Sformułowano w ten sposób kryterium częstotliwości. Z uwagi na niestacjonarność badanych sygnałów, klasyczna analiza częstotliwościowa (za cały przedział zarejestrowanego sygnału) może stanowić jedynie wstępna weryfikację zgodności z warunkiem (b). Właściwe spełnienie warunku (b) należy zbadać wykorzystując jedną z analiz czasowo-częstotliwościowych (-korelacyjnych), np. krótkoczasową analizę częstotliwościową (*ang. Short Time Fourier Transform, STFT*) lub analizę falkową (*ang. Wavelets*). Zakładamy, że $u_{s\alpha}, u_{s\beta}, i_{s\alpha}, i_{s\beta}$ są odfiltrowanymi dolnoprzepustowo napięciami i prądami stojana. Częstotliwości odcienia filtrów należy dobrać tak, aby w stanie ustalonej prędkości napędu wielkości $|\underline{u}_s|, |\underline{i}_s|, \angle(\underline{u}_s, \underline{i}_s)$ były z dobrym przybliżeniem stałe. Jednocześnie dynamika zmian tych wielkości nie może być obniżona bardziej niż dynamika zmian prędkości kątowej wirnika. Przy częstotliwościach pracy dostępnych na rynku energoelektronicznych łączników półprzewodnikowych, spełnienie tych warunków w większości układów napędowych nie stanowi problemu. Bazując na iloczynie skalarnym i wektorowym zaproponowano pierwsze sześć sygnałów spełniających kryterium częstotliwości:

$$u_1 = |\underline{u}_s| = \sqrt{u_{s\alpha}^2 + u_{s\beta}^2} \quad (4.13)$$

$$u_2 = |\underline{i}_s| = \sqrt{i_{s\alpha}^2 + i_{s\beta}^2} \quad (4.14)$$

$$u_3 = \Re(\underline{u}_s \underline{i}_s^*) = i_{s\alpha}u_{s\alpha} + i_{s\beta}u_{s\beta} = |\underline{u}_s| |\underline{i}_s| \cos \angle(\underline{u}_s, \underline{i}_s) \quad (4.15)$$

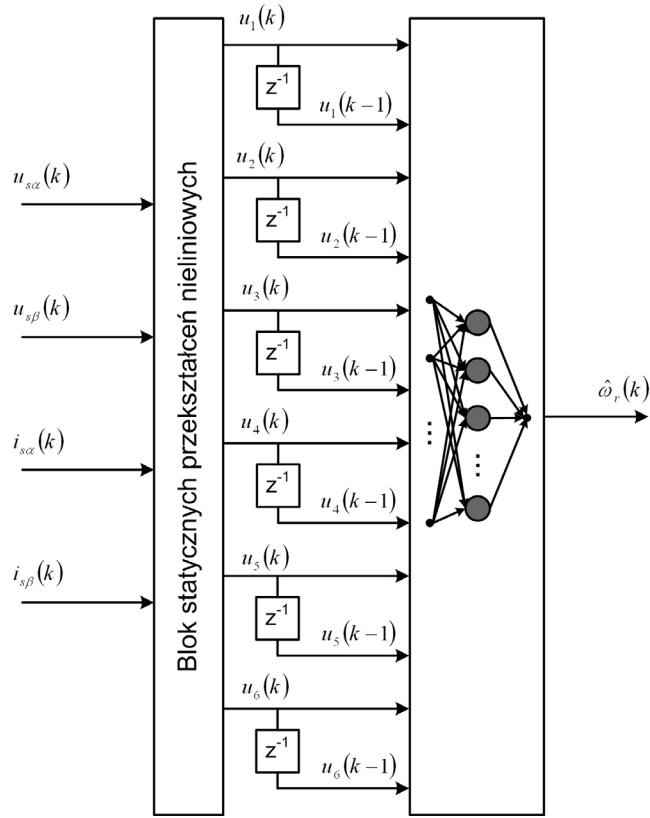
$$u_4 = \Im(\underline{u}_s \underline{i}_s^*) = i_{s\alpha}u_{s\beta} - i_{s\beta}u_{s\alpha} \propto |\underline{u}_s| |\underline{i}_s| \sin \angle(\underline{u}_s, \underline{i}_s) \quad (4.16)$$

$$u_5 = \Re\left(\frac{\underline{u}_s}{\underline{i}_s}\right) = \frac{i_{s\alpha}u_{s\alpha} + i_{s\beta}u_{s\beta}}{i_{s\alpha}^2 + i_{s\beta}^2} = \frac{|\underline{u}_s|}{|\underline{i}_s|} \cos \angle(\underline{u}_s, \underline{i}_s) \quad (4.17)$$

$$u_6 = \Im\left(\frac{\underline{u}_s}{\underline{i}_s}\right) = \frac{i_{s\alpha}u_{s\beta} - i_{s\beta}u_{s\alpha}}{i_{s\alpha}^2 + i_{s\beta}^2} \propto \frac{|\underline{u}_s|}{|\underline{i}_s|} \sin \angle(\underline{u}_s, \underline{i}_s). \quad (4.18)$$

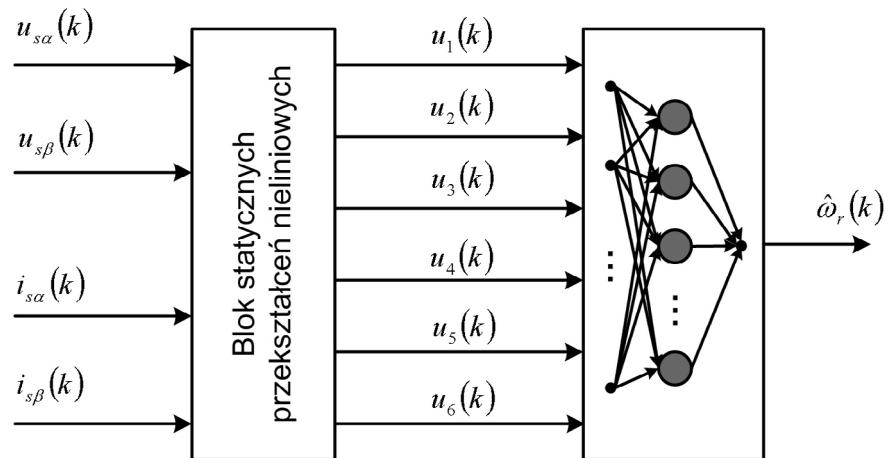
Zastępując w schemacie z rysunku 4.16 chwilowe wartości prądów i napięć sygnałami określonymi zależnościami (4.13)-(4.18) otrzymujemy estymator jak na rysunku 4.17.

Przeprowadzone badania symulacyjne i eksperymentalne wskazały na możliwość zreduko-



Rysunek 4.17. Neuronowy estymator prędkości ze wstępnym przetwarzaniem nieliniowym

wania linii opóźnień w tej strukturze do zera. W konsekwencji otrzymano estymator jak na rysunku 4.18, złożony z bloku przekształceń nieliniowych i neuronowego aproksymatora funkcji nieliniowej. Jest to model w pełni **statyczny** (!!!). Wyniki badań nad tą



Rysunek 4.18. Neuronowy estymator prędkości z liniami opóźnień zredukowanymi do zera

strukturą opublikowano w [146]. Omawiany estymator posłużył do budowy bezczujnikowego napędu SFOC (Stator Field Oriented Control). Dla przejrzystości pracy przyjęto, że niniejszy rozdział zawierać będzie jedynie opis teoretyczny opracowanych metod tworzenia bazy aproksymatora neuronowego. Wyniki badań symulacyjnych i eksperymentalnych zebrane zostaną w dwóch oddzielnych rozdziałach pracy.

Zaproponowane sygnały (4.15)-(4.18) posiadają prostą interpretację fizyczną. Są to odpowiednio: moc czynna i bierna oraz składowe „impedancji chwilowej”. Dalsze rozbudowywanie bazy aproksymatora zainspirowane zostało siedciami typu GMDH (Group Method of Data Handling) [2]. Jeden z prostszych elementów przetwarzających w sieciach GMDH to neuron wielomianowy realizujący funkcję

$$y = a_0 + a_1 u_1 + a_2 u_2 + a_{11} u_1^2 + a_{22} u_2^2 + a_{12} u_1 u_2, \quad (4.19)$$

gdzie: $a_0, a_1, a_2, a_{11}, a_{22}, a_{12}$ - współczynniki dobierane w procesie uczenia, u_1, u_2 - wejścia neuronu. Stąd zaproponowano kolejne sygnały wejściowe aproksymatora neuronowego, będące wybranymi iloczynami i potęgami sygnałów (4.13)-(4.18):

$$u_7 = |\underline{u}_s|^2 = u_{s\alpha}^2 + u_{s\beta}^2 \quad (4.20)$$

$$u_8 = |\underline{i}_s|^2 = i_{s\alpha}^2 + i_{s\beta}^2 \quad (4.21)$$

$$u_9 = |\underline{u}_s| |\underline{i}_s| = \sqrt{(u_{s\alpha}^2 + u_{s\beta}^2)(i_{s\alpha}^2 + i_{s\beta}^2)} \quad (4.22)$$

$$u_{10} = \left[\Re \left(\frac{\underline{u}_s}{\underline{i}_s} \right) \right]^2 = \left(\frac{i_{s\alpha} u_{s\alpha} + i_{s\beta} u_{s\beta}}{i_{s\alpha}^2 + i_{s\beta}^2} \right)^2 \quad (4.23)$$

$$u_{11} = \left[\Im \left(\frac{\underline{u}_s}{\underline{i}_s} \right) \right]^2 = \left(\frac{i_{s\alpha} u_{s\beta} - i_{s\beta} u_{s\alpha}}{i_{s\alpha}^2 + i_{s\beta}^2} \right)^2 \quad (4.24)$$

$$u_{12} = \Re(\underline{u}_s \underline{i}_s^*) \cdot \Re \left(\frac{\underline{u}_s}{\underline{i}_s} \right) = \frac{(i_{s\alpha} u_{s\alpha} + i_{s\beta} u_{s\beta})^2}{i_{s\alpha}^2 + i_{s\beta}^2} \quad (4.25)$$

$$\begin{aligned} u_{13} &= \Re(\underline{u}_s \underline{i}_s^*) \cdot \Im \left(\frac{\underline{u}_s}{\underline{i}_s} \right) = \Im(\underline{u}_s \underline{i}_s^*) \cdot \Re \left(\frac{\underline{u}_s}{\underline{i}_s} \right) \\ &= \frac{(i_{s\alpha} u_{s\alpha} + i_{s\beta} u_{s\beta})(i_{s\alpha} u_{s\beta} - i_{s\beta} u_{s\alpha})}{i_{s\alpha}^2 + i_{s\beta}^2} \end{aligned} \quad (4.26)$$

$$u_{14} = \Im(\underline{u}_s \underline{i}_s^*) \cdot \Im \left(\frac{\underline{u}_s}{\underline{i}_s} \right) = \frac{(i_{s\alpha} u_{s\beta} - i_{s\beta} u_{s\alpha})^2}{i_{s\alpha}^2 + i_{s\beta}^2}. \quad (4.27)$$

Sygnałów spełniających kryterium częstotliwości jest nieskończonie wiele. Wykorzystując działanie dzielenia możemy zdefiniować kolejne transformacje

$$u_{15} = \frac{|\underline{u}_s|}{|\underline{i}_s|} = \sqrt{\frac{u_{s\alpha}^2 + u_{s\beta}^2}{i_{s\alpha}^2 + i_{s\beta}^2}} \quad (4.28)$$

$$u_{16} = \frac{\Re(\underline{u}_s \underline{i}_s^*)}{|\underline{u}_s|} = \frac{i_{s\alpha} u_{s\alpha} + i_{s\beta} u_{s\beta}}{\sqrt{u_{s\alpha}^2 + u_{s\beta}^2}} \quad (4.29)$$

$$u_{17} = \frac{\Im(\underline{u}_s \underline{i}_s^*)}{|\underline{u}_s|} = \frac{i_{s\alpha}u_{s\beta} - i_{s\beta}u_{s\alpha}}{\sqrt{u_{s\alpha}^2 + u_{s\beta}^2}} \quad (4.30)$$

$$u_{18} = \frac{\Re\left(\frac{\underline{u}_s}{\underline{i}_s}\right)}{|\underline{u}_s|} = \frac{i_{s\alpha}u_{s\alpha} + i_{s\beta}u_{s\beta}}{(i_{s\alpha}^2 + i_{s\beta}^2) \sqrt{u_{s\alpha}^2 + u_{s\beta}^2}} \quad (4.31)$$

$$u_{19} = \frac{\Im\left(\frac{\underline{u}_s}{\underline{i}_s}\right)}{|\underline{u}_s|} = \frac{i_{s\alpha}u_{s\beta} - i_{s\beta}u_{s\alpha}}{(i_{s\alpha}^2 + i_{s\beta}^2) \sqrt{u_{s\alpha}^2 + u_{s\beta}^2}}. \quad (4.32)$$

Sięgając po działanie pierwiastkowania otrzymujemy na przykład:

$$u_{20} = \sqrt{\left| \Im(\underline{u}_s \underline{i}_s^*) \cdot \Re\left(\frac{\underline{u}_s}{\underline{i}_s}\right) \right|} = \sqrt{\frac{(i_{s\alpha}u_{s\alpha} + i_{s\beta}u_{s\beta})(i_{s\alpha}u_{s\beta} - i_{s\beta}u_{s\alpha})}{i_{s\alpha}^2 + i_{s\beta}^2}}. \quad (4.33)$$

Zależnie od struktury układu regulacji, do zbioru potencjalnych wejść sieci można zaliczyć wartości zadane (np. prędkość zadaną [22]), wyjścia regulatorów, inne wielkości estymowane jak moment elektromagnetyczny. Otrzymany w ten sposób zbiór sygnałów może być bardzo liczny. Istnieje duże prawdopodobieństwo, że tak intuicyjnie rozbudowywany zestaw sygnałów cechuje redundancja (nadmiarowość) informacji. Od strony czysto matematycznej, stosunkowo łatwo jest zagwarantować ich liniową niezależność. Jednak z praktycznego punktu widzenia, zależy nam na “silnej” liniowej niezależności tych sygnałów, a zatem wymagane jest, aby wartości własne macierzy kowariancji tych sygnałów były możliwie dalekie od zera. W obecności reguł wiążących \underline{i}_s z \underline{u}_s , proponowane sygnały opisujące obiekt są, w granicach błędu pomiarowego, zazwyczaj liniowo zależne. Podawanie na wejścia perceptronu wielowarstwowego uczonego metodą wstępnej propagacji błędów sygnałów liniowo zależnych, niepotrzebnie zwiększa złożoność problemu i może pogorszyć zdolności generalizacyjne sieci. Niezbędne staje się dokonanie selekcji optymalnego podzbioru, który posłuży do budowy estymatora prędkości kątowej wirnika. W dalszej części rozdziału przedstawione zostaną analityczne metody tworzenia bazy aproksymatora neuronowego.

4.5. Metody tworzenia bazy sygnałów dla neuronowego estymatora prędkości kątowej wirnika silnika klatkowego

Założono, że dysponujemy spróbkowanymi sygnałami u_1, u_2, \dots, u_n zebranymi w macierz $\mathbf{U}_{k \times n}$, gdzie k jest liczbą próbek. Jednocześnie stworzono skojarzony z \mathbf{U} wektor $\boldsymbol{\omega}$ próbek zmierzonej prędkości kątowej ω_r . Przyjmujemy, że spełniono podstawowe wymagania dotyczące tworzenia zbioru uczącego, tj. zebrane pary $((u_1, u_2, \dots, u_n), \omega_r)$ w miarę równomiernie pokrywają przestrzeń możliwych stanów pracy układu napędowego. Przy czym dla

badań symulacyjnych zbiory wygenerowano w oparciu o modele symulacyjne układu napędowego, natomiast dla estymatora testowanego w układzie rzeczywistym, zbiory uczące skonstruowane w oparciu o próbki zebrane podczas pracy układu napędowego wyposażonego w czujnik prędkości. Z doświadczeń autora wynika, że wszelkie próby implementowania w układzie eksperymentalnym estymatora nauczonego w oparciu o zbiory pochodzące z symulacji, kończą się niepowodzeniem. Związane jest to ze wszelkimi uproszczeniami związanymi z modelowaniem matematycznym nielinowego układu, jakim jest połączenie falownika napięcia z silnikiem indukcyjnym.

4.5.1. Wybrane podstawowe pojęcia z matematyki statystycznej

Zaproponowane w pracy metody doboru sygnałów wejściowych sieci statycznej estymującej prędkość kątową wirnika, bazują na algorytmach statystyki matematycznej. Większość algorytmów z tej grupy wprowadza standaryzowanie analizowanych sygnałów. Założmy, że uzyskaliśmy wektor k próbek sygnału u_i . Dla uproszczenia zapisu przyjmijmy, że \sum oznacza sumowanie po wszystkich próbkach. Wartość średnia sygnału dana jest wzorem

$$E\{u_i\} = \mu_i = \frac{1}{k} \sum u_i. \quad (4.34)$$

Estymatę wariancji uzyskiwaną metodą największej wiarygodności wyznaczamy ze wzoru

$$\sigma_i^2 = \frac{1}{k} \sum (u_i - \mu_i)^2 \quad (4.35)$$

i nazywamy estymatą obciążoną [147]. Nieobciążona estymata wariancji zakładająca rozkład Gaussa opisana jest wzorem

$$\sigma_i^2 = \frac{1}{k-1} \sum (u_i - \mu_i)^2. \quad (4.36)$$

Pierwiastek z wariancji nazywamy odchyleniem standardowym lub dyspersją

$$\sigma_i = \sqrt{\frac{1}{k} \sum (u_i - \mu_i)^2} \quad \vee \quad \sigma_i = \sqrt{\frac{1}{k-1} \sum (u_i - \mu_i)^2}. \quad (4.37)$$

Wprowadzono pojęcie zmiennej standaryzowanej, której wartość średnia jest zerowa a wariancja jednostkowa. Standaryzację sygnału dokonujemy zgodnie z zależnością

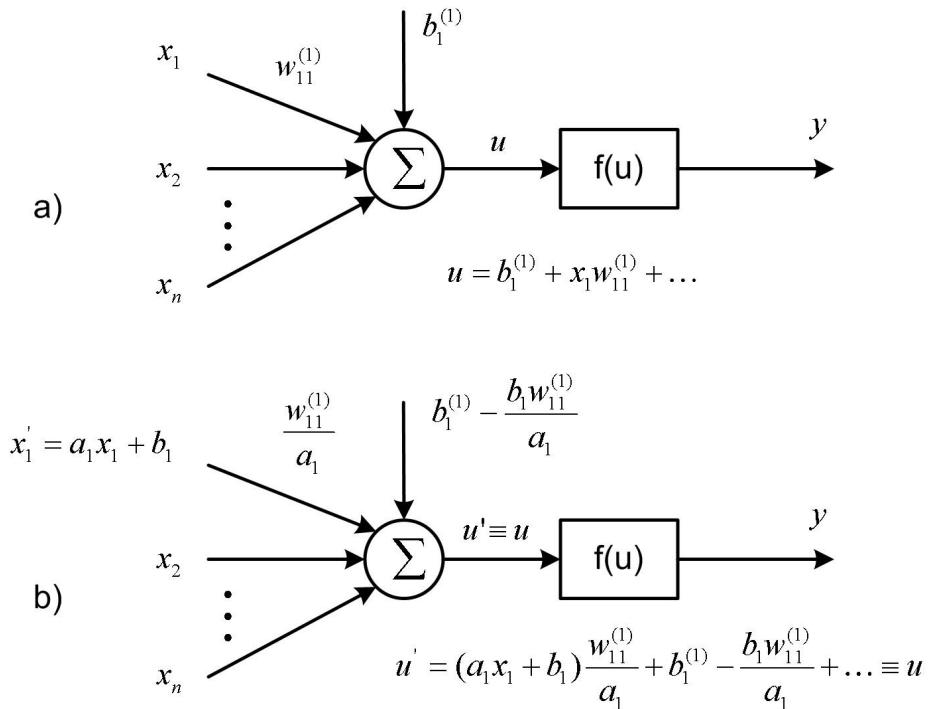
$$u_i^{std} = \frac{u_i - \mu_i}{\sigma_i}. \quad (4.38)$$

Chcąc zmierzyć liniową zależność dwóch sygnałów u_i i u_j definiujemy pojęcie kowariancji

$$\sigma_{ij} = \frac{1}{k} \sum (u_i - \mu_i) (u_j - \mu_j) \quad \vee \quad \sigma_{ij} = \frac{1}{k-1} \sum (u_i - \mu_i) (u_j - \mu_j) \quad (4.39)$$

i posługujemy się współczynnikiem korelacji

$$r_{ij} = \frac{\sigma_{ij}}{\sigma_i \sigma_j} = \frac{\sum (u_i - \mu_i) (u_j - \mu_j)}{\sqrt{\sum (u_i - \mu_i)^2} \sqrt{\sum (u_j - \mu_j)^2}}. \quad (4.40)$$



Rysunek 4.19. Ilustracja niezmienniczości informacji niesionej przez sygnał wejściowy perceptronu względem skalowania i składowej stałej: a) wybrany neuron z warstwy wejściowej, b) przeksztalcenie wagi i progu, korespondujące z liniowym przeksztalceniem wybranego sygnału wejściowego, zapewniające tożsamościową równość wyjść obu neuronów

Zauważmy, że współczynnik korelacji (4.40) jest iloczynem skalarnym wektorów standaryzowanych zgodnie z (4.38) podzielonym odpowiednio przez k lub $k - 1$. Współczynnik ten przyjmuje wartość 0 dla sygnałów nieskorelowanych (ortogonalnych). Sygnały ortogonalne nie niosą informacji redundantnej o obiekcie. Wartości 1 i -1 oznaczają współliniowość wektorów, a informacja o obserwowanym układzie jest niepotrzebnie powielana na wejściach estymatora neuronowego.

Projektując zestaw sygnałów wejściowych dla perceptronu wielowarstwowego, należy uwzględnić fakt niezmienniczości informacji dla tej struktury względem skalowania i składowej stałej. Trenując perceptron na zbiorze (u, y) otrzymujemy macierze wag $\mathbf{W}^{(1)} \dots \mathbf{W}^{(m)}$ i progów (*ang. biasów*) $\mathbf{b}^{(1)} \dots \mathbf{b}^{(m)}$, gdzie m - liczba warstw. Dysponując sygnałami zmodyfikowanymi zgodnie z $u'_i = a_i u_i + b_i$, gdzie a_i, b_i dane liczby rzeczywiste, możemy dokonać jednoznacznie określonego przeksztalcenia macierzy $\mathbf{W}^{(1)}$ i $\mathbf{b}^{(1)}$, takiego że $y' \equiv y$, tj. otrzymany perceptron jest identyczny z nauczonym na zbiorze (u, y) . Szkic dowodu w sytuacji przeksztalcenia jednego sygnału wejściowego zilustrowano na rysunku 4.19. Dokonując omawianego przeksztalcenia na sygnale u_1 należy równocześnie podzielić wszystkie wagi pierwszej warstwy związane z sygnałem u_1 przez a_1 oraz zmniejszyć wszystkie biasy $b_j^{(1)}$ warstwy pierwszej o $\frac{b_1 w_{1j}^{(1)}}{a_1}$, gdzie j - numer neuronu. W rezultacie sygnały za węzłami

sumacyjnymi w pierwszej warstwie nie ulegają zmianie. Na tej podstawie stwierdzamy, że na przykład standaryzowanie potencjalnych sygnałów wejściowych aproksymatora neuronowego nie zmienia informacji wykorzystywanej do uczenia omawianej sieci. Należy dodatkowo wspomnieć, że szereg algorytmów uczenia wprowadza wcześniejszą normalizację sygnałów np. do przedziału $\langle -1, 1 \rangle$. Zilustrowana niezmienniczość informacji dla perceptronu względem skalowania i składowej stałej, umożliwia przeprowadzenie procesu tworzenia bazy sygnałów dla neuronowego estymatora prędkości kątowej wirnika silnika klatkowego, w oparciu o sygnały standaryzowane zgodnie z (4.38), natomiast proces uczenia perceptronu może odbyć się w oparciu o sygnały znormalizowane do przedziału $\langle -1, 1 \rangle$. Postępowanie takie nie powoduje utraty spójności całego procesu projektowania estymatora.

Na początku badań nad siecią statyczną jako estymatorem prędkości posługiwano się graficznym porównywaniem np. sygnałów (4.13)-(4.18) z sygnałem prędkości kątowej ω_m . Pozwoliło to na wyciągnięcie bardzo podstawowych wniosków dotyczących braku informacji o kierunku wirowania wału silnika w sygnałach (4.13)-(4.15) i (4.17) oraz możliwości wnioskowania o kierunku wirowania wału z sygnałów (4.16) i (4.18). Należy podkreślić, że graficzne porównanie sygnałów ma wiele wspólnego z analitycznym wyznaczeniem współczynnika korelacji (4.40). Porównując graficznie dwa sygnały u_i i u_j kierujemy się przede wszystkim ich średnią odległość od siebie mierzoną na osi wartości. Wykorzystując niezmienniczość informacji względem omówionych przekształceń należy zminimalizować odległość średniokwadratową między badaną parą sygnałów. Zakładając, że dopuszczaemy przekształcenie sygnału u_j w $u'_j = au_j + b$, zadanie polega na znalezieniu minimum funkcji

$$f(a, b) = \frac{1}{k} \sum (u_i - u'_j)^2 = \frac{1}{k} \sum (u_i - au_j - b)^2. \quad (4.41)$$

Uzyskujemy to poprzez wyznaczenie punktu stacjonarnego określonego układem równań

$$\begin{cases} \frac{\partial f}{\partial a} = -\frac{2}{k} \sum u_j (u_i - au_j - b) = 0 \\ \frac{\partial f}{\partial b} = -\frac{2}{k} \sum (u_i - au_j - b) = 0 \end{cases}, \quad (4.42)$$

z którego otrzymujemy

$$\begin{cases} a = \frac{k \sum u_i u_j - \sum u_i \sum u_j}{k \sum u_j^2 - (\sum u_j)^2} \\ b = \frac{\sum u_i - a \sum u_j}{k} \end{cases}. \quad (4.43)$$

Dla tak wyznaczonych a i b wykreślamy w jednym układzie współrzędnych sygnały u_i i u'_j . Powyższe rozumowanie przeprowadzone dla sygnałów standaryzowanych prowadzi do graficznej interpretacji współczynnika korelacji. Przyjmując $\sum u_i = \sum u_j = 0$ oraz $\frac{1}{k} \sum u_i^2 = \frac{1}{k} \sum u_j^2 = 1$ na mocy (4.43) otrzymujemy

$$\begin{cases} a = \frac{\sum u_i u_j}{k} \\ b = 0 \end{cases}. \quad (4.44)$$

Stąd korzystając z (4.41) wyznaczamy

$$\begin{aligned}
 f_{\min} &= \frac{1}{n} \sum \left(u_i - \frac{\sum u_i u_j}{k} u_j \right)^2 = \\
 &= \frac{1}{n} \sum \left(u_i^2 - 2u_i u_j \frac{\sum u_i u_j}{k} + \frac{(\sum u_i u_j)^2}{k^2} u_j^2 \right) = \\
 &= \frac{1}{n} \sum u_i^2 - 2 \frac{(\sum u_i u_j)^2}{k^2} + \frac{1}{k} \frac{(\sum u_i u_j)^2}{k^2} \sum u_j^2 = \\
 &= 1 - 2 \left(\frac{1}{k} \sum u_i u_j \right)^2 + \left(\frac{1}{k} \sum u_i u_j \right)^2 = \\
 &= 1 - r_{ij}^2
 \end{aligned} \tag{4.45}$$

Tak rozumiana minimalna odległość średniokwadratowa dwóch sygnałów standaryzowanych jest funkcją współczynnika korelacji r_{ij} i przyjmuje wartość maksymalną równą 1 dla sygnałów ortogonalnych. Inne interpretacje fizyczne współczynnika korelacji można znaleźć w [148].

4.5.2. Algorytm największego spadku liczby warunkowej

Pierwsza propozycja załgorytmizowania procesu tworzenia bazy sygnałów dla neuronowego estymatora prędkości kątowej wirnika silnika klatkowego wykorzystuje rozkład według wartości singularnych (szczególnych, osobliwych) SVD (Singular Value Decomposition) [15, 149, 1, 111, 150]. Zakładamy, że zadanie polega na wyłonieniu spośród sygnałów u_1, u_2, \dots, u_n , spełniających kryterium częstotliwości, podzbioru możliwie najbardziej liniowo niezależnych sygnałów, które zostaną przyjęte za bazę neuronowego aproksymatora prędkości kątowej wirnika.

Badanie współczynnika korelacji pozwala zgrubnie określić jakość proponowanego zestawu sygnałów wejściowych estymatora, ze względu na pojawiające się w nim pary sygnałów, oraz ze względu na korelację wybranego sygnału wejściowego z sygnałem odtwarzanym. Metodą pozwalającą porównywać zestawy ponad dwóch sygnałów jest SVD. Metoda ta bazuje na twierdzeniu algebry liniowej, mówiącym, że każdą macierz \mathbf{A} można przedstawić w postaci iloczynu ortogonalnej kolumnami macierzy \mathbf{X} (złożonej z wektorów kolumnowych o długości 1), diagonalnej macierzy z dodatnimi lub zerowymi elementami s_1, \dots, s_n zwanyymi wartościami singularnymi, oraz transponowanej unitarnej macierzy \mathbf{Y} . jeżeli założymy, że liczba wierszy macierzy \mathbf{A} jest większa lub równa liczbie kolumn, to otrzymujemy

$$\mathbf{A}_{m \times n, m \geq n} = \mathbf{X}_{m \times n} \cdot \begin{bmatrix} s_1 & 0 & \cdots & 0 \\ 0 & s_2 & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & s_n \end{bmatrix} \cdot \mathbf{Y}_{n \times n}^T. \tag{4.46}$$

Jeżeli macierz \mathbf{A} jest kwadratowa, to macierz do niej odwrotną znajdujemy z zależności

$$\mathbf{A}^{-1} = \mathbf{Y} \cdot \begin{bmatrix} \frac{1}{s_1} & 0 & \cdots & 0 \\ 0 & \frac{1}{s_2} & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{s_n} \end{bmatrix} \cdot \mathbf{X}^T. \quad (4.47)$$

Wartości własne niosą informację o stopniu liniowej niezależności wierszy i kolumn danej macierzy. Jeżeli przynajmniej jedna z nich jest zerowa, to macierz jest osobliwa, tj. nie istnieje macierz do niej odwrotna (we wzorze (4.47) pojawia się dzielenie przez zero). Miarą osobliwości może być tzw. liczba warunkowa (*ang.* conditional number) będąca ilorazem największej i najmniejszej wartości singularnej. Dla macierzy osobliwej liczba warunkowa dąży do nieskończoności. Macierz źle uwarunkowana to taka, dla której odwrotność liczby warunkowej zbliża się do precyzyji obliczeń. Liczba warunkowa może być wykorzystana do porównywania liniowej niezależności sygnałów. Na podstawie wartości singularnych możemy określić względny rząd macierzy [111]. Wadami liczby warunkowej jako miary liniowej niezależności zbioru sygnałów są: zmienniczość względem skalowania wierszy lub kolumn oraz zmienniczość względem dodawania składowej stałej do wiersza lub kolumny. Obie te niedogodności można jednak rozwiązać pracując na sygnałach standaryzowanych zgodnie z (4.38).

Wynikiem działania procedury wyłaniającej ze zbioru sygnałów u_1, u_2, \dots, u_n , podzbiór p możliwie najbardziej liniowo niezależnych sygnałów, powinien być podzbiór o najmniejszej liczbie warunkowej. Jest to zagadnienie o złożoności obliczeniowej $\binom{n}{p} = \frac{n!}{(n-p)!p!}$, co przy próbie wyłonienia np. podzbioru 15-tu sygnałów wejściowych aproksymatora neuronowego spośród 30-tu sygnałów kandydackich oznacza konieczność wykonania ponad 155 milionów rozkładów SVD. Dodatkowo wymagana jest wiedza *a priori* o liczbie p sygnałów do wyłonienia. Jeżeli dla założonego p najmniejsza z uzyskanych liczb warunkowych jest zbyt duża, to procedurę należy powtórzyć dla $p - 1$ co dodatkowo komplikuje algorytm. Brak szybkiego algorytmu wyboru podzbioru sygnałów o najmniejszej liczbie warunkowej skłonił do zaproponowania algorytmu największego spadku liczby warunkowej.

Na podstawie zebranych synchronicznie standaryzowanych próbek sygnałów u_1, u_2, \dots, u_n budujemy macierz $\mathbf{U}_{k \times n}$, gdzie n jest liczbą badanych sygnałów, a k liczbą próbek każdego sygnału ($k \gg n$). Następnie tworzymy macierz $\mathbf{A} = \frac{\mathbf{U}^T \mathbf{U}}{k}$, która zachowuje liniowe zależności występujące między kolumnami macierzy \mathbf{U} . Zauważmy, że dla sygnałów postaci (4.38) macierz \mathbf{A} jest macierzą autokorelacji. Macierz ta jest symetryczna. Wartości osobliwe macierzy symetrycznej są równe wartościom bezwzględnym jej wartości własnych. Dodatkowo dla macierzy postaci $\mathbf{U}^T \mathbf{U}$ zachodzi równość wartości osobliwych i własnych [151]. Tak przygotowaną macierz \mathbf{A} wykorzystujemy w procesie eliminacji po jednym sygnale. Procedura wyłonienia “dobrego” zestawu wykorzystuje algorytm iteracyjny polegający na

odrzuceniu w każdym kroku jednego sygnału tak, aby uzyskać największy spadek liczby warunkowej. Algorytm ten jest nieporównywalnie szybszy od badania wszystkich możliwych podzbiorów. Przykładowo wyłonienie podzbioru 15-tu sygnałów wejściowych aproksymatora neuronowego spośród 30-tu sygnałów kandydackich związane jest z wykonaniem jedynie $30 + 29 + \dots + 16 = \frac{30+16}{2} \cdot 15 = 345$ rozkładów SVD (około pół miliona razy mniej niż w przypadku badania wszystkich podzbiorów 15-to elementowych). Algorytm największego spadku, jak większość algorytmów gradientowych, nie jest zbieżny do minimum globalnego. Kryterium zatrzymania procedury jest odrzucenie określonej liczby sygnałów lub spadek liczby warunkowej poniżej zadanego poziomu.

Opisane postępowanie gwarantuje zestaw silnie liniowo niezależnych sygnałów wejściowych estymatora. W skrajnym jednak przypadku może spowodować wybranie sygnałów, które jednocześnie będą silnie niezależne od estymowanej prędkości. Dodatkowo wymagana jest pewna wiedza *a priori* o docelowej liczbie sygnałów lub górnej dopuszczalnej wartości liczby warunkowej. Badania symulacyjne i eksperymentalne nad neuronowym estymatorem prędkości z bazą określana na podstawie algorytmu największego spadku liczby warunkowej opublikowano w [152].

4.5.3. Analiza składowych głównych

Niedoskonałości algorytmu największego spadku liczby warunkowej uzasadniają dalsze poszukiwania. Kolejnym algorymem dedykowanym redukcji wymiarowości zestawu danych jest analiza składowych głównych PCA (Principal Component Analysis). Zadanie polega na liniowym przekształceniu sygnałów u_1, u_2, \dots, u_n , spełniających kryterium częstotliwości, w zestaw możliwie najmniejszej liczby sygnałów, niosących możliwie najczęściej informacji o stanie obserwowanego układu. Rozwiążanie tak postawionego zadania zależy oczywiście od przyjętej miary informacji. Jeżeli tą miarą będzie wariancja sygnału odniesiona do wariancji szumów, to rozwiązanie zadania uzyskujemy przy pomocy PCA.

Algorytmy PCA zostały stworzone na potrzeby analizy układów z wieloma zmiennymi i są szeroko wykorzystywane w bioinżynierii, chemii, geologii, marketingu, meteorologii. Dysponując wieloma zmiennymi związanymi z obserwowanym obiektem nierazko stwierdzamy, że istnieją grupy zmiennych o zbliżonym przebiegu czasowym. Wykorzystując tę redundancję możemy grupę zmiennych zastąpić pojedynczą zmienną. Algorytm PCA generuje zbiór nowych zmiennych, zwanych składowymi głównymi, będących liniowymi kombinacjami oryginalnych zmiennych. Składowe główne są ortogonalne. Wariancja pierwszej składowej jest największa spośród wszystkich możliwych kombinacji liniowych. Kolejna składowa jest ortogonalna do poprzednich, a wybór kierunku spośród pozostałych ortogonalnych do już wykorzystanych, określony jest maksymalizacją wariancji tworzonej składowej. Cały zbiór składowych głównych składa się z takiej samej liczby zmiennych jak zbiór

oryginalnych, ale w większości sytuacji sumaryczna wariancja kilku pierwszych składowych przewyższa 80% wariancji zbioru oryginalnego [1]. Z kolei szereg ostatnich składowych ma wariancję na poziomie wariancji szumu i zostaje automatycznie pominięty w dalszej analizie. Gdy wariancja sygnału jest zbliżona do wariancji występujących szumów, to sygnał w zasadzie nie niesie informacji o stanie układu i jest nieprzydatny w procesie uczenia struktury neuronowej.

PCA jest standardowo uzyskiwana przez analityczne rozwiązywanie zagadnienia wartości własnych. Można pokazać, że macierz przekształcenia, maksymalizująca wariancję kolejnych składowych, dana jest poprzez wektory własne macierzy kowariancji, korespondujące z wartościami własnymi uporządkowanymi od największej do najmniejszej. Poszczególne wartości własne są jednocześnie wariancją tworzonych składowych. Należy przy tym zaznaczyć, że składowe główne zależą od sposobu skalowania zmiennych oryginalnych. W statystyce najczęściej używa się PCA opartej na macierzy kowariancji, natomiast w przypadku sieci neuronowych częściej wybierana jest macierz korelacji [2]. W przeprowadzonych badaniach przyjęto, że analizowane sygnały są standaryzowane do zerowej wartości średniej i jednostkowej wariancji. Dla takich sygnałów macierz kowariancji jest tożsamościowo równa macierzy korelacji. Dodatkowo standaryzowanie sygnałów wprowadza bardzo ważną cechę do zbioru badanych sygnałów. Zakłada ono bowiem, że każda zmienna spełniająca kryterium częstotliwości jest równie przydatna w proponowanej architekturze. Różnicowanie wariancji sygnałów poddawanych analizie składowych głównych oznaczałoby faworyzowanie sygnałów o większej wariancji i deprymowanie tych o mniejszej wariancji. PCA można również zrealizować przy użyciu samoorganizującej się sieci neuronowej [153, 101, 154]. Istnieje algorytm uczenia bez nauczyciela jednowarstwowego perceptronu liniowego zbieżny do składowych głównych. Warunkiem koniecznym prawidłowej samoorganizacji sieci jest zerowa wartość średnia sygnałów wejściowych. Chcąc wyznaczyć pierwszą składową, korzystamy z reguły Oji [153]:

$$\Delta \mathbf{w} = \eta \mathbf{y} (\mathbf{X}^T - \mathbf{y}^T \mathbf{w}), \quad (4.48)$$

gdzie \mathbf{X} - macierz n sygnałów po k próbkach o wymiarach $n \times k$, η - współczynnik uczenia, \mathbf{w} - wektor wag sieci (jednoneuronowej) o wymiarach $1 \times n$, $\mathbf{y} = \mathbf{w} \mathbf{X}$ - wyjście sieci o wymiarach $1 \times k$. Zbieżność reguły (4.48) podyktowana jest odpowiednio małym współczynnikiem uczenia η . Chcąc wyznaczyć wszystkie n składowych głównych, należy przyjąć $\mathbf{w} = \mathbf{W}$ o wymiarach $n \times n$ i zmodyfikować regułę Oji do reguły Sangera, zwanej uogólnionym algorytmem Hebba (GHA, Generalized Hebbian Algorithm) i danej zależnością [153]:

$$\Delta \mathbf{W} = \eta (\mathbf{Y} \mathbf{X}^T - \text{tril}(\mathbf{Y} \mathbf{Y}^T) \mathbf{W}), \quad (4.49)$$

gdzie $\text{tril}(\bullet)$ oznacza macierz, w której elementy powyżej diagonali zastąpiono zerami. Wyjścia sieci uczonej zgodnie z tą regułą są zbieżne do składowych głównych uporządkowanych

od największej do najmniejszej wariancji. Należy przy tym podkreślić, że szybkość zbiegania się poszczególnych wyjść do składowych głównych, zależy od wariancji tych składowych i dla kilku ostatnich może być bardzo wolna. W przypadku opracowanego estymatora prędkości, składowe te i tak zostają pominięte. Dodatkową zaletą reguły (4.49) jest możliwość wyznaczenia jedynie p pierwszych składowych głównych - wystarczy przyjąć \mathbf{W} o wymiarach $p \times n$. Zauważmy, że GHA dotyczy sieci z zerowymi progami. Przy pomocy progów możemy zrealizować usuwanie składowej stałej. Zakładając notację Matlaba 6.5, tworzymy obiekt

$$gha_nn = \text{newff}(\text{repmat}([-1, 1], n, 1), p, \{'purelin'\}) \quad (4.50)$$

i przyjmujemy

$$gha_nn.IW\{1\} = \mathbf{W} \quad (4.51)$$

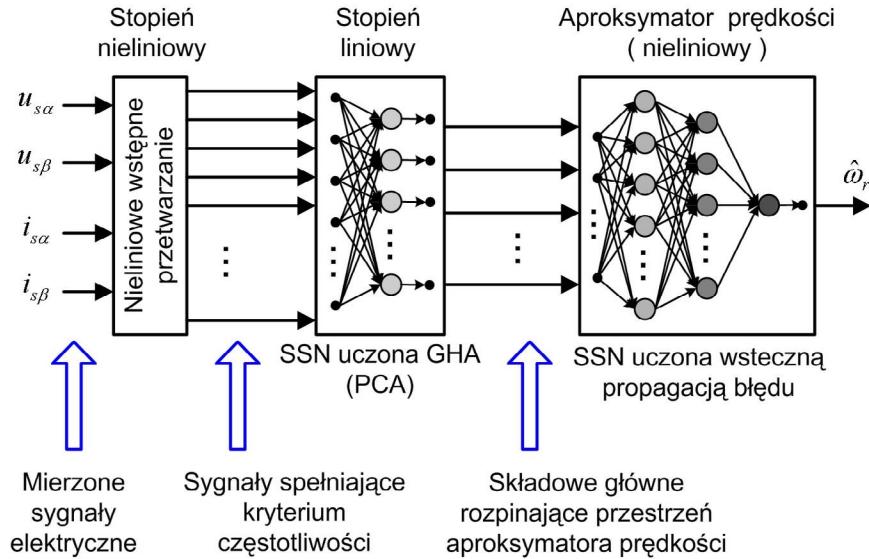
oraz progi (biasy)

$$gha_nn.b\{1\} = -\mathbf{W} * \text{mean}(\mathbf{X}')'. \quad (4.52)$$

Przyjmując, że przetwarzamy zmienne standaryzowane, możemy sformułować kilka prostych kryteriów zatrzymania procedury ekstrakcji kolejnych składowych:

- *a priori* - po wyznaczeniu określonej liczby składowych;
- *sumarycznej wariancji* - do osiągnięcia sumarycznej wariancji składowych stanowiącej określony procent całkowitej wariancji sygnałów (zazwyczaj 95%);
- *Kaisera (pierwiastka charakterystycznego)* - do otrzymania wszystkich wektorów odpowiadających wartościom własnym nie mniejszym od 1, tj. kierunki o wariancji nie mniejszej niż wariancja pojedynczego sygnału wejściowego;
- *Scree test* - graficzne rozwiązanie otrzymywane na wykresie wartości własne jako malejącej funkcji numeru składowej (subiektywne).

Estymator prędkości projektowany z wykorzystaniem PCA składa się z dwustopniowego wstępniego przetwarzania mierzonych sygnałów elektrycznych oraz neuronowego aproksymatora funkcji nieliniowej. Pierwszy stopień (nieliniowy) wstępniego przetwarzania realizuje, narzucone przez kryteria przydatności w proponowanej architekturze, dopasowanie częstotliwościowe sygnałów oraz rozszerzenie bazy aproksymatora. Drugi stopień (liniowy), wykorzystujący model PCA, generuje zestaw sygnałów dla neuronowego aproksymatora funkcji. Stopień liniowy pozwala ograniczyć rozmiar zbioru uczącego, przy jednoczesnej maksymalizacji informacji o stanie obiektu obserwowanego. Schemat estymatora przedstawia rysunek 4.20.



Rysunek 4.20. Neuronowy estymator prędkości kątowej wirnika silnika indukcyjnego z dwustopniowym wstępny przetwarzaniem sygnałów i przestrzenią aproksymatora rozpoczętą na składowych głównych

Model PCA służy do wyznaczenia optymalnych kierunków obserwacji. Związane jest to niestety z redukcją wymiaru przestrzeni aproksymatora w stosunku do liczby proporcjonowanych przekształceń nieliniowych. Jest to podstawowa cecha modelu PCA, który pozwala aproksymować dane przy użyciu mniejszej liczby zmiennych, czyli dokonuje kompresji liczby wymiarów. Niemniej jednak liczba sensownych kierunków obserwacji jest większa od początkowej liczby czterech sygnałów elektrycznych. Algorytm PCA wykorzystuje statystykę drugiego rzędu i gwarantuje dekorelację (ortogonalność) sygnałów przetworzonych z jednoczesną redukcją szumów [155]. Wszystkie te cechy PCA mają pozytywny wpływ na przebieg procesu uczenia aproksymatora prędkości i generalizację w trybie odtwarzania. Z uwagi na szeregowe połączenie dwóch struktur neuronowych, omawiany estymator może być interpretowany jako blok przekształceń algorytmicznych i blok hybrydowej sieci neuronowej, w której pierwsza warstwa uczona jest bez nauczyciela, a kolejne z nauczycielem. Wyniki badań symulacyjnych i eksperymentalnych nad tą strukturą opublikowano w [156, 157]. Porównując niniejsze rozwiązanie z algorytmem największego spadku liczby warunkowej, należy przed wszystkim podkreślić, że **redukacja wymiarowości przy użyciu PCA nie pociąga za sobą utraty użytecznej informacji. Eliminacja metodą największego spadku liczby warunkowej jest związana z utratą części informacji niesionej przez odrzucane sygnały.** Wadą estymatora z pośrednim przetwarzaniem PCA jest konieczność wykonania w czasie rzeczywistym wszystkich opracowanych przekształceń nieliniowych generujących sygnały wejściowe dla bloku neuronowego. Wady tej nie posiada estymator zaprojektowany w oparciu o eliminację metodą największego gradientu liczby warunkowej. W rozwiązaniu tym implementujemy bowiem jedynie te

przekształcenia nieliniowe, które otrzymaliśmy jako zredukowaną bazę aproksymatora neuronowego.

4.5.4. Analiza składowych niezależnych

Wśród algorytmów dedykowanych określaniu cech zbiorów wielu sygnałów na szczególną uwagę zasługuje analiza składowych niezależnych ICA (Independent Component Analysis) [16, 158, 159]. Podstawowym założeniem tego modelu jest minimalizacja wspólnych cech tworzonych składowych. Jest to ściśle związane z pojęciem statystycznej niezależności. Mówimy, że dwie zmienne y_i i y_j są niezależne, jeżeli informacja o wartości zmiennej y_i nie daje żadnej informacji o wartości zmiennej y_j i odwrotnie. Niezależność statystyczna dwóch sygnałów definiowana jest poprzez gęstość prawdopodobieństwa. Sygnały są niezależne wtedy i tylko wtedy, gdy gęstość rozkładu łącznego prawdopodobieństwa jest równa iloczynowi gęstości brzegowych [155]. Najważniejszą cechą zmiennych niezależnych jest prawdziwość równości

$$E \{f_i(y_i) f_j(y_j)\} = E \{f_i(y_i)\} E \{f_j(y_j)\} \quad (4.53)$$

dla dowolnych funkcji f_i i f_j . Zauważmy, że niezależność implikuje nieskorelowanie (liniowe). Przyjmując w (4.53) $f_i(y) = f_j(y) = y$, otrzymujemy

$$E \{y_i y_j\} = E \{y_i\} E \{y_j\}, \quad (4.54)$$

co jest równoważne zerowej kowariancji. Latwo bowiem pokazać, że

$$\sigma_{ij} = \frac{1}{k} \sum (y_i - \mu_i)(y_j - \mu_j) = E \{y_i y_j\} - E \{y_i\} E \{y_j\}. \quad (4.55)$$

Z drugiej jednak strony nieskorelowanie (ortogonalność) nie oznacza niezależności. Prostym przykładem zmiennych zależnych nieskorelowanych są $y_1 = [0, 0, 1, -1]$ oraz $y_2 = [1, -1, 0, 0]$, dla których

$$E \{y_1 y_2\} = E \{y_1\} E \{y_2\} = 0, \quad (4.56)$$

ale, na przykład,

$$E \{y_1^2 y_2^2\} = 0 \quad (4.57)$$

$$E \{y_1^2\} E \{y_2^2\} = \frac{1}{4} \neq E \{y_1^2 y_2^2\}. \quad (4.58)$$

Mówi się, że nieskorelowanie jest słabszą wersją niezależności [155].

Sygnały wejściowe neuronowego aproksymatora prędkości kątowej wirnika generowane przez model PCA nie są niezależne. Zadano sobie pytanie, czy wykorzystanie bazy niezależnych statystycznie sygnałów pozwoli na uzyskanie lepszych wyników, niż w przypadku bazy ortogonalnej? Zbudowano neuronowy model ICA. Uczenie takiego modelu polega

na minimalizacji wspólnej informacji niesionej przez sygnały. Prawidłowo nauczony model rozwiązuje tzw. zadanie ślepej separacji źródeł (*ang.* Blind Source Separation, BSS) zwane też pod nazwą problemu koktajl party (*ang.* Coctail-party Problem) [155, 160]. Model ten wykorzystywany jest do ekstrakcji cech, między innymi, w elektroencefalografii (EEG) [161] i tomografii (funkcjonalny rezonans jądrowy fMRI) [2].

Istnieją algorytmy samoorganizacji jednowarstwowego perceptronu liniowego zbieżne do składowych niezależnych. Liczna grupa spośród nich wykorzystuje kurtozę (kumulant statystyczny czwartego rzędu, względny moment centralny czwartego rzędu):

$$\text{kurt}(y) = \frac{\frac{1}{n} \sum (y - \mu)^4}{\left(\frac{1}{n} \sum (y - \mu)^2\right)^2} \stackrel{\mu=0}{=} \frac{E\{y^4\}}{(E\{y^2\})^2} \quad (4.59)$$

lub eksces (eksces kurtozy [148]):

$$\gamma_{\text{kurt}} = \text{kurt}(y) - 3 \stackrel{\mu=0}{=} \frac{E\{y^4\}}{(E\{y^2\})^2} - 3, \quad (4.60)$$

jako miarę poprawnej separacji składowych. W przeprowadzonych badaniach wykorzystano **nieliniową** regułę hebbowskiego i antyhebbowskiego uczenia perceptronu **liniowego**, określoną zależnościami:

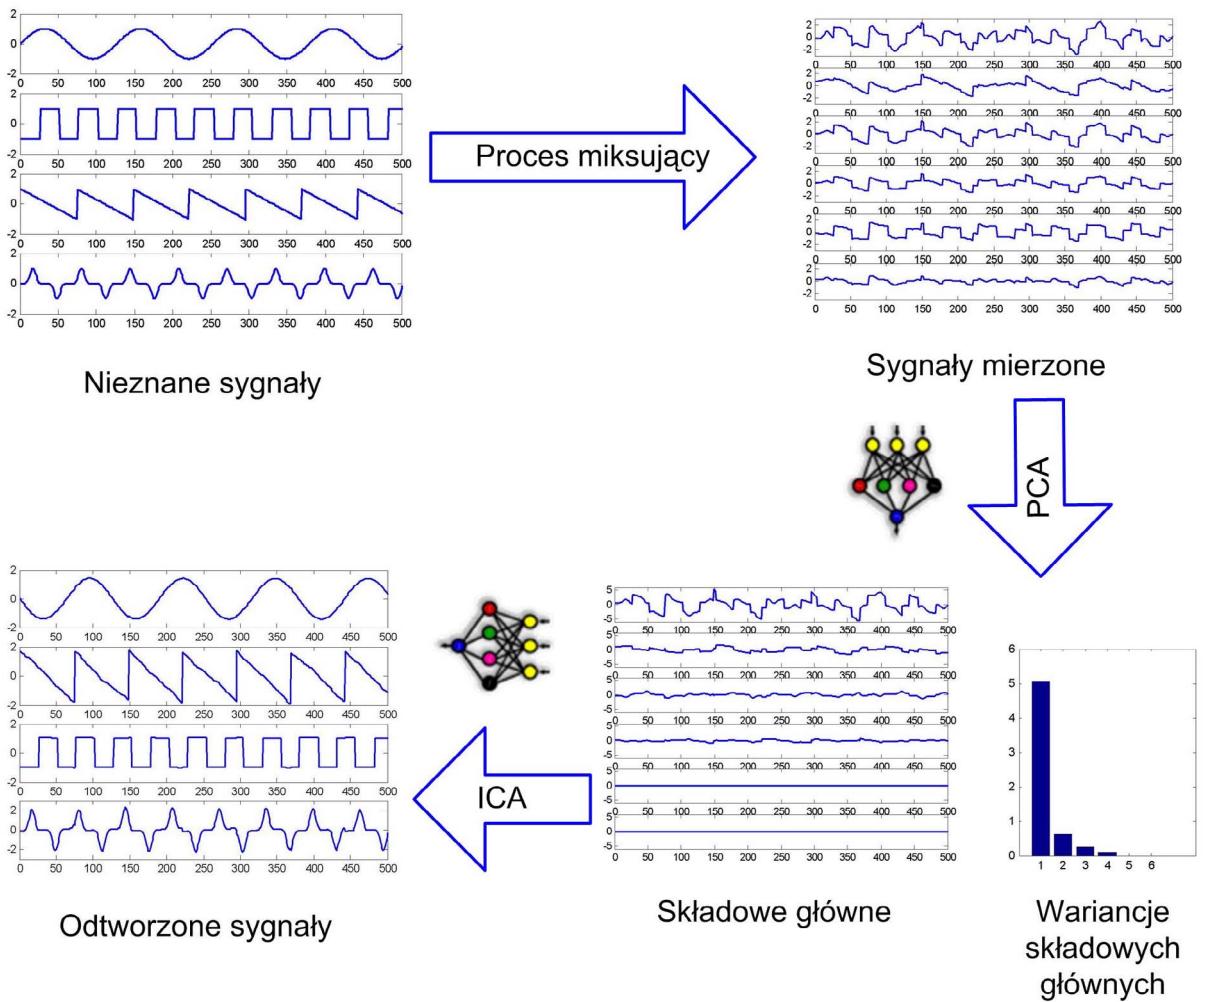
$$\Delta \mathbf{W} = \eta \mathbf{X} \cdot f(\mathbf{X}^T \mathbf{W} \cdot \text{diag}(\text{sign}(\mathbf{c}))) + \alpha \mathbf{W} (\mathbf{I} - \mathbf{W}^T \mathbf{W}), \quad (4.61)$$

$$\mathbf{c} = E \left\{ \mathbf{W}^T \mathbf{X} \cdot f(\mathbf{W}^T \mathbf{X}) - \frac{d}{dt} f(\mathbf{W}^T \mathbf{X}) \right\}, \quad (4.62)$$

gdzie $f(z) = \tanh(2z)$ oraz $\frac{d}{dt} f(z) = 2(1 - \tanh^2(2z))$. Dla prawidłowo dobranych współczynników η i α , wyjścia tego modelu $y = \mathbf{W}^T \mathbf{X}$ są zbieżne do składowych niezależnych. Uzasadnienie wzorów (4.61) i (4.62) oraz reguły doboru występującej w nich nieliniowej funkcji kontrastującej f można znaleźć między innymi w [16, 160, 155, 162, 163]. W algorytmie tym sygnały podane na wejścia modelu muszą być wybielone (sferowane), tj. musi zachodzić

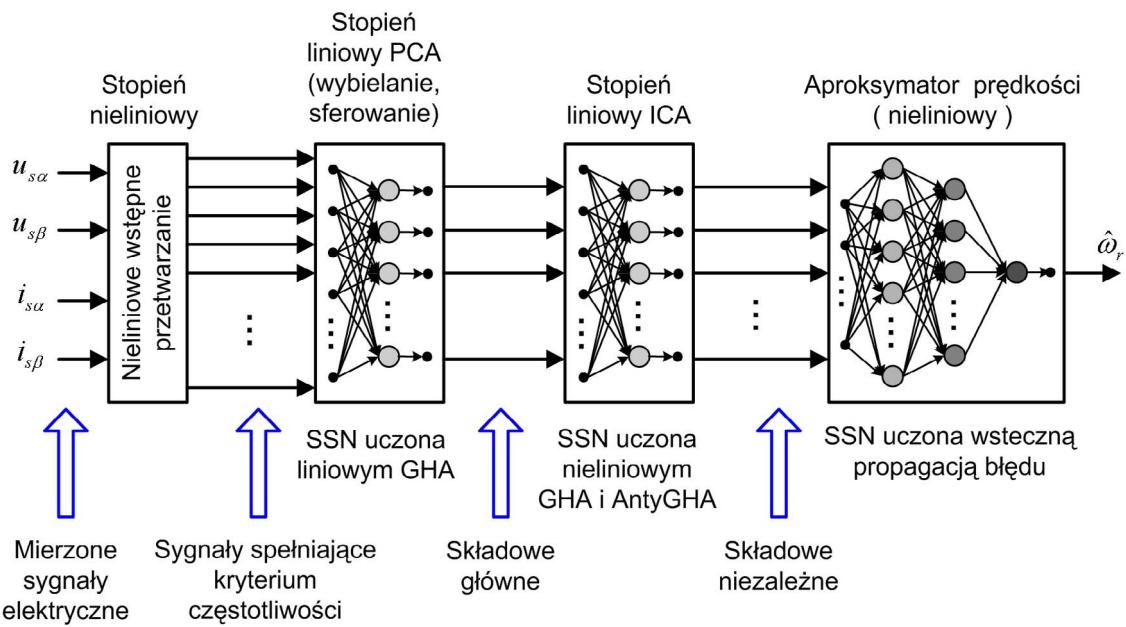
$$E\{\mathbf{X} \mathbf{X}^T\} = \mathbf{I}, \quad (4.63)$$

gdzie \mathbf{I} jest macierzą jednostkową. Sferowanie można wykonać przy użyciu modelu PCA. Wystarczy wyznaczone składowe główne przeskalać do jednostkowej wariancji. Dodatkowo model PCA, który realizuje w tym rozwiążaniu wstępne przetwarzanie dla modelu ICA, pozwala określić liczbę składowych niezależnych równą liczbie wyekstrahowanych składowych głównych. Liczbę tę otrzymujemy oczywiście na mocy jednego z omówionych kryteriów (a priori, sumarycznej wariancji, Kaisera, Scree test). Ilustrację działania tych algorytmów przedstawiono na rysunku 4.21. W przykładzie tym założono, że należy odtworzyć nieznane sygnały na podstawie sygnałów mierzonych, będących liniowymi kombinacjami sygnałów źródłowych, przy braku jakichkolwiek informacji o procesie miksującym.

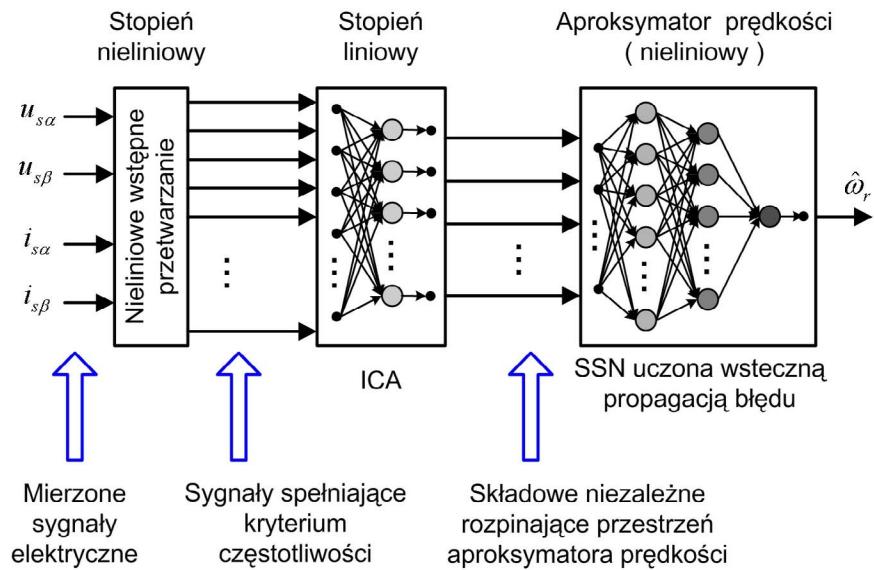


Rysunek 4.21. Ilustracja działania algorytmu odtwarzania nieznanych sygnałów źródłowych przy użyciu analizy składowych niezależnych

Zbudowano estymator neuronowy prędkości o strukturze jak na rysunku 4.22. Estymator ten składa się z bloku przekształceń nieliniowych, sieci wybielającej sygnały (PCA), sieci generującej składowe niezależne (ICA) oraz neuronowego aproksymatora prędkości kątowej wirnika silnika. W rozwiązaniu tym pojawia się połączenie dwóch warstw liniowych - warstwy realizującej wyznaczanie składowych głównych (wybielanie) i warstwy ekstrahującej składowe niezależne. Przechodząc do implementacji należy te dwie warstwy zastąpić jedną warstwą równoważną. Jest to oczywiście zawsze możliwe, bo złożenie dwóch przekształceń liniowych jest też przekształceniem liniowym. W konsekwencji otrzymujemy estymator jak na rysunku 4.23. Jego złożoność i liczba operacji numerycznych jakie należy wykonać w czasie rzeczywistym, jest identyczna jak dla estymatora z ortogonalną bazą aproksymatora. Otrzymany stopień liniowy ICA zweryfikowano przy użyciu pakietu FastICA [164]. Przeprowadzone badania nie wskazują na polepszenie odtwarzania prędkości w stosunku do aproksymatora z bazą ortogonalną. Można zatem przyjąć, że rozwiązania przedstawione na rysunkach 4.20 i 4.23 należy traktować alternatywnie, bez wskazania na lepsze lub gorsze.



Rysunek 4.22. Neuronowy estymator prędkości kątowej wirnika silnika indukcyjnego z trójestopniowym wstępnym przetwarzaniem sygnałów i przestrzenią aproksymatora rozpiętą na składowych niezależnych



Rysunek 4.23. Neuronowy estymator prędkości kątowej wirnika silnika indukcyjnego z dwustopniowym wstępnym przetwarzaniem sygnałów i przestrzenią aproksymatora rozpiętą na składowych niezależnych

4.5.5. Klasteryzacja

Żadna z opisanych wyżej metod tworzenia bazy aproksymatora neuronowego nie weryfikuje sygnałów kandydackich pod kątem ich związku z odtwarzaną prędkością. Oceny tej możemy dokonać dopiero analizując spadek błędu uczenia sieci. Algorytm największego spadku liczby warunkowej, analiza składowych głównych PCA i analiza składowych niezależnych ICA gwarantują uzyskanie zestawu silnie liniowo niezależnych sygnałów, co oczywiście nie jest jedynym warunkiem skutecznej aproksymacji sygnału odtwarzanego. PCA i ICA zapewniają niemal bezstratną kompresję liczby wymiarów, ale jednocześnie wymagają implementacji wszystkich podlegających analizie przekształceń nieliniowych sygnałów mierzonych. Z kolei algorytm największego gradientu liczby warunkowej pozwala na implementację jedynie wybranych przekształceń nieliniowych, z jednoczesną niepożądaną możliwością wyeliminowania sygnałów silnie skorelowanych z sygnałem odtwarzanym. Opracowano interaktywną procedurę selekcji $p < n$ sygnałów ze zbioru kandydackiego $U = \{u_1, u_2, \dots, u_n\}$, bazującą na następujących założeniach:

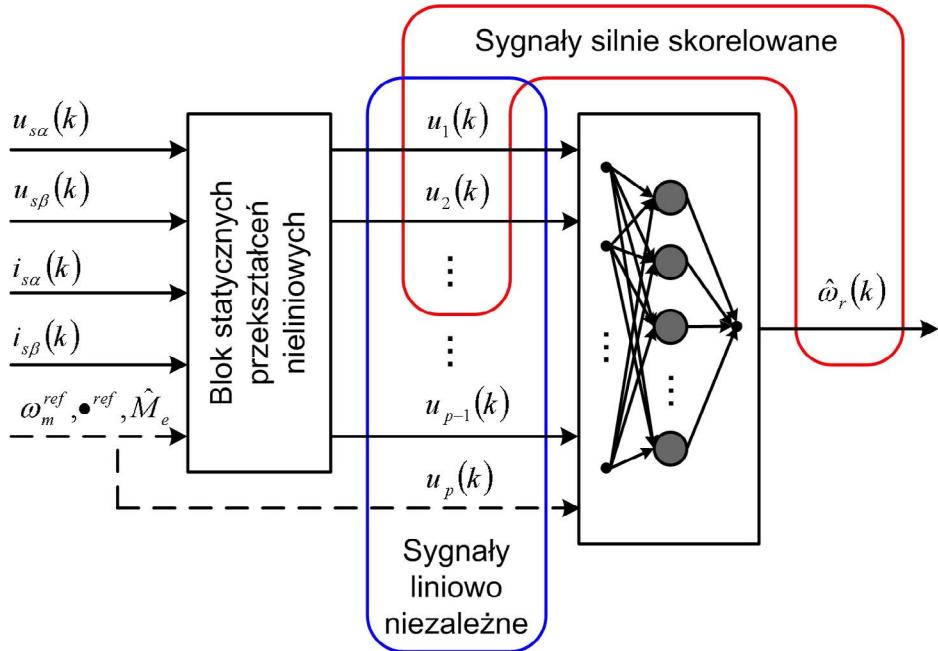
- każde ograniczenie liczby sygnałów poniżej liczby p_{PCA} składowych głównych, uzywanej na podstawie analizy PCA z typowym progiem 95%, wiąże się z utratą części informacji niesionej przez sygnały kandydackie;
- tworzenie bazy aproksymatora ma polegać na odrzucaniu sygnałów ze zbioru U , co umożliwi ograniczenie liczby przekształceń nieliniowych koniecznych do wykonania w czasie rzeczywistym;
- ze zbioru U nie wolno odrzucić l sygnałów o największych współczynnikach korelacji $r_{i\omega}$, $i = 1 \dots n$, z sygnałem prędkości kątowej wirnika;
- otrzymany zbiór ma zawierać możliwie silnie liniowo niezależne sygnały.

Założenie (d) jest w dużej mierze sprzeczne z założeniem (c). Pozostawienie w zbiorze chociaż dwóch sygnałów silnie skorelowanych z sygnałem odtwarzanym, a tym samym silnie skorelowanych ze sobą, obniża znacząco stopień liniowej niezależności sygnałów w zbiorze wynikowym. Należy zatem przyjąć, że (c) ma większą wagę niż (d). Oznacza to klasteryzację zbioru U na podzbiór U_l zawierający l sygnałów najsilniej skorelowanych z sygnałem odtwarzanym oraz podzbiór dopełniający U_{n-l} . Pozostaje jeszcze podanie wzorów określających liczbę sygnałów p oraz liczbę sygnałów l . Sformułowano heurystyczne zależności, odnoszące się jedynie do obiektu dynamicznego będącego przedmiotem badań:

$$l = \left[\frac{p_{PCA}}{2} \right], \quad (4.64)$$

$$p = l + p_{PCA}. \quad (4.65)$$

Stwierdzono bowiem, że dla zbioru $15 - 25$ sygnałów (określonych wzorami (4.13)-(4.18) i (4.20)-(4.33) oraz dodatkowo prędkość zadana, wyjścia regulatorów, moment elektromagnetyczny), opisujących układ napędowy, otrzymujemy $p_{PCA} \in \{6, 7, 8, 9\}$. Stosując (4.65), ograniczamy liczbę sygnałów tworzących bazę aproksymatora prędkości do, odpowiednio $p \in \{9, 10, 12, 13\}$. Należy przy tym podkreślić, że zaproponowane wzory (4.64) i (4.65) mają sens jedynie przy analizie wielowymiarowej (przyjmijmy $n \geq 15$). Dla małej liczby sygnałów, np. $n = 5$, zazwyczaj otrzymujemy na ich podstawie $p \geq n$, co słusznie sugeruje, że zbiór U nie zawiera informacji nadmiarowej i najlepiej wykorzystać wszystkie n sygnałów jako wejścia aproksymatora neuronowego. Interaktywność procedury polega na wyświetleniu uporządkowanych współczynników korelacji $r_{i\omega}$, wariancji kolejnych składowych głównych oraz wyznaczonych p_{PCA} , l , p . Osoba projektująca bazę aproksymatora, może zaakceptować wyznaczone parametry p_{PCA} , l , p lub zmodyfikować je poprzez wykorzystanie innego kryterium na p_{PCA} , bądź określić l i p arbitralnie. Następnie, metodą największego spadku liczby warunkowej, ze zbioru U_{n-l} eliminowane jest $n - p$ sygnałów, przy czym **liczba warunkowa wyznaczana jest każdorazowo dla zbioru poszerzonego o sygnały nie podlegające eliminacji**. Otrzymujemy w ten sposób możliwie najlepsze spełnienie warunku (d) przy jednoczesnym spełnieniu warunku (c). Końcowym efektem działania procedury jest wyświetlenie nazw (numerów) sygnałów tworzących bazę aproksymatora prędkości kątowej wirnika. Schemat otrzymanego estymatora przedstawiono na rysunku 4.24.



Rysunek 4.24. Aproksymator prędkości kątowej wirnika, z liniowo niezależnymi sygnałami wejściowymi i silną korelacją między wyjściem i wybranymi wejściami

4.6. Podsumowanie

Propozycje odtwarzania prędkości kątowej wirnika silnika klatkowego przy użyciu sztucznych sieci neuronowych trenowanych off-line wynikają z założenia, że w prądach i napięciach stojana zawarta jest wystarczająca informacja o wartości rozważanej wielkości mechanicznej. W typowych rozwiązaniach neuronowych tego zadania, mierzone prądy i napięcia stojana podawane są (zazwyczaj po liniowym przetworzeniu do składowych prostokątnych $\alpha\beta$) bezpośrednio na wejścia perceptronu wielowarstwowego estymującego prędkość. Modelowanie dynamiki odbywa się poprzez rozbudowanie bazy aproksymatora o opóźnione wartości prądów i napięć (linie opóźnień na wejściach) oraz niekiedy o opóźnione wartości wyjścia sieci (sprzężenie rekurencyjne). Podstawowym problemem tych architektur jest częstotliwościowe **niedopasowanie** sygnałów wejściowych sieci i wyjściowego sygnału prędkości. Dodatkowo w rozwiązaniach z liniami opóźnień, konieczne jest spełnienia warunku równości częstotliwości próbkowania zbioru uczącego i częstotliwości pracy estymatora w trybie odtwarzania, co niepotrzebnie rozbudowuje zbiór uczący. Pojawia się również problem rozróżnialności sygnałów wejściowych sieci. Z kolei najprostsze rozwiązania rekurencyjne (sekwencyjna sieć Jordana) nie dają gwarancji stabilności otrzymanego modelu. W rozdziale zaproponowano wstępne nieliniowe przetwarzanie sygnałów prądów i napięć zapewniające częstotliwościowe dopasowanie sygnałów wejściowych sieci do sygnału odtwarzanej prędkości kątowej wirnika. Umożliwiło to m.in. zredukowanie linii opóźnień do zera. W konsekwencji tego otrzymano strukturę w pełni statyczną. Dodatkowo rozważono możliwość rozbudowania bazy aproksymatora o sygnały dostępne w układzie sterowania, takie jak wartości zadane, wyjścia regulatorów, inne wielkości estymowane. Omówiono szereg analiz korelacyjnych pozwalających na tworzenie, w oparciu o sygnały spełniające kryterium dopasowania częstotliwościowego, efektywnej bazy neuronowego aproksymatora prędkości. Wyniki badań symulacyjnych i eksperymentalnych opracowanych struktur przedstawiono w kolejnych rozdziałach pracy.

Rozdział 5

Neuronowy estymator strumienia stojana z dynamicznym wstępnym przetwarzaniem sygnałów elektrycznych

5.1. Ograniczenia modelu napięciowego

Niemal każdy napęd wektorowy prądu przemennego z silnikiem klatkowym, zawiera w swej strukturze sterowania, estymator strumienia stojana lub wirnika. Właściwości dynamiczne napędu bezczujnikowego zależą głównie od dokładności estymat strumieni i prędkości, wykorzystywanych do wyznaczania sterowania. Jak już wspomniano w rozdziale 3., strumienie można uzyskać jako wyjścia wielu modeli [18, 119] lub zrekonstruować przy użyciu filtra Kalmana [25], bądź obserwatora Luenbergera [43, 44, 46]. Niemniej jednak, w wielu aplikacjach strumień stojana wyznaczany jest w oparciu o tzw. model napięciowy:

$$\underline{\psi}_s(t) = \underline{\psi}_s(t_0) + \int_{t_0}^t (\underline{u}_s(t) - \hat{R}_s \underline{i}_s(t)) dt, \quad (5.1)$$

w którym \hat{R}_s jest odtwarzaną rezystancją stojana. Model ten jest szczególnie preferowany w napędach bez czujnika prędkości. W napędach tych model prądowy musiałby być pobudzany niepewną estymatą prędkości. Prawidłowe modelowanie rezystancji stojana ma kluczowe znaczenie dla stabilności sterowania przy małych prędkościach. Napęd znajduje się wówczas w punktach pracy, dla których rezystancyjny spadek napięcia $R_s \underline{i}_s$ jest porównywalny z przyłożonym napięciem \underline{u}_s . Należy przy tym podkreślić, że prawidłowa adaptacja parametru \hat{R}_s jest niezbędna nie tylko dla właściwej pracy układu w obszarze

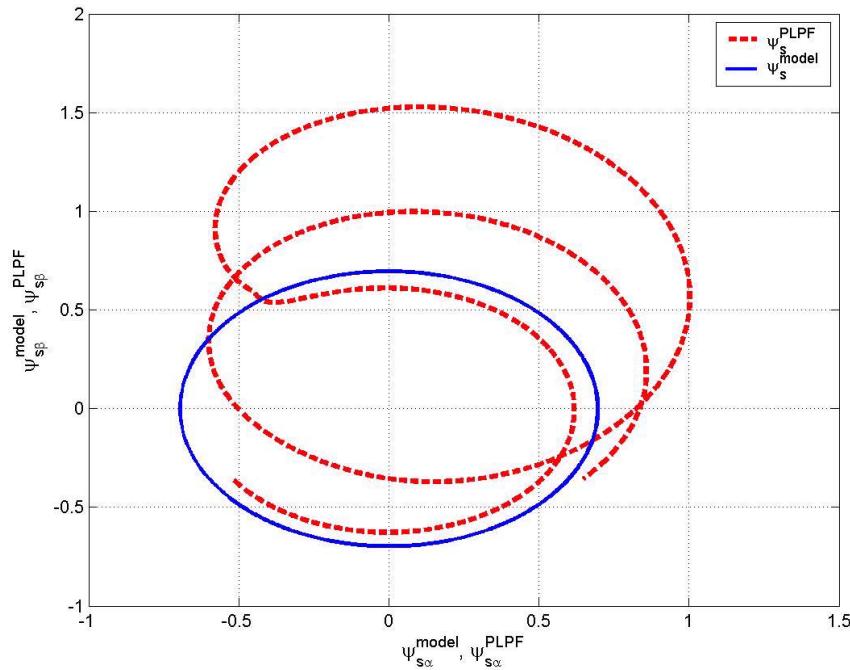
małych prędkości (częstotliwości stojana). Wiele algorytmów sterowania wektorowego silnikiem indukcyjnym, jest bardzo czułych na niedokładności w określeniu R_s , w szczególności gdy rozważane są stany przejściowe zawierające zerowe prędkości (na przykład nawrót od prędkości znamionowej do przeciwej). W napędach tych możemy obserwować wyraźne pogorszenie dynamiki, aż do niestabilności spowodowanej nieprawidłową orientacją układu odniesienia, w którym wyznaczane są wielkości sterujące. Praktyczna implementacja modelu (5.1) wymaga rozwiązania problemów związanych z idealnym integratorem i adaptacją występującą w nim rezystancji. W rozdziale 3. opisano wybrane realizacje całkowania rozwiązujące problem dryftu i warunków początkowych. Do najsukcesniejszych, zdaniem autora, należy zaliczyć:

- przestrajany filtr dolnoprzepustowy (PLPF) z korekcją fazy i amplitudy [131];
- integrator z ogranicznikiem amplitudy we współrzędnych biegunowych [124];
- integrator z adaptacyjną kompensacją (amplituda strojona we współrzędnych biegunowych przy użyciu regulatora PI i sygnału błędu proporcjonalnego do iloczynu skalarnego wektora siły elektromotorycznej i odtworzonego strumienia) [124];
- idealny integrator dla szerokopasmowej rekonstrukcji strumienia stojana z estymatorem offsetu napięcia [165];
- integrator z korekcją typu PI wykorzystującą zadaną amplitudę strumienia [138].

Jakikolwiek schemat odtwarzania strumienia stojana zawierający całkowanie indukowanej siły elektromotorycznej, wymaga dodatkowego algorytmu adaptacji parametru \hat{R}_s . Ze wszystkich czynników zewnętrznych największy wpływ na rezystancję ma temperatura. Błąd modelowania rezystancji stojana wynikający ze zmian temperatury uzwojeń, może prowadzić do nieakceptowalnych błędów odtwarzania strumienia. W przedziale temperatur -30°C do 150°C zależność rezystancji od temperatury można, z dobrym przybliżeniem, opisać wzorem

$$R_T = R_{T_0} (1 + \alpha_T (T - T_0)), \quad (5.2)$$

gdzie α_T oznacza termiczny współczynnik rezystywności TWR (dla miedzi $\alpha_T \cong 0.0043 \text{ K}^{-1}$). Konsekwencją tego jest, na przykład, zmiana rezystancji uzwojeń o ponad 20%, przy wzroście temperatury o 50°C . Na rysunku 5.1 przedstawiono trajektorię strumienia stojana odtworzonego przy użyciu przestrajanego filtra dolnoprzepustowego z kompensacją fazy i amplitudy opisanego w [131], przy założeniu wzrostu rezystancji stojana o 30% i braku algorytmu adaptacji, tj. $R_s = 1.3\hat{R}_s$. Zauważmy, że niedokładność rzędu 30% w określeniu rozważanego parametru, prowadzi do błędów odtwarzania strumienia przekraczających 100%. Nadązna identyfikacja rezystancji stojana i wirnika jest tematem wielu publikacji (np. [165, 44, 8, 166]) i nie będzie omawiana w niniejszej pracy.



Rysunek 5.1. Trajektoria fazowa strumienia stojana podczas nawrota odtworzona przy użyciu PLPF i nieprawidłowej identyfikacji rezystancji stojana ($R_s = 1.3\hat{R}_s$)

5.2. Rekonstrukcja strumienia stojana wspomagana sieciami neuronowymi

Jak dotąd, opracowano szereg SSN rozwiązujących niektóre problemy związane z rekonstrukcją strumienia stojana, w szczególności:

- nadążną identyfikację rezystancji stojana [8, 166];
- całkowanie [12, 17];
- eliminację składowej stałej z sygnału całkowanego i wyniku całkowania [14].

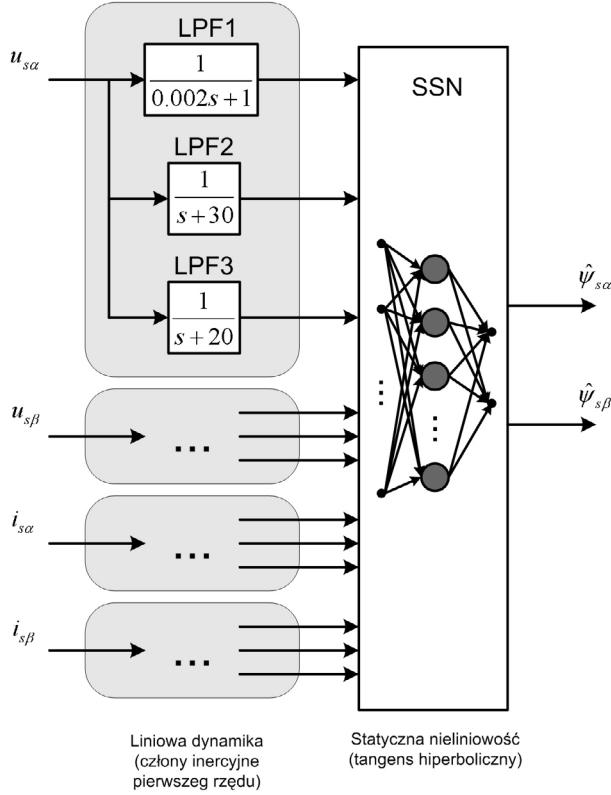
Propozowane struktury nie wykorzystują jednak potencjalnych możliwości związanych z nieliniowym zachowaniem sieci neuronowych. Wszystkie wymienione rozwiązania oparto na liniowej sieci neuronowej. Wyjątkiem może być jedynie [12]. Niemniej jednak i tutaj główna sieć neuronowa posiada liniowe funkcje aktywacji - jedynie pomocnicza sieć generująca dla niej wagę jest nieliniowa.

Pierwszą, znaną autorowi, próbę estymacji strumienia wykorzystującą "inteligentne" zachowania nieliniowej sieci neuronowej (np. generalizację) opisano w [13] oraz przytoczono w [6]. Idea polega na odtwarzaniu składowych strumienia bezpośrednio na podstawie prądów i napięć stojana w miejscu siły elektromotorycznej (patrz rys. 3.14 w rozdziale 3).

Rezystancja stojana nie występuje jawnie w takim modelu. Zawierając zmiany R_s w zbiorze uczącym, możliwym staje się uzyskanie pewnego stopnia odporności nauczonej struktury na zmiany tego parametru. Jednocześnie, obecność przynajmniej jednej warstwy z ograniczoną funkcją aktywacji (np. sigmoidalną unipolarną lub tangensem hiperbolicznym) zapewnia ograniczone wartości wyjść, co powoduje brak niepożądanego zjawiska dryftu. Pomimo niewątpliwych zalet, zaproponowany schemat posiada kilka poważnych ograniczeń wynikających z obecności sieci rekurencyjnej. Przede wszystkim narzuca równe okresy próbkowania w fazie uczenia i odtwarzania. Z jednej strony, chcąc uzyskać odpowiednią gładkość estymaty, musimy przyjąć krótkie okresy próbkowania (np. $\frac{1}{100}$ okresu strumienia w warunkach znamionowych). Z drugiej jednak strony, uzyskany zbiór uczący będzie bardzo duży i proces uczenia może okazać się trudny do przeprowadzenia na komputerze klasy PC. Dodatkowo, brak jest gwarancji stabilnej pracy estymatora po przejściu do konfiguracji równoległej (patrz rozdział 3.). Te i inne cechy rekurencyjnych sieci neuronowych uzasadniają poszukiwanie nowego zbioru zmiennych (różnego od $\{\underline{u}_s, \underline{i}_s\}$), opisującego obiekt, który przekształca zadanie modelowania dynamiki w relację statyczną łatwą do aproksymowania przy użyciu jednokierunkowej sieci neuronowej [145]. W rezultacie możliwe stanie się zróżnicowanie częstotliwości próbkowania zbioru uczącego i częstotliwości odtwarzania oraz wyeliminowany zostanie problem niestabilności emulatora. Oczywiście, system jako całość może zachowywać się niestabilnie wskutek błędów odtwarzania strumienia, niemniej jednak emulator obiektu będzie stabilny z zasady. Szczegółowe omówienie korzyści wynikających z zastąpienia architektury rekurencyjnej strukturą jednokierunkową, zamieszczono w rozdziale 4.

5.3. Neuronowy aproksymator składowych strumienia stojana ze wstępny dynamicznym przetwarzaniem sygnałów

W typowym rozwiązaniu neuronowym zadania aproksymowania dynamiki obiektu, historia w czasie wprowadzana jest na wejścia sieci przy użyciu linii opóźnień i sprzężeń rekurencyjnych (rys. 4.2 w rozdziale 4.). W wielu sytuacjach uzyskanie odpowiedniej dokładności wymaga użycia bardzo długich linii opóźnień (dłuższych niż 20). Nieefektywność takich rozwiązań polega na wprowadzaniu na wejścia sieci opóźnionych wartości sygnałów opisujących obiekt, bez ich uprzedniego przetworzenia. Autor stwierdził, w toku prowadzonych badań, że dodatkowe dynamiczne przetwarzanie sygnałów prądów i napięć pozwala na wyeliminowanie rekursji ze schematu 3.14. W opracowanym estymatorze, historia w czasie wprowadzana jest na wejścia neuronowego aproksymatora funkcji nielinio-



Rysunek 5.2. Neuronowy estymator strumienia stojana ze wstępny dynamicznym przetwarzaniem sygnałów elektrycznych

wej w sposób pośredni, przy pomocy członów inercyjnych pierwszego rzędu. Zbiór wielkości elektrycznych stojana $\{u_{s\alpha}, u_{s\beta}, i_{s\alpha}, i_{s\beta}\}$ przekształcany jest w sposób dynamiczny, przy użyciu trzech różnych filtrów dolnoprzepustowych, w zbiór 12-stu zmiennych opisujących $\{u_{s\alpha}^{LPF1}, u_{s\alpha}^{LPF2}, u_{s\alpha}^{LPF3}, u_{s\beta}^{LPF1}, u_{s\beta}^{LPF2}, u_{s\beta}^{LPF3}, i_{s\alpha}^{LPF1}, i_{s\alpha}^{LPF2}, i_{s\alpha}^{LPF3}, i_{s\beta}^{LPF1}, i_{s\beta}^{LPF2}, i_{s\beta}^{LPF3}\}$, przy czym przykładowo

$$u_{s\alpha}^{LPF1} = u_{s\alpha} \frac{1}{s + \omega_1}; \quad (5.3)$$

$$u_{s\alpha}^{LPF2} = u_{s\alpha} \frac{1}{s + \omega_2}; \quad (5.4)$$

$$u_{s\alpha}^{LPF3} = u_{s\alpha} \frac{1}{s + \omega_3}. \quad (5.5)$$

Pozostałe zmienne opisujące tworzone są w sposób analogiczny. Biegunki $-\omega_1, -\omega_2, -\omega_3$ dobrane zostały metodą prób i błędów. Stwierdzono, że najlepsze wyniki uzyskuje się, gdy dwa spośród nich realizują przybliżone całkowanie a trzeci ma stosunkowo małą stałą czasową (odfiltrowuje jedynie szумy). Te prawie nieprzetworzone dynamicznie sygnały wraz z sygnałami reprezentującymi w sposób przybliżony całki z wielkości elektrycznych tworzą przestrzeń, która przekształca rozważane zadanie modelowania (w szerokim zakresie stanów układu dynamicznego) w zagadnienie aproksymowania relacji typu funkcja. Schemat otrzymanego estymatora przedstawiono na rysunku 5.2. Zaproponowany schemat posiada kilka wyraźnych zalet:

- brak problemu dryftu (w odróżnieniu od nieskompensowanego idealnego integratora);
- możliwość zróżnicowania okresów próbkowania w fazie uczenia i odtwarzania (w przeciwieństwie do architektury z liniami opóźnień i/lub rekurencją);
- odporność na zmiany rezystancji stojana (w odróżnieniu od każdej metody bazującej na całkowaniu indukowanej siły elektromotorycznej, przy założeniu braku nadążej identyfikacji rezystancji).

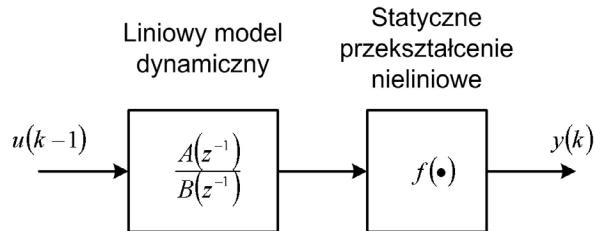
Dwie z nich wydają się być szczególnie ważne. Po pierwsze, rozmiar zbioru uczącego może zostać zdecydowanie zmniejszony. Przykładowo, w trakcie badań prowadzonych nad opisaną strukturą, estymator był próbkowany z okresem 10^{-4} s (podyktowanym gładkością rekonstruowanego przebiegu), podczas gdy zbiór uczący uzyskano przy próbkowaniu z okresem 10^{-2} s (w pewnym stopniu wynikającym z twierdzenia Shannona o próbkowaniu). Konsekwencją tego było 100-krotne zredukowanie rozmiaru zbioru uczącego, w stosunku do podobnego dla sieci z liniami opóźnień. Po drugie, estymator cechuje pewna odporność na zmiany R_s . Jest to zrozumiałe z uwagi na niewystępowanie tego parametru w propozowanej strukturze. Wspomniana niewrażliwość wzrasta znacząco, gdy zmiany R_s zostają wprowadzone do zbioru uczącego (patrz rozdział 6.). Opracowany estymator może być rozumiany jako szeregowe połączenie niezmennego w czasie liniowego systemu dynamicznego (LTI, Linear Time Invariant) oraz bloku statycznych przekształceń nieliniowych (w tym przypadku realizowanych przy użyciu SSN). Pod tym względem może zostać zaliczony do szerszej grupy modeli identyfikacji Wienera (rys. 5.3).

Zaproponowaną strukturę można również interpretować jako filtr dolnoprzepustowy z neuronowym korektorem fazy i amplitudy. Zauważmy bowiem, że zależność (5.1) daje się zapisać w postaci

$$\begin{aligned} \underline{\psi}_s(t) &= \underline{\psi}_s(t_0) + \int_{t_0}^t \underline{u}_s(t) dt - \int_{t_0}^t \hat{R}_s \underline{i}_s(t) dt \stackrel{\hat{R}_s = \text{const}}{=} \\ &= \underline{\psi}_s(t_0) + \int_{t_0}^t \underline{u}_s(t) dt - \hat{R}_s \int_{t_0}^t \underline{i}_s(t) dt. \end{aligned} \quad (5.6)$$

Przybliżone wartości sygnałów $\int_{t_0}^t \underline{u}_s(t) dt$ oraz $\int_{t_0}^t \underline{i}_s(t) dt$ generowane przez filtry LPF2 i LPF3 (patrz rys. 5.2), są wejściami nieliniowej sieci neuronowej realizującej między innymi korekcję fazy i amplitudy.

Koncepcję omówionego neuronowego aproksymatora składowych strumienia stojana opublikowano w [167].



Rysunek 5.3. Model Wienera nieliniowego obiektu dynamicznego

5.4. Podsumowanie

Estymatory algorytmiczne strumienia stojana bazujące na całkowaniu indukowanej siły elektromotorycznej nie pozwalają, przy założeniu braku dodatkowej nadążej identyfikacji rezystancji, na dostatecznie precyzyjną orientację sterowania w układach DSFOC. Temperaturowy wzrost rezystancji stojana rzędu 30% powoduje wyraźne pogorszenie dynamiki układu i może prowadzić do niestabilnej pracy napędu. Odtwarzanie strumienia stojana na podstawie prądów i napięć stojana podawanych bezpośrednio na wejścia SSN, daje potencjalne możliwości uodpornienia tej struktury na zmiany parametru modelu napięciowego. Proponowane w literaturze rozwiązanie wykorzystuje rekurencyjną sieć neuronową. Niestety estymator ten odziedziczył szereg wad związanych z uczeniem sieci rekurencyjnej. W rozdziale zaproponowano estymator neuronowy ze wstępny dynamiczny przetwarzaniem mierzonych sygnałów elektrycznych. Nowe zmienne opisujące pozwoliły na przekształcenie problemu modelowania w zagadnienie odtwarzania relacji typu funkcja. Dzięki temu uniknięto szeregu problemów związanych ze stosowaniem sieci rekurencyjnych. Zachowano jednocześnie "inteligentne" działanie estymatora przy zmianach parametru obiektu.

Rozdział 6

Badania symulacyjne opracowanych estymatorów prędkości kątowej wirnika i wektora strumienia stojana silnika indukcyjnego

6.1. Opis układu sterowania

Na potrzeby symulacyjnych badań estymatorów prędkości i strumienia, zbudowano model napędu prądu przemiennego ze sterowaniem polowo-zorientowanym. Spośród szeregu dostępnych rozwiązań sterowania wektorowego, zdecydowano się na układ regulacji DSFOC (Direct Stator Field Oriented Control) [18]. Dokonując tego wyboru kierowano się następującymi założeniami:

- układ ma posiadać dobre właściwości ruchowe,
- algorytm sterowania, w realizacji bezczujnikowej, powinien wymuszać obecność estymatora strumienia stojana i prędkości kątowej wirnika, które to w konsekwencji przeprowadzonych badań zostaną zastąpione estymatorami neuronowymi,
- pojawiające się w układzie sprzężenia zwrotne powinny pochodzić od wielkości mierzonych (prądy stojana) i bezpośrednio od wielkości estymowanych, z wykorzystaniem sztucznych sieci neuronowych (zgodnie z założeniami rozprawy - strumienia stojana i prędkości kątowej wirnika).

Brak sprzężeń od wielkości innych, niż wyżej wymienione, ma ułatwić interpretowanie zmian pojawiających się w układzie przy przejściu z sygnału mierzonego (modelowanego matematycznie) na estymowany. Dodatkowo założono, że silnik indukcyjny sterowany jest

prądowo. Stąd rolą układu regulacji jest wypracowanie zadanych wartości składowych prądu stojana.

Po pewnych uproszczeniach (związkanych z pominięciem wpływu anizotropii, nasycenia magnetycznego, zjawisk histerezy, prądów wirowych, wyższych harmonicznych przestrzennego rozkładu pola w szczelinie powietrznej, koncentracji uzwojeń), symetryczny trójfazowy silnik klatkowy można opisać, w wirującym układzie współrzędnych xy związanym z wektorem strumienia stojana, równaniami

$$\underline{u}_s = R_s \underline{i}_s + \frac{d}{dt} \underline{\psi}_s + j\omega_{\psi s} \underline{\psi}_s \quad (6.1)$$

$$0 = R_r \dot{\underline{i}}_r + \frac{d}{dt} \underline{\psi}_r + j(\omega_{\psi s} - p_b \omega_m) \underline{\psi}_r \quad (6.2)$$

$$\underline{\psi}_s = L_s \underline{i}_s + L_m \underline{i}_r \quad (6.3)$$

$$\underline{\psi}_r = L_r \dot{\underline{i}}_r + L_m \underline{i}_s \quad (6.4)$$

$$M_e = \frac{3}{2} p_b (\underline{\psi}_s \times \underline{i}_s) \quad (6.5)$$

$$\frac{d}{dt} \omega_m = \frac{1}{J} (M_e - M_z), \quad (6.6)$$

gdzie poszczególne oznaczenia jak w (2.1) oraz dodatkowo M_e - moment wytwarzany w maszynie, $\omega_{\psi s}$ - prędkość kątowa wirowania układu współrzędnych równa w metodzie SFOC prędkości kątowej wektora przestrzennego $\underline{\psi}_s$ strumienia stojana. U podstaw wykorzystanej metody sterowania leży przyjęcie układu odniesienia, tak aby $\psi_{sy} = 0$, czyli $\underline{\psi}_s = \psi_{sx}$. Równanie (6.5) określające moment elektromagnetyczny przybiera wtedy postać

$$M_e = \frac{3}{2} p_b (\underline{\psi}_s \times \underline{i}_s) = \psi_{sx} i_{sy} - \psi_{sy} i_{sx} \stackrel{\psi_{sy}=0}{=} \psi_{sx} i_{sy}. \quad (6.7)$$

Zakładając, że układ regulacji zapewnia $\psi_{sx} = const$, otrzymujemy proporcjonalność rozwijanego momentu elektromagnetycznego do składowej i_{sy} prądu stojana. Z kolei strumień ψ_{sx} można regulować składową i_{sx} . Niestety, tak zaproponowane tory regulacji nie są odsprzężone - zmiany i_{sy} skutkują pojawieniem się stanów przejściowych na ψ_{sx} . Jest to zjawisko doskonale znane i wynika ono bezpośrednio z równań (6.2)–(6.4). Oznaczając $\omega_{\psi s} - p_b \omega_m = \omega_{sl}$, otrzymujemy układ równań

$$0 = R_r \dot{\underline{i}}_r + \frac{d}{dt} \underline{\psi}_r + j\omega_{sl} \underline{\psi}_r \quad (6.8)$$

$$\underline{\psi}_s = L_s \underline{i}_s + L_m \dot{\underline{i}}_r \quad (6.9)$$

$$\underline{\psi}_r = L_r \dot{\underline{i}}_r + L_m \underline{i}_s. \quad (6.10)$$

Wyznaczając $\dot{\underline{i}}_r$ z (6.9) i wstawiając do (6.10) mamy

$$\underline{\psi}_r = \frac{L_r}{L_m} (\underline{\psi}_s - L_s \underline{i}_s) + L_m \dot{\underline{i}}_s = \frac{L_r}{L_m} (\underline{\psi}_s - \sigma L_s \underline{i}_s), \quad (6.11)$$

gdzie $\sigma = 1 - \frac{L_m^2}{L_s L_r}$. Podstawiając (6.11) do (6.8) uzyskujemy

$$0 = \frac{R_r}{L_m} \left(\underline{\psi}_s - L_s \underline{i}_s \right) + \frac{L_r}{L_m} \frac{d}{dt} \underline{\psi}_s - \frac{\sigma L_r L_s}{L_m} \frac{d}{dt} \underline{i}_s + j\omega_{sl} \frac{L_r}{L_m} \left(\underline{\psi}_s - \sigma L_s \underline{i}_s \right). \quad (6.12)$$

Rozpisując (6.12) na część rzeczywistą i urojoną oraz uwzględniając $\psi_{sy} = 0$, otrzymujemy

$$\frac{1}{\sigma L_s} \frac{d}{dt} \psi_{sx} + \frac{1}{\sigma \tau_r L_s} \psi_{sx} = \frac{d}{dt} i_{sx} + \frac{1}{\sigma \tau_r} i_{sx} - \omega_{sl} i_{sy} \quad (6.13)$$

$$\omega_{sl} \left(\frac{\psi_{sx}}{\sigma L_s} - i_{sx} \right) = \frac{d}{dt} i_{sy} + \frac{1}{\sigma \tau_r} i_{sy}, \quad (6.14)$$

przy czym $\tau_r = \frac{L_r}{R_r}$. Zależność (6.13) opisuje sprzężenie między i_{sy} i ψ_{sx} . Zadanie bloku od-sprzęgającego, polega na takim modyfikowaniu sygnału i_{sx}^{ref} , będącego wyjściem regulatora strumienia, aby w stanach dynamicznych zmiany i_{sy} nie powodowały stanów przejściowych na ψ_{sx} . Odsprzężenie uzyskujemy dodając do wyjścia regulatora strumienia sygnał i_{xy} , taki że

$$i_{sx} = i_{sx}^{ref} + i_{xy} = const \text{ dla } \psi_{sx}^{ref} = const. \quad (6.15)$$

Wstawiając $i_{sx} = i_{sx}^{ref} + i_{xy}$ do (6.13), otrzymujemy

$$\frac{1}{\sigma L_s} \frac{d}{dt} \psi_{sx} + \frac{1}{\sigma \tau_r L_s} \psi_{sx} = \frac{d}{dt} i_{sx}^{ref} + \frac{1}{\sigma \tau_r} i_{sx}^{ref} + \underbrace{\frac{d}{dt} i_{xy} + \frac{1}{\sigma \tau_r} i_{xy} - \omega_{sl} i_{sy}}_{\text{odsp. strumienia}}. \quad (6.16)$$

Przyrównując do zera wyszczególnioną w (6.16) sumę, odspółczamy tor regulacji strumienia od toru regulacji momentu. Należy zatem przyjąć

$$\frac{d}{dt} i_{xy} + \frac{1}{\sigma \tau_r} i_{xy} = \omega_{sl} i_{sy}, \quad (6.17)$$

przy czym ω_{sl} wyznaczamy z zależności (6.14). Z równania (6.17) wynika, że i_{xy} otrzymujemy jako wyjście członu inercyjnego pierwszego rzędu o biegunie $-\frac{1}{\sigma \tau_r}$, pobudzanego wymuszeniem $\omega_{sl} i_{sy}$. Wyznaczenie ω_{sl} wiąże się ze zróżniczkowaniem składowej prądu i_{sy} , co w przypadku napędu przekształtnikowego jest działaniem trudnym, obarczonym dużymi niedokładnościami mogącymi prowadzić do niestabilności układu napędowego. Dlatego w praktyce przyjmuje się przybliżone rozwiązanie (np. [126, 128, 129, 12]):

$$i_{xy} = \frac{\sigma L_s i_{sy}^2}{\psi_{sx} - \sigma L_s i_{sx}}, \quad (6.18)$$

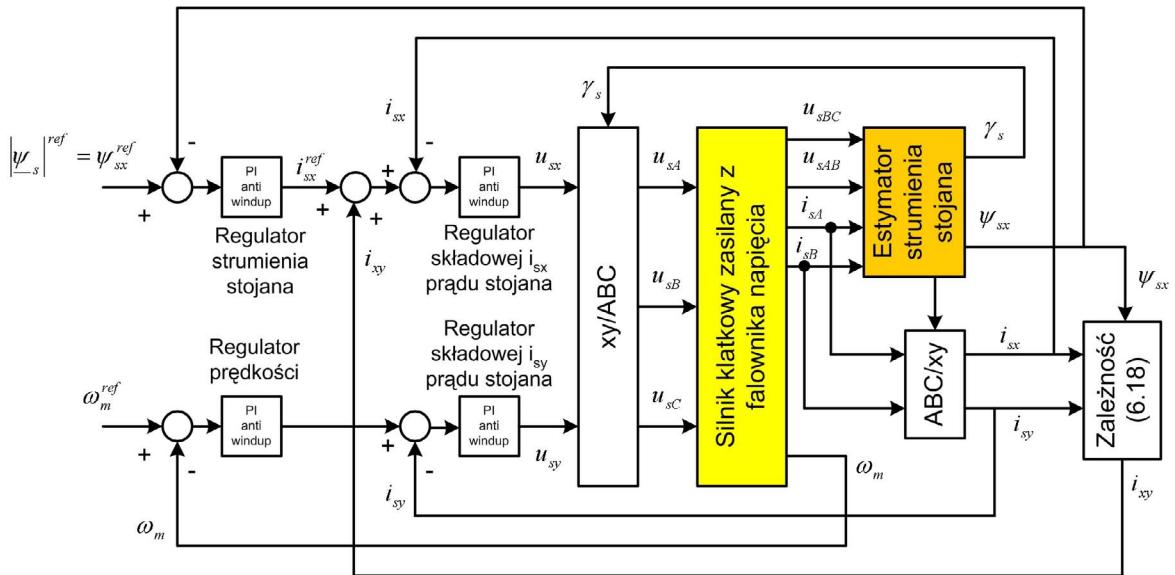
które zakłada pominięcie pochodnych w (6.14) i (6.17). W rzeczywistości nie oznacza to jednak całkowitego pominięcia wpływu tych pochodnych na rozwiązanie. Zauważmy, że wstawiając (6.14) do (6.17), otrzymujemy

$$\frac{d}{dt} i_{xy} + \frac{1}{\sigma \tau_r} i_{xy} = \left(\frac{d}{dt} i_{sy} + \frac{1}{\sigma \tau_r} i_{sy} \right) i_{sy} \frac{\sigma L_s}{\psi_{sx} - \sigma L_s i_{sx}}. \quad (6.19)$$

Natomiast (6.18) jest rozwiązaniem dokładnym bardzo zbliżonego równania

$$\frac{d}{dt} i_{xy} + \frac{1}{\sigma \tau_r} i_{xy} = \left(2 \frac{d}{dt} i_{sy} + \frac{1}{\sigma \tau_r} i_{sy} \right) i_{sy} \frac{\sigma L_s}{\psi_{sx} - \sigma L_s i_{sx}}. \quad (6.20)$$

Poglądowy schemat układu regulacji przedstawiono na rysunku 6.1.



Rysunek 6.1. Schemat układu regulacji DSFOC

W środowisku Matlab&Simulink [1] zbudowano model symulacyjny napędu DSFOC w dwóch wersjach. W wersji pierwszej założono, że falownik napięcia jest liniowym wzmacniaczem mocy. Uznanie, że z uwagi na konfigurację układów odtwarzania wybranych zmiennych stanu, dopuszczalne jest pominięcie wyższych harmonicznych wymuszenia napęciowego. Model symulacyjny zawiera filtry dolnoprzepustowe w torach pomiarowych, wprowadzające przesunięcie fazowe i zmianę amplitudy sygnałów wykorzystywanych do estymacji. Model ten liczony jest z krokiem 10^{-4} s. Dodatkowo modelowany jest również szum pomiarowy i systemowy. W drugiej wersji zamodelowano przekształtnik wraz z modulatorem wektorowym DPWM (Discontinuous Pulse Width Modulation) [168, 169], pracującym z częstotliwością 10 kHz. Zamodelowanie modulatora PWM wymusiło krok obliczeń rzędu 10^{-6} s. Off-line'owe trenowanie neuronowych estymatorów, wymaga generowania zbiorów uczących, w miarę równomiernie pokrywających przestrzeń możliwych stanów układu, uwzględniających również zmiany parametrów obiektu i układu regulacji. Z tych powodów zdecydowaną większość badań symulacyjnych przeprowadzono na modelu pierwszym. Końcową weryfikację stanowić będą eksperymenty z wykorzystaniem rzeczywistego silnika zasilanego z falownika napięcia. Do badań użyto silnik klatkowy o parametrach podanych w tabeli 6.1.

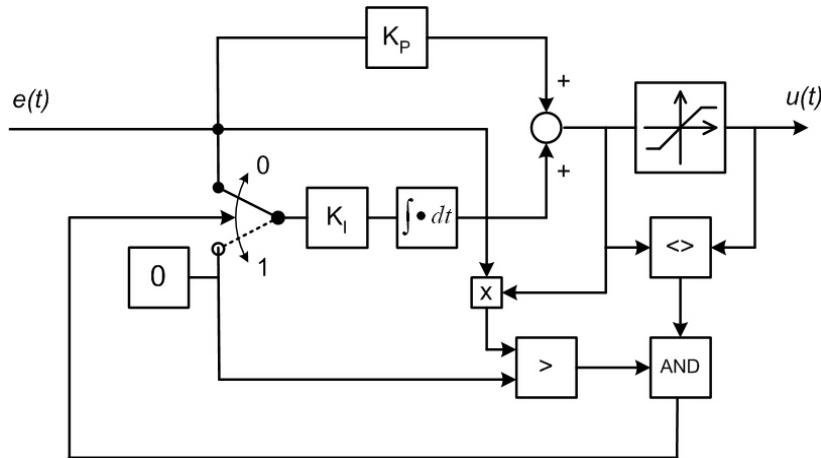
Tablica 6.1. Parametry silnika

Lp.	Parametr	Symbol	Jednostka	Wartość
1	Moc znamionowa	P_N	kW	1.5
2	Napięcie znamionowe Δ/Y	U_Δ/U_Y	V	127/220
3	Prąd znamionowy Δ/Y	I_Δ/I_Y	A	12.0/6.9
4	Prędkość znamionowa	n_N	obr / min	930
5	Rezystancja stojana (dla 25 °C)	R_s	Ω	1.540
6	Rezystancja wirnika	R_r	Ω	1.294
7	Indukcyjność stojana	L_s	mH	100.4
8	Indukcyjność wirnika	L_r	mH	96.9
9	Indukcyjność wzajemna	L_m	mH	91.5
10	Liczba par biegunów	p_b	—	3
11	Moment bezwładności	J	kg m ²	0.15

Wykorzystany układ regulacji zawiera cztery regulatory typu PI. Liniowy regulator PI realizuje zależność

$$u(t) = K_P e(t) + K_I \int_0^t e(t) dt, \quad (6.21)$$

gdzie: u - sygnał sterujący, e - uchyb regulacji, K_P , K_I - wzmacnienia odpowiednio w torze proporcjonalnym i całkującym. Praktyczna realizacja struktury (6.21) wymaga wprowadzenia ograniczenia na sygnał wyjściowy regulatora, z jednoczesnym modyfikowaniem działania części całkującej. Związane jest to z tzw. efektem *windup'u* [170]. Zagadnienie *anti-windup'u* jest szeroko omawiane w literaturze (np. [171, 172, 173, 174]). Proponowane coraz to nowsze rozwiązania wskazują na brak algorytmu "idealnego". Autorzy podkreślają konieczność projektowania sposobu ograniczania części całkującej w zależności od obiektu regulacji. Najpopularniejsze schematy anti-windup'u można podzielić na dwie grupy. Pierwsza z nich zawiera algorytmy wprowadzające ujemne sprzężenie zwrotne obejmujące część całkującą (ang. *tracking anti-windup, back-calculation*), natomiast druga - algorytmy realizujące odcinanie całkowania (ang. *conditional integration, clamping*). W układzie regulacji z rysunku 6.1 wykorzystano regulatory nieliniowe z warunkowym całkowaniem jak na rysunku 6.2. Decyzję o zastosowaniu takiego, a nie innego algorytmu anti-windup'u, podjęto po porównawczych badaniach kilkunastu rozwiązań znanych autorowi z literatury. Wybrana struktura regulatorów zapewnia dobre właściwości dynamiczne układu przy jednocześnie małych przeregulowaniach. Nastawy regulatorów dobrano wstępnie przy pomocy Matlab® NCD Blockset oraz dostrojono metodą prób i błędów. Przechodząc do realizacji dyskretnej nieliniowego regulatora PI z anti-windup'em, należy wybrać pomiędzy algorytmem pozycyjnym (bezwzględnym) i prędkościowym (przyrostowym). Jedne strategie



Rysunek 6.2. Nieliniowy regulator typu PI z anti-windup'em zrealizowany poprzez warunkowe całkowanie [172, 174]

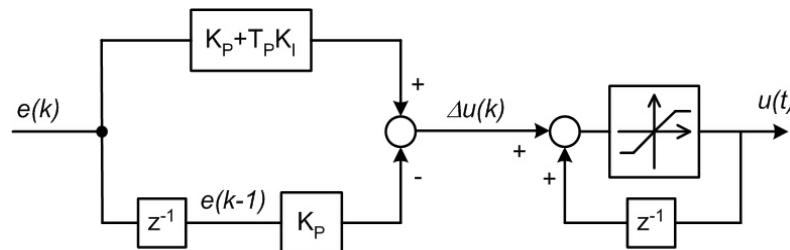
anti-windup'u są wygodniejsze w realizacji przy wykorzystaniu algorytmu prędkościowego (np. tracking anti-windup), inne zaś dedykowane są realizacji prędkościowej. Dyskretyzacja zależności (6.21), przy założeniu $\dot{u}(t = kT_P) \approx \frac{u(k) - u(k-1)}{T_P}$ oraz $\dot{e}(t = kT_P) \approx \frac{e(k) - e(k-1)}{T_P}$, prowadzi do równania

$$u(k) = u(k-1) + K_P e(k) + T_P K_I e(k) - K_P e(k-1), \quad (6.22)$$

gdzie T_P oznacza okres próbkowania. Oznaczając $\Delta u(k) = u(k) - u(k-1)$, otrzymujemy

$$\Delta u(k) = K_P e(k) + T_P K_I e(k) - K_P e(k-1). \quad (6.23)$$

Zależność (6.23) opisuje postać prędkościową algorytmu PI. Szeregowo rozbudowanie tej struktury o sumator z nasyceniem (rys. 6.3), prowadzi do uzyskania ograniczonych bezwzględnych wartości sygnału sterującego, bez konieczności implementowania dodatkowej logiki właściwej realizacji ciągłej z rysunku 6.2. Zaletą algorytmu prędkościowego jest brak zjawiska windup'u integratora. Odpowiednie rozbudowanie algorytmu prędkościowego do pozycyjnego pozwala na skutecną realizację nieliniowego regulatora typu PI, generującego bezwzględne wartości sterowania. Strukturę z rysunku 6.3 wykorzystano przy realizacji układu eksperymentalnego.



Rysunek 6.3. Dyskretna realizacja nieliniowego regulatora PI

6.2. Badania neuronowych estymatorów prędkości kątowej wirnika

W celu umożliwienia porównania metod doboru sygnałów wejściowych dla zaproponowanej w rozdziale 4. architektury neuronowego estymatora prędkości, założono istnienie dwóch niezmiennych podczas kolejnych symulacji zestawów parametrów wymuszeń. Pierwszy z nich służy do generowania zbiorów uczących, drugi - testowania estymatorów. Zestawy te różnią się ziarnami generatorów pseudolosowych prędkości zadanej i momentu zakłócenia. Wybrane parametry symulacji zebrane w tabeli 6.2. Zauważmy, że w modelu

Tablica 6.2. Parametry symulacji

Lp.	Parametr	Jednostka	Wartość [Zakres]
1	Czas symulacji	s	[0; 150]
2	Okres próbkowania modelu	μs	100
3	Okres próbkowania zbioru uczącego	ms	10
4	Rezystancja stojana R_s	Ω	[1; 2]
5	Okres wywoływania generatora losowego R_s	s	0.2
6	Prędkość zadana ω_m^{ref}	rad/s	[-100; 100]
7	Okres wywoływania generatora losowego ω_m^{ref}	s	1
8	Moment zakłócający M_z	N m	[-15; 15]
9	Okres wywoływania generatora losowego M_z	s	1

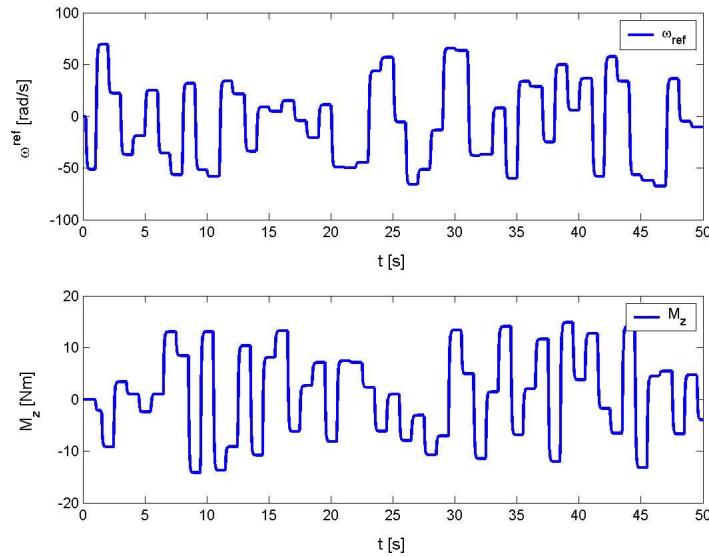
wykorzystanym do zbierania próbek uczących, uwzględniono zmiany rezystancji stojana w zakresie $\pm 30\%$ wartości znamionowej. Przykładowy fragment profilu prędkości zadanej i momentu zakłócającego dla zbioru uczącego przedstawiono na rysunku 6.4. Do uczenia sieci użyto zmodyfikowanego przez Levenberga i Marquardta algorytmu propagacji wstecznej. Przy porównywaniu różnych rozwiązań posłużono się błędem średniokwadratowym

$$\bar{e} = \frac{1}{k_{\max}} \sum_{k=1}^{k=k_{\max}} (\hat{\omega}_m(k) - \omega_m(k))^2. \quad (6.24)$$

Dodatkowo, każdy rysunek przedstawiający prędkość estymowaną, uzupełniono o wykres błędu odtwarzania

$$e(k) = \hat{\omega}_m(k) - \omega_m(k). \quad (6.25)$$

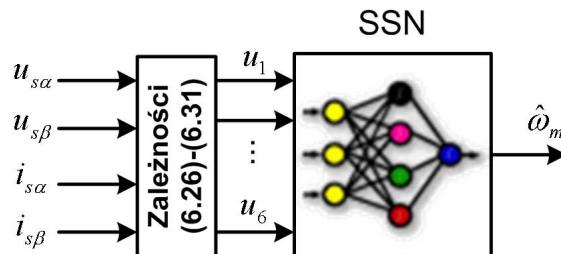
Opracowane estymatory prędkości przetestowano wstępnie przy założeniu stałości parametrów silnika i układu regulacji. Na podstawie uzyskanych wyników, dokonano analizy porównawczej metod tworzenia bazy aproksymatora neuronowego. Wybrane rozwiązanie



Rysunek 6.4. Fragment profilu prędkości zadanej i momentu obciążenia wykorzystanego przy tworzeniu zbioru uczącego

poddano następnie szczegółowym badaniom, uwzględniającym zmiany wybranych parametrów obiektu regulacji (momentu bezwładności i rezystancji stojana) oraz zmianę nastaw regulatorów (poziomu ograniczenia prądowego w torze regulacji prędkości kątowej wirnika).

6.2.1. Estymator prędkości kątowej wirnika - struktura A



Rysunek 6.5. Schemat estymatora A

W oparciu o analizę częstotliwościową i czasowo-częstotliwościową, zweryfikowano dopasowanie sygnałów (4.13)–(4.18), tj.

$$u_1 = |\underline{u}_s| = \sqrt{u_{s\alpha}^2 + u_{s\beta}^2} \quad (6.26)$$

$$u_2 = |i_s| = \sqrt{i_{s\alpha}^2 + i_{s\beta}^2} \quad (6.27)$$

$$u_3 = \Re(\underline{u}_s \underline{i}_s^*) = i_{s\alpha} u_{s\alpha} + i_{s\beta} u_{s\beta} \quad (6.28)$$

$$u_4 = \Im(\underline{u}_s \underline{i}_s^*) = i_{s\alpha} u_{s\beta} - i_{s\beta} u_{s\alpha} \quad (6.29)$$

$$u_5 = \Re\left(\frac{\underline{u}_s}{\underline{i}_s}\right) = \frac{i_{s\alpha}u_{s\alpha} + i_{s\beta}u_{s\beta}}{i_{s\alpha}^2 + i_{s\beta}^2} \quad (6.30)$$

$$u_6 = \Im\left(\frac{\underline{u}_s}{\underline{i}_s}\right) = \frac{i_{s\alpha}u_{s\beta} - i_{s\beta}u_{s\alpha}}{i_{s\alpha}^2 + i_{s\beta}^2}, \quad (6.31)$$

do sygnału odtwarzanej prędkości. Dla kontrastu, na rysunkach 6.6 i 6.7 podano również widma nieprzetworzonego sygnału składowej prądu stojana i nieprawidłowo przetworzonego $u_{21} = i_{s\alpha}u_{s\beta} + i_{s\beta}u_{s\alpha}$. W oparciu o sygnały (6.26)–(6.31) nauczono sieć 6–7–3–1 aproksymowania prędkości w strukturze z rysunku 4.18. Konfigurację modelu symulacyjnego przedstawiono na rysunku 6.8. Estymator przetestowano w układzie ze sprzężeniem od prędkości modelowanej (rys. 6.9a) i układzie ze sprzężeniem od prędkości estymowanej (rys. 6.9b). Zauważmy, że największe błędy odtwarzania występują w stanach zmian sygnału prędkości zadanej. Należy przy tym podkreślić, że nawet stosunkowo duże błędy estymacji w stanach przejściowych napędu, mogą pozostawać bez wpływu na funkcjonowanie rozważanego napędu DSFOC. Związane jest to z nasycaniem się regulatora prędkości (rys. 6.10). Nieliniowa charakterystyka regulatora, znacząco ogranicza wpływ błędu odtwarzania na pracę układu, w wybranych stanach przejściowych, wywołanych zmianą prędkości zadanej. Zjawiskiem bardzo korzystnym jest wysoka korelacja zmiennej boolowskiej

$$u_{sat} = \begin{cases} 1 & \text{dla regulatora nienasyconego} \\ 0 & \text{dla regulatora nasyconego} \end{cases} \quad (6.32)$$

ze zmienną określającą występowanie największych błędów odtwarzania (rys. 6.11). Przydatne staje się więc wprowadzenie nowej zmiennej określającej błąd odtwarzania

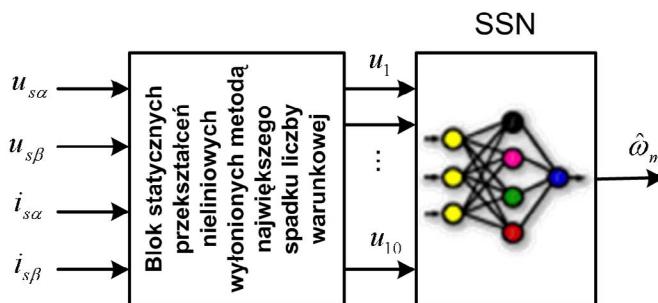
$$e_{sat}(k) = (\hat{\omega}_m(k) - \omega_m(k)) u_{sat}(k). \quad (6.33)$$

Pozwala ona na analizowanie błędu odtwarzania z pominięciem stanów, w których błąd ten nie ma znaczącego wpływu na pracę napędu. Wykres tak określonego błędu przedstawiono na rysunku 6.12. W oparciu o zależność (6.33), zdefiniowano wskaźnik jakości analogiczny do (6.24):

$$\bar{e}_{sat} = \frac{1}{k'_{\max}} \sum_{k=1}^{k=k_{\max}} (\hat{\omega}_m(k) - \omega_m(k))^2 u_{sat}(k), \quad (6.34)$$

przy czym k'_{\max} jest liczbą niezerowych elementów wektora \mathbf{u}_{sat} . Wskaźniki (6.24) oraz (6.34), wyznaczone dla założonego profilu wymuszeń testujących (zgodnego z parametrami określonymi w tabeli 6.2), zebrano w tabeli 6.3 na stronie 123. Jakość odtwarzania zbadano w układzie ze sprzężeniem zwrotnym od prędkości modelowanej ($\bar{e}^{enkoder}$, $\bar{e}_{sat}^{enkoder}$), oraz po przełączeniu sprzężenia zwrotnego na sygnał prędkości estymowanej (\bar{e}^{SSN} , \bar{e}_{sat}^{SSN}). Estymator A umożliwił stabilną pracę napędu bezczujnikowego dla założonego charakteru pobudzeń.

6.2.2. Estymator prędkości kątowej wirnika - struktura B



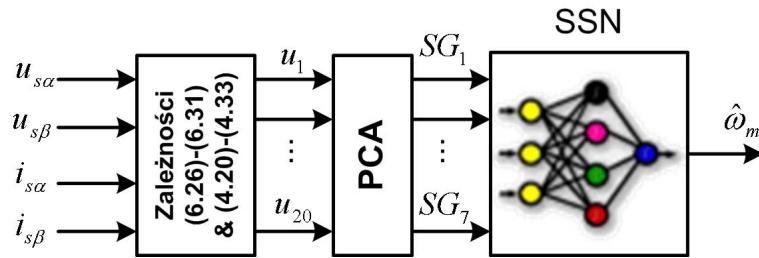
Rysunek 6.13. Schemat estymatora B

Kolejnym krokiem było rozszerzenie zbioru sygnałów (6.26)–(6.31) o sygnały (4.20)–(4.33) i wyznaczenie, metodą największego spadku liczby warunkowej, dziesięciu sygnałów wejściowych dla neuronowego aproksymatora prędkości kątowej wirnika. Spadek liczby warunkowej, dla rozważanego zbioru 20-stu sygnałów, przedstawiono na rysunku 6.14. Przykładowe wyniki odtwarzania przy użyciu sieci 10–7–3–1 zilustrowano na rysunku 6.15. Na rysunku tym oraz kolejnych przedstawiających przebiegi odtworzonej prędkości kątowej wirnika, przyjęto następujący porządek:

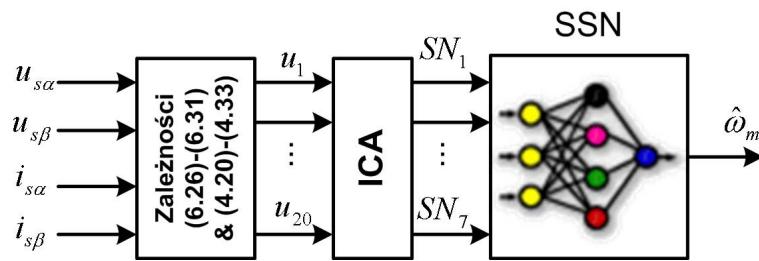
- w kolumnie (a) zamieszczono przebiegi dotyczące układu ze sprzężeniem od prędkości modelowanej,
- zaś w kolumnie (b), przebiegi odnoszące się do napędu ze sprzężeniem od prędkości estymowanej.

Zaobserwowano wzrost wszystkich czterech błędów średnich w stosunku do estymatora A (patrz tabela 6.3 na stronie 123). Potwierdziło to obawy sygnalizowane w podrozdziale 4.5.2. Wybrane sygnały są silnie liniowo niezależne, ale jednocześnie są słabo skorelowane z odtwarzaną prędkością kątową wirnika. Wybrana intuicyjnie baza w estymatorze A pozwala na dokładniejsze rozwiązanie zadania w stosunku do bazy określonej analitycznie w estymatorze B.

6.2.3. Estymator prędkości kątowej wirnika - struktura C i C'

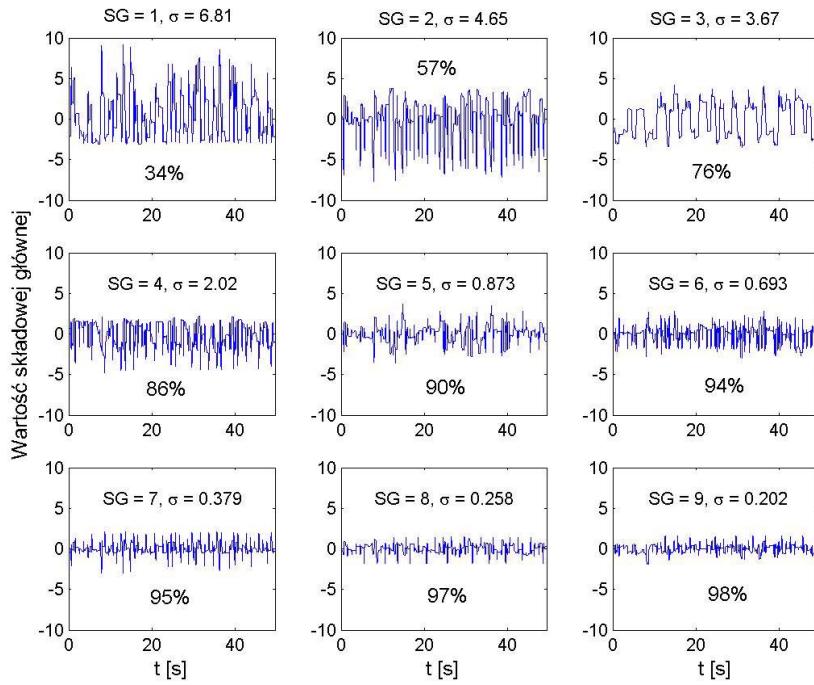


Rysunek 6.16. Schemat estymatora C

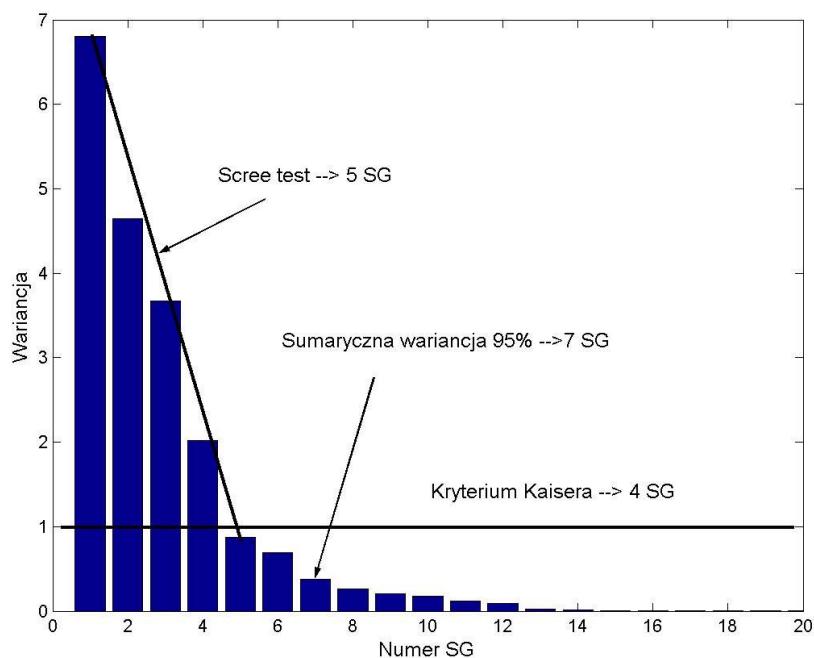


Rysunek 6.17. Schemat estymatora C'

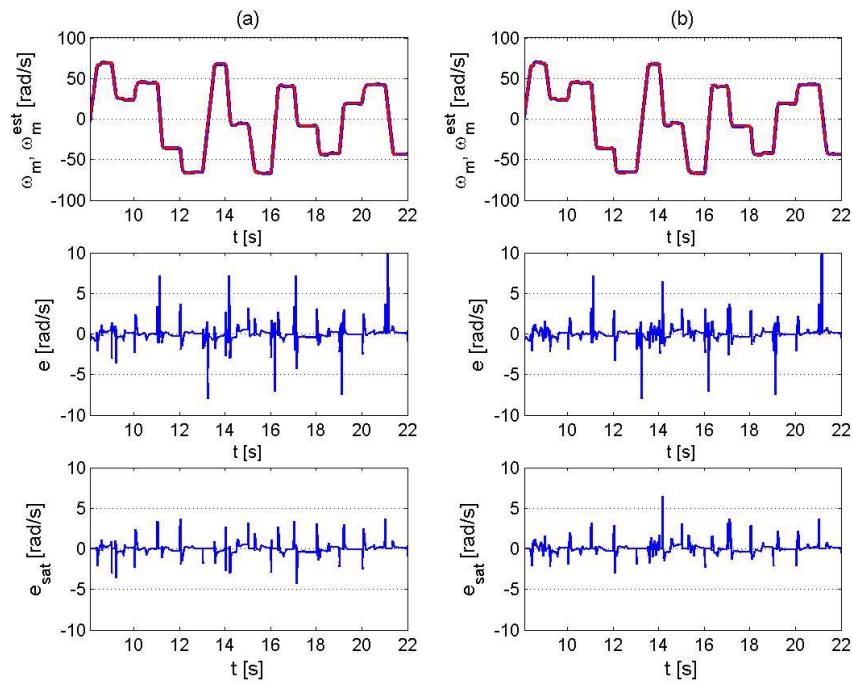
Wykorzystując analizę PCA, wyznaczono składowe główne (SG) zbioru sygnałów (4.13)–(4.18), (4.20)–(4.33). Pierwsze dziewięć SG, dla założonego profilu wymuszeń uczących, zamieszczono na rysunku 6.18. Posługując się kryteriami opisanymi w podrozdziale 4.5.3, określono wymiar bazy aproksymatora. Kryterium sumarycznej wariancji z typowym progiem 95% wskazuje na 7-em składowych (patrz rys. 6.18). Zgodnie z kryterium pierwiastka charakterystycznego (Kaisera), należałoby wziąć 4-ry składowe (patrz rys. 6.18 lub 6.19). Z kolei Scree test sugeruje 5 składowych (patrz rys. 6.19). Na tej podstawie dokonano kompresji liczby wymiarów z 20-stu do 7-miu budując estymator jak na rysunku 4.20. Przykładowe wyniki odtwarzania prędkości kątowej przy użyciu sieci 7–7–3–1, przedstawiono na rysunku 6.20. Stwierdzono wyraźny spadek błędów odtwarzania w stosunku do rozwiązań A i B (patrz tabela 6.3 na stronie 123). Przewagą tego rozwiązania nad poprzednimi dwoma, jest determinowanie bazy poprzez kompresję informacji, zawartej w proponowanych zmiennych opisujących silnik, zamiast odrzucanie wybranych z nich. Poważną wadą rozwiązania C jest konieczność implementowania wszystkich (w omawianym przypadku 20-stu), nieliniowych funkcji definiujących zmienne opisujące. Te same zalety i wady posiada rozwiązanie C' z bazą rozpiętą na składowych niezależnych.



Rysunek 6.18. Kilka początkowych składowych głównych (SG) i ich wariancje (σ) dla przykładowego zbioru 20-stu zmiennych opisujących silnik - w procentach podano sumaryczną wariancję SG pierwszych składowych

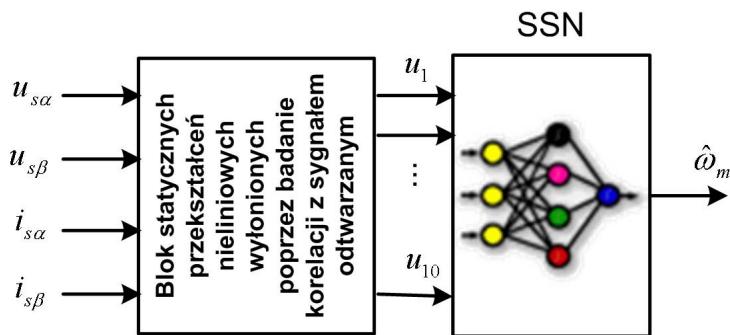


Rysunek 6.19. Wariancja kolejnych składowych jako funkcja numeru składowej

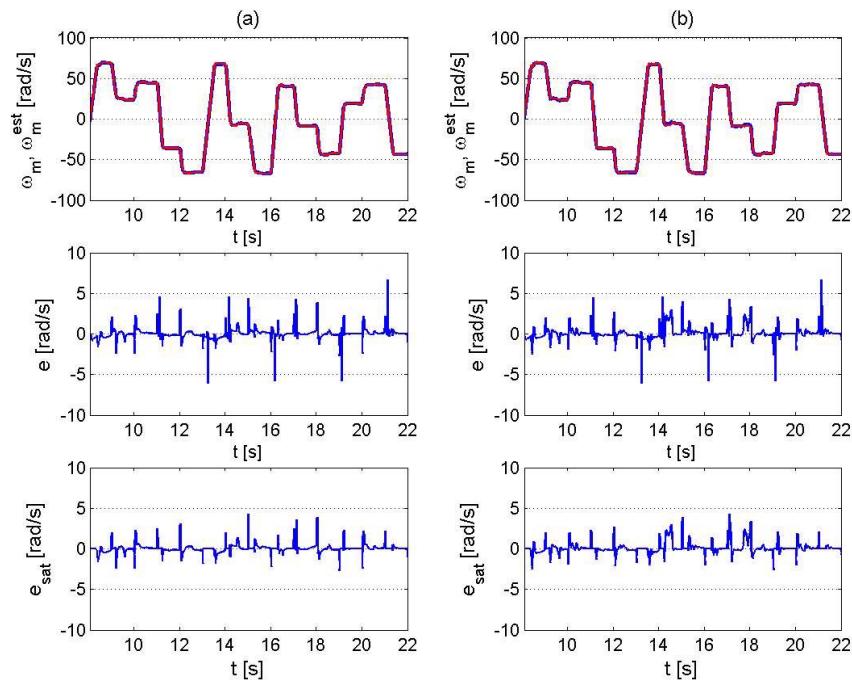


Rysunek 6.20. Wyniki odtwarzania prędkości na podstawie wszystkich 20-stu zdefiniowanych sygnałów i bazie aproksymatora rozpiętej na 7-miu składowych głównych: a) w sprzężeniu zwrotnym wykorzystano prędkość modelowaną, b) w sprzężeniu zwrotnym wykorzystano estymatę neuronową

6.2.4. Estymator prędkości kątowej wirnika - struktura D



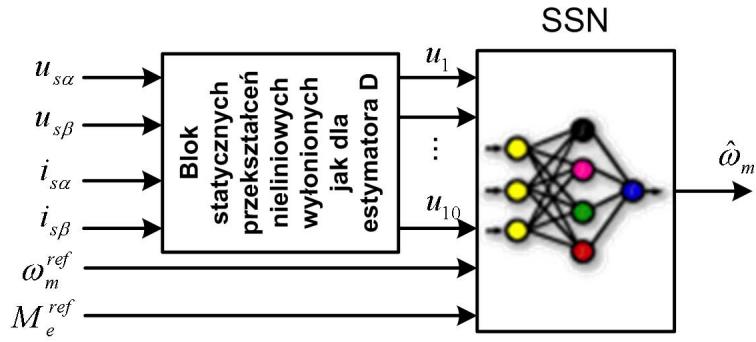
Rysunek 6.21. Schemat estymatora D



Rysunek 6.22. Wybrane przebiegi z układu napędowego, z bazą aproksymatora określona metodą klasteryzacji sygnałów kandydackich: a) pętla regulacji od prędkości modelowanej, b) pętla regulacji od prędkości estymowanej przy użyciu SSN

Na podstawie badań przeprowadzonych nad estymatorem C określono liczbę składowych głównych $p_{PCA} = 7$ (z kryterium sumarycznej wariancji). Na mocy wzorów (4.64) i (4.65) wyłoniono $l = 3$ sygnały o największej korelacji z sygnałem odtwarzanej prędkości kątowej wirnika, zaś metodą opisaną w podrozdziale 4.5.5, wyłoniono bazę $p = 10$ sygnałów. Za wejście procedury przyjęto sygnały (4.13)–(4.18) i (4.20)–(4.33). Przeprowadzone testy dla sieci 10–7–3–1 potwierdziły dużą skuteczność tak zaprojektowanego estymatora. Cechującego niższe błędy średnie w porównaniu z estymatorami A, B, C i C' (patrz tabela 6.3 na stronie 123, wyróżniono kolorem niebieskim). Jednocześnie nie posiada on podstawowej wady rozwiązań C i C', tj. wymaga implementowania jedynie wyłonionych p funkcji nielinowych. Przykładowe wyniki pracy napędu z estymatorem D zamieszczone na rysunku 6.22.

6.2.5. Estymator prędkości kątowej wirnika - struktura E



Rysunek 6.23. Schemat estymatora E

W rozwiązaniach A, B, C, C' oraz D, przy określaniu bazy aproksymatora neuronowego, założono dostępność jedynie prądów i napięć stojana. Niemniej jednak szereg algorytmów sterowania dla napędu z silnikiem indukcyjnym, związany jest z wyznaczaniem wielkości, które w oczywisty sposób spełniają kryterium częstotliwości, będące kluczowym warunkiem przydatności sygnału w proponowanej architekturze estymatora. W wybranym do badań napędzie DSFOC można wskazać co najmniej dwa takie sygnały:

- prędkość zadawaną ω_m^{ref} ,
- oraz wyjście regulatora prędkości, które w omawianej sytuacji można utożsamiać z sygnałem zadanego momentu elektromagnetycznego M_e^{ref} .

Uwzględnienie tych sygnałów w bazie aproksymatora, nie wiąże się z instalowaniem jakichkolwiek dodatkowych czujników pomiarowych, i w zasadzie, nie komplikuje dodatkowo układu sterowania od strony numerycznej. Sygnały te można dołączyć do zbioru kandydackiego lub założyć, że nie podlegają one procesowi eliminacji czy kompresji, i podać je bezpośrednio na wejścia aproksymatora neuronowego. Rozszerzając bazę aproksymatora D o sygnały ω_m^{ref} i M_e^{ref} , otrzymano rozwiązanie z siecią 12–7–3–1, przedstawione na rysunku 6.24. Zaobserwowano dalszy spadek średnich błędów w stosunku do rozwiązania D (patrz tabela 6.3 na stronie 123, wyróżniono kolorem niebieskim). Przykładowe przebiegi zarejestrowane w układzie z estymatorem E pokazano na rysunku 6.25.

Rozszerzanie bazy aproksymatora o wybrane sygnały wyznaczane w układzie sterowania, może spowodować utratę odporności estymatora na zmiany parametrów układu regulacji. Na rysunku 6.26 przedstawiono pracę układy bezczujnikowego po zmianie dynamiki układu poprzez obniżenie ograniczenia prądowego z $2I_N$ do $1.2I_N$ (zmiana nie uwzględniona

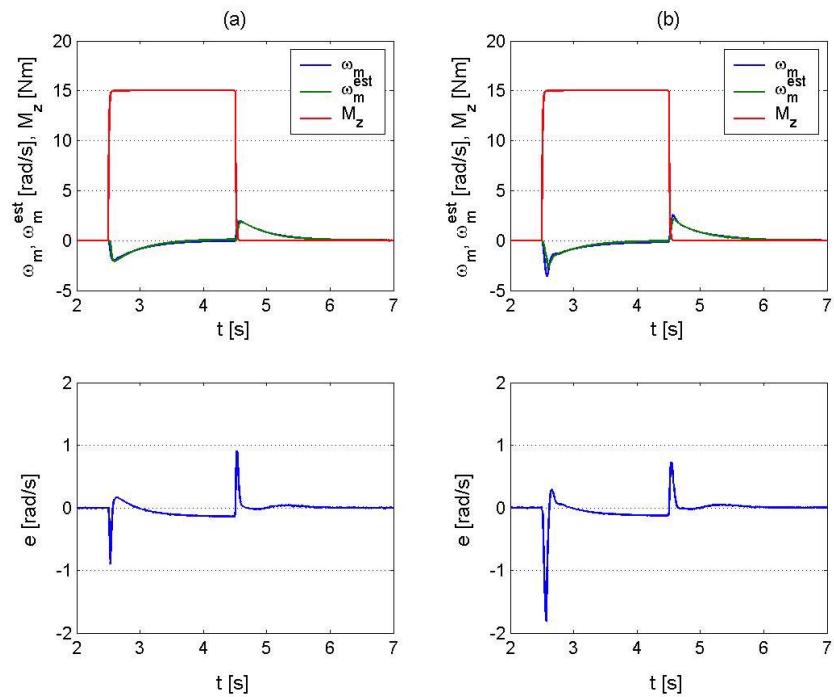
przy tworzeniu zbioru uczącego). Pojawiające się błędy estymacji (patrz tabela 6.3 na stronie 123, wyróżniono kolorem czerwonym), uniemożliwiły skuteczną pracę układu bezczujnikowego. Napęd zachowywał się oscylacyjnie i nie osiągał asymptotycznie wartości prędkości zadanej. Zmiana ograniczenia prądowego spowodowała zmianę relacji między parą sygnałów ($\omega_m^{ref}, M_e^{ref}$) i sygnałami mierzonymi na stojanie. Relacja ta nie była uwzględniona podczas tworzenia zbioru uczącego. Z kolei zbadane rozwiązania wykorzystujące wyłącznie mierzone prądy i napięcia, wykazują dobrą odporność na rozważaną zmianę parametrów układu regulacji (patrz podrozdział 6.2.6).

Wniosek. **Rozszerzanie bazy aproksymatora neuronowego o sygnały wyznaczane w układzie sterowania (np. wartości zadane, wyjścia regulatorów), może spowodować bezużyteczność estymatora w sytuacji zmiany parametrów tegoż układu sterowania. Bazowanie wyłącznie na informacji zawartej w prądach i napięciach stojana maszyny indukcyjnej pozwala na zaprojektowanie estymatora uniwersalnego w sensie jego niezależności od struktury i parametrów układu regulacji.** Wykorzystanie estymatora E w układzie, który zakłada możliwość dokonywania zmian nastaw regulatorów, uwarunkowane jest uwzględnieniem tych zmian podczas tworzenia zbioru uczącego.

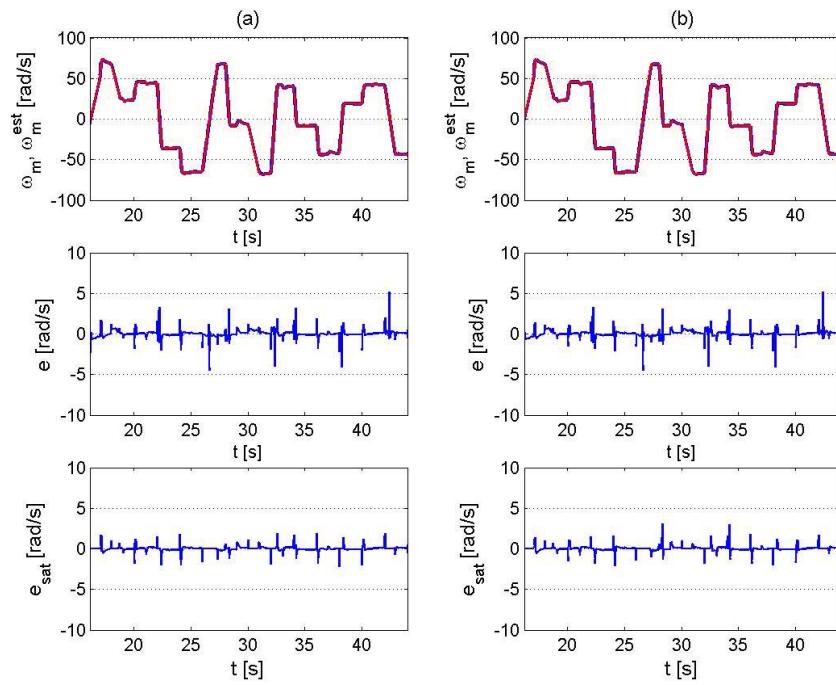
6.2.6. Szczegółowe badania estymatora D

Do badań szczegółowych wybrano estymator D, jako dający najlepsze wyniki, przy założeniu nie korzystania z sygnałów pochodzących z układu regulacji. Przeprowadzono kolejno cztery niezależne testy układu z estymatorem D w pętli sprzężenia zwrotnego, w następujących warunkach:

- skokowej zmiany obciążenia do wartości znamionowej przy zerowej wartości prędkości zadanej (rys. 6.27);
- wzrostu rezystancji stojana o 30% względem wartości znamionowej (rys. 6.28);
- dwukrotnego wzrostu momentu bezwładności układu napędowego w stosunku do podanego w tabeli 6.1 (zmiany tego parametru nie były uwzględnione w zbiorze uczącym) (rys. 6.29);
- zmiany dynamiki układu poprzez obniżenie ograniczenia prądowego z $2I_N$ do $1.2I_N$ (rys. 6.30).



Rysunek 6.27. Odpowiedź układu na skokową zmianę momentu obciążenia przy zerowej prędkości zadanej: a) sprzężenie zwrotne od prędkości modelowanej, b) estymator neuronowy D (rys. 6.21) w pętli sprzężenia zwrotnego



Rysunek 6.30. Przebieg błędu odtwarzania w układzie ze zmienionymi ograniczeniami prądowymi (z $2I_N$ na $1.2I_N$), przy wykorzystaniu w pętli sprzężenia zwrotnego: a) sygnału prędkości modelowanej, b) sygnału otrzymanego na wyjściu estymatora D (rys. 6.21)

Tablica 6.3. Porównanie błędów estymatorów A, B, C, D i E

Estymator	Błąd \bar{e}^{enkoder}	Błąd $\bar{e}_{\text{sat}}^{\text{enkoder}}$	Błąd \bar{e}^{SSN}	Błąd $\bar{e}_{\text{sat}}^{\text{SSN}}$
A (moc, impedancja)	1.5661	0.5027	1.7335	0.8584
B (liczba warunkowa)	2.9613	0.6690	3.4833	1.4814
C (PCA)	0.8466	0.3137	0.9656	0.5059
C' (ICA)	0.8512	0.3181	0.9642	0.5032
D (klasteryzacja)	0.5208	0.3313	0.6674	0.4885
E ($\omega_m^{\text{ref}}, M_e^{\text{ref}}$)	0.1127	0.0751	0.2691	0.1317
D (zmiana ograniczenia prądowego)	0.3019	0.1493	0.3285	0.1573
D (zwiększyony moment bezwładności)	1.0104	0.3454	1.0221	0.3822
D ($R_s = \text{var}$)	1.6713	0.4008	1.7251	0.5506
E (zmiana ograniczenia prądowego)	26.0779	9.9473	93.2886	10.3012

Wyniki tych testów przedstawiono na wskazanych wyżej rysunkach oraz podsumowano w tabeli 6.3 (wyróżniono kolorem zielonym). Szczególnie interesujące z poznawczego punktu widzenia są wyniki testu, w którym zmieniono nastawy regulatorów zmniejszając tym samym dynamikę zmian prędkości kątowej wirnika. Obserwujemy około dwukrotny spadek błędów średnich, pomimo tego, że zmiany parametrów układu regulacji nie zostały uwzględnione podczas tworzenia zbioru uczącego. Zauważmy jednak, że ograniczając dynamikę obiektu, otrzymujemy spełnienie warunku

$$\omega_m \stackrel{\varepsilon, \delta}{=} f(\underline{u}_s, \underline{i}_s) \quad (6.35)$$

dla mniejszych ε, δ (patrz opis zależności (4.8)).

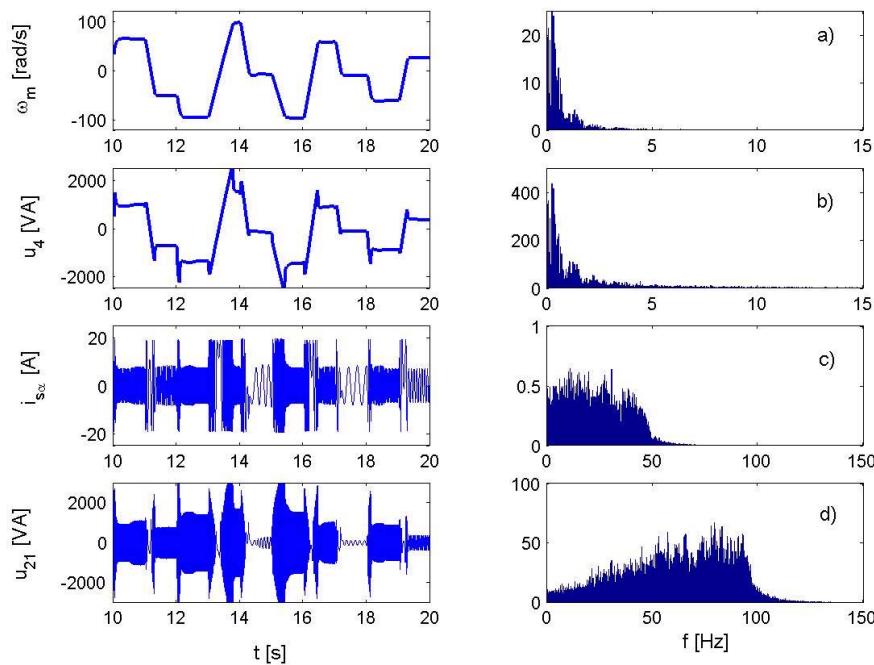
6.3. Badania neuronowego estymatora strumienia magnetycznego stojana

Zbudowano rekonfigurowalny model symulacyjny o strukturze jak na rysunku 6.31. Założono parametry symulacji zgodne z określonymi w tabeli 6.2 i wygenerowano zbiór uczący dla sieci z rysunku 5.2. Przyjęto sieć o strukturze 12–15–5–2. Otrzymany neuronowy estymator strumienia stojana porównano z przestrajanym filtrem dolnoprzepustowym opisanym w podrozdziale 3.3 (rys. 3.6), przy braku dodatkowego algorytmu adaptacji rezystancji stojana. Na rysunku 6.32 przedstawiono przykładowe przebiegi czasowe strumienia odtworzonego przy użyciu PLPF oraz estymatora neuronowego, przy czym ustawiona w PLPF rezystancja była równa rezystancji zawartej w modelu silnika. Podczas kolejnego testu zwiększoño rezystancję stojana do $R_s = 1.3R_{s25^\circ\text{C}}$ pozostawiając jednocześnie rezystancję, służącą do wyznaczenia siły elektromotorycznej całkowanej przy użyciu PLPF, na niezmienionym poziomie $R_{s25^\circ\text{C}}$. Stwierdzono wyraźne pogorszenie jakości odtwarzania składowych strumienia stojana metodą PLPF (rys. 6.33). Jednocześnie estymator neuronowy uczony na zbiorze uwzględniającym zmiany rezystancji stojana, pozwolił na uzyskanie dużygodnijszych estymat. Dla przejrzystości wyników, w obu przypadkach do sterowania wykorzystano składowe strumienia modelowanego. Kolejny test obejmował wykorzystanie estymowanych składowych strumienia stojana do wyznaczenia sterowania. Zachowanie się napędu z neuronowym estymatorem strumienia stojana, zostało porównane z napędem wyposażonym w algorytmiczny układ całkowania typu PLPF. Założono, że rezystancja stojana silnika wzrosła temperaturowo do $R_s = 1.3R_{s25^\circ\text{C}}$, podczas gdy w bloku wyznaczania indukowanej siły elektromotorycznej pozostało niezmienioną wartość $\hat{R}_s = R_{s25^\circ\text{C}}$. Moment zakłócający wygenerowano zgodnie z parametrami określonymi w tabeli 6.2. Napęd DSFOC z estymatorem strumienia bazującym na PLPF był niestabilny i nie podał za sygnałem referencyjnym. Z kolei opracowany neuronowy estymator strumienia zapewnił

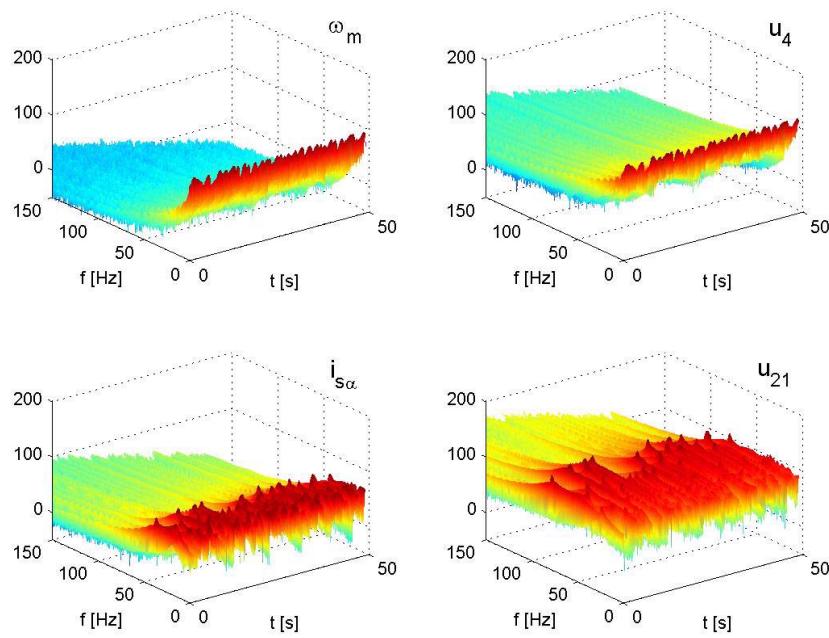
stabilną pracę układu (rys. 6.34).

6.4. Podsumowanie

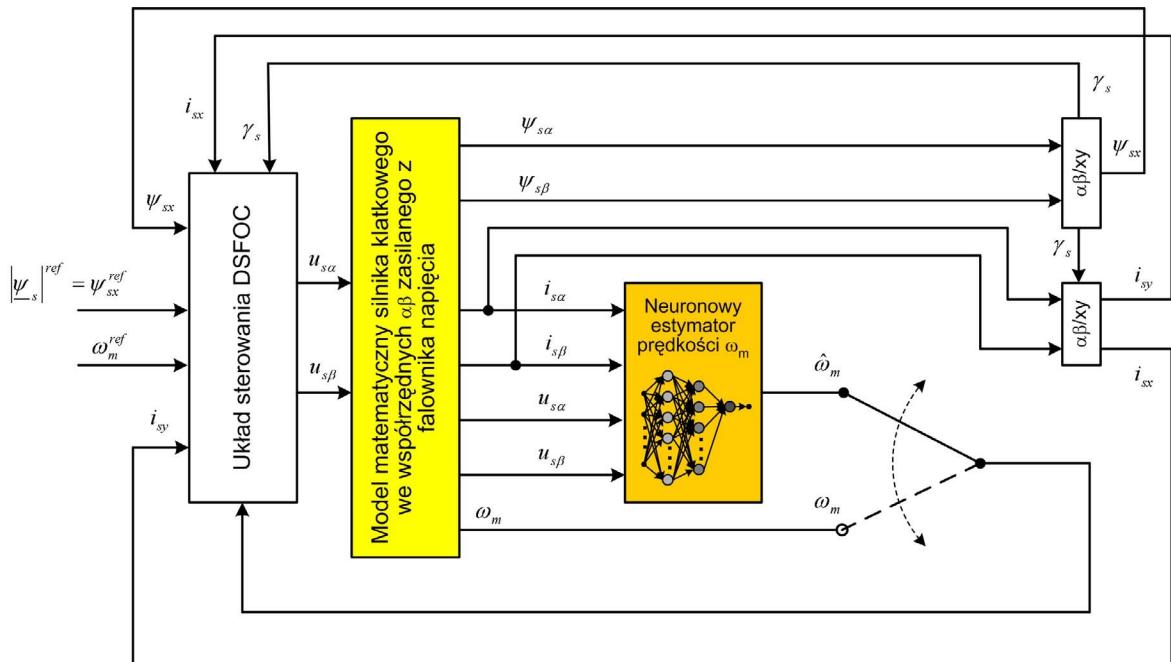
W rozdziale przedstawiono badania symulacyjne opracowanych estymatorów prędkości kątowej wirnika i strumienia stojana maszyny indukcyjnej. **Wyniki badań potwierdziły możliwość wykorzystania statycznej jednokierunkowej sieci neuronowej, uczonej w trybie off-line, do aproksymowania wybranych wielkości mechanicznych i magnetycznych w napędzie bezczujnikowym prądu przemiennego.** Przeprowadzono badania porównawcze zaproponowanych metod tworzenia bazy neuronowego aproksymatora prędkości kątowej wirnika. Na podstawie odpowiednio dobranych wskaźników wyłoniono najskuteczniejszą metodę wykorzystującą klasteryzację sygnałów kandydackich. **Pokazano, że przy odpowiednich założeniach, rozszerzenie bazy aproksymatora o sygnały dostępne w układzie sterowania, może w sposób znaczący poprawić jakość uzyskiwanych estymat.** Zbadano opracowany model Wienera dla strumienia stojana. Porównano jego działanie z wybranym estymatorem algorytmicznym bez dodatkowej adaptacji rezystancji stojana. **Opracowany neuronowy estymator strumienia zapewnił stabilną pracę układu napędowego w dużo większym obszarze stanów niż rozwiązanie algorytmiczne.**



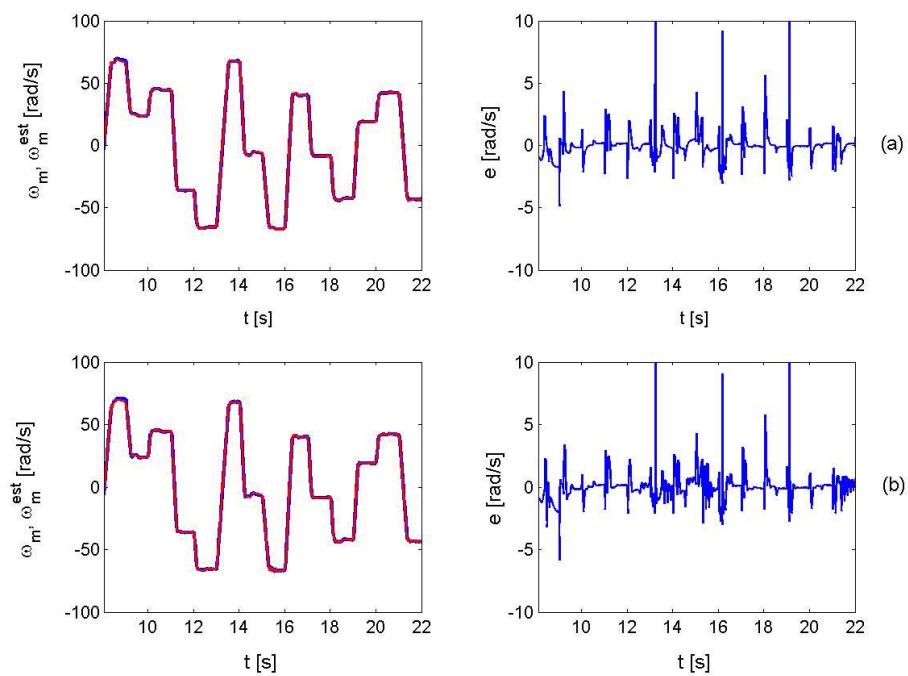
Rysunek 6.6. Widma częstotliwościowe wybranych sygnałów: a) prędkości kątowej wirnika, b) przydatnego w proponowanej architekturze $u_4 = i_{s\alpha}u_{s\beta} - i_{s\beta}u_{s\alpha}$, c) nieprzetworzonego prądu stojana, d) nieprzydatnego w proponowanej architekturze $u_{21} = i_{s\alpha}u_{s\beta} + i_{s\beta}u_{s\alpha}$



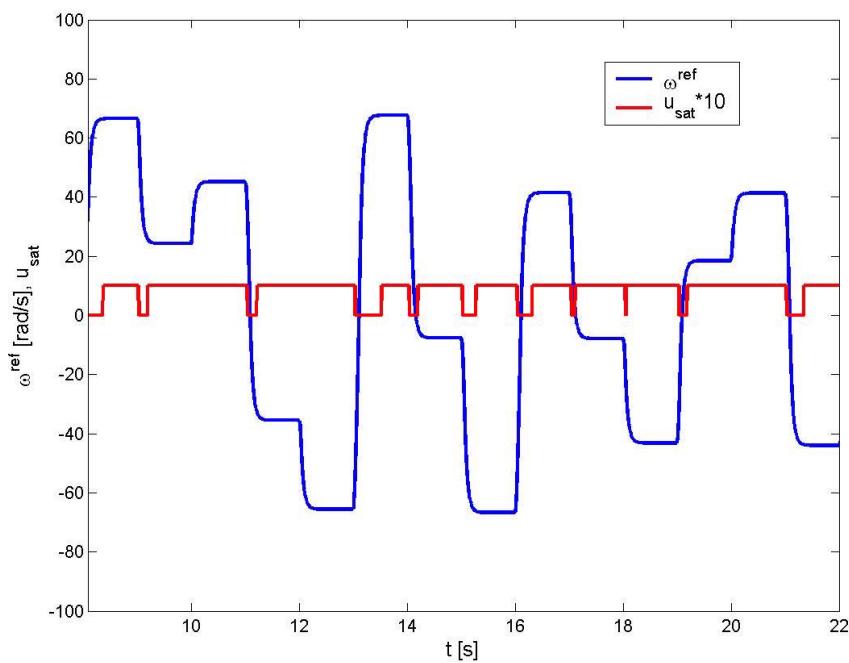
Rysunek 6.7. Analiza czasowo-częstotliwościowa sygnałów: prędkości kątowej wirnika ω_m , przydatnego w proponowanej architekturze $u_4 = i_{s\alpha}u_{s\beta} - i_{s\beta}u_{s\alpha}$, nieprzetworzonego prądu stojana $i_{s\alpha}$, nieprzydatnego w proponowanej architekturze $u_{21} = i_{s\alpha}u_{s\beta} + i_{s\beta}u_{s\alpha}$



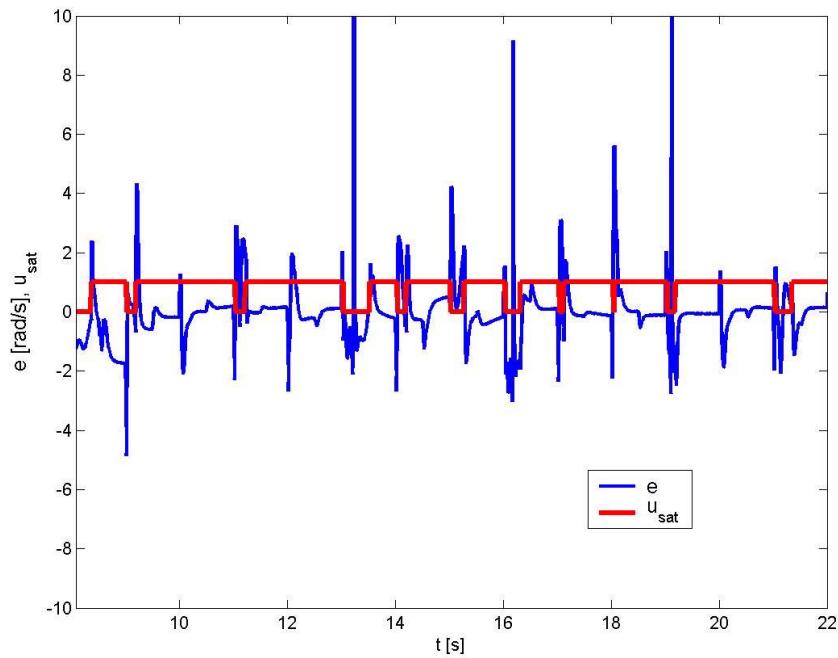
Rysunek 6.8. Schemat modelu symulacyjnego do badania estymatorów prędkości kątowej wirnika



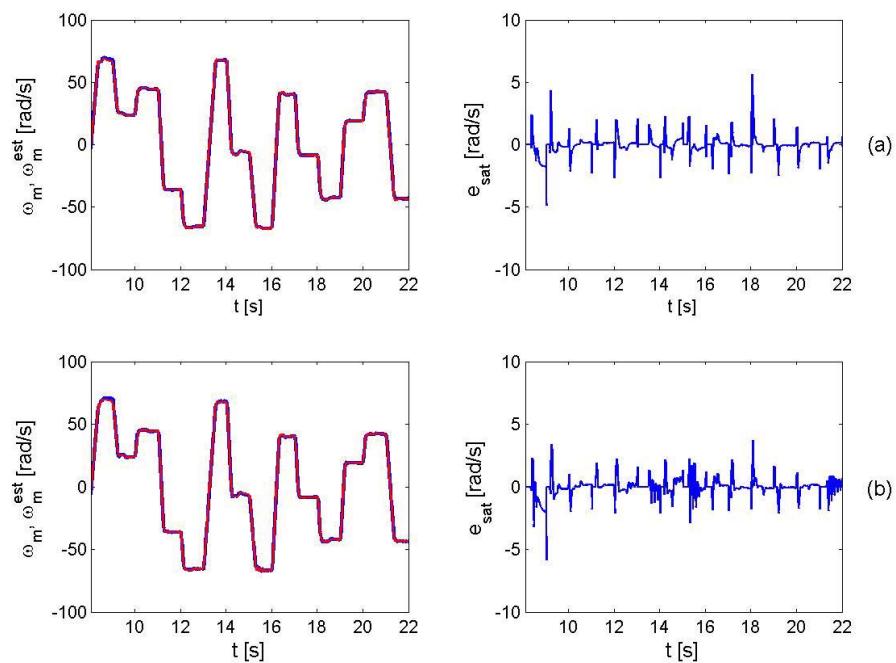
Rysunek 6.9. Odtwarzanie prędkości na podstawie sześciu podstawowych sygnałów przy sprzążeniu od: a) prędkości z modelu silnika, b) prędkości estymowanej



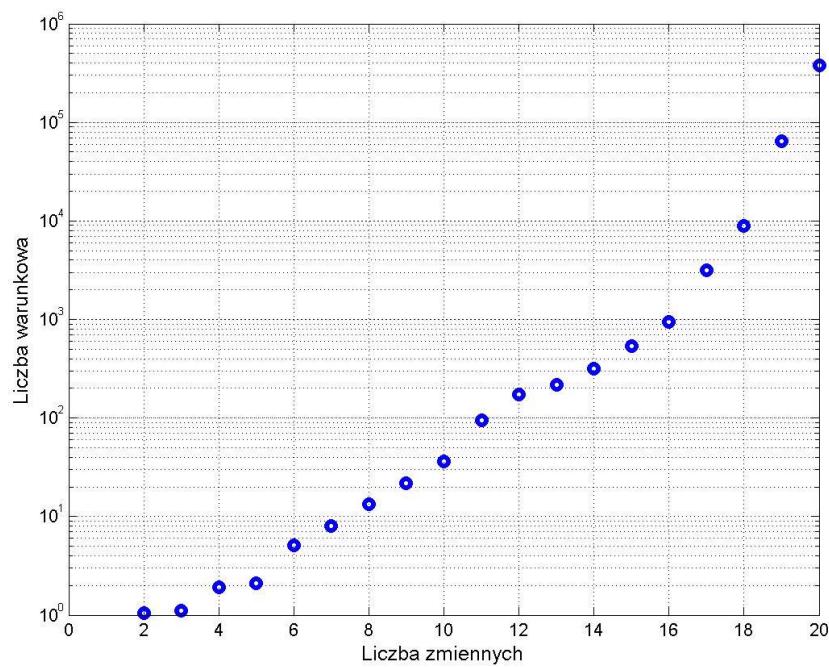
Rysunek 6.10. Nasycanie się regulatora prędkości przy zmianach wartości sygnału zadającego (zmienna u_{sat} określona zgodnie z (6.32))



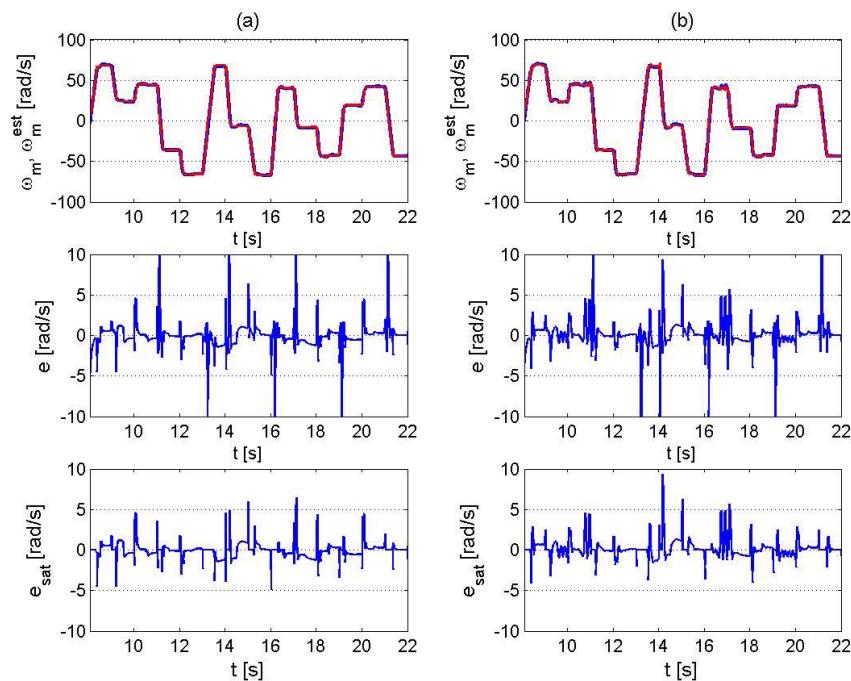
Rysunek 6.11. Zmiany sygnału boolowskiego u_{sat} skorelowane z sygnałem błędu e



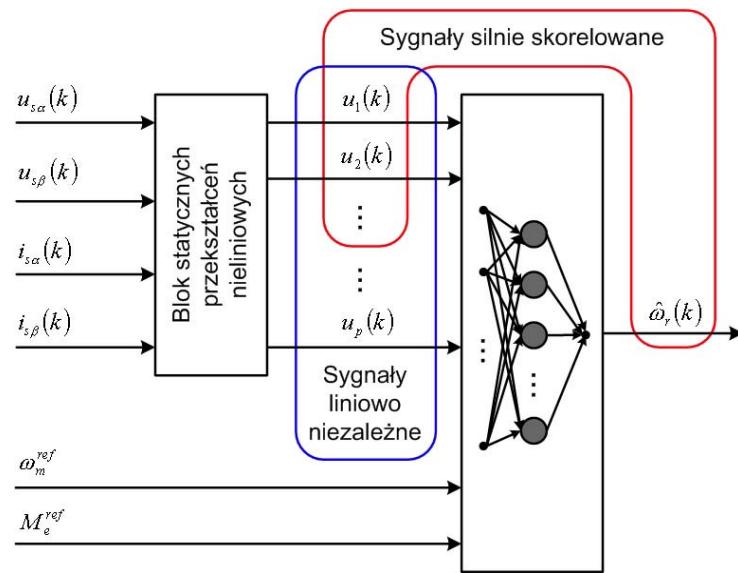
Rysunek 6.12. Odtwarzanie prędkości na podstawie sześciu podstawowych sygnałów przy sprężeniu od prędkości z modelu silnika (a) oraz prędkości estymowanej (b). Wykres błędu zmodyfikowany zgodnie z zależnością (6.33)



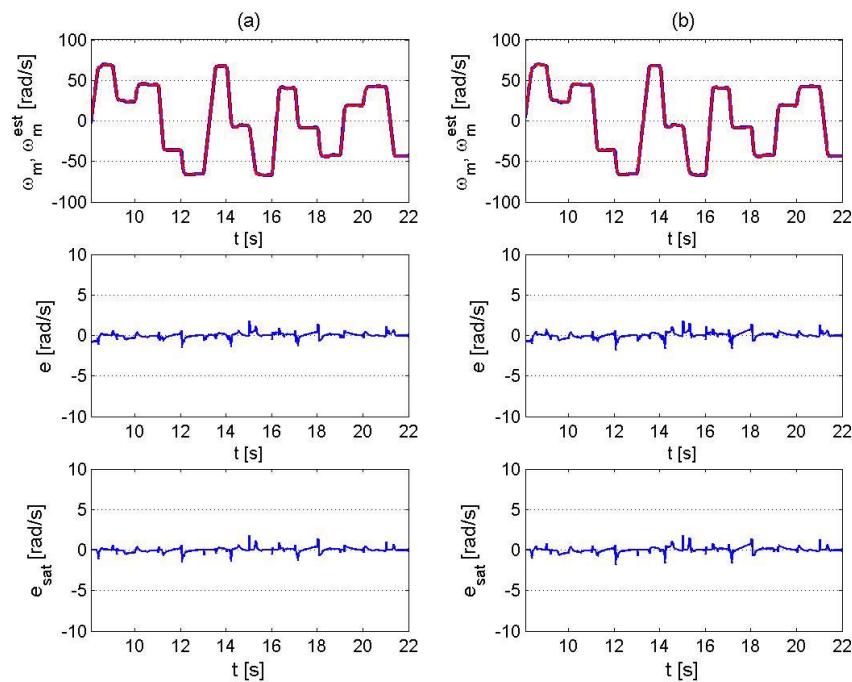
Rysunek 6.14. Zmiany liczby warunkowej po zastosowaniu algorytmu największego spadku



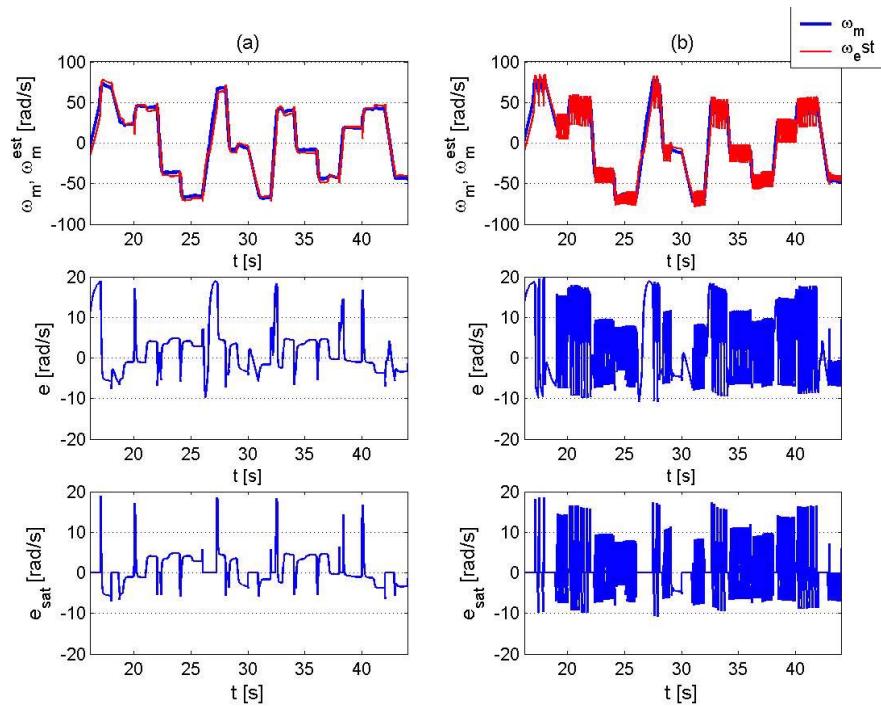
Rysunek 6.15. Odtwarzanie prędkości na podstawie dziesięciu sygnałów wyłonionych metodą największego spadku liczby warunkowej: a) sprzężenie od prędkości modelowanej, b) sprzężenie od prędkości estymowanej przy użyciu SSN



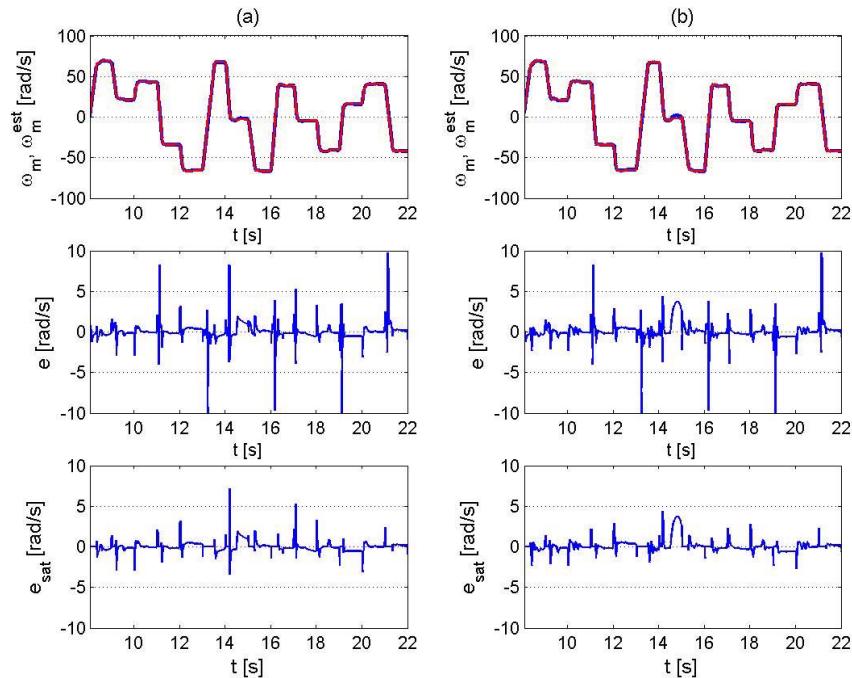
Rysunek 6.24. Struktura estymatora z dodatkowymi sygnałami na wejściach, pochodzącyymi z układu regulacji



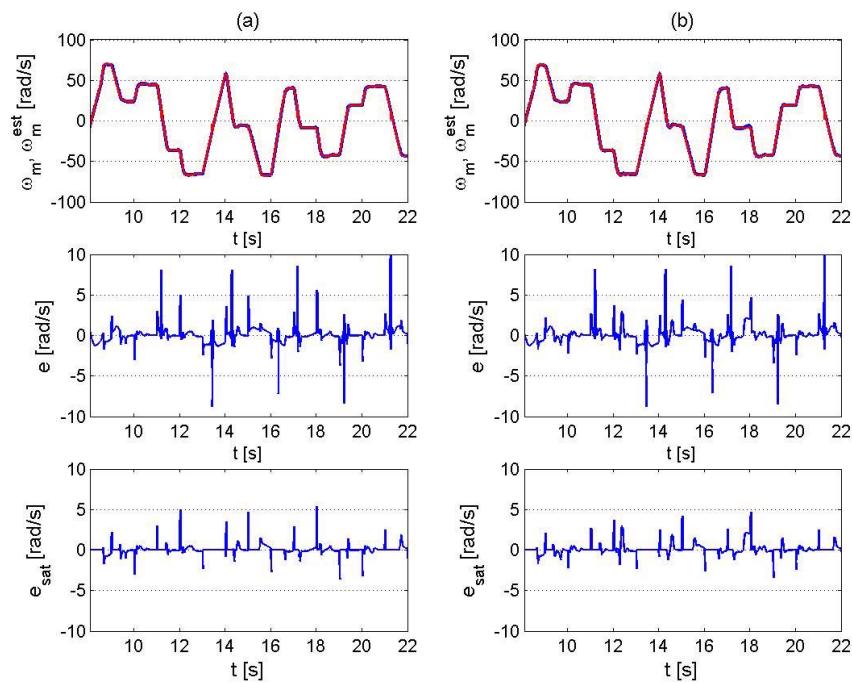
Rysunek 6.25. Przebiegi zarejestrowane w układzie z estymatorem wykorzystującym sygnały dodatkowe ω_m^{ref} i M_e^{ref} : a) w pętli regulacji użyto sygnału prędkości modelowanej, b) w pętli regulacji użyto SSN



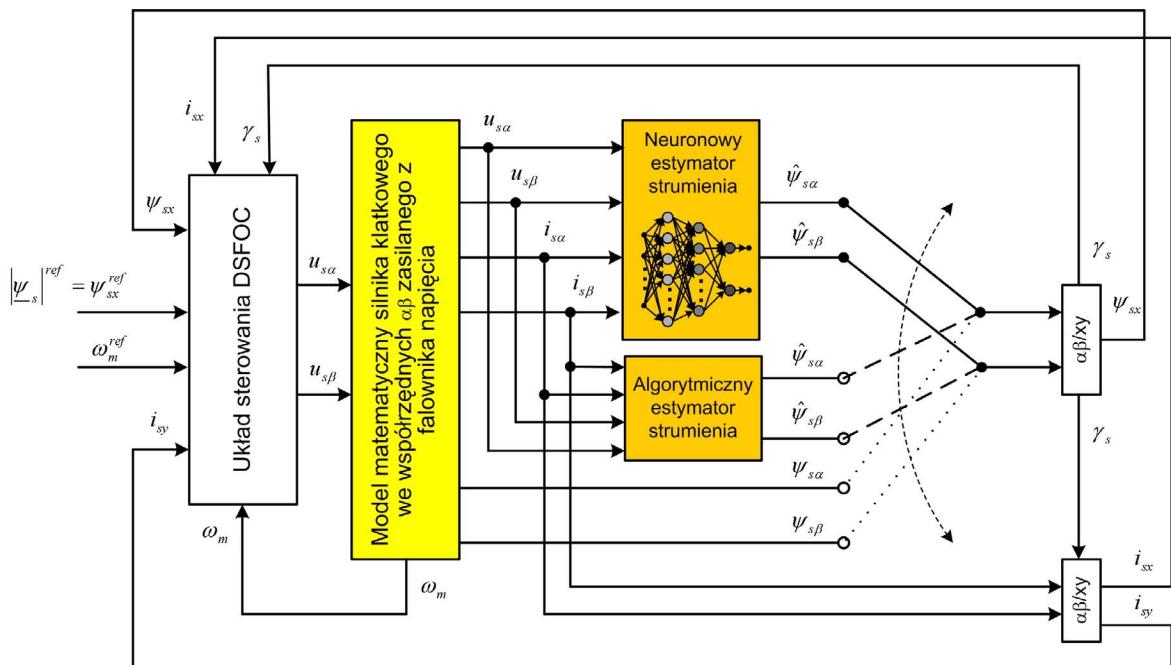
Rysunek 6.26. Przebieg błędu odtwarzania w układzie ze zmienionymi ograniczeniami prądowymi (z $2I_N$ na $1.2I_N$), przy zastosowaniu estymatora E (rys. 6.23), dla sprężenia od:
a) prędkości modelowanej, b) prędkości odtworzonej przez SSN



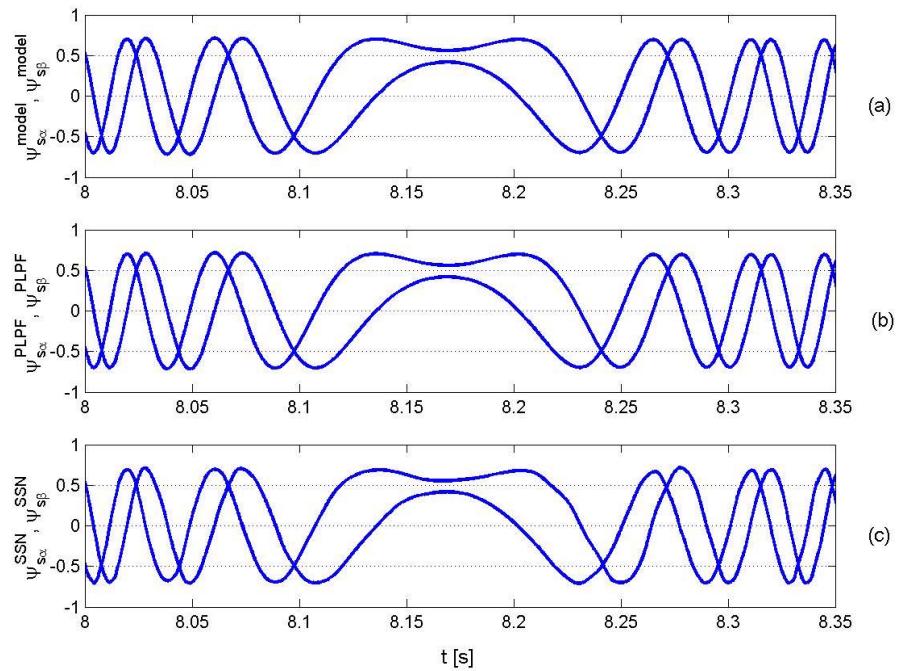
Rysunek 6.28. Zachowanie się napędu z estymatorem D przy wzroście rezystancji stojana o 30%, dla układu regulacji wykorzystującego sygnał a) prędkości modelowanej oraz b) prędkości odtworzonej



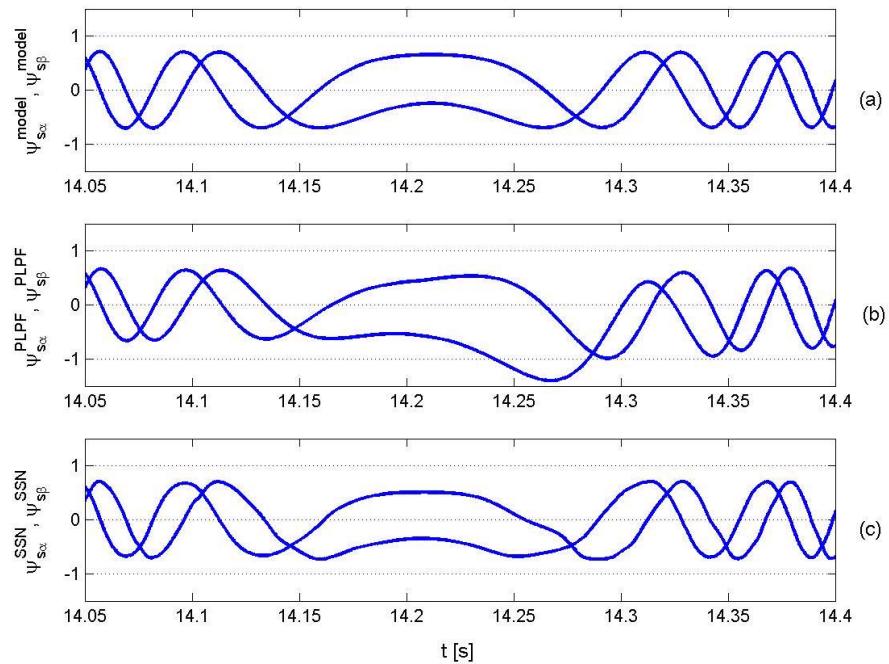
Rysunek 6.29. Praca napędu przy dwukrotnie większym momencie bezwładności skojarzonym z wałem silnika i sprzężeniu od: a) prędkości modelowanej oraz b) odtworzonej przy użyciu struktury neuronowej D (rys. 6.21)



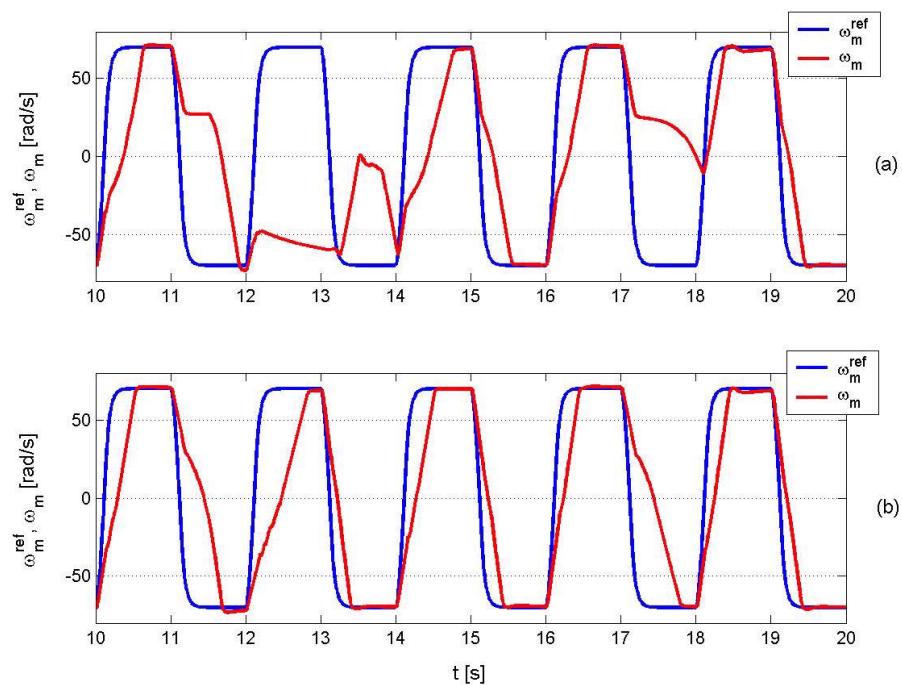
Rysunek 6.31. Schemat modelu symulacyjnego do badania estymatorów wektora strumienia stojana



Rysunek 6.32. Estymacja składowych $\psi_{s\alpha}$ i $\psi_{s\beta}$ wektora strumienia stojana podczas nawrotu silnika przy $R_s = R_{s25^\circ\text{C}}$: a) składowe modelowane, b) składowe odtworzone przy użyciu PLPF z $\hat{R}_s = R_s$, c) estymowane za pomocą sztucznej sieci neuronowej



Rysunek 6.33. Estymacja składowych $\psi_{s\alpha}$ i $\psi_{s\beta}$ wektora strumienia stojana podczas nawrotu silnika przy $R_s = 1.3R_{s25^\circ\text{C}}$: a) składowe modelowane, b) składowe odtworzone przy użyciu PLPF z $\hat{R}_s = R_{s25^\circ\text{C}}$, c) estymowane za pomocą sztucznej sieci neuronowej



Rysunek 6.34. Porównanie pracy napędu z: a) estymatorem strumienia bazującym na PLPF oraz b) proponowanym neuronowym aproksymatorem strumienia, przy wzroście rezystancji uzwojeń stojana

Rozdział 7

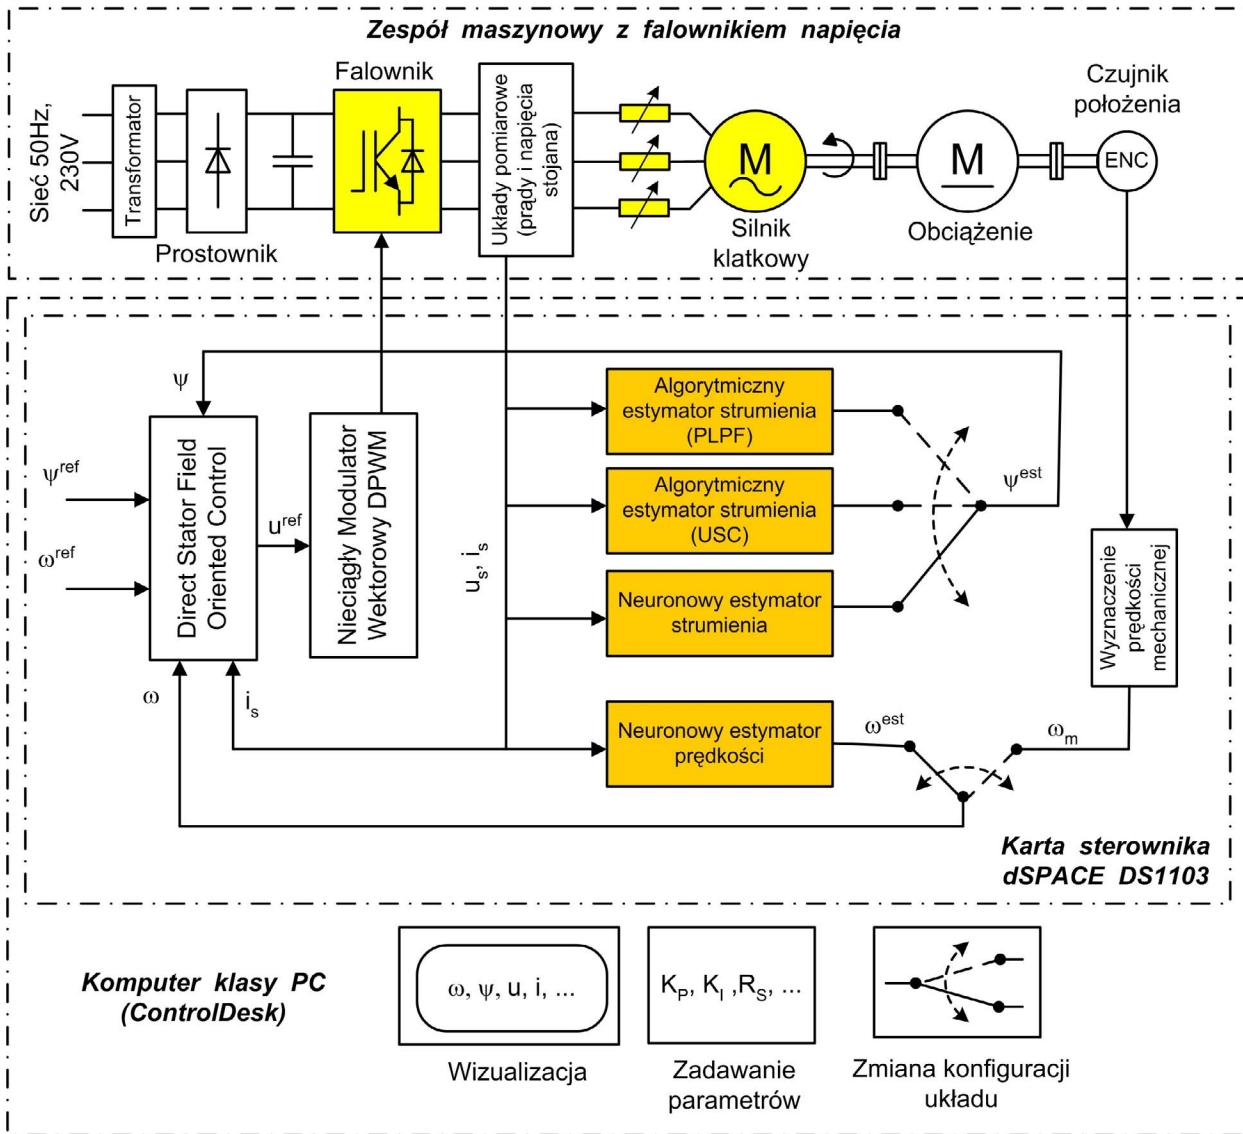
Badania eksperymentalne

7.1. Opis stanowiska laboratoryjnego

W oparciu o kartę DS1103 zbudowano stanowisko laboratoryjne umożliwiające badanie algorytmów sterowania silnikiem indukcyjnym. W skład stanowiska wchodzą m.in.:

- komputer klasy PC z zainstalowaną kartą sterownika mikroprocesorowego DS1103 (procesory Motorola PowerPC 604e / 400 MHz oraz Texas Instruments DSP TMS320F 240 / 20 MHz) firmy dSpace [175];
- falownik napięcia (moduły mocy PM150DSA120 firmy Mitsubishi);
- transformator separujący i obniżający napięcie (napięcie obwodu pośredniczącego $U_{DC} \cong 160$ V);
- układy pomiaru prądów i napięć firmy LEM (pomiar dwóch prądów stojana i dwóch napięć międzyprzewodowych stojana lub - zależnie od konfiguracji - napięcia obwodu pośredniczącego);
- optoizolacja w torach sterowania kluczami energoelektronicznymi (nadajniki SFH750 i odbiorniki SFH551 firmy Siemens);
- zespół maszynowy (silnik klatkowy o parametrach podanych w tabeli 6.1, silnik prądu stałego, enkoder);
- rezystory dodatkowe dołączane do obwodu stojana umożliwiające wymuszanie zmian rezystancji R_s .

Użyty sterownik może być programowany z poziomu środowiska MATLAB/SIMULINK i wraz z dołączanym do niego oprogramowaniem, stanowi skuteczne narzędzie do szybkiego



Rysunek 7.1. Schemat układu eksperymentalnego

prototypowania układów sterowania cyfrowego. W trakcie badań eksperymentalnych wykorzystano następujące oprogramowanie:

- środowisko MATLAB/SIMULINK z RTI (ang. Real-Time Interface) do generowania kodu programu dla sterownika;
- biblioteki MLIB/MTRACE [176] umożliwiające dostęp do karty sterownika z poziomu MATLABa;
- środowisko ControlDesk [177, 178] służące do tworzenia wirtualnych paneli sterowania.

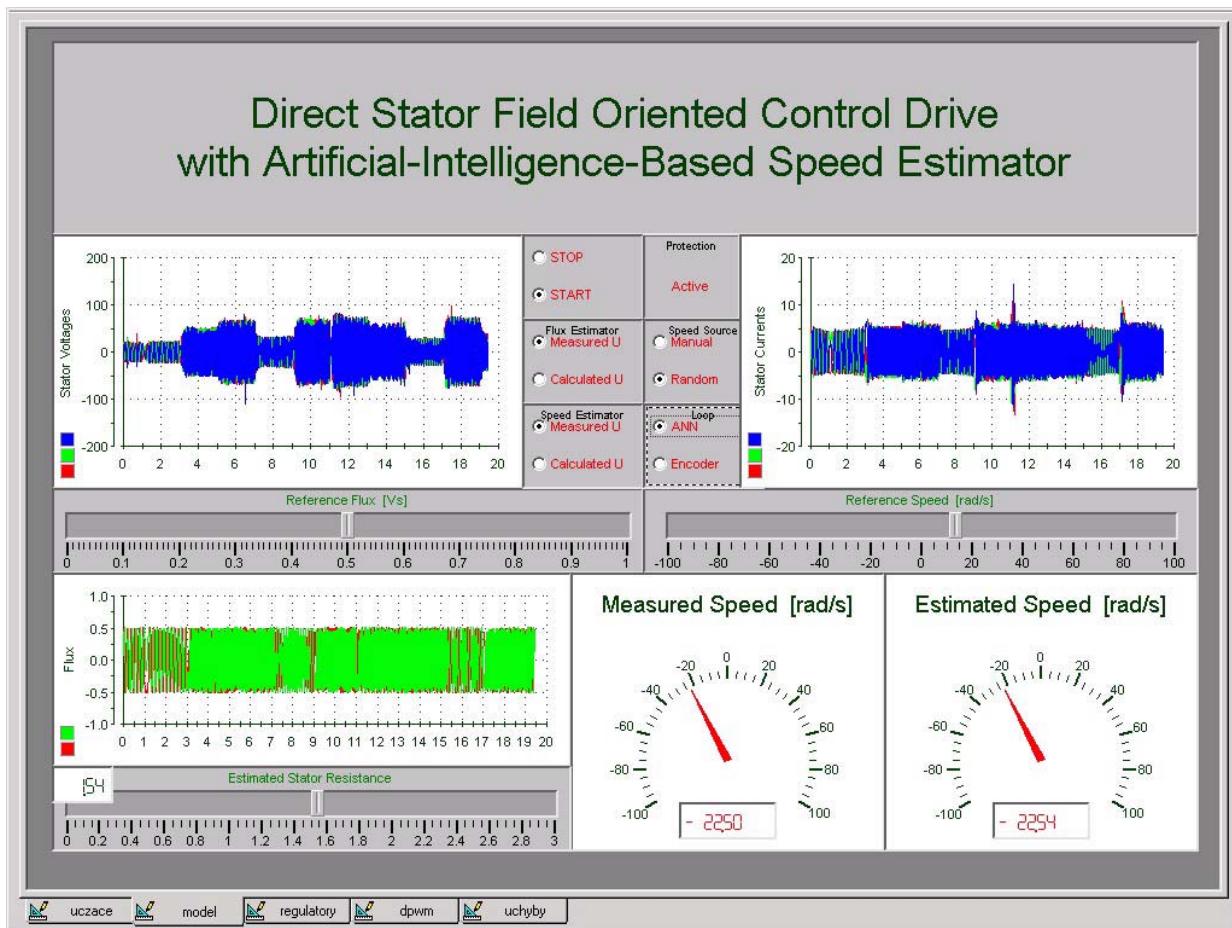
Poglądowy schemat układu eksperymentalnego zamieszczono na rysunku 7.1.

Obniżone napięcie obwodu pośredniczącego, uniemożliwiające pracę napędu w pełnym zakresie prędkości przy znamionowym strumieniu, podyktowane zostało badawczo-dydaktycznym charakterem stanowiska. Należy przy tym podkreślić, że większość, a wasadzie wszystkie problemy sterowania prędkością silnika indukcyjnego, dotyczą obszaru niskich częstotliwości strumienia stojana.

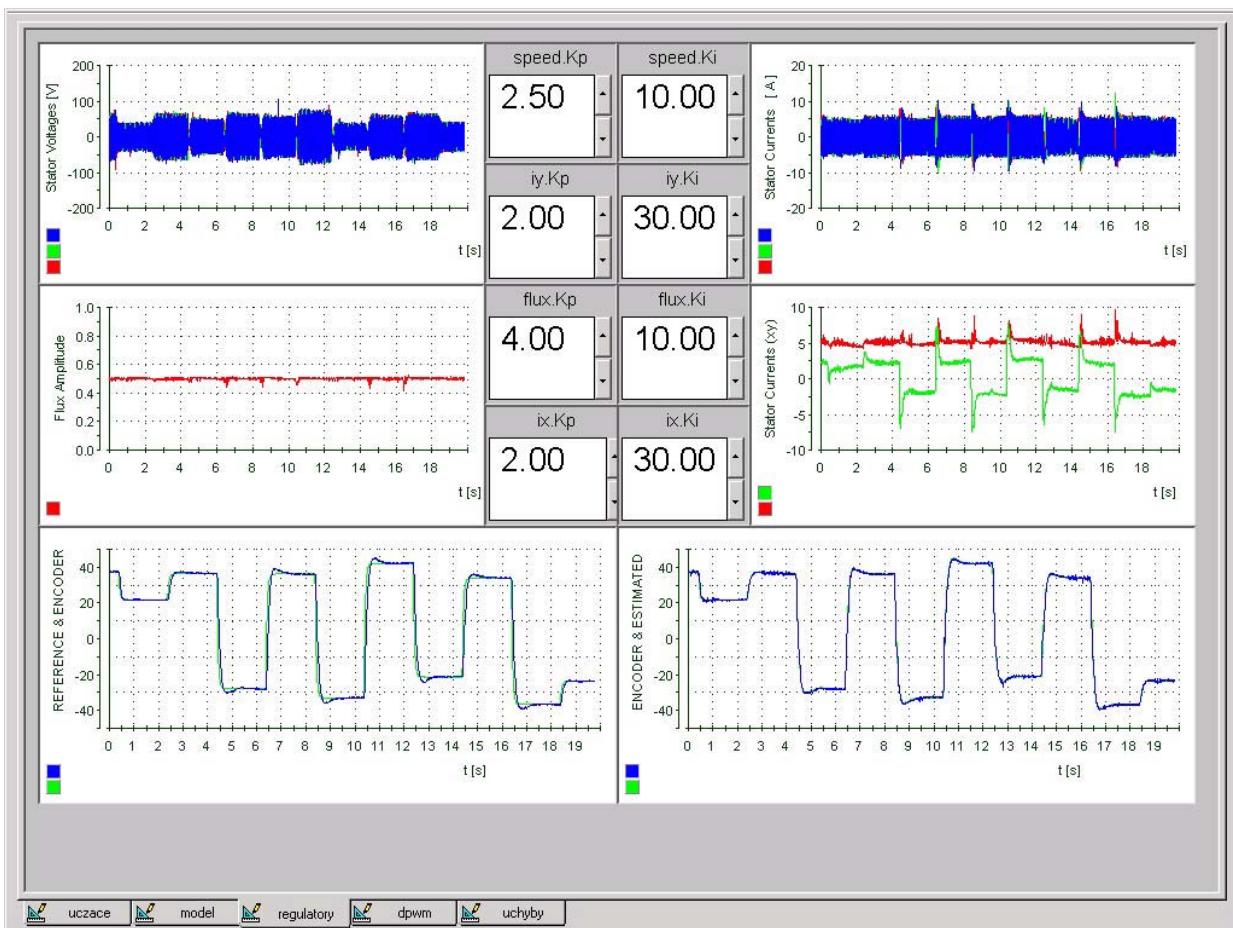
Z poziomu MATLABa zaimplementowano na karcie sterowanie typu DSFOC. Do estymacji strumienia wykorzystano strukturę z rysunku 3.10. Prędkość mierzoną przy użyciu enkodera. Algorytm sterowania wykonywany był z okresem $500\ \mu s$. Wektorowy modulator szerokości impulsów, realizujący modulację nieciągłą (DPWM), pracował z okresem $100\ \mu s$. Początkowo przyjęto nastawy regulatorów identyczne ze zoptymalizowanymi dla modelu symulacyjnego. Napęd zachowywał się stabilnie, niemniej jednak jego właściwości dynamiczne były wyraźnie różne od zaobserwowanych w trakcie symulacji. Nastawy z modelu symulacyjnego potraktowano więc jako punkt wyjściowy dla metody prób i błędów. Modyfikując nastawy regulatora prędkości (w zakresie nie przekraczającym $\pm 50\%$ wartości początkowych), otrzymano odpowiedzi układu bardzo zbliżone do uzyskanych drogą symulacyjną. Podobnie jak w modelu symulacyjnym, ograniczono szybkość zmian sygnału zadającego prędkość kątową wirnika. Jest to często stosowana modyfikacja, pozwalająca na ograniczenie (lub całkowite wyeliminowanie) przeregulowania przy jednoczesnym zachowaniu dobrych właściwości dynamicznych napędu. Dla założonego ograniczenia prądowego należy zarejestrować odpowiedź układu na skokową zmianę prędkości zadanej. Na tej podstawie należy oszacować szybkość narastania prędkości kątowej wirnika. Następnie przy pomocy członu inercyjnego pierwszego rzędu lub członu wprost ograniczającego pochodną sygnału, kształtuujemy sygnał referencyjny prędkości. Ograniczenie rzędu dwukrotnej wartości szybkości oszacowanej dla napędu pobudzonego skokiem jednostkowym, nie powoduje wyraźnego zmniejszenia dynamiki napędu przy zmianach prędkości zadanej. Tak przygotowany układ uruchomiono i z okresem $10\ ms$ zebrano dane uczące dla neuronowego estymatora prędkości. W trakcie zbierania 50-ciu tys. par uczących napęd pobudzany był losowym profilem prędkości zadanej i momentu obciążającego. Nauczona w trybie off-line SSN zaimplementowano następnie na karcie sterownika. Stworzono wirtualny panel sterowania umożliwiający nadzór nad dalszą częścią eksperymentu. Przykładowe dwie zakładki panelu przedstawiono na rysunkach 7.2 i 7.3.

7.2. Wyniki badań estymatora prędkości kątowej wirnika

Celem przeprowadzonych badań eksperimentalnych było sprawdzenie, czy, a jeżeli tak, to w jakim stopniu, przełączenie sprzężenia zwrotnego na prędkość estymowaną przy użyciu



Rysunek 7.2. Główna zakładka wirtualnego panelu sterowania eksperymentalnego bezczujnikowego napędu DSFOC z neuronowym aproksymatorem prędkości kątowej wirnika



Rysunek 7.3. Przykładowa zakładka wirtualnego panelu sterowania eksperimentalnego napędu z neuronowym aproksymatorem prędkości kątowej wirnika, umożliwiająca obserwację przebiegów prędkości oraz modyfikację nastaw regulatorów “on the fly”.

opracowanej SSN, zmieni pracę napędu. Przedstawione w rozprawie wyniki badań eksperymentalnych dotyczą estymatora A (dokładny opis na stronie 113). Przeprowadzone testy obejmowały porównanie pracy napędu bez czujnika prędkości, z pracą napędu z czujnikiem prędkości w następujących stanach:

- zmiany wartości sygnału prędkości zadanej;
- skokowej zmiany momentu zakłócającego;
- zmiany nastaw regulatorów na znaczaco różne od tych, które wykorzystano w trakcie tworzenia zbioru treningowego.

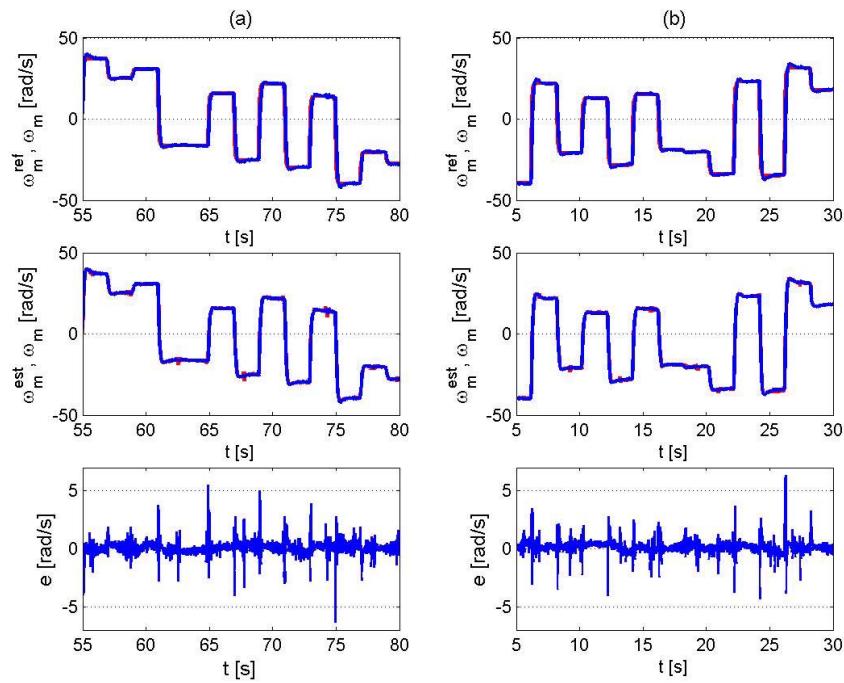
Należy przy tym podkreślić, że celem przeprowadzonych badań nie było dokonanie oceny zaimplementowanego sterowania DSFOC w wersji z czujnikiem prędkości, czy też określenie optymalnych nastaw regulatorów.

Przykładowe przebiegi zarejestrowane w układzie pobudzanym losowym profilem prędkości zadanej przedstawiono na rysunku 7.4. Dla większej czytelności, powiększony fragment tych przebiegów zamieszczono na rysunku 7.5. Podobnie jak przy prezentowaniu wyników w rozdziale poświęconym badaniom symulacyjnym, przyjęto następujący porządek na rysunkach przedstawiających oscylogramy prędkości:

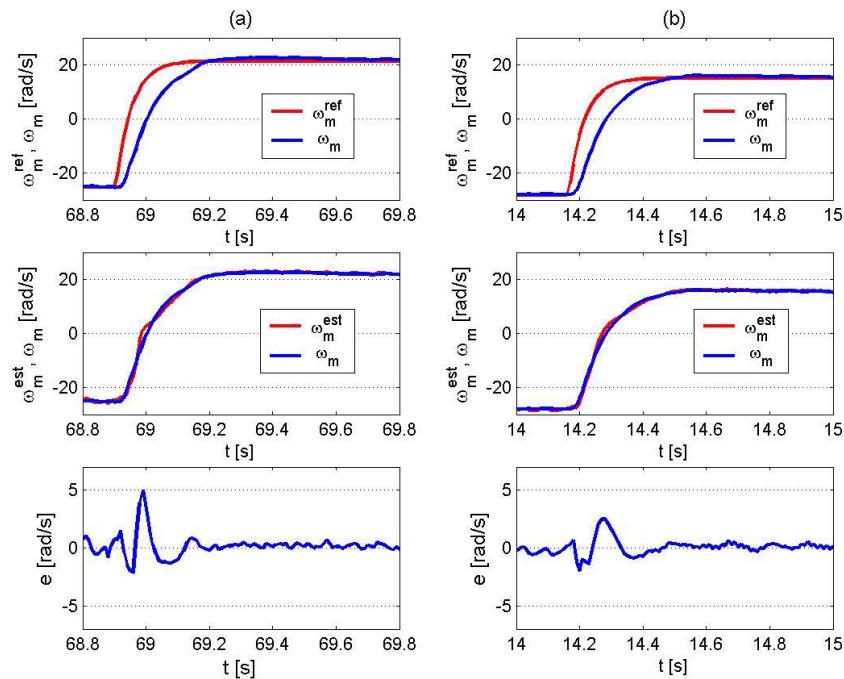
- w kolumnie (a) podano przebiegi zarejestrowane w układzie ze sprzężeniem zwrotnym od prędkości mierzonej przy użyciu enkodera,
- zaś w kolumnie (b), przebiegi uzyskane w napędzie bezczujnikowym, tj. po przełączeniu sygnału sprzężenia na neuronowy aproksymator prędkości kątowej wirnika.

Wyniki testów obejmujących zmiany wartości sygnału prędkości zadanej były zbieżne z wynikami uzyskanymi drogą symulacyjną. Napęd bezczujnikowy zachowywał się stabilnie (dla założonego losowego profilu prędkości zadanej) i prawidłowo osiągał wartość prędkości zadanej. Średnie błędy odtwarzania wyniosły odpowiednio $\bar{e}^{enkoder} = 0.5384$ oraz $\bar{e}^{SSN} = 0.4733$.

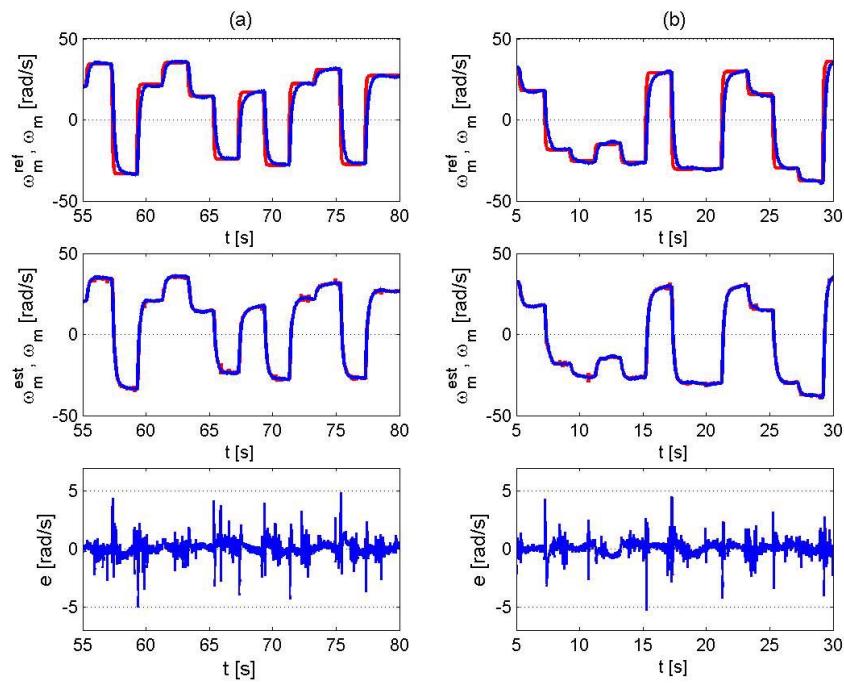
Kolejny test, zakładał trzykrotne zmniejszenie wzmacnienie w torach regulatora prędkości. Skutkiem czego było wyraźne zmniejszenie dynamiki napędu. Nastawy te nie były “widziane” przez sieć w trybie uczenia. Zarejestrowane wyniki podano na rysunku 7.6 i powiększono na rysunku 7.7. Uzyskane błędy odtwarzania to odpowiednio $\bar{e}^{enkoder} = 0.5699$ i $\bar{e}^{SSN} = 0.5637$. Z otrzymanych wyników można wnioskować o odporności estymatora na zmiany parametrów układu regulacji. Należy przy tym zaznaczyć, że badana odporność na zmiany nastaw regulatorów (zilustrowana na przykładzie regulatora prędkości), pojawia się wyłącznie przy uczeniu sieci w oparciu o próbki zarejestrowane w układzie



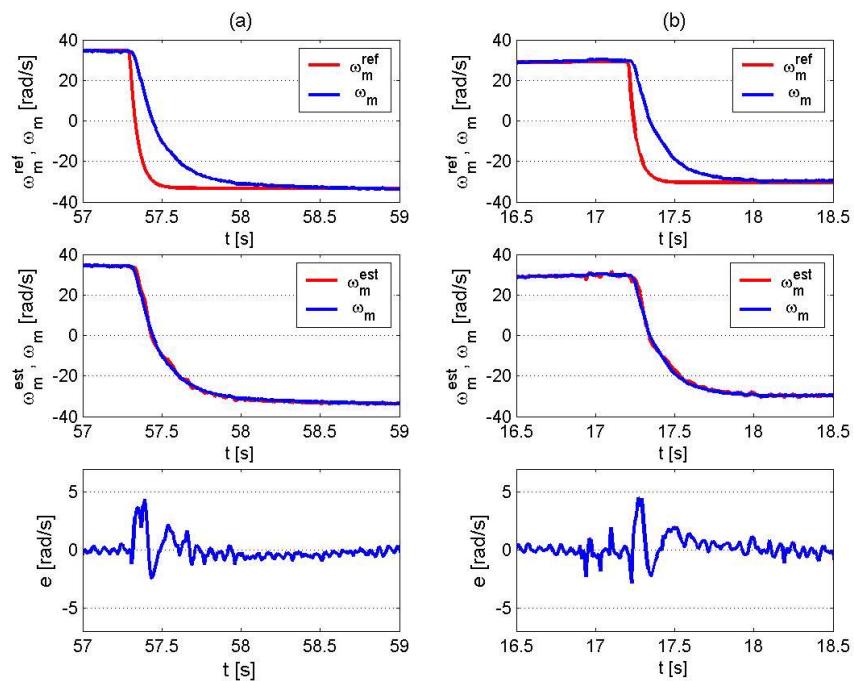
Rysunek 7.4. Oscylogramy sygnału zadającego, zmierzonej prędkości kątowej wirnika, prędkości odtworzonej przy użyciu SSN oraz błędu estymacji, zarejestrowane podczas zmian wartości sygnału zadającego - przy sprężeniu zwrotnym od: a) sygnału z enkodera, b) sygnału z estymatora neuronowego



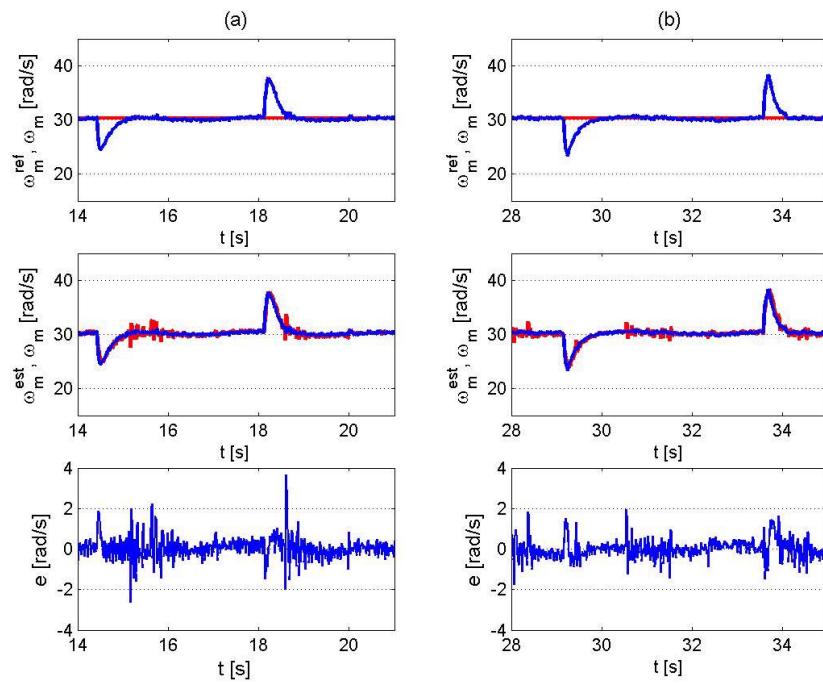
Rysunek 7.5. Powiększenia fragmentów przebiegów z rysunku 7.4



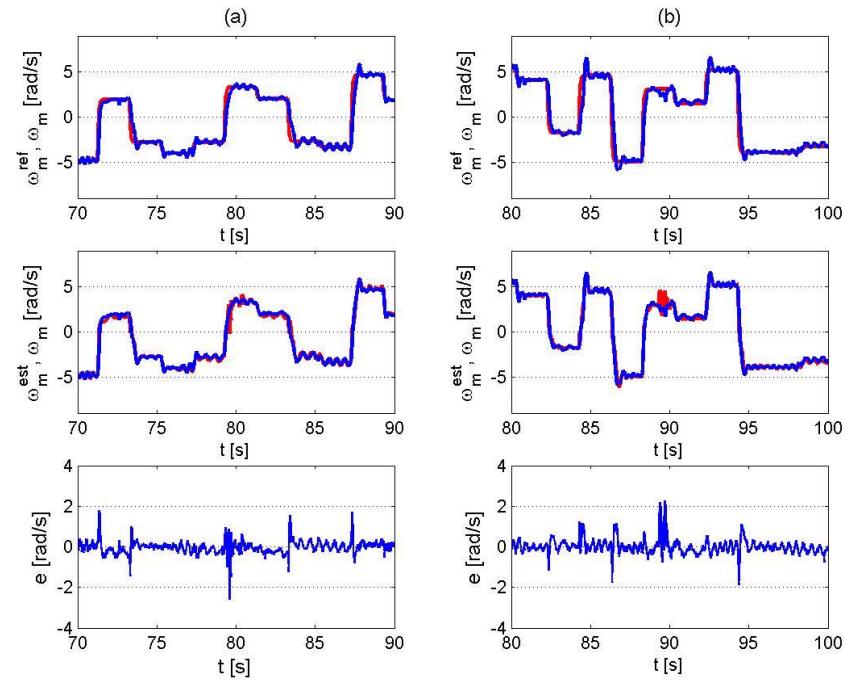
Rysunek 7.6. Odtwarzanie prędkości kątowej wirnika podczas zmian wartości sygnału zadającego przy zmniejszonych 3-krotnie wzmacnieniach w torach regulatora prędkości, przy sprzężeniu od: a) prędkości mierzonej i b) po przełączeniu pętli regulacji na sygnał prędkości estymowanej przy użyciu SSN



Rysunek 7.7. Powiększenia fragmentów przebiegów z rysunku 7.6



Rysunek 7.8. Odpowiedź układu na skokowe zmiany momentu zakłócającego (sekwencja: bieg jałowy – obciążenie ok. $0.6M_N$ – bieg jałowy), przy sprzężeniu od: a) sygnału enkodera oraz b) dla konfiguracji bez czujnika prędkości



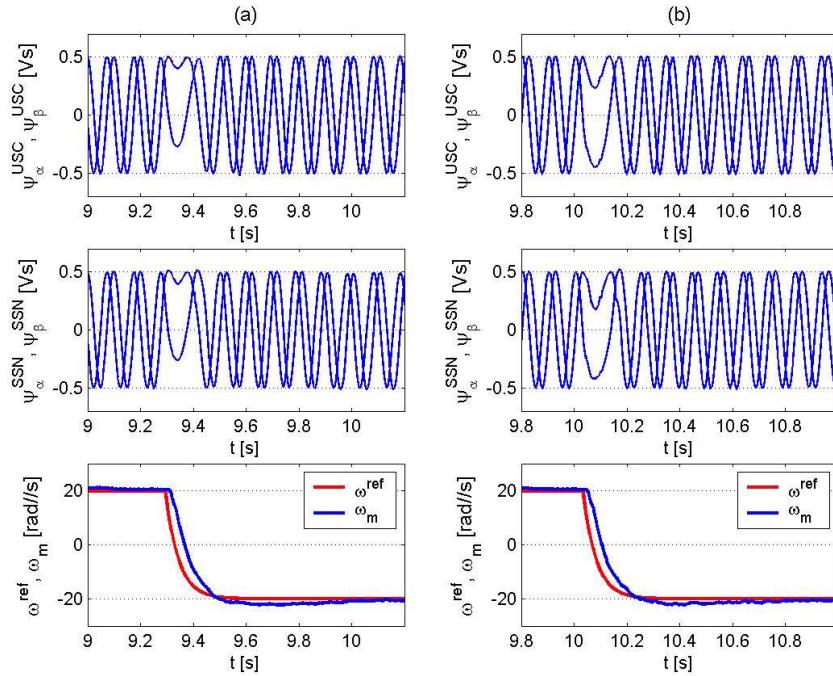
Rysunek 7.9. Praca napędu w obszarze małych prędkości kątowych wirnika: a) napęd z czujnikiem prędkości, b) napęd bezczujnikowy

o większej dynamice, w porównaniu z układem o zmienionych nastawach regulatorów. Nie zaobserwowano analogicznej odporności w przypadku konstruowania zbioru uczącego z wykorzystaniem napędu o obniżonej dynamice zmian prędkości (np. w wyniku zmniejszonych wzmacnianie w regulatorach, czy też obniżonych poziomach nasyceń tychże regulatorów), a testowaniu estymatora w układzie o maksymalnej założonej dynamice. Tak zbudowany zbiór uczący nie zapewnia bowiem równomiernego pokrycia przestrzeni stanów obiektu. Zwiększając dynamikę napędu, generujemy stany obiektu, które są zbyt odległe od stanów zawartych w tak przygotowanym zbiorze uczącym. Nie można wtedy uzyskać prawidłowej generalizacji. **Należy zatem konstruować zbiór uczący w oparciu o sygnały zarejestrowane w napędzie o maksymalnej założonej dynamice zmian prędkości kątowej wirnika.**

Zbadano odpowiedź układu bezczujnikowego na skokową zmianę momentu obciążenia (rys. 7.8) oraz pracę dla małych wartości prędkości zadanej (rys. 7.9). Podczas obu testów napęd zachowywał się stabilnie. Niemniej jednak przy prędkościach mniejszych od 5% prędkości znamionowej, układ miał tendencję do niespokojnej pracy (patrz pusta kolumna na rysunku 7.9, w chwili $t \cong 90\text{ s}$). Podobne problemy zarejestrowano również podczas badań napędu z przetwornikiem mechaniczno-elektrycznym przy prędkościach poniżej 2% prędkości znamionowej. Są one wypadkową szeregu zagadnień, które należałyby rozwiązać w przypadku implementowania sterowania DSFOC na potrzeby napędu, którego celem jest śledzenie niewielkich zmian prędkości zadanej w obszarze częstotliwości strumienia stojana bliskich zeru. Do najważniejszych z nich należy zaliczyć odpowiednie ekranowanie układów pomiarowych, zapewniające odporność układu na zakłócenia elektromagnetyczne generowane przez sam napęd, oraz realizację bloku wyznaczania strumienia stojana uwzględniającą algorytm adaptacji rezystancji stojana.

7.3. Wyniki badań estymatora strumienia stojana

W układzie regulacji zaimplementowano trzy różne estymatory strumienia: przestrajany filtr dolnoprzepustowy PLPF (rys. 3.6, str. 54), ulepszony schemat całkowania USC (rys. 3.10, str. 58) oraz strukturę neuronową z rysunku 5.2. Filtry kształtujące sygnały wejściowe, jak i liczby neuronów w poszczególnych warstwach, przyjęto zgodnie z modelem symulacyjnym. Z uwagi na klasyczne wykonanie silnika, przyjęto, że nauczyciel dla neuronowego estymatora strumienia będą oba estymatory algorytmiczne (PLPF, USC). Zmianę rezystancji stojana wymuszano dodatkowymi rezystorami dołączanymi do obwodu stojana (patrz rys. 7.1 na str. 137). W zależności od konfiguracji umożliwiały one powiększenie rezystancji w stosunku do znamionowej o ok. 20%, 30% i 45%. Założono, że temperaturowe zmiany rezystancji uzwojeń silnika, w warunkach ustalonego obciążenia i niezmiennej temperatury



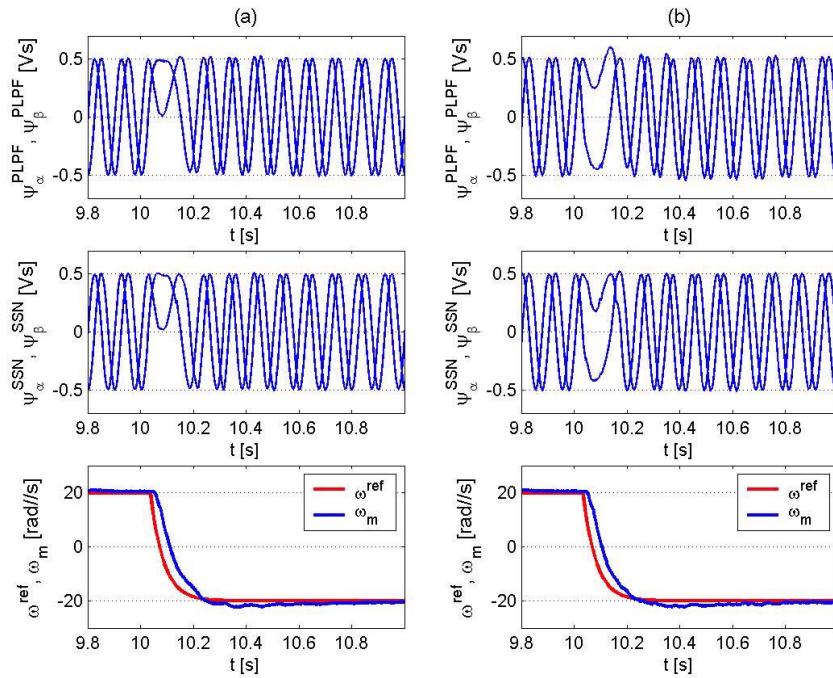
Rysunek 7.10. Porównanie pracy układu przy sprzężeniu zwrotnym od: a) USC i b) estymatora neuronowego, przy założeniu prawidłowej identyfikacji rezystancji stojana występującej w bloku wyznaczenia siły elektromotorycznej wykorzystywanej w USC.

otoczenia, są pomijalnie małe. Generując zbiór uczący zmieniano rezystancję dodatkową w obwodzie stojana i jednocześnie korygowano odpowiednio rezystancję w estymatorach PLPF i USC. Tak nauczony estymator neuronowy porównano z PLPF i USC przy założeniu braku dodatkowego algorytmu adaptacji rezystancji stojana. Na rysunkach przedstawiających przykładowe wyniki testów omawianego estymatora przyjęto następujący porządek:

- w kolumnie (a) podano przebiegi zarejestrowane w układzie ze sprzężeniem zwrotnym od jednego z dwóch estymatorów algorytmicznych (PLPF lub USC),
- zaś w kolumnie (b), przebiegi uzyskane w napędzie z neuronowym estymatorem składowych wektora strumienia stojana.

Na rysunku 7.10 przedstawiono wyniki testu porównawczego aproksymatora neuronowego z estymatorem USC, przy założeniu prawidłowej identyfikacji rezystancji stojana występującej w bloku wyznaczenia siły elektromotorycznej wykorzystywanej w USC. Podobnie na rysunku 7.11 zamieszczono sygnały zarejestrowane dla PLPF.

Następnie zwiększyliśmy rezystancję stojana o ok. 30%. Przy braku adaptacji parametru \hat{R}_s obserwujemy wyraźne pogorszenie dynamiki napędu z USC i PLPF. Związane jest to z nieprawidłowym wyznaczeniem całkowanej indukowanej siły elektromotorycznej, pociągającym za sobą błędную orientację układu odniesienia, w którym wyznaczane jest sterowanie.

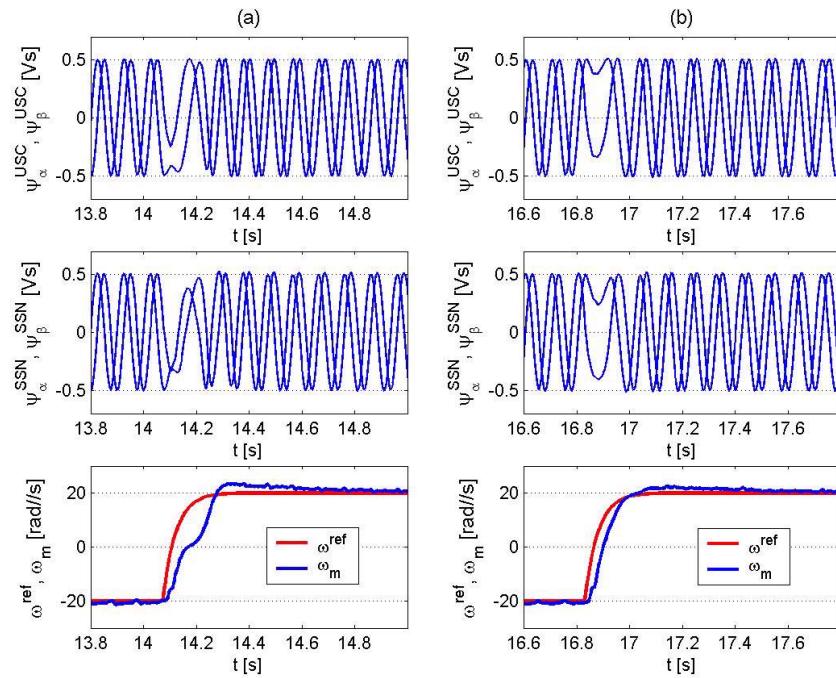


Rysunek 7.11. Porównanie pracy układu przy sprzężeniu zwrotnym od: a) PLPF i b) estymatora neuronowego, przy założeniu prawidłowej identyfikacji rezystancji stojana występującej w bloku wyznaczenia siły elektromotorycznej wykorzystywanej w PLPF.

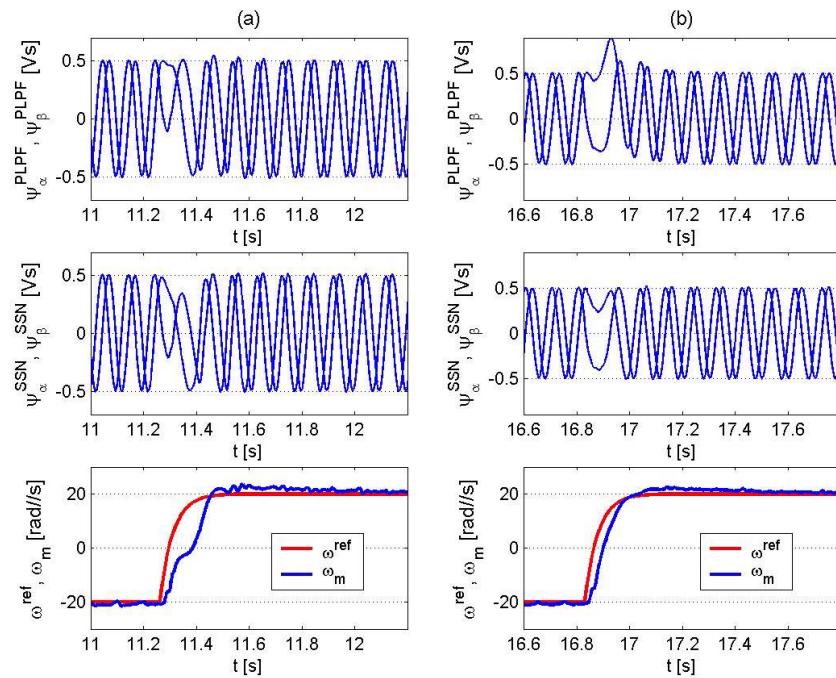
Natomiast układ z neuronowym estymatorem strumienia cechuje dużo lepsza dynamika. Zaobserwowano tym samym “inteligentne” działanie aproksymatora. Odpowiednie wyniki przedstawiono na rysunkach 7.12 i 7.13.

7.4. Podsumowanie

Wyniki przeprowadzonych badań eksperymentalnych neuronowego estymatora prędkości kątowej ze wstępny nieliniowym przetwarzaniem sygnałów elektrycznych, potwierdziły jego użyteczność do budowy rozpatrywanego napędu bezczujnikowego. W obszarze małych prędkości szczególnie ważna staje się realizacja odpowiedniego napędu z czujnikiem prędkości, służącego do generowania zbiorów uczących dla aproksymatora neuronowego. Zdaniem autora, nieuzasadnione byłoby oczekiwanie, że napęd bezczujnikowy z neuronowym aproksymatorem prędkości ucznionym w trybie off-line, będzie funkcjonował lepiej niż napęd, którym posłużono się do generowania zbioru uczącego. Z kolei testy neuronowego estymatora strumienia stojana potwierdziły wyniki badań symulacyjnych, wskazujące na możliwość uzyskania struktury neuronowej dużo bardziej odpornej na zmiany rezystancji stojana niż estymator algorytmiczny bez adaptacji tegoż parametru.



Rysunek 7.12. Porównanie pracy układu przy sprzężeniu zwrotnym od: a) USC i b) estymatora neuronowego, przy założeniu wzrostu rezystancji stojana o ok. 30% nie uwzględnionego w bloku wyznaczenia siły elektromotorycznej wykorzystywanej w USC.



Rysunek 7.13. Porównanie pracy układu przy sprzężeniu zwrotnym od: a) PLPF i b) estymatora neuronowego, przy założeniu wzrostu rezystancji stojana o ok. 30% nie uwzględnionego w bloku wyznaczenia siły elektromotorycznej wykorzystywanej w PLPF.

Rozdział 8

Wnioski końcowe

Sztuczne sieci neuronowe mogą być postrzegane jako proste (w obliczu znanych metod uczenia), uniwersalne układy aproksymacyjne odwzorowujące wielowymiarowe zbiory danych. Z drugiej jednak strony, służą do konstruowania systemów sztucznej inteligencji mających zdolność uczenia się i adaptacji do zmieniających się warunków środowiskowych, zdolność uogólniania nabytej wiedzy (tzw. generalizacji) i w tym sensie zdolność do podejmowania decyzji na podstawie niepełnych lub sprzecznych przesłanek. Elastyczność SSN w modelowaniu zależności nieliniowych jest głównym powodem ich popularności w różnych dziedzinach nauki i techniki, w tym w automatyce. Jedną z możliwości jest wykorzystanie SSN do modelowania dynamiki obiektu. Odtwarzanie wybranych nieskalarnych lub trudno mierzalnych zmiennych stanu obiektu jest zazwyczaj warunkiem koniecznym osiągnięcia prawidłowego sterowania tymże obiektem. Modelowanie dynamiki uzyskiwane jest zazwyczaj w dwojakim sposobie. W jednych aplikacjach stosowane są sieci uczone on-line. W rozwiązaniach tych proces adaptacji wag sieci w czasie rzeczywistym projektuje się tak, aby wyjścia lub wybrane wagi sieci były zbieżne do niedostępnych parametrów i/lub zmiennych stanu obiektu (np. [8]) lub pełniły rolę sygnałów sterujących (np. [40]). W drugiej grupie aplikacji stosowane są sieci rekurencyjne, bądź też sieci jednokierunkowe z liniami opóźnień na sygnałach wejściowych, uczone w trybie off-line (liczne przykłady w [4, 10]). W rozwiązaniach tych modelowanie dynamiki uzyskujemy poprzez wprowadzenie rekursji i/lub wejść historycznych. Przedstawiony podział nie wyklucza oczywiście rozwiązań mieszanych wykorzystujących, na przykład, sieć rekurencyjną uczoną w trybie on-line [9]. Niniejszą pracę poświęcono zastosowaniu sieci jednokierunkowych, uczonych off-line, do rozwiązania zadania odtwarzania prędkości kątowej wirnika i strumienia stojana silnika indukcyjnego, na potrzeby realizacji bezczujnikowego polowozorientowanego napędu wektorowego. W pracy omówiono problemy dotyczące znanych rozwiązań rekurencyjnych i/lub z liniami opóźnień, uzasadniając w ten sposób celowość dalszych poszukiwań. Zaproponowano metody tworzenia bazy aproksymatora opartego

na jednokierunkowej sieci neuronowej, umożliwiające skuteczne rozwiązywanie zadania od- twarzania wybranych zmiennych stanu w napędzie prądu przemiennego. Pokazano, że odpowiednie statyczne (nieliniowe) lub dynamiczne (liniowe) przetwarzanie sygnałów elektrycznych, może znaczco uproszczyć zadanie aproksymacji i dodatnio wpłynąć na zdolności do generalizacji.

Z uzyskanych drogą symulacyjną i eksperimentalną, wyników badań neuronowego es- tymatora prędkości kątowej wirnika, można wysnuć następujące wnioski:

1. Odpowiednie wstępne nieliniowe przetwarzanie sygnałów prądów i napięć stojana pozwala rozwiązać szereg utrudnień pojawiających się przy próbie bezpośredniego podawania tych sygnałów na wejścia sieci.
2. Zastosowanie metod badania liniowej niezależności kandydackich sygnałów wejściowych umożliwia wielokrotne zredukowanie rozmiaru zbioru uczącego z jednoczesnym wzrostem zdolności sieci do uogólniania nabyczej wiedzy.
3. Wykorzystanie typowych analiz korelacyjnych (Analiza Składowych Głównych, Ana- liza Składowych Niezależnych) poprawia jakość uzyskiwanych estymat prędkości.
4. Dalszy spadek błędów odtwarzania można uzyskać determinując bazę aproksymatora w oparciu o współczynniki korelacji prędkości kątowej z sygnałami kandydackimi.
5. Rozbudowywanie bazy aproksymatora o sygnały dostępne w układzie sterowania (np. zadany moment elektromagnetyczny, prędkość zadana) znaczco polepsza dokładność estymatora, przy założeniu stałości parametrów układu sterowania.
6. Nie należy rozbudowywać bazy aproksymatora o sygnały wymienione w punkcie 5., przy założeniu zmienności nastaw regulatorów. Prowadzi to bowiem do znacznego pogorszenia właściwości obserwatora.
7. Możliwe jest uzyskanie dobrej odporności wybranych struktur na zmiany parametrów obiektu (np. momentu bezwładności, rezystancji stojana) i nastaw układu regula- cji (np. wzmacnienia w torach regulatora prędkości). Stwierdzono, że odporność na jedne z nich (np. zmiany momentu bezwładności i wzmacnienia w torach regulatora prędkości) pojawia się samoistnie, tj. nie ma potrzeby uwzględniania zmian tych parametrów w zbiorze uczącym. Podczas gdy zmiany innych (np. rezystancji sto- jana) należy uwzględnić przy tworzeniu zbioru uczącego. W przeciwnym przypadku struktura nauczona w trybie off-line nie będzie dostatecznie odporna na zmiany tych parametrów.

8. Prawidłowo nauczony jednokierunkowy perceptron wielowarstwowy bez linii opóźnień na sygnałach wejściowych, może skutecznie zastąpić przetwornik mechaniczno-elektryczny prędkości kątowej wirnika w napędzie prądu przemiennego (zweryfikowano dla napędu DSFOC).

Z kolei badania nad neuronowym aproksymatorem strumienia stojana wskazują, że:

9. Neuronowy aproksymator funkcji (w postaci sieci jednokierunkowej) wraz z odpowiednim dynamicznym przetwarzaniem sygnałów prądów i napięć stojana, o strukturze zainspirowanej modelem identyfikacji Wienera, może realizować zadanie odtwarzania strumienia stojana silnika indukcyjnego.
10. Możliwe jest uzyskanie lepszej odporności na zmiany rezystancji stojana, niż przy zastosowaniu metod bazujących na całkowaniu indukowanej siły elektromotorycznej (przy założeniu braku dodatkowego algorytmu adaptacji wspomnianego parametru).
11. W obszarze rozwiązań neuronowych zadania odtwarzania strumienia stojana, opracowana struktura stanowi jedyne znane autorowi rozwiązanie nierekurencyjne.

Za najcenniejsze osiągnięcia własne autor uważa:

1. Opracowanie nowych struktur estymatorów neuronowych prędkości kątowej wirnika i strumienia stojana na potrzeby napędu z silnikiem prądu przemiennego.
2. Sformułowanie kryteriów oceny przydatności sygnałów w proponowanej architekturze estymatora prędkości.
3. Zbadanie możliwości wykorzystania algorytmu największego spadku liczby warunkowej, analizy składowych głównych i analizy składowych niezależnych do polepszania dokładności uzyskiwanych estymat. W konsekwencji zaproponowanie własnej metody eliminacji sygnałów wejściowych sieci ze zbioru kandydackiego, bazującej na klasteryzacji w oparciu o współczynnik korelacji.
4. Zbadanie funkcjonowania opracowanych estymatorów prędkości w pętli sprzężenia zwrotnego w napędzie DSFOC.
5. Opracowanie aproksymatora strumienia stojana opartego na statycznej sieci jednokierunkowej i wykorzystującego dynamiczne przetwarzanie sygnałów prądów i napięć w celu rozszerzenia bazy aproksymatora.
6. Eksperymentalną weryfikację wybranych wyników badań symulacyjnych.

Za niemniej ważne, chociaż niekoniecznie oryginalne osiągnięcia, autor uważa:

7. Stworzenie szeregu kilkudziesięciu modeli symulacyjnych znanych obserwatorów prędkości kątowej wirnika i strumienia stojana silnika indukcyjnego, w tym rozszerzonego filtru Kalmana, rozszerzonego obserwatora Luenbergera, obserwatora w trybie ruchu ślizgowego, adaptacyjnych układów z modelem odniesienia, estymatorów parametrycznych z neuronową siecią uczoną w trybie on-line, estymatorów nieparametrycznych z siecią rekurencyjną, z/bez liniami opóźnień na sygnałach wejściowych, trenowaną w trybie off-line, stanowiących tło i inspirację do poszukiwań nowych rozwiązań. Modele te mogą zostać wykorzystane do dalszych badań z zakresu bezczujnikowych napędów prądu przemienneego.
8. Udowodnienie, że opublikowany w *IEEE Transactions on Power Electronics* (2004), adaptacyjny filtr neuronowy składowej stałej na wyjściu idealnego członu całkującego, jest równoważny członowi inercyjnemu pierwszego rzędu stosowanemu od dawna jako najprostsze i zarazem najmniej doskonałe rozwiązanie problemów związanych z wykorzystaniem algorytmu idealnego całkowania przy wyznaczaniu strumienia stojana na podstawie indukowanej siły elektromotorycznej.

Za problem otwarty należy uznać zalgorytmizowanie procesu doboru filtrów występujących w opracowanym neuronowym estymatorze wektora przestrzennego strumienia stojana.

Autor ma nadzieję, że wyniki analiz i badań zamieszczonych w niniejszej pracy, pozwolą osobom zajmującym się projektowaniem neuroestymatorów w napędzie elektrycznym prądu przemiennej, uniknąć wielu błędów wynikających przede wszystkim z przeświadczenia o uniwersalności sieci neuronowych jako aproksymatorów. Zgodnie z posiadaną przez autora wiedzą z zakresu neuroestymatorów dla silnika klatkowego uczonych w trybie off-line, nie opublikowano wcześniej pracy poświęconej zasadom i metodom tworzenia bazy dla neuronowych aproksymatorów prędkości kątowej wirnika i strumienia stojana. Ewentualne prace z tego zakresu skupią się na doborze struktury samej sieci oraz metod jej uczenia. Autor jest przekonany, że przeniesienie ciężaru poszukiwań na opracowanie odpowiedniego wstępnie przetwarzania sygnałów dostępnych w układzie napędowym, w celu wyznaczenia skutecznej bazy aproksymatora neuronowego, okazało się decyzją słuszną.

Bibliografia

- [1] Mathworks. *Matlab Release 13 Manual*, June 2002.
- [2] W. Duch, J. Korbicz, L. Rutkowski, and R. Tadeusiewicz, editors. *Sieci neuronowe*, volume 6 of *Biocybernetyka i inżynieria biomedyczna 2000*. Akademicka Oficyna Wydawnicza EXIT, 2000.
- [3] I. Boldea and S.A. Nasar. *The Induction Machine Handbook*. The Electric Power Engineering Series. CRC Press LLC, 2002.
- [4] T. Orłowska-Kowalska. *Bezczujnikowe układy napędowe z silnikami indukcyjnymi*, volume 48 of *Postępy Napędu Elektrycznego i Energoelektroniki*. Oficyna Wydawnicza Politechniki Wrocławskiej, 2003.
- [5] Z. Krzemieński. *Cyfrowe sterowanie maszynami asynchronicznymi*, volume 45 of *Postępy Napędu Elektrycznego i Energoelektroniki*. Wydawnictwo Politechniki Gdańskiej, 2001.
- [6] M.P. Kaźmierkowski, R. Krishnan, and F. Blaabjerg. *Control in Power Electronics - Selected Problems*. Academic Press, An imprint of Elsevier Science, London/New York/Paris/Tokyo/..., 2002.
- [7] L. Ben-Brahim, S. Tadakuma, and A. Akdag. Speed control of induction motor without rotational transducers. *IEEE Transactions on Industry Applications*, 35(4):844–850, July/August 1999.
- [8] D. L. Sobczuk. *Application of ANN for control of PWM inverter fed induction motor drives*. PhD thesis, Warsaw University of Technology, Faculty of Electrical Engineering, 1999.
- [9] S.-H. Kim, T.-S. Park, J.-Y. Yoo, and G.-T. Park. Speed-sensorless vector control of an induction motor using neural network speed estimation. *IEEE Transactions on Industrial Electronics*, 48(3):609–614, June 2001.
- [10] P. Vas. *Artificial-intelligence-based electrical machines and drives: application of fuzzy, neural, fuzzy-neural, and genetic-algorithm-based techniques*. Oxford University Press, 1999.
- [11] T. Orłowska-Kowalska and P. Migas. Analysis of the induction motor speed estimation quality using neural networks of different structure. *Archives of Electrical Engineering*, L(4):411–425, 2001.
- [12] J. O. P. Pinto, B. K. Bose, and L. E. B. Silva. A stator-flux-oriented vector-controlled induction motor drive with space-vector PWM and flux-vector synthesis by neural networks. *IEEE Transactions on Industry Applications*, 37(5):1308–1318, September/October 2001.
- [13] L. Grzesiak and B. Beliczyński. Simple neural cascade architecture for estimating of stator and rotor flux vectors. *EPE Conference CD-ROM*, 1999.
- [14] M. Cirrincione, M. Pucci, G. Cirrincione, and G.-A. Capolino. A new adaptive integration methodology for estimating flux in induction machine drives. *IEEE Transactions on Power Electronics*, 19(1):25–34, January 2004.
- [15] W. H. Press, S. A. Teukolsky, W. T. Wetterling, and B. P. Flannery. *Numerical recipes in C: The art of scientific computing*. Cambridge University Press, 1992.
- [16] A. Cichocki and S. Amari. *Adaptive Blind Signal and Image Processing: Learning Algorithms and Applications*. John Wiley & Sons, Ltd, England, 2002.

- [17] Bimal K. Bose. *Modern Power Electronics and AC Drives*. Prentice Hall PTR, Pearson Education, New Jersey, 2002.
- [18] P. Vas. *Sensorless Vector and Direct Torque Control*, volume 42 of *Monographs in Electrical and Electronic Engineering*. Oxford University Press, 1998.
- [19] K. Pieńkowski. Interpretacja fizyczna stanów elektromagnetycznych w silnikach indukcyjnych podczas hamowania prądem stałym. *Zeszyty Naukowe Politechniki Śląskiej, seria Elektryka*, 177:81–88, 2001.
- [20] C. Schauder. Adaptive speed identification for vector control of induction motors without rotational transducers. *IEEE Transactions on Industry Applications*, 28(5):1054–1061, September/October 1992.
- [21] M. Elloumi, L. Ben-Brahim, and M.A. Al-Hamadi. Survey of speed sensorless controls for IM drives. *IEEE Industrial Electronics Society Conference IECON*, 2:1018–1023, August/September 1998.
- [22] B. Beliczyński and L. Grzesiak. Induction motor speed estimation: neural versus phenomenological model approach. *ELSEVIER Neurocomputing*, 43:17–36, 2002.
- [23] Bo Peterson. *Induction machine speed estimation - observations on observers*. PhD thesis, Lund Institute of Technology (LTH), Sweden, 1996.
- [24] R. E. Kalman. A new approach to linear filtering and prediction problems. *Transactions of the ASME-Journal of Basic Engineering*, 82:35–45, 1960.
- [25] Texas Instruments Europe. *Sensorless Control with Kalman Filter on TMS320 Fixed-Point DSP*, 1997.
- [26] M.C. VanDyke, J.L. Schwartz, and C.D. Hall. Unscented Kalman filtering for spacecraft attitude state and parameter estimation. *14th AAS / AIAA Space Flight Mechanics Conference*, 2004.
- [27] G. Welch and G. Bishop. An introduction to the Kalman filter. SIGGRAPH course materials, www.cs.unc.edu/~welch/kalman/, 2001.
- [28] G. Welch and G. Bishop. An introduction to the Kalman filter. Manual from www.cs.unc.edu/~welch/kalman/, May 2003.
- [29] Li Cai, Yinhai Zhang, Zhongchao Zhang, Chenyang Liu, and Zhengyu Lu. Application of genetic algorithms in EKF for speed estimation of an induction motor. *IEEE Power Electronics Specialists Conference PESC*, 1(7):345–349, June 2003.
- [30] K. L. Shi, T. F. Chan, Y. K. Wong, and S. L. Ho. Speed estimation of an induction motor drive using extended Kalman filter. *IEEE Power Engineering Society Winter Meeting*, 1:243–248, January 2000.
- [31] M. Hilairet, F. Auger, and C. Darengosse. Two efficient Kalman filters for flux and velocity estimation of induction motors. *IEEE Power Electronics Specialists Conference PESC*, 2:891–896, June 2000.
- [32] I. Zein, L. Loron, and C. Forgez. An extended Kalman filter and an appropriate model for the real-time estimation of the induction motor variables and parameters. *ACTA Press Proceedings - Measurement and Control*, 2001.
- [33] J. El Hassan, E. v. Westerholt, X. Roboam, and B. de Fornel. Comparison of different state models in direct torque control of induction machines operating without speed sensor. *IEEE Industry Applications Conference*, 3:1345–1352, October 2000.
- [34] M. A. Ouhrouche. Estimation of speed, rotor flux and rotor resistance in cage induction motor sensorless drive using the EKF algorithm. *International Journal of Power and Energy Systems*, 22(2):103–109, 2002.

- [35] T. Orłowska-Kowalska and K. P. Dyracz. Induction motor flux, speed and rotor time-constant estimation using extended Kalman filter. *International Conference on Electrical Drives and Power Electronics EDPE*, pages 491–496, September 2003.
- [36] L. Salvatore, S. Stasi, and F. Cupertino. Improved rotor speed estimation using two Kalman filter-based algorithms. *IEEE Industry Applications Conference*, 1:125–132, September/October 2001.
- [37] J. L. Mora, A. Torralba, and L. G. Franquelo. An adaptive speed estimator for induction motors based on a Kalman filter with low sample time. *IEEE Power Electronics Specialists Conference PESC*, 2:794–798, June 2001.
- [38] D. Erdogmus, J. C. Principe, and G. Thampi. Adaptive linear observer for nonlinear systems. *Proceedings of CONTROLO, Portuguese Conference on Automatic Control*, pages 56–60, September 2002.
- [39] D. Erdogmus, A. Umut Genc, and J. C. Principe. A neural network perspective to extended Luenberger observers. *Institute of Measurement and Control (CNEL, University of Florida)*, 35(2):10–16, February 2002.
- [40] D. Wyszomierski. *Napęd prądu przemiennego z neuronowym regulatorem prędkości uczonym on-line*. PhD thesis, Warsaw University of Technology, 2003.
- [41] T. Orłowska-Kowalska. Application of extended Luenberger observer for flux and rotor time-constant estimation in induction motor drive. *IEE Proceedings D*, 136(6):324–330, November 1989.
- [42] T. Du and M. A. Brdys. Shaft speed, load torque and rotor flux estimation of induction motor drive using an extended Luenberger observer. *IEEE 6th International Conference on Electrical Machines and Drives*, 376:179–184, September 1993.
- [43] H. Kubota, K. Matsuse, and T. Nakano. DSP-based speed adaptive flux observer of induction motor. *IEEE Transactions on Industry Applications*, 29(2):344–348, March/April 1993.
- [44] H. Kubota and K. Matsuse. Speed sensorless field-oriented control of induction motor with rotor resistance adaptation. *IEEE Transactions on Industry Applications*, 30(5):1219–1224, September/October 1994.
- [45] J. Maes and J. Melkebeek. Adaptive flux observer for sensorless induction motor drives with enhanced dynamic performance. *EPE Conference CD-ROM*, 1999.
- [46] J. Maes and J. A. Melkebeek. Speed-sensorless direct torque control of induction motors using an adaptive flux observer. *IEEE Transactions on Industry Applications*, 36(3):778–785, May/June 2000.
- [47] G. Griva, F. Profumo, R. Bojoi, V. Bostan, M. Cuibus, and C. Ilas. General adaptation law for MRAS high performance sensorless induction motor drives. *IEEE Power Electronics Specialists Conference PESC*, 2:1197–1202, June 2001.
- [48] G. Griva, F. Profumo, L. Rosell, and R. Bojoi. Optimization of fuzzy-like Luenberger observer for high speed sensorless induction motor drives using genetic algorithms. *IEEE Industry Applications Conference*, 2:1268–1274, October 2000.
- [49] Jooho Song, Kyo-Beum Lee, Joong-Ho Song, Ick Choy, and Kwang-Bae Kim. Sensorless vector control of induction motor using a novel reduced-order extended Luenberger observer. *IEEE Industry Applications Conference*, 3:1828–1834, October 2000.
- [50] T. L. Skvarenina. *The power electronics handbook*. Industrial electronics series. CRC Press, Boca Raton/London/New York/Washington D.C., 2002.
- [51] V. I. Utkin. Sliding mode control design principles and applications to electric drives. *IEEE Transactions on Industrial Electronics*, 40(1):23–36, February 1993.
- [52] A. Alessandri. Design of sliding-mode observers and filters for nonlinear dynamic systems. *Proceedings of the 39th IEEE Conference on Decision and Control*, 3:2593–2598, December 2000.

- [53] M. Tursini, R. Petrella, and F. Parasiliti. Adaptive sliding-mode observer for speed-sensorless control of induction motors. *IEEE Transactions on Industry Applications*, 36:1380–1387, October 2000.
- [54] A. Derdiyok, Zhang Yan, M. K. Güven, and V. Utkin. A sliding mode speed and rotor time constant observer for induction machines. *Conference of the IEEE Industrial Electronics Society IECON*, 2:1400–1405, December 2001.
- [55] Yuhong Zheng and K. A. Loparo. Adaptive flux observer for induction motors. *Proceedings of American Control Conference*, 4:2329–2333, June 1998.
- [56] T. Orłowska-Kowalska and M. Pawlak. Design and implementation of a new sliding-mode observer for speed-sensorless control of induction machine. *IEEE Transactions on Industrial Electronics*, 49:1177–1182, October 2002.
- [57] H.-U. Rehman, A. Derdiyok, M. K. Güven, and Longya Xu. A new current model flux observer for wide speed range sensorless control of an induction machine. *IEEE Transactions on Power Electronics*, 17:1041–1048, November 2002.
- [58] H.-U. Rehman and Longya Xu. A voltage model flux observer design requiring no stator resistance or voltage signal information. *Applied Power Electronics Conference and Exposition APEC*, 1:299–303, March 2002.
- [59] N. Inanc, M. K. Güven, H. Rehman, A. Derdiyok, and Longya Xu. A new sliding mode flux and speed observer for speed sensorless control of induction machine. *National Aerospace and Electronics Conference NAECON, Proceedings of the IEEE*, pages 574–578, October 2000.
- [60] A. Derdiyok. A novel speed estimation algorithm for induction machines. *ELSEVIER, Electric Power Systems Research*, 64:73–80, 2003.
- [61] A. Derdiyok, H. Rehman, M. K. Güven, N. Inanc, and Longya Xu. A robust sliding mode observer for speed estimation of induction machine. *Applied Power Electronics Conference and Exposition APEC*, 1:413–418, March 2001.
- [62] A. Consoli and A. Testa. An alternative to high frequency current detection techniques for zero speed sensorless control of AC motor drives. *EPE Journal*, 13(3):30–35, August 2003.
- [63] M. Hilairet and F. Auger. Frequency estimation for sensorless control of induction motors. *IEEE International Conference on Acoustics, Speech, and Signal Processing ICASSP*, 7:925–928, May 2001.
- [64] A. Ballini, G. Franceschini, E. Lorenzani, C. Tassoni, and F. Filippetti. Sensorless speed detection in induction machine. *International Conference on Electrical Machines ICEM*, August 2002.
- [65] P.L. Jansen and R.D. Lorenz. Transducerless position and velocity estimation in induction and salient AC machines. *IEEE Transactions on Industry Applications*, 31(2):240–247, March/April 1995.
- [66] P.L. Jansen and R.D. Lorenz. Transducerless field orientation concepts employing saturation-induced saliences in induction machines. *IEEE Transactions on Industry Applications*, 32(6):1380–1393, November/December 1996.
- [67] Jung-Ik Ha and Seung-Ki Sul. Sensorless field-orientation control of an induction machine by high-frequency signal injection. *IEEE Transactions on Industry Applications*, 35(1):45–51, January/February 1999.
- [68] F. Briz, A. Diez, and M.W. Degner. Dynamic operation of carrier-signal-injection-based sensorless direct field-oriented AC drives. *IEEE Transactions on Industry Applications*, 36(5):1360–1368, September/October 2000.
- [69] M.W. Degner and R.D. Lorenz. Using multiple saliences for the estimation of flux, position, and velocity in AC machines. *IEEE Transactions on Industry Applications*, 34(5):1097–1104, September/October 1998.

- [70] C. Caruana, G.M. Asher, and K.J. Bradley. Reduction of secondary saliences for improved sensorless control of induction machines using HF injection. *EPE-PEMC Conference*, September 2002.
- [71] C. Caruana, G.M. Asher, K.J. Bradley, and M. Woolfson. Flux position estimation in cage induction machines using synchronous HF injection and Kalman filtering. *IEEE Transactions on Industry Applications*, 39(5):1372–1378, September/October 2003.
- [72] R.D. Lorenz. Key issues in zero speed self-sensing motion control. Specjalne seminarium autorskie, Warszawa, March 2001.
- [73] A. Consoli, G. Scarella, and A. Testa. A new zero-frequency flux-position detection approach for direct-field-oriented-control drives. *IEEE Transactions on Industry Applications*, 36(3):797–804, May/June 2000.
- [74] G. Bottiglieri, G. Scelba, G. Scarella, A. Testa, and A. Consoli. Sensorless speed estimation in induction motor drives. *IEEE International Electric Machines and Drives Conference IEMDC*, 1:624–630, June 2003.
- [75] D. Drevenšek and D. Žarko. A study of sensorless control of induction motor at zero speed utilizing high frequency voltage injection. *EPE Journal*, 13(3):7–11, August 2003.
- [76] J. Holtz. Sensorless position control of induction motors - an emerging technology. *IEEE Trasactions on Industrial Electronics*, 45(6):840–852, December 1998.
- [77] M. Schrödl. Sensorless control of AC motors (permanent magnet synchronous motors, induction motors). Tutorial, EPE, 2003.
- [78] T.M. Wolbank, R. Woehrnshimmel, and J.L. Machl. Zero speed sensorless control signals of induction motors with closed rotor slots. *IEEE Power Electronics Specialists Conference PESC*, June 2002.
- [79] V.-M. Leppänen and J. Luomi. Speed sensorless induction machine control for zero speed and frequency. *IEEE Conference of the Industrial Electronics Society IECON*, 1:400–405, November 2002.
- [80] V.-M. Leppänen and J. Luomi. Effect of equation of motion on low-frequency impedance of induction motors - an approach for rotor flux angle estimation. *EPE-PEMC*, September 2002.
- [81] V.-M. Leppänen and J. Luomi. Rotor flux angle tracking controller for sensorless induction motor drives. *Industry Applications Conference, IAS Annual Meeting*, 2:856–863, October 2002.
- [82] V.-M. Leppänen and J. Luomi. Observer using low-frequency injection for sensorless induction motor control - parameter sensitivity analysis. *IEEE International Electric Machines and Drives Conference IEMDC*, 1:609–616, June 2003.
- [83] V.-M. Leppänen. Low-frequency injection-based speed sensorless control of induction motors - applicability and implementation aspects. *EPE Conference CD-ROM*, 2003.
- [84] F.-J. Lin, R.-J. Wai, R.-H. Kuo, and D.-C. Liu. A comparative study of sliding mode and model reference adaptive speed observers for induction motor drive. *ELSEVIER Electric Power Systems Research*, 44:163–174, 1998.
- [85] H. Madadi Kojabadi and L. Chang. Model reference adaptive system pseudoreduced-order flux observer for very low speed and zero speed estimation in sensorless induction motor drives. *IEEE Power Electronics Specialists Conference PESC*, 1:301–305, June 2002.
- [86] G. Yang and T.-H. Chin. Adaptive-speed identification scheme for a vector-controlled speed sensorless inverter-induction motor drive. *IEEE Transactions on Industry Applications*, 29(4):820–825, July/August 1993.

- [87] T. Orłowska-Kowalska. Rotor flux observers and speed estimators for sensorless induction motor drives - comparative study. *EPE Power Electronics and Motion Control Conference PEMC*, 2002. CD-ROM.
- [88] V. Vasić, S. Vukosavić, and R. Dejan. Induction motor control with parallel speed and stator resistance MRAS based estimation. *EPE Power Electronics and Motion Control Conference PEMC*, 2002. CD-ROM.
- [89] E. Levi and M. Wang. A speed estimator for high performance sensorless control of induction motors in the field weakening region. *IEEE Transactions on Power Electronics*, 17(3):365–378, May 2002.
- [90] K. Ohyama, G.M. Asher, and M. Sumner. Comparison of the practical performance and operating limits of sensorless induction motor drive using a closed loop flux observer and a full order flux observer. *EPE Conference CD-ROM*, 1999.
- [91] Y.A. Kwon and D.W. Jin. A novel MRAS based speed sensorless control of induction motor. *Industrial Electronics Society Conference IECON*, 2:933–938, November/December 1999.
- [92] F.-Z. Peng and T. Fukao. Robust speed identification for speed-sensorless vector control of induction motors. *IEEE Transactions on Industry Applications*, 30(5):1234–1240, September/October 1994.
- [93] F.Z. Peng. Speed and flux sensorless field oriented control of induction motors for electric vehicles. *IEEE Applied Power Electronics Conference and Exposition APEC*, 1:133–139, February 2000.
- [94] Li Zhen and Longya Xu. Sensorless field orientation control of induction machines based on a mutual MRAS scheme. *IEEE Transactions on Industrial Electronics*, 45(5):824–831, October 1998.
- [95] C.-M. Ta, T. Uchida, and Y. Hori. MRAS-based speed sensorless control for induction motor drives using instantaneous reactive power. *IEEE Industrial Electronics Society Conference IECON*, 2:1417–1422, November/December 2001.
- [96] J. Jelonkiewicz and A. Przybył. Stator resistance insensibility in model reference adaptive system speed estimator. *Krajowa Konferencja Naukowa SENE*, 1:209–214, November 2001.
- [97] H. Tajima and Y. Hori. Speed sensorless field-orientation control of the induction machine. *IEEE Transactions on Industry Applications*, 29(1):175–180, January/February 1993.
- [98] V. Bostan, M. Cuibus, C. Ilas, and R. Magureanu. High performance sensorless solutions for induction motor control. *IEEE Power Electronics Specialist Conference PESC*, 2:556–561, June 2003.
- [99] S. Sangwongwanich, U. Nittayatareekul, and P. Magyar. Direct speed estimation based on back EMF of induction motors - its equivalent MRAS representation and stability analysis. *EPE Conference CD-ROM*, 2003.
- [100] L. Ben-Brahim and S. Tadakuma. Practical considerations for sensorless induction motor drive system. *IEEE Industrial Electronics Society Conference IECON*, 2:1002–1007, August/September 1998.
- [101] S. Osowski. *Sieci neuronowe w ujęciu algorytmicznym*. Wydawnictwa Naukowo-Techniczne WNT, 2 edition, 1996.
- [102] T. Orłowska-Kowalska and M. Pawlak. Induction motor speed estimation based on neural modelling method. *Archives of Electrical Engineering*, XLIX(1):35–48, 2000.
- [103] D.L. Sobczuk and P.Z. Grabowski. DSP implementation of neural network speed estimator for inverter fed induction motor. *IEEE Industrial Electronics Society Conference IECON*, 2:981–985, August/September 1998.
- [104] M. Cirrincione and M. Pucci. An MRAS based speed estimation method with a linear neuron for high performance induction motor drives and its experimentation. *IEEE International Electric Machines and Drives Conference IEMDC*, 1:617–623, June 2003.

- [105] L.R. Medsker and L.C. Jain, editors. *Recurrent Neural Networks - Design and Applications*. CRC Press, 2001.
- [106] D. Tikk, L.T. Kóczy, and T.D. Gedeon. A survey on universal approximation and its limits in soft computing techniques. Technical report, Budapest University of Technology and Economics, Hungary, 2001. www.mft.hu/publications/tikk/ or citeser.nj.nec.com.
- [107] M.T. Wishart and R.G. Harley. Identification and control of induction machine using artificial neural networks. *IEEE Transactions on Industry Applications*, 31(3):612–619, May/june 1995.
- [108] G. Horváth and R. Dunay. Modelling of non-linear dynamic systems by using neural networks. *Proceedings of the IEEE International Symposium on Industrial Electronics ISIE*, 1:92 –97, June 1996.
- [109] J. Korbicz and A. Janczak. A neural network approach to identification of structural systems. *Proceedings of the IEEE International Symposium on Industrial Electronics ISIE*, 1:98 –103, June 1996.
- [110] S.J. Huang, C.-L. Huang, and Y.-S. Lin. Sensorless speed identification of vector-controlled induction drives via neural network based estimation. *ELSEVIER Electric Power Systems Research*, 48:1–10, 1998.
- [111] B. Beliczyński. On input discretisation processes for tapped delay neural architecture. *International Conference on Artificial Neural Networks and Genetic Algorithms ICANNGA*, pages 28–32, April 2003.
- [112] B. Beliczyński and L. Grzesiak. Induction motor speed estimation: limitations of certain neural schemes based on time instances of periodic signals. *Industrial Electronics Society IECON, Conference of the IEEE*, 1:653 –657, November/December 2001.
- [113] J. Jelonkiewicz and A. Przybył. Neural networks implementation of model reference adaptive systems in induction motor drive. *EPE Conference CD-ROM*, 2001.
- [114] R. M. Bharadwaj and A. G. Parlos. Neural state filtering for adaptive induction motor speed estimation. *Mechanical Systems and Signal Processing*, *ELSEVIER Science*, 17(5):903–924, 2003.
- [115] M. Depenbrock and C. Evers. Model-based speed identification for induction machines in the whole operating range. *EPE Conference CD-ROM*, 2003.
- [116] H. Abu-Rub, J. Guziński, Z. Krzemiński, and H. A. Toliyat. Speed observer system for advanced sensorless control of induction motor. *IEEE Transactions on Energy Conversion*, 18(2):219–224, June 2003.
- [117] H. Abu-Rub, J. Guziński, S. Ahmed, and H. A. Toliyat. Sensorless torque control of AC induction motors. *IEEE Industrial Electronics Society Conference IECON*, 1, November/December 2001.
- [118] J. Guziński, H. Abu-Rub, and H. A. Toliyat. An advanced low-cost sensorless induction motor drive. *IEEE Transactions on Industry Applications*, 39(6):1757–1764, November/December 2003.
- [119] P. L. Jansen and R. D. Lorenz. A physically insightful approach to the design and accuracy assessment of flux observers for field oriented induction machine drives. *IEEE Transactions on Industry Applications*, 30(1):101–110, January/February 1994.
- [120] K.D. Hurst, T.G. Habetler, G. Griva, and F. Profumo. Zero-speed tacholess IM torque control: simply a matter of stator voltage integration. *IEEE Transactions on Industry Applications*, 34(4):790–795, July/August 1998.
- [121] C. M. Ritter. Induction machine flux observers: toward a unified classification. *IEEE International Electric Machines and Drives Conference IEMD*, pages 610–612, May 1999.
- [122] T. Orłowska-Kowalska and Cz. T. Kowalski. Comparative study of different flux estimators for sensorless induction motor drive. *Archives of Electrical Engineering*, XLIX(1):49–63, 2000.

- [123] D. Seyoum, C. Grantham, and M.F. Rahman. Simplified flux estimation for control application in induction machines. *IEEE International Electric Machines and Drives Conference IEMDC*, 2:691–695, June 2003.
- [124] Jun Hu and Bin Wu. New integration algorithms for estimating motor flux over a wide speed range. *IEEE Transactions on Power Electronics*, 13(5):969–977, September 1998.
- [125] F. Profumo, G. Griva, P. Vranka, and V. Donescu. Low speed performance improvement of sensorless flux estimator for field oriented induction motor drives using a fast offset compensation method. *EPE Power Electronics and Motion Control Conference PEMC*, 1998. CD-ROM.
- [126] M.-H. Shin, D.-S. Hyun, S.-B. Cho, and S.-Y. Choe. An improved stator flux estimation for speed sensorless stator flux orientation control of induction motors. *IEEE Transactions on Power Electronics*, 15(2):312–318, March 2000.
- [127] C.-C. Wang and C.-H. Fang. Sensorless scalar-controlled induction motor drives with modified flux observer. *IEEE Transactions on Energy Conservation*, 18(2):181–186, June 2003.
- [128] D.-I. Kim, M.-H. Shin, and D.-S. Hyun. A design of robust speed controller for speed sensorless stator-flux-oriented induction motor drive. *IEEE Industrial Electronics Society Conference IECON*, 1:406–411, November 2002.
- [129] T.-S. Kuen, M.-H. Shin, and D.-S. Hyun. Speed sensorless stator flux-oriented control of induction motor in the field weakening region using Luenberger observer. *IEEE Power Electronics Specialist Conference PESC*, 3:1460–1464, June 2003.
- [130] M.-H. Shin and D.-S. Hyun. Speed sensorless stator flux-oriented control of induction machine in the field weakening region. *IEEE Transactions on Power Electronics*, 18(2):580–586, March 2003.
- [131] M. Hinkkanen and J. Luomi. Modified integrator for voltage model flux estimation of induction motors. *IEEE Industrial Electronics Society Conference IECON*, 2:1339–1343, November/December 2001.
- [132] N.R.N. Idris, A.H.M. Yatim, and N.A. Azli. Direct torque control of induction machines with constant switching frequency and improved stator flux estimation. *IEEE Industrial Electronics Society Conference IECON*, 2:1285–1291, November/December 2001.
- [133] N.R.N. Idris and A.H.M. Yatim. An improved stator flux estimation in steady-state operation for direct torque control of induction machines. *IEEE Transactions on Industry Applications*, 38(1):110–116, January/February 2002.
- [134] B. K. Bose and N. T. Patel. A programmable cascaded low-pass filter-based flux synthesis for a stator flux-oriented vector-controlled induction motor drive. *IEEE Transactions on Industrial Electronics*, 44(1):140–143, February 1997.
- [135] B. Karanayil, M. F. Rahman, and C. Grantham. An implementation of a programmable cascaded low-pass filter for a rotor flux synthetizer for an induction motor drive. *IEEE Power Electronics Specialists Conference PESC*, 4:1965–1970, June 2002.
- [136] L. E. B. da Silva, B. K. Bose, and J. O. P. Pinto. Recurrent-neural-network-based implementation of a programmable cascaded low-pass filter used in stator flux synthesis of vector-controlled induction motor drive. *IEEE Transactions on Industrial Electronics*, 46(3):662–665, June 1999.
- [137] Yong Yi, Hailong Song, and Dianguo Xu. Research on speed sensorless vector control of induction motor based on stator flux orientation. *IEEE Power Electronics Specialists Conference PESC*, 2002. CD-ROM.
- [138] G.D. Andreeescu and A. Popa. Flux estimator based on integrator with DC-offset correction loop for sensorless direct torque and flux control. *International Conference on Electrical Machines ICEM*, 2002. CD-ROM.

- [139] T. Orłowska-Kowalska. Zastosowanie sieci neuronowych do estymacji strumienia wirnika silnika indukcyjnego. *Przegląd Elektrotechniczny*, LXXVII(7-8):187–190, 2001.
- [140] F. J. Doyle, R. K. Pearson, and B. A. Ogunnaike. *Identification and Control Using Volterra Models*. Communications and Control Engineering Series. Springer London, 2002.
- [141] J. Korbicz, A. Obuchowicz, and D. Uciński. *Sztuczne sieci neuronowe. Podstawy i ich zastosowania*. Akademicka Oficyna Wydawnicza PLJ, Warszawa, 1994.
- [142] *Mathematica 5 on-line help*. <http://documents.wolfram.com>, 2004.
- [143] R. I. W. Lang. A future for dynamic neural networks. Technical Report CYB/1/PG/RIWL/V1.0, Dept. Cybernetics, University of Reading, UK, 2000.
- [144] G. Cybenko. Approximation by superposition of a sigmoidal functions. *Mathematics of Control, Signals, and Systems*, 2:303–314, 1989.
- [145] B. Beliczyński and K. Kubowicz. Approximately static relationship between model variables. *Przegląd Elektrotechniczny*, 4:385–389, April 2004.
- [146] L. M. Grzesiak, B. Ufnalski, and B. Beliczyński. BezczuJNIKOWY napęd prądu przemienneGO z neuronowym estymatorem prędkości kątowej. *Przegląd Elektrotechniczny*, 3, March 2003.
- [147] H. Abramowicz. *Jak analizować wyniki pomiarów?* PWN, 1992.
- [148] *MathWorld - A Wolfram Web Resource* <http://mathworld.wolfram.com/>.
- [149] K. H. Rosen, J. G. Michaels, J. L. Gross, J. W. Grossman, and D. R. Shier, editors. *Handbook of discrete and combinatorial mathematics*. CRC Press, 2000.
- [150] F. Jabbari. Eigenvalues, singular values and pseudo-inverse. Course materials, <http://www.eng.uci.edu/~fjabbari/>, Department of Mechanical and Aerospace Engineering, University of California, Irvine, 2003.
- [151] T. Kaczorek. *Teoria sterowania i systemów*. Wydawnictwo Naukowe PWN, Warszawa, 1996.
- [152] L. M. Grzesiak, B. Beliczyński, and B. Ufnalski. Input preprocessing in tapped delay neural architecture for induction motor speed estimation. *EPE Conference CD-ROM*, 2003.
- [153] A. P. Papliński. Generalized hebbian learning and its application in dimensionality reduction - illustrative example. Technical Report 97-2, MONASH Australia's International University, Faculty of Computing and Information Technology, Department of Digital Systems, June 1997.
- [154] *NeuroSolutions 4.2 Manual* from <http://www.nd.com/>, 2003. (free evaluation copy).
- [155] A. Hyvärinen and E. Oja. Independent component analysis: A tutorial. Helsinki University of technology, Laboratory of Computer and Information Science, <http://www.cis.hut.fi/projects/ica/>, April 1999.
- [156] L. M. Grzesiak and B. Ufnalski. Projektowanie neuronowego estymatora prędkości kątowej silnika indukcyjnego przy zastosowaniu analizy składowych głównych. *Materiały konferencyjne IV Krajowej Konferencji - Metody i systemy komputerowe w badaniach naukowych i projektowaniu inżynierskim*, 2003.
- [157] L. M. Grzesiak and B. Ufnalski. Design of speed estimator for induction motor using principal component analysis and neural networks. *Przegląd Elektrotechniczny*, 5:493–497, May 2004.
- [158] Tee-Won Lee. *Independent Component Analysis: Theory and Applications*. Kluwer Academic Publishers, Boston/Dordrecht/London, 1998.
- [159] J.-F. Cardoso. Dependence, correlation and gaussianity in independent component analysis. *Journal of Machine Learning Research*, 4:1177–1203, 2003.

- [160] A. Hyvärinen. Survey on independent component analysis. *Neural Computing Surveys*, 2:94–128, 1999.
- [161] L. Parra and P. Sajda. Blind source separation via generalized eigenvalue decomposition. *Journal of Machine Learning Research*, 4:1261–1269, 2003.
- [162] A. Hyvärinen and E. Oja. Independent component analysis by general non-linear hebbian-like learning rules. *Signal Processing*, 64(3):301–313, February 1998.
- [163] A. Hyvärinen. One-unit contrast functions for independent component analysis: a statistical analysis. *IEEE Neural Networks for Signal Processing VII Workshop*, pages 388–397, 1997.
- [164] The FastICA Package for Matlab. <http://www.cis.hut.fi/projects/ica/fastica/>, January 2001. Helsinki University of Technology, Laboratory of Computer and Information Science.
- [165] J. Holtz and J. Quan. Drift- and parameter-compensated flux estimator for persistent zero-stator-frequency operation of sensorless-controlled induction motors. *IEEE Transactions on Industry Applications*, 39(4):1052–1060, July/August 2003.
- [166] B. Karanayil, M. F. Rahman, and C. Grantham. On-line stator and rotor resistance estimation scheme for vector-controlled induction motor drive using artificial neural networks. *IEEE Industry Applications Conference IAS*, 1:132–139, October 2003.
- [167] L.M. Grzesiak and B. Ufnalski. Neural stator flux estimator with dynamical signal preprocessing. *IEEE Conference AFRICON*, 2004.
- [168] L. M. Grzesiak, B. Ufnalski, A. Kaszewski, and P. Roszczyk. Sterowanie falownika bazujące na modulacji metodą wektora przestrzennego - realizacja w mikrokontrolerze TMS320LF2406. *Przegląd Elektrotechniczny*, 3:207–212, March 2003.
- [169] M. Malinowski. *Sensorless control strategies for three-phase PWM rectifiers*. PhD thesis, Warsaw University of Technology, Faculty of Electrical Engineering, 2001.
- [170] D. Vrančić. *Design of anti-windup and bumpless transfer protection*. PhD thesis, University of Ljubljana, Slovenia, 1997.
- [171] M. Hamdan and Zhiqiang Gao. A novel PID controller for pneumatic proportional valves with hysteresis. *IEEE Industry Applications Conference*, 2:1198–1201, October 2000.
- [172] A. Scott Edward Hodel and C. E. Hall. Variable-structure PID control to prevent integrator windup. *IEEE Transactions on Industrial Electronics*, 48(2):442–451, April 2001.
- [173] M. Tharayil and A. Alleyne. A generalized PID error governing scheme for SMART/SBLI control. *IEEE American Control Conference*, 1:346–351, May 2002.
- [174] A. Visioli. Modified anti-windup scheme for PID controllers. *IEE Control Theory and Applications*, 150(1):49–54, January 2003.
- [175] dSPACE GmbH, Germany. *DS1103 PPC Controller Board - Installation and Configuration Guide for release 3.4*, May 2002.
- [176] dSPACE GmbH, Germany. *MLIB/MTRACE - MATLAB-dSPACE Interface and Trace Libraries for release 3.4*, May 2002.
- [177] dSPACE GmbH, Germany. *ControlDesk - Experiment Guide for release 3.4*, May 2002.
- [178] dSPACE GmbH, Germany. *ControlDesk - Automation Guide for release 3.4*, May 2002.